

摘要：

英伟达在AMD年度发布会前夕密集亮牌：Vera CPU性能较x86芯片近乎翻倍、延迟压缩六倍，Vera Rubin NVL72实测能效较上代跃升10倍。OpenAI、Anthropic、SpaceX已率先拿到首批芯片。这场精心择时的数据轰炸，既是对AMD的正面狙击，更是英伟达强势闯入CPU市场、志在2000亿美元蛋糕的宣战书。

英伟达在劲敌AMD年度产品发布会召开前夕，打出一记重拳，密集披露新一代Vera Rubin平台的实测性能数据，并正式公开自研CPU芯片Vera的完整规格。

周二，英伟达披露，Vera CPU在代理式AI任务上的性能较x86芯片高出近一倍，延迟改善幅度达六倍。与此同时，云计算合作伙伴CoreWeave的早期生产测试显示，Vera Rubin NVL72平台在运行DeepSeek R1模型时，每兆瓦算力产生的token吞吐量较上一代基于Blackwell架构的GB200 NVL72系统提升10倍。

上述数据的发布时机颇具深意。AMD将于本周四在旧金山举行年度产品发布会"Advancing AI"，英伟达此时集中释放性能数据，被外界普遍解读为一次有意为之的市场造势。对于正在评估下一代AI基础设施投资的云厂商和企业客户而言，这批数据将直接影响其采购决策。

与此同时，英伟达亦正式公布Vera CPU已于6月完成首批交付，客户涵盖OpenAI、Anthropic和SpaceX。这标志着英伟达正式将触角延伸至CPU市场，对AMD和英特尔的传统地盘发起直接冲击。

Vera CPU亮相：英伟达正式进军服务器CPU市场

英伟达周二公布了数据中心CPU产品Vera的完整规格、基准测试结果及架构信息，这是潜在客户全面评估该芯片所必需的关键数据。该公司表示，Vera芯片已于6月向OpenAI、Anthropic和SpaceX等客户完成交付。

Vera是英伟达首颗从核心层面自主设计的服务器CPU，采用代号为"Olympus core"的定制微架构，而非沿用Arm提供的现成设计方案。

英伟达Vera产品市场负责人Hannah Coutand介绍，该芯片的设计重心在于单核速度、高内存带宽和低延迟，目标是"使代理能够尽快返回GPU，并保持GPU始终处于高度利用状态"。在硬件规格层面，Vera功耗在250瓦至450瓦之间，每颗芯片最高支持1.5TB低功耗内存。

在最新公布的基准测试中，英伟达展示了Vera相较于x86芯片在代理式AI任务上实现1.9倍性能提升，延迟降低6倍。英伟达还表示，Vera在部分行业标准基准测试中超越AMD旗舰EPYC Turin CPU近100%。此前，英伟达亦称Vera在AI代理任务的整体性能上较x86芯片高出50%。

Vera的推出是英伟达垂直整合战略的最新一步。Wolfe Research估算，Vera芯片单颗均价约为5000美元，预计今年出货量约达130万颗。英伟达超大规模计算副总裁Ian Buck表示，代理式AI使CPU变得"更加不可或缺"，并预测服务器CPU整体市场规模最终可能达到2000亿美元。

Vera Rubin实测：10倍能效跃升

CoreWeave于今年6月初完成了业界首次Vera Rubin NVL72的部署与验证，涵盖电力、冷却、网络和计算的全栈确认。此次披露的数据，是Vera Rubin NVL72硅片性能的首次公开实测结

果。

测试以DeepSeek R1模型为基准，在相同交互响应目标下，Vera Rubin NVL72每兆瓦每秒生成的token数量达到GB200 NVL72的10倍。CoreWeave同时指出，针对Vera Rubin所做的优化也可回溯应用于GB200 NVL72系统，使后者在三个月内每兆瓦吞吐量提升逾四倍。英伟达表示，上述成果经过超过25万种独立配置、逾140万GPU小时的测试验证。

从架构层面看，Vera Rubin NVL72机架集成72颗Rubin GPU与36颗Vera CPU，通过260 TB/s全互联NVLink 6架构连接，并原生支持NVFP4精度。CoreWeave表示，这一效率提升意味着客户可在相同功耗预算内处理更多推理流量，或以更少电力运行相同负载，从而降低每token成本。

CoreWeave还披露了具体应用场景：一家全球网络安全公司预计以10倍的每瓦性能运行威胁检测推理；一家自主编程代理公司预计以大幅降低的token成本扩展代理任务；一家AI原生搜索引擎则预计在不突破响应时间限制的前提下向更多用户扩展实时搜索服务。

基础设施协同优化：软硬件一体化释放更大效能

英伟达强调，上述性能提升并非单纯依赖芯片本身，而是硬件与软件协同设计策略的综合成果。通过对完整基础设施和能源栈的动态优化，英伟达表示可在相同功耗范围内部署多40%的GPU。

在冷却方面，英伟达采用45°C闭环液冷系统，与标准冷却方式相比，每兆瓦每年可节约约400万加仑水。在网络层面，第六代NVLink 6互联架构在大型语言模型模拟解码吞吐量上较以太网架构高出2.3倍；Spectrum-X平台则实现了1.6倍更快的远程直接内存访问带宽，同时减少1.7倍的交换机数量，光功率效率提升五倍，可靠性提升十倍。

英伟达最新一代Spectrum-6平台已开始向CoreWeave、微软、Nebius B.V.、SpaceX AI Corp.和特斯拉等AI工厂客户交付。目前，英伟达正加速向谷歌云、微软Azure、Meta、Oracle云基础设施、戴尔科技、OpenAI和CoreWeave等客户和合作伙伴发货。

英伟达仍是CPU领域挑战者

尽管Vera的性能数据引人注目，英伟达在CPU市场仍面临显著的市场份额挑战。Gartner分析师Kevin Knox表示，AMD目前是企业级AI服务器CPU领域的主要竞争对手。据报道，英特尔在服务器CPU市场占有约66.8%的份额，AMD约为33%，且AMD正持续抢占市场份额，并与超大规模云服务商建立了深厚合作关系。

受代理式AI兴起带动的CPU需求预期提振，AMD和英特尔今年以来股价涨幅分别达到128%和149%，远超英伟达同期约8%的涨幅，成为2026年表现最亮眼的芯片股。

就现阶段而言，英伟达的主要云服务商合作伙伴名单中仅列出了Oracle，尚未涵盖其他主流云厂商。Hannah Coutand承认，Vera目前仍处于“早期采用阶段”，不过OpenAI计划最早本季度开始大规模部署Vera芯片。

Cambrian AI Research创始人Karl Freund将英伟达的战略意图概括为：“他们的目的是让客户摆脱对英特尔或AMD CPU的依赖，而他们对这部分收入志在必得。他们选择专注于打造一款目前市场上其他任何人都尚未提供的独特CPU。”

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 329

 收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论