

摘要：

英伟达自研CPU Vera已完成对Anthropic、OpenAI、SpaceX AI及甲骨文云的首批交付。Vera旨在满足Agent AI对CPU的需求，黄仁勋将Vera定位为公司"下一个数十亿美元级业务"。甲骨文已表态，计划于2026年起部署数十万颗英伟达Vera CPU。

英伟达将其自研CPU Vera交付给全球顶尖AI实验室，标志着这家芯片巨头在GPU霸主地位之外，正式开辟新的硬件战线。

英伟达副总裁Ian Buck于上周五亲手将首批Vera CPU系统送抵Anthropic、OpenAI及SpaceX AI三家机构，并于本周一完成对甲骨文云基础设施（OCI）的交付。

这是Vera CPU从今年3月GTC大会宣布至今，首次进入客户生产环境。英伟达CEO黄仁勋在GTC发布时将Vera定位为公司"下一个数十亿美元级业务"。

OCI方面已明确表态，计划于2026年起部署数十万颗英伟达Vera CPU，成为首家在超大规模环境中部署Vera的云服务提供商。

为何Agent AI需要一颗新的CPU

英伟达的核心论点在于：Agent AI的工作负载与GPU训练和推理有本质区别。

当AI模型从"回答问题"转变为"执行任务"，大量并发的调度、工具调用、代码生成、长上下文检索等操作随之涌现——这些均属CPU密集型工作，并非GPU所长。Ian Buck在OCI交付现场表示：

"当AI模型被提问时，答案往往不是现成的，模型实际上需要生成Python代码才能得出正确答案，这正是我们看到CPU需求急剧攀升的原因。"

Vera搭载88颗英伟达自研Olympus核心，内存带宽达1.2 TB/s，满载情况下单核性能较前代提升50%。英伟达将其定位为专为高吞吐推理、Agent沙箱及强化学习工作负载设计的新一类CPU。

逐站交付：从旧金山到硅谷

上周五的首站交付在Anthropic位于旧金山SoMa区的办公室完成。Anthropic计算负责人James Bradbury接收了系统，并与Buck就Vera的架构特性进行了深入交流。Bradbury表示：

"扩展计算是模型成长的重要加速器，我们很高兴看到Vera在解决Agent工作负载方面展现出成为生态系统重要组成部分的潜力。"

在OpenAI位于Mission Bay的总部，计算基础设施负责人Sachin Katti接收了系统。Buck在交流中甚至当场取出螺丝刀，打开机箱盖，向对方展示系统内部构造。

当天最后一站是SpaceX AI位于帕洛阿尔托的办公室。英伟达团队向马斯克详细介绍了系统内部结构。SpaceX AI正评估将Vera用于强化学习工作负载及驱动其训练架构的基于Agent的仿真流水线。

OCI领跑超大规模部署

本周一在甲骨文AI客户中心，OCI产品管理负责人Karan Batta及首席客户与合作伙伴成功官Gary Miller对Vera系统进行了现场参观。Batta明确了OCI的部署意图：

"OCI计划从2026年起部署数十万颗英伟达Vera CPU，因为Agent AI需要大规模的持续性能。Vera的架构专为高吞吐推理工作负载而设计，能够提供OCI为下一代企业AI提供动力所需的效率、密度和占用空间。"

英伟达方面表示，OCI是首家在超大规模层面部署Vera的云服务提供商。

Miller则着眼于企业客户侧的验证需求，表示团队迫切希望让客户在该中心对Vera展开测试与定制，以充分释放其在Agent AI场景下的潜力。

Vera在英伟达整体架构中的定位

Vera并非孤立产品，而是英伟达"极致协同设计"体系的核心组件之一，与Rubin GPU、BlueField 4 DPU、Spectrum-X网络及MGX机架架构共同构成完整的AI工厂基础设施。

在Vera Rubin NVL72配置中，Vera通过第二代NVLink-C2C与两颗Rubin GPU相连，形成统一内存架构，使加速计算资源保持高效利用。

英伟达表示，Vera的高速核心与互连设计能够以传统基础设施两倍的能效，完成向GPU馈送数据所需的调度、控制与数据搬移工作。

对于投资者而言，Vera的正式交付提供了一个可追踪的商业里程碑：从OCI已公开承诺的"数十万颗"订单规模，到AI头部实验室的同步采用，英伟达正在将Agent AI对CPU的需求转化为可见的新增营收来源。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

298 收藏

分享到:

写评论

请发表您的评论





表情



图片

发布评论

