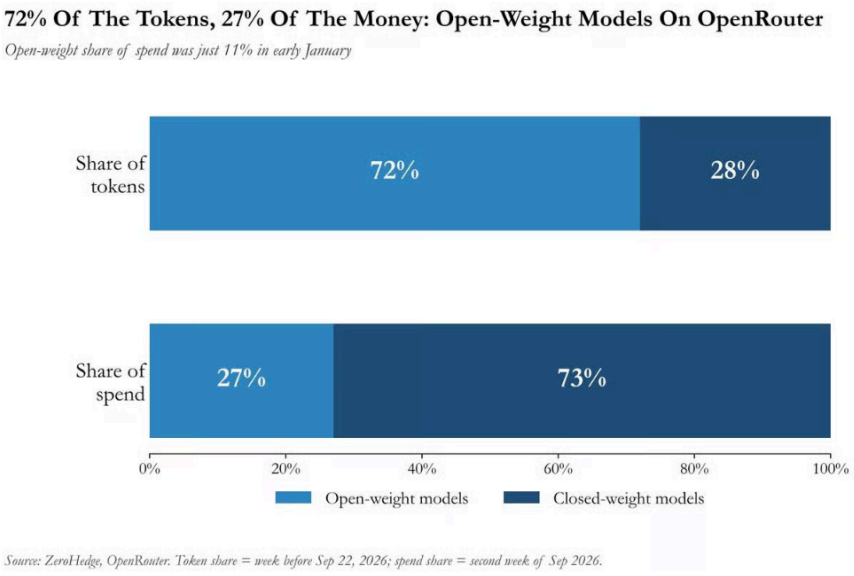
摘要：

OpenRouter数据显示，Token需求20个月暴增250倍，但72%的流量涌向收费最低的开源模型，仅贡献27%支出；Token价格每季度崩跌47%，GPU租金却同步飙升160%。钱流向GPU持有者，账单转嫁给股东。高盛认为，加之科技圈外未见实质生产力红利，这场资本循环岌岌可危，空头逻辑正占据上风。

AI需求数据正在制造一场罕见的市场分歧：同一组数字，多头和空头各取所需，双方都宣称胜利。这场争论的核心，是一个令人不安的结构性矛盾——**Token消耗量爆炸式增长，但绝大多数增量流向了收费最低的模型，而服务这些Token的GPU成本却在同步攀升。**

据高盛Bobby Molavi在其最新报告中披露，OpenRouter数据显示，开源权重模型（open-weight models）在9月第二周处理了72%的Token流量，却仅获得27%的平台总支出；与此同时，闭源模型虽然份额从1月初的89%降至73%，仍牢牢掌控着绝大部分货币化收益。



更值得关注的是，OpenRouter平台9月中旬约69%的Token来自中国AI实验室。Molavi将当前市场定性为“无法操作”（unplayable），并指出AI生产力红利迄今尚未在科技行业以外留下可量化的痕迹。

这一结构性矛盾正在重塑市场对AI投资回报的预期。GPU租金持续上涨，Token售价持续下跌，两端同时承压，意味着算力供应商坐享租金红利，而为此买单的企业客户和最终股东，却面临ROI难以兑现的困境。Meta近期向股东募资最高950亿美元用于AI资本开支，其芯片供应商同步入股，标志着“供应商融资”已从债务形式演变为股权形式，**资本循环的可持续性疑问愈发迫切。**

Token需求爆炸：250倍增长背后的真实图景

需求本身的增长无可置疑。Molavi援引OpenRouter数据指出，Token需求自去年11月以来增长了27倍，开源权重模型目前占据72%的Token份额。从更长周期看，OpenRouter平台周度Token处理量从2025年1月中旬的0.5万亿枚，飙升至9月14日当周的128.4万亿枚，**20个月内增长约250倍。**



GPU定价同样印证了需求的真实性。H200租赁价格年内上涨160%，B200上涨120%，H100上涨35%。更具说服力的是，**2020年出产的A100芯片，其当前租赁价格已高于年初水平**，这直接冲击了此前关于GPU折旧周期的核心假设——若一块芯片在六年后仍能产生更高收益，那么以三年为基准的悲观折旧预测便站不住脚，超大规模云厂商（hyperscaler）的长期盈利潜力也因此需要重新评估。

对多头而言，这是最有力的论据：需求是真实的，算力资产的经济寿命比空头预期的更长。

Token价格的自由落体：历史上最快的通缩

然而，需求爆炸的另一面，是Token价格以前所未有的速度崩塌。据Epoch AI于9月22日发布的研究报告《思维价格的暴跌》（The Plunging Price of Thought），**自2023年以来，达到同等AI性能水平的成本每季度下降约47%，即每年降低约13倍；在前沿模型领域，这一速度更快，平均每季度下降66%，即每年降低约75倍。**

Epoch AI给出的最直观案例：

> 2025年1月，OpenAI的o3模型在GPQA Diamond博士级科学题基准测试中答对75%，每题成本约0.30美元；如今GPT-5.6 Luna达到同等分数，每题成本仅0.0004美元，**18个月内价格下降725倍**——相当于一辆标价5万美元的汽车跌价至69美元。

从历史横向比较来看，大语言模型推理价格的下降速度是DNA测序的4倍、1940至2001年间计算能力提升速度的6倍、锂离子电池的18倍、电力的54倍。

不过，**客户实际支付的价格下降远慢于标价**。YipitData追踪的近2千万亿（quadrillion）年化Token数据显示，API服务的有效Token定价在2025年下半年下降了39%（OpenRouter上为44%），但截至2026年5月的年初至今仅下降6%。

原因在于：开发者持续追逐更便宜的模型，而企业客户则在增加高端模型的使用比例，前沿实验室凭借最新模型的溢价能力暂时支撑了收入端——但Epoch的数据表明，这种溢价的半衰期以季度计，因为开源克隆版本很快便能以极低成本完成同等任务。

多空分歧的核心：谁在赚钱，谁在买单

这正是Molavi所描述的"同一数据，两种解读"困境的核心所在。

多头的逻辑是：需求持续扩大，可寻址市场（TAM）仍在增长，Token消耗量的爆炸式增长证明AI正在被广泛采用。

空头的逻辑则是：**每Token成本在上升，每Token收入在下降，而增量流量的主体正是那些收费最低的开源模型。**OpenRouter数据清晰呈现了这一图景：开源权重模型处理了72%的Token，却只拿走27%的支出；中国AI实验室贡献了平台近七成的Token流量。高盛动量篮子（Goldman momo basket）恰好在6月底见顶，时间节点与中国开源权重模型大规模涌入AI市场高度吻合。

Molavi将这一矛盾概括为：**GPU租金上涨与Token售价下跌，是同一挤压从两端呈现的结果。**对GPU持有者而言是利好；对支付租金的企业而言，则是另一番景象。

生产力红利缺席：S&P 493的沉默

AI资本开支的终极逻辑，是通过生产力提升带动全社会收益。但目前，这一逻辑尚未在科技行业以外得到数据验证。

Molavi援引一份策略师报告指出，**AI“尚未在科技宇宙以外的关键数据中呈现出可量化的生产力提升”**：Mag 7（七大科技巨头）的人均营收和利润率均有所提升，但S&P 493（标普500其余493家公司）的对应指标几乎持平。

这一现实正在改变企业界的AI决策逻辑。Molavi观察到，大量企业正从"Token支出与增长和生产力的相关性"转向"Token支出与成本及利润率影响"的审视框架。**CFO们已经找到了AI这条预算线，他们想知道花出去的钱买到了什么。**

“繁荣循环”与资本可持续性之问

支撑当前AI资本开支狂潮的，是Molavi所描述的一个“繁荣循环”：超大规模云厂商的资本开支越多，流入AI生态的收入就越多，进而吸引风险资本和成长股权资本涌入，形成双向资金流——而这一切的锚点，是最初的AI资本开支本身。

这个循环的致命弱点，在于其可持续性：一旦资本开支放缓，整个生态的收入能否自我维持？

私募市场同样未能免疫。Molavi指出，当前的退出案例“数量可观但极度集中”（SpaceX、Cerebras、Cursor、Hugging Face），部分项目的估值重估"除了一份投资意向书之外没有任何催化剂"，整个私募市场的交易逻辑"仿佛Token时代永不落幕、万物皆将被颠覆"。

在融资端，随着债务窗口收窄，Meta近期宣布向股东募资最高950亿美元用于AI资本开支，其芯片供应商同步参与入股。**供应商融资已从债务形式演变为股权形式，提供者与使用者之间的收入与融资边界日益模糊。**

Molavi将整场辩论的本质归结为四个问题：**建设成本几何、谁来买单、痛苦是否值得、以及需要等待多久才能看到收入回报。**

当前的数据格局是：Token需求增长250倍，但增量收益流向收费最低的模型；GPU租金上涨，但账单最终转嫁给股东；生产力红利在科技行业以外尚无踪迹。

Molavi的结论是，需求的真实性无可置疑，但**“需求增长250倍，而资金流向最廉价模型、租金流向GPU持有者、账单转嫁给股东”，并非当初资本开支所承诺的ROI故事。**在这场多空拔河中，空头或许握有更有力的那半段绳子。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限免

106 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

3 条评论

见闻用户
1小时前 中国

所有企业都在用的时候，大家就处在同一起跑线上，行业利润不会因此上升，但行业确实已发生根本改变。就业创造和就业破坏同时发生，居民收入在短期也可能没有大的变化。

0 回复

assksun
6小时前 中国上海

科技圈外未见实质生产力红利
高盛难得说对一次，AI始终还是在小圈子里挣钱，对绝大部分人来说就是个高级搜索引擎

4 回复

tzfeng 4小时前 中国浙江省

回复 **assksun**:

游戏，影视，广告等行业的助手，提高了效率，但对他们的利润也没明显的利润增长

2 回复