

摘要：

AI资本开支还在上升，AI基础设施股也没有降温。真正的问题变成了：芯片层已经把第一轮利润留在账上，市场现在争的是这笔利润是否已经被充分定价；如果Agentic AI继续放大token价值，下一轮增量利润会继续留在硬件层，还是开始向模型实验室、云厂商和企业软件层重新分配。

过去两年，AI交易几乎统治了全球股票市场。

英伟达、半导体设备、HBM、先进封装、数据中心、电力设备、变压器、制冷、燃气轮机，凡是能被放进AI基础设施链条里的资产，都被市场反复重估。这个交易没有失效，反而涨到让投资者不得不重新面对一个更难的问题：AI产业链第一阶段的赢家已经被市场奖励到极致，下一步还能继续涨吗？

高盛和SemiAnalysis的两份报告，正好站在这个分岔口上。

高盛James Covello的判断偏冷：AI基础设施第一阶段已经充分定价，芯片和“卖铲子”的链条拿走了太多确定利润，但企业端ROI仍然没有普遍跑通，云厂商的现金流压力也在上升。按照这套逻辑，接下来更好的相对交易，不是继续追逐半导体，而是看多超大规模云厂商、低配半导体。

AI Spend vs. Benefit: Marking our views to market two years later

Revisiting June 2024's "Top of Mind: GenAI:
too much spend, too little benefit?"

April 2026

James Covello

Goldman, Sachs & Co.

1-212-902-1918

james.covello@gs.com

SemiAnalysis给出的答案几乎相反：如果Agentic AI真的让token变成生产资料，模型实验室的毛利率开始改善，前沿模型仍然有定价权，那么AI基础设施并不是“涨够了”，而是还没有完全按照新一轮token价值重新定价。英伟达、台积电、内存、Neocloud、模型实验室，都还有继续分走增量价值的理由。



AI Value Capture - The Shift To Model Labs

Vera Rubin VR NVL72: V for Value - Rubin delivers a step jump in performance per TCO. ROI accruing to users, Neoclouds, Hyperscalers, AI Labs, Memory Vendors or GPU Manufacturers?

DANIEL NISHBALL, DYLAN PATEL, CHEANG KANG WEN, AND 6 OTHERS

MAY 01, 2026 • PAID

这不是一场关于AI有没有前途的争论。

AI资本开支还在上升，AI基础设施股也没有降温。真正的问题变成了：芯片层已经把第一轮利润留在账上，市场现在争的是这笔利润是否已经被充分定价；如果Agentic AI继续放大token价值，下一轮增量利润会继续留在硬件层，还是开始向模型实验室、云厂商和企业软件层重新分配。

高盛盯的不是AI热不热，是这条路还没跑通

高盛这篇报告，其实不在于唱衰用户增长，也不是说技术不行，而是在提醒市场——AI，现在还没真正赚到钱。

Covello先承认了两件事：消费者采用AI的速度比他们原先预期更快；云厂商即使股价承压，也没有像他们预想的那样削减AI资本开支，反而继续提高投入。AI没有降温，资本开支也没有退潮。

但高盛看得更靠后。

消费者用AI，很多还停留在免费层。用户增长可以证明产品吸引力，却不能直接支付GPU、数据中心、电力、网络和模型推理的账单。企业端才是AI经济能否闭环的关键：企业愿不愿意持续付费，能不能从AI里省下成本、增加收入、提高产出，决定整条链条能否长期承受今天的资本开支。


高盛给出的答案偏谨慎。

报告提到，企业在生成式AI上的投入已经很大，但大量组织还没有拿到可验证的回报；同时，全球IT支出仍在上升，AI并没有在总量层面让企业技术预算降下来。对投资者来说，这意味着一个很现实的问题：企业在买AI、试AI、谈AI，但AI还没有普遍进入利润表。

这与AI基础设施链条的利润形成了鲜明反差。

芯片公司已经赚钱，存储、电力、数据中心相关公司被市场反复重估。云厂商则在另一端承担资本开支。数据中心建设、GPU采购、电力接入、网络设备、服务器机架，这些支出都先落在云厂商账上。高盛报告称，超大规模云厂商已经消耗掉部分经营现金流富余，并开始通过债务支持数据中心建设，2025年数据中心债务发行额翻倍至1820亿美元。

Hyperscalers have burned through cash flow from operations



Source: Compustat, FactSet, Goldman Sachs Global Investment Research

这就是高盛眼里的不平衡。

正常半导体周期里，芯片公司赚大钱，通常说明客户也在扩张。客户赚钱，继续买芯片，芯片公司继续繁荣。AI这一轮更别扭：芯片链条利润最清楚，客户层和应用层的回报还没有同样清楚。

所以，高盛的判断并不是“AI没用”，而是“现在的分账方式难以长期线性外推”。

半导体公司已经把第一阶段最确定的利润吃到嘴里。问题是，下游客户有没有足够利润，继续供养上游这么高的资本开支和利润集中度。

高盛的交易建议，其实押的是“均值回归”

高盛给出的交易建议看似反直觉：相对看多超大规模云厂商，低配半导体。

这背后有两条路径。

第一条路径，企业AI ROI开始兑现。企业证明AI能带来收入、效率和成本优势，市场就会重新理解云厂商的资本开支。过去被认为拖累自由现金流的投入，会重新变成未来收入和平台控制力。云厂商估值修复，半导体也会受益，但由于半导体此前已经被市场奖励很多，相对弹性未必更大。

第二条路径，企业ROI继续困难。云厂商在现金流压力和投资者压力下削减资本开支，市场会奖励更好的现金流纪律。半导体链条则要面对订单预期下修。


高盛认为，这两条路径都支持“云厂商相对半导体更好”。真正让这笔交易失败的情形，是第三条路径：企业ROI仍然模糊，云厂商却继续不计成本加码，半导体继续吃掉产业链绝大部分利润。

这恰恰是过去两年市场最熟悉的状态。

也正因为如此，高盛报告的矛头不是AI技术，而是市场定价。AI基础设施的好处已经被交易得很充分，云厂商的坏处也被交易得很充分。下一步，市场要看这两个方向是否反转。

Exhibit 1: Market breadth is extremely narrow


Market breadth calculated as the distance of the S&P 500 from its 52-week high less the distance of the median S&P 500 constituent from its 52-week high



Source: Goldman Sachs Global Investment Research

Exhibit 4: Momentum has recently surged

Long/short factor comparing top and bottom S&P 500 quintiles based on trailing 12-month returns, equal-weighted and rebalanced monthly



Source: Goldman Sachs Global Investment Research

SemiAnalysis看到的，是token的价值突变

SemiAnalysis从完全不同的入口切入。

它并不否认2023年至2025年，AI价值主要流向基础设施。英伟达、电力、数据中心、存储，确实是第一阶段的大赢家。模型公司和推理服务商在早期并不舒服，很多AI产品看起来只是一个更好的搜索框，毛利率也远谈不上漂亮。

但SemiAnalysis认为，2025年底以后，事情发生了变化。

变化来自Agentic AI。

过去的token更像“问答成本”。用户问一句，模型答一句。它能节省时间，但价值边界有限。现在的token开始进入复杂工作流：写代码、做财务模型、生成仪表盘、分析财报、整理数据、制作图表。

SemiAnalysis用自己的公司做例子。它们的分析师已经每天用agent处理研究和建模工作，过去这些任务要么需要初级分析师花很多小时，要么根本没有时间排进工作流。文章披露，SemiAnalysis在Anthropic Claude上的年化token支出一度达到1095万美元，token支出约相当于员工薪酬的30%。

这组数字未必能代表所有企业，但它代表了一类边际用户的变化。

对普通消费者来说，AI订阅可能只是每月几十美元的工具。对高强度知识工作者来说，token开始变成生产资料。

几美元、几十美元的token，换来的不只是几段文字，而是模型、图表、代码、数据清洗、财报分析，甚至是过去根本不会被执行的工作。用户看待AI成本的方式也会随之变化：他们不再只

问“每百万token多少钱”，而会问“这些token替代了多少人工，增加了多少产出”。

这就是SemiAnalysis与高盛分歧的起点。

高盛看到的是平均企业的ROI还不清楚。SemiAnalysis看到的是最强用户已经开始大量消耗token，而且愿意为更强模型付费。

模型实验室为什么突然变得重要

SemiAnalysis的第二个关键判断，是模型实验室的单位经济性正在改善。


这与过去市场的担忧相反。

此前，模型公司被认为夹在芯片和云厂商之间。收入增长很快，但训练和推理成本更快。用户越多，成本越高。模型越强，资本开支越重。这个模式看起来像高增长、低毛利、高烧钱。

Agentic AI改变了这张表。

- 。价格端，前沿模型能执行更高价值的任务，用户愿意为更强模型付溢价。
- 。成本端，硬件迭代、推理优化、缓存机制和软件工程持续降低单位token成本。
- 。产品端，模型公司可以通过更高端SKU、更快响应、更强推理能力，做出分层定价。

SemiAnalysis提到，在B300运行DeepSeek的案例中，不同软件优化组合可以让同一硬件吞吐量从约1000、8000提高到约14000 tokens/秒/GPU。叠加硬件升级，最优化的GB300 NVL72配置相对H100在FP8下吞吐量约高17倍；如果切到Hopper原生不支持的FP4，差距可达32倍，而每GPU总拥有成本只高约70%。



这意味着，模型实验室一边可以提高token创造的经济价值，一边可以降低token生产成本。

SemiAnalysis称，Anthropic ARR从90亿美元升至440亿美元以上，推理基础设施毛利率从38%升至70%以上。即便模型标价下降，高端模型使用占比提升、缓存命中率提高、硬件效率改善，也可能推动毛利率继续扩张。

如果这一判断成立，AI产业链的第二阶段就不再只是“芯片继续赢”或“云厂商反弹”。



模型实验室会从烧钱层，变成新的价值捕获层。

真正的分歧：平均企业，还是边际用户

高盛和SemiAnalysis表面上在争AI ROI，实际争的是哪个样本更能代表未来。

高盛看的是平均企业。

这些企业有复杂的数据系统、历史IT包袱、权限管理、合规要求、审批流程。很多公司为了向市场和董事会交代AI战略，先做聊天机器人、内部助手、试点项目。花钱是真的，但业务流程未必改变。流程不改，ROI就很难进财报。

这就是高盛强调数据结构和编排层的原因。

一个零售企业如果没有打通库存、客户画像和推荐系统，AI客服可能推荐一个缺货商品。一个企业如果没有模型路由层，简单查询也交给最贵的前沿模型，成本自然失控。AI落地卡住的地方，已经不只是模型不够强，而是企业还没有准备好让模型进入业务系统。

SemiAnalysis看的是边际用户。

研究、代码、建模、图表、财报分析，这些任务天然适合agent。它们高度文本化、数字化、结构化，结果容易评估，用户也有能力把AI嵌入 workflow。这样的组织，会比普通企业更早看到ROI，也更愿意加大token消费。

资本市场要判断的，是这种领先样本会不会扩散。

如果SemiAnalysis看到的只是少数超级用户的异常值，高盛框架会占上风。AI资本开支会越来越受现金流约束，半导体链条需要消化高预期，云厂商可能因为支出纪律和估值压缩获得相对回报。

如果SemiAnalysis看到的是扩散前夜的领先指标，市场就不能用平均企业今天的低ROI否定AI链条。Agentic AI一旦进入更多白领 workflow，token需求、模型收入、云收入和硬件需求会一起上升。

这个判断，比“看多AI还是看空AI”更重要。市场交易的从来不是静态平均数，而是边际变化能不能变成主流。

英伟达：已经赚够，还是仍未充分涨价

高盛和SemiAnalysis最大的资本市场分歧，最终落在英伟达和半导体链条上。

高盛的视角很直接：半导体已经拿走了第一阶段最大、最确定的利润。市场把“卖铲子”逻辑打进价格以后，风险回报开始变差。只要云厂商资本开支松动，半导体链条就会面对估值和订单的双重压力。

SemiAnalysis则认为，英伟达和台积电控制了AI时代最稀缺的资源，却还没有完全按价值定价。

文章提到，内存价格过去一年上涨约6倍，Neocloud一年期H100租赁合同价格较2025年10月低点上涨约40%。与此同时，英伟达和台积电并没有像下游token价值那样快速重新定价。




SemiAnalysis把英伟达称为AI生态的“央行”。

这个比喻很贴切。英伟达控制的是算力流动性。它有能力涨价，但不能把整个系统抽干。价格提得太狠，会刺激客户加速转向自研ASIC、TPU、Trainium，也会带来监管压力。台积电也类似。先进节点极度稀缺，但它长期重视客户关系和生态稳定，不会在景气上行期把所有稀缺性一次性变现。

克制不代表没有空间。

Rubin VR NVL72是SemiAnalysis判断英伟达仍有定价权的重要依据。按照其模型，Neocloud要让VR NVL72项目达到类似GB300项目的15.6% IRR，租金约需4.92美元/小时/GPU；如果按照GB300的每PFLOP租赁价格平价推算，VR NVL72理论天花板约为12.25美元/小时/GPU；即便采用更保守的0.55美元/PFLOP，也对应约9.63美元/小时/GPU，接近成本定价门槛的两倍。



这里的含义很清楚：只要下游token价值继续上升，英伟达的新系统仍有提价空间，Neocloud仍可能赚钱，终端用户仍可能接受。

高盛和SemiAnalysis的分歧由此变得锋利。

高盛认为，半导体独赚不可持续，因为下游还没有足够利润。

SemiAnalysis认为，下游利润池正在变大，所以硬件层不是赚太多，而是还没有完全按照价值收费。

判断胜负的变量只有一个：AI创造的新利润池，能不能大到同时养活模型实验室、云厂商、Neocloud、英伟达、台积电、存储和电力链。

蛋糕不够大，高盛赢。

蛋糕继续变大，SemiAnalysis赢。

云厂商处在最微妙的位置

云厂商是这场争论中最尴尬的一层。

它们既是资本开支最大买单者，也是AI需求最可能变现的平台。它们被英伟达、存储、电力链挤压，也拥有企业客户、云服务、模型API、自研芯片和软件生态。

高盛看多云厂商，是因为市场已经把很多坏处打进去了。资本开支压制自由现金流，投资者质疑AI ROI，估值承压。后面只要出现两种情况之一，云厂商都有修复路径：企业AI收入兑现，或者资本开支收缩。

SemiAnalysis则从需求侧看云厂商。只要token需求继续扩张，模型实验室和企业客户就需要更多算力。算力受到先进制程、内存、电力、机架级系统限制。买方最担心的不是贵，而是拿不到。

所以云厂商不是单纯受害者，也不是自动赢家。

它们必须用财报证明，AI资本开支可以转成收入、利润和客户粘性。云业务增长是否重新加速，AI收入披露是否更清晰，推理利用率能不能提高，自研芯片能否降低对英伟达依赖，企业客户是否从试点转向长期部署，自由现金流有没有稳定下来，这些指标都会比过去更重要。

这些指标改善，高盛的相对看多云厂商逻辑会增强。

这些指标迟迟不改善，云厂商仍然像夹在英伟达和企业客户之间的资本开支承压层。

软件层决定ROI能不能从样本变成平均数

高盛报告里对“数据结构”和“编排层”的强调，可能是最接近企业现实的一部分。

企业AI不会永远停留在员工打开聊天框提问。真正有财务影响的AI，要进入客服、销售、财务、采购、研发、风控、供应链、IT运维。每个流程都有数据、权限、合规、审批、历史系统和责任边界。

模型再强，也不能绕过这些东西。

这就是企业软件层重新变得重要的地方。低风险、高频任务可以交给轻量模型或开源模型；高风险、高价值任务才需要前沿模型。中间需要一层系统判断任务类型、调用数据、控制权限、选择模型、监控成本、回写结果。

- 。传统SaaS公司的优势，是行业经验、客户关系、数据入口和工作流沉淀。劣势是技术债和迭代速度。
- 。AI原生公司的优势，是产品速度、模型调用能力和成本结构。劣势是缺少企业入口和行业上下文。
- 。前沿模型公司的优势，是最强智能。劣势是缺少企业流程控制权。

软件层不会简单被AI吃掉。没有数据和流程控制权的软件公司，可能被模型抽象掉。掌握数据结构、工作流和模型路由的软件公司，反而有机会把AI变成更大的市场，从卖座席变成卖生产力。

企业ROI能不能从SemiAnalysis这样的强用户样本扩散到普通企业，很大程度上取决于这一层。

资本市场下一步看六件事

AI交易过去问的是：谁最靠近算力？



这个问题现在太粗了。

下一阶段，市场会追问更细的变量。

第一，token价值是否继续上升。Agentic AI如果从代码、研究、分析扩散到更多白领 workflow，模型实验室和推理链会继续重估。

第二，模型实验室毛利是否继续改善。收入增长已经不够，市场会看推理成本、缓存效率、SKU升级和前沿模型定价权。

第三，云厂商能否把资本开支转成收入。AI capex本身不再自动算利好，只有能进入云收入、推理毛利和企业合约的capex，才会被市场奖励。

第四，英伟达能否继续从系统级瓶颈涨价。GPU只是第一层，Rubin、SOCAMM、网络、机架级系统、软件栈和供应链采购能力，决定英伟达能不能继续抽成。

第五，台积电和存储能否重新定价稀缺。先进节点、HBM、DRAM、SOCAMM和先进封装，如果继续成为供给瓶颈，价值不会轻易离开上游。

第六，企业软件能否拿到AI落地入口。没有流程入口的软件公司会被压缩，有入口、有数据、有编排能力的软件公司可能变得更贵。

AI“铲子”统治市场之后，争论才刚开始

AI基础设施交易没有失效。

它涨得太猛，才逼出了高盛和SemiAnalysis这场分歧。

高盛提醒市场，芯片链的好处已经被打得很满。如果企业ROI迟迟不来，云厂商现金流会反噬资本开支，半导体独赚的格局会被修正。

SemiAnalysis提醒市场，不能用2024年的AI体验判断2026年的Agentic AI。token正在变成生产资料，模型实验室开始改善毛利，算力供给仍然紧张，英伟达和台积电可能还没有完全按照价值定价。

这两种判断放在一起，AI交易的重心已经变化。

过去两年，市场奖励的是稀缺资产。接下来，市场要看谁能把AI创造的经济价值持续留在利润表里。

如果SemiAnalysis看到的是边际拐点，AI链条的蛋糕会继续变大，模型实验室、云厂商、英伟达、台积电、存储和电力链都有继续分账的理由。

如果高盛看到的是更接近平均企业的现实，资本开支会先撞上现金流，半导体链条需要消化过高预期，云厂商反而因为估值压缩和潜在支出纪律获得更好的相对回报。

现在最可能的状态，介于两者之间。

最强用户已经开始猛买token，普通企业还没算清账。资本市场会先交易最强用户带来的边际变化，再等平均企业用财报验证。验证越快，SemiAnalysis的世界越近；验证越慢，高盛的交易



越有胜率。

AI“铲子”仍然统治市场，但问题已经从“谁卖铲子”变成了另一张账本：谁已经赚够了，谁还能继续涨价，谁会成为下一层真正的收租人。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码 免费领取

限免

562 收藏

分享到:

写评论

请发表您的评论

表情

图片

发表评论

2 条评论

- GENE（余顺吉）

5小时前 中国广东省

简单理解就是他未知来回答的肯定，然后让自己再次循环，形成闭环。

0

回复
- wscn3714631560

5小时前 中国北京

所以，ai产生的利在哪？过去一年能造五千万汽车，现在能造五十亿，每个家庭每年得买两辆车？

0

回复