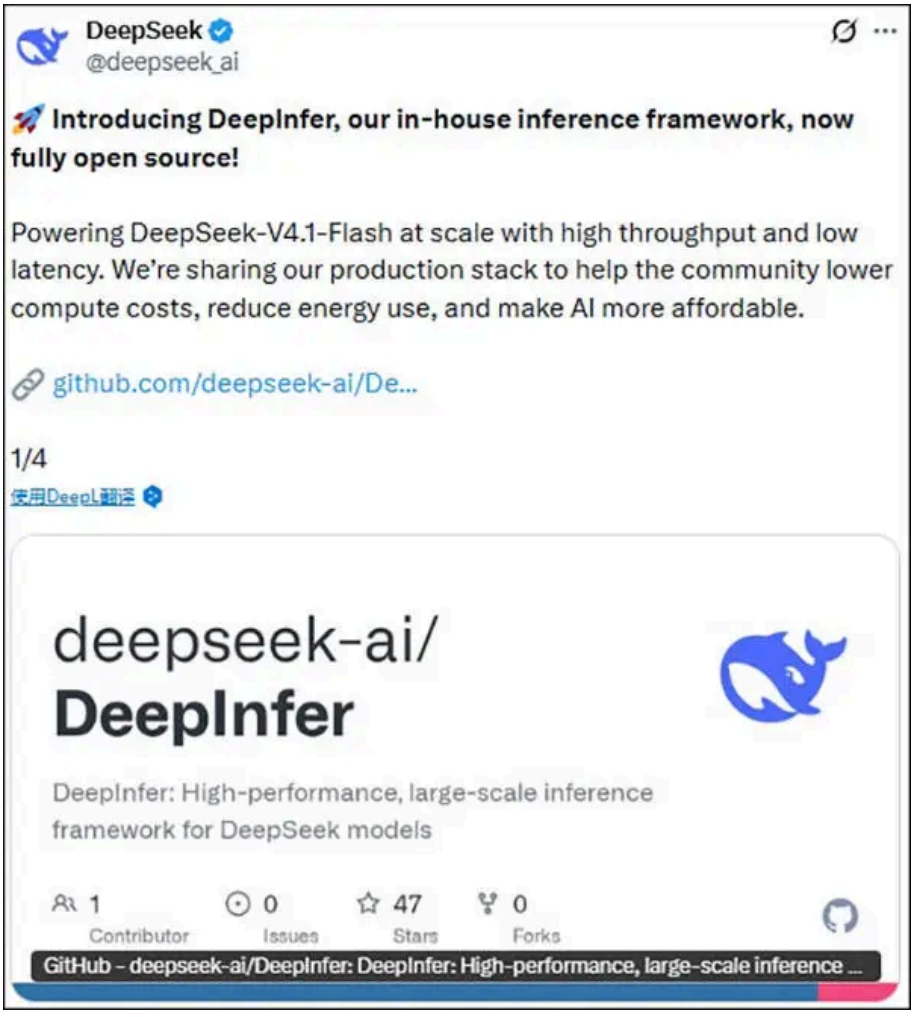
摘要：

OpenAI的名字里虽然带着“开放”，但其核心模型长期采取闭源策略，反倒是来自中国的DeepSeek正用实际行动践行“开放”一词，可能是对开源大语言模型生态贡献最大的公司之一。

在美国人工智能（AI）企业专注价格昂贵的闭源模型之际，DeepSeek将自己的技术“家底”向外界开放，赢得海外网友称赞。

10月20日，DeepSeek宣布开源内部生产级推理框架DeepInfer。

该框架是DeepSeek在面临美国尖端芯片出口限制下，确保大模型紧追美国顶尖AI模型的核心。推理框架负责管理模型如何使用计算资源来处理用户请求，其设计会影响延迟、吞吐量以及运行模型所需的硬件，因此是影响AI运营成本的重要因素。



美国彭博社21日指出，推理技术通常被AI公司视为核心竞争力，较少对外公开，而DeepSeek此次公开推理框架，让外界得以一窥其是如何在压低运行成本的同时，确保AI模型性能的。

即使是同一款AI模型，实际运行成本也可能因所采用的软件不同而存在较大差异。更加高效的软件能够降低每次请求所需的计算资源，并有望进一步减少能源消耗。

DeepInfer整合了分布式推理、投机解码等多项技术，能够让AI工作负载分配到不同硬件上，从而让模型在更短时间内生成更多输出，并进一步挖掘芯片的性能。目前，该框架已兼容英伟达

SM100 GPU和华为昇腾950 NPU。

这其中不少的底层技术已被业界广泛采用，但DeepSeek针对自身模型进行了专门的优化，使这些技术能够更加高效地协同运行。

美媒称，对于AI托管服务商而言，更低的推理成本意味着更大的利润空间，并有可能进一步转化为更低的AI服务价格。**对于企业用户来说，如果选择在自有基础设施上运行DeepSeek模型，DeepInfer也可能帮助其降低算力成本。**

不仅如此，DeepSeek开源DeepInfer后，其他开发者也可以研究其中的技术方案，并将部分方法应用到自己的模型推理系统中。

在DeepSeek宣布开源DeepInfer的帖子下方，美国加州一家专注于大语言模型与AI开源优化、本地训练和推理的公司Unsloth AI公开感谢DeepSeek称，其已经借助Dynamic GGUFs，让DeepSeek-V4.1-Flash-1017能够在配备128GB内存的设备上实现本地运行。

评论区还出现了大量海外开发者和AI从业者的积极反馈。**一名来自印度的社交媒体博主直接用“Real OPEN AI”（真正的开放AI）评价DeepSeek**，并配上一段调侃OpenAI首席执行官山姆·奥尔特曼的视频。



欧洲AI从业者也用漫画嘲讽美国AI公司的闭源模型仅限特定“朋友圈”，与之相对的是中国公司通过降低成本，让AI模型更普惠。



一名来自孟加拉国的软件开发者赞叹说，DeepSeek可能是对开源大语言模型生态贡献最大的公司之一。

当然，DeepSeek此次发布的并不是一套完整的推理技术栈。其文档提到，要构建完整的服务，还需要KV缓存系统、Prefill/Decode解耦，以及在数据并行副本之间进行负载均衡等功能，这些内容并未完全包含在此次开源项目中。不过，大部分核心的解耦功能已经实现。

AI基础设施初创公司Requesty首席执行官蒂博·杰古（Thibault Jaigu）表示，DeepInfer降低了部署DeepSeek模型的门槛，但企业仍需要具备相应的算力和技术能力。他认为，DeepSeek实际上是在告诉外界，“任何人都可以自行托管我们的模型，不过要实现高效的管理，还是有一些技巧需要注意”。

在广大海外网友看来，DeepSeek所做的已不仅仅是发布一个开源推理框架，而是它正在把越来越多原本属于企业内部的技术公开出来，让更多人能够参与进来。这与美国AI行业越来越强调闭源模型、庞大的算力投入和商业护城河的路线形成鲜明对比。

OpenAI的名字里虽然带着“开放”，但其核心模型长期采取闭源策略，反倒是来自中国的DeepSeek正用实际行动践行“开放”一词。

“为善与众行之，为巧与众能之。”正如DeepSeek所说，“我们期待着在不远的未来，能够看到全球AI服务的范围与质量获得前所未有的扩展与提升，变得更加公平、透明、可信赖，进而实现在全社会范围内加快技术迭代、减少能源浪费。”

本文来源：大橘财经

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限免

18 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论