

摘要：

浪潮计算机产品经理指出，“现在连板卡都缺货。”“内存价格从去年到现在涨了三倍。”中科曙光高级副总裁认为，现在算力离普通人更近了，未来的总体方向是云化，个人通过App即可获得强大AI能力；AI Agent时代，CPU和存储扮演的角色越来越重要。

7月27日，国家统计局公布1—6月规上工业企业利润数据。


上半年，算力需求大幅增长，推动电子行业利润同比增长96.9%，拉动全部规模以上工业企业利润增长8.5个百分点，集成电路制造行业利润增长更是高达2579.5%。

同一日，存储龙头长鑫科技登陆科创板，上市首日高开471%，收盘涨465.82%，市值3.28万亿元，超越工商银行成为A股总市值“一哥”。

夸张数字背后，算力市场的真实现状是怎样的？普通人和这场算力“狂飙”有什么关系？近日，在郑州举办的光合组织2026智能计算应用大会期间，《每日经济新闻》记者（以下简称每经记者）展开实地调研。

服务器合同价一周有效连板卡都缺货

7月中旬，郑州，室外气温逼近40摄氏度。郑州国际文化交流中心，人头攒动。走进一楼展厅，一台两人高的机柜映入眼帘，这是国内首台十万卡AI（人工智能）算力集群。人群环绕在机柜周围，仰着头才能看清顶部。展厅里人很密，站久了身上发黏，一位工作人员告诉记者，空调其实已经开得很低了，主要是人太多。往两侧走，各厂商的服务器机箱沿着过道一字排开，每个展位前都围了好几层人，站在外围的人只能侧着身子从缝隙里看。



两人高的机柜被层层围住 图片来源：每经记者 张宏 摄

展厅里的人大致分两类。一类是服务器零部件及整机厂商，另一类是AI应用厂商。两类人混在一起，过道里时不时有人停下来交换微信，或询问服务器参数，或交流行业动态。中午从餐厅走回会场，一路上仍有人在讨论各自的技术路径。现场的热闹场景，让每经记者联想到90年代互联网刚刚兴起时的盛况。

根据国家统计局公布的数据，今年上半年，服务器、高性能工作站相关领域中，计算机整机制造、计算机外围设备制造行业利润分别增长689.3%、305.8%；电子器件制造领域中，集成电路制造、半导体分立器件制造行业利润增长2579.5%、31.2%；电子元件及电子专用材料制造领域中，电子专用材料制造、电子电路制造行业利润增长209.7%、26.9%。

夸张数字背后，算力市场的真实现状是怎样的？

“现在连板卡都缺货。”浪潮计算机展台的产品经理刘树奇告诉每经记者，“内存价格从去年到现在涨了三倍，去年1万块钱一个内存条，可能今年涨到3万块还买不着。”

刘树奇口中的板卡是服务器的“地基”，也就是大家常见的绿色PCB电路板，CPU（中央处理器）、GPU（图形处理器）、存储等网络组件都靠它来互联互通。



现场展出的主板 图片来源：每经记者 张宏 摄

一位前来观展的GPU厂商感慨：“当时我们签的单子要一起卖服务器，结果找服务器，一天一个价，没法交付。原来就20万元，然后变成50万元，又变成80万元，买不着。”

刘树奇说：“有段时间，合同价一周有效。一周以后，就得再核一次，价格可能就不一样了。”

从交谈中，每经记者得知，这种供应紧缺的情况，从去年末开始，一直延续到现在。

普通人如何接触算力？


“飞驰”的订单，由什么支撑？这场算力“狂飙”离普通人有多远？

浪潮计算机AI产品部廖广山告诉每经记者，“普通人使用大模型属于云端推理，占用的是云端算力，不占用手机的算力资源”。

而如果要解决私密性问题，让数据只在本地流转，则需要本地化部署。廖广山说：“本地化部署主要的开支就是购买服务器，本身模型是开源的，在官网下载镜像就可以。”

一家AI应用服务商，或一家科研机构，要本地化部署模型并开展训练，需要使用多少算力？

面对记者提出的这一疑问，廖广山说：“这由实际要达成的效果决定，一般分预训练和微调。举例来说，如果使用DeepSeek做训练，在本地运行DeepSeek需要1倍资源；若要微调，则需要大概4到8倍的资源；若要推理训练则需要20多倍的资源。你所说的场景应该属于微调。”



刘树奇向前来问询的厂商介绍服务器 图片来源：每经记者 张宏 摄

刘树奇举例训练的过程，假设一家机构要开发一个模型，识别路口一天内经过多少人、多少辆车、多少动物，以及空气质量。就需要先搭建模型，分设多个识别字段——什么样的轮廓是“人”，什么样的特征是“动物”，什么样的形状算“车”。模型建好后，还要不断“喂”数据，比如各种品牌、各种外形的车辆，让系统持续学习。只要数据量够大，模型就会越练越精准。

“如果只是需要保证训练的稳定性，如要保证AI短剧中人物形象的一致性，不一定要本地化部署，只要购买大模型厂商的租户隔离服务就可以。”廖广山说。

算力价格暴涨之下，算力离普通人是越来越近了，还是越来越高端、触不可及了？

对于每经记者的这一问题的，中科曙光高级副总裁李斌认为，现在算力离普通人更近了。“以郑州的曙光8000为例，过去主要服务科研院所的科学家，现在很大一部分资源已经接到手机App（应用程序）后端，提供Token（词元）服务。可能大家打开手机，背后的算力就来自郑州。”

CPU和存储扮演的角色越来越重要

在普通人看来，服务器机箱的构成，与台式计算机有些类似，都是由CPU、GPU、存储、硬盘、散热等部件组装而成。

廖广山给记者打了个比方：“如果说前者只是玩具汽车，那后者就是真正的火箭。两者在设计复杂度、结构精密程度以及用途上，完全不在一个维度，后者能完成的计算也复杂得多。研制一套服务器要花上千万元的费用。”

不过，相似之处在于，随着算力需求的变化，服务器内不同部件的配比会发生变化。

李斌认为，在超长上下文的推理中，存储扮演的角色越来越重要。

海光信息服务器产品部总经理张攀勇则表示，随着AI Agent（人工智能体）时代的到来，大量工作实际上是在CPU上完成的——包括任务编排、工具调用与处理，以及记忆管理等。而GPU的角色，更多聚焦于模型推理本身。这也带来了一种范式转变。从他们的工作负载观察来看，CPU与GPU的比重发生了明显变化。过去在双路GPU服务器中，常见配置是1颗CPU搭配8颗GPU，或2颗CPU搭配8颗GPU，CPU与GPU的比例大致在1:4到1:8之间。但在当前的数据中心场景下，由于前述各类负载的增加——比如沙箱环境、存储系统、数据库、向量计算等——整体配比已经从过去的1：4、1：8，逐渐演变为1：1。

而要让机身变得更小，廖广山认为，可能要依赖于液冷的成熟。



采用液冷散热方案的服务器体积更小 图片来源：每经记者 张宏 摄

算力终将像水电一样，即开即用

算力是否存在结构性过剩？

李斌告诉每经记者，算力短缺或过剩存在阶段性波动，但总体看，AI驱动的需求仍在增长，尤其是对于高端算力的需求，智能体兴起后算力需求会更大。

“从IT（信息技术）产业发展规律来看，同等性能或效果所需的成本大概率是持续下降的，这是产业趋势。长期看，算力一定会更加普惠。”李斌举例说，“在大模型爆发之前，行业最火的是人脸识别。如今这项技术的技术门槛和使用成本都大幅降低。未来大模型也可能遵循同样的路

径：一方面，模型自身的能力将持续进化；另一方面，推理效率不断提升，单位任务所需的算力成本随之下降。最终，大模型将演变为像水电一样的基础能力，离大家更近。”

算力的终极形态是怎样的？

李斌认为，未来的总体方向是云化，同时边端设备（如具身智能）会配备轻量化算力实现实时响应。个人无需购买笨重本地设备，通过App即可获取强大AI能力。

海光信息副总裁应志伟也告诉每经记者，算力终将像水电一样，需要时即开即用，无论通过本地部署还是云端接入，都能随时响应。所有业务都会深度接入AI能力，否则便难以适应这个时代。算力将无处不在，人们在使用中甚至不会察觉它的存在——这才是真正的大趋势。

“过去依赖大型算力中心，是因为模型复杂、体量庞大，对算力要求极高，普通终端设备难以承载，只能依托集中式算力来完成训练和推理。这一方向不会改变，但也要看到另一面：当模型真正落地应用时，不同行业、不同用户的需求千差万别。程序员或许需要千亿甚至万亿参数的大模型来辅助编程，但在很多场景下，一个监控摄像头做人脸识别，几十亿参数的轻量模型就足够了。此类细分场景不胜枚举：嵌入式设备做电源波形检测，网络延迟反而会把优势抵消；孩子在家做数学题，本地小模型就能解决，无需调用云端大模型。”应志伟表示。

他接着指出，因此，AI发展到成熟阶段，一定会根据应用特点和行业需求，分化出各自的细分形态。这种分化将体现在各个层面：未来的芯片布局不会仅限于数据中心的大型AI芯片，手机、手环、手表、智能眼镜等所有终端设备，都将具备相应的AI处理能力，各自解决特定场景下的具体问题。比如，智能眼镜可以本地记录会议内容并生成纪要，很多场景未必有网络条件，本地处理能力就必不可少。大型算力中心会继续承担对算力和模型要求最高的顶级任务，但应用场景必将日益丰富多元。

本文来源：[每日经济新闻](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

VIP会员·7天畅读卡 | 大师课·入门串讲

扫码

免费领取



限免

77 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

