

5月27日，小米宣布MiMo-V2.5系列大模型API价格体系进行永久性调价，最高降幅度达99%，且不再区分上下文长度。

具体来看MiMo-V2.5-Pro：

百万tokens输入（缓存命中）只需要0.025元。

百万tokens输入（缓存未命中）3元。

百万tokens输出6元。

不仅如此，Token Plan方面，小米采取“加量不加价”策略，用户在Agent或Code场景下的可用Token数量将提升至原来的5-8倍，并把规则调整为“所见即所得”，简化了因换算导致的复杂计价逻辑。

这是继DeepSeek上周宣布V4-Pro永久降价至原价25%之后，国内头部大模型在短短一周内的又一次重磅价格调整。

国际比较看，DeepSeek与小米的最新定价已显著低于主流海外厂商。

国际主流模型方面，OpenAI GPT-4o的标准输入价格为每百万Tokens 2.5美元，输出价格为10美元；Claude Sonnet 4.6的输入为每百万Tokens 3美元，输出为15美元。

与简单的“烧钱”不同，小米此次降价的逻辑指向工程层面的成本结构优化。

据小米解释，基于 SGLang HiCache 完整支持 SWA（Sliding Window Attention），将 KV Cache 在 GPU 显存、CPU 内存、SSD 等多级存储之间的数据搬运量降低至优化前的近 1/7，并将可缓存 token 数量提升至优化前的近 5 倍，显著提升了缓存命中率和推理效率。此外，小米还通过优化专家方案、输入长度分桶策略等手段，进一步提升集群输入吞吐能力。

这与DeepSeek的降价逻辑一脉相承，都是通过架构创新以及推理系统的工程化优化，结构性地压低单位Token服务成本，再将红利让渡给开发者。

从行业情况来看，本轮国产大模型降价潮亦是伴随着应用方需求的变化，随着大模型正在从“聊天”进入“干活”的阶段，真正让开发者和企业用户焦虑的也不再只是一次问答金额，而是Agent在多轮推理、调用和自动化成本工作流等过程中持续燃烧的Token。

当百万Tokens价格被不断压低，国内大模型的竞争也会继续向下游传导。对于开发者来说，成本下降意味着更多Agent等应用供给会迎来井喷；对于厂商来说，低价背后则是更高的推理效率、更强的算力调度能力，以及更长周期的生态投入。

价格战未必能直接决定谁的模型最强，但可以推动其更快地被开发者调用，小米MiMo此时大幅降价正是国内大模型走向“规模化使用”的又一个注脚。

Xiaomi MIMO

MiMo-V2.5 系列 API 永久降价

📅 永久降价将于 5 月 27 日 00:00 (北京时间) 正式生效

单位: ¥ / 百万 tokens

MiMo-V2.5-Pro

调价后价格 / 对比降幅

		对比 ≤256k	对比 256k-1M
输入 缓存命中	¥0.025	¥1.40 ↓98%	¥2.80 ↓99%
输入 未命中缓存	¥3.000	¥7.00 ↓57%	¥14.00 ↓79%
输出	¥6.000	¥21.00 ↓71%	¥42.00 ↓86%

MiMo-V2.5

调价后价格 / 对比降幅

		对比 ≤256k	对比 256k-1M
输入 缓存命中	¥0.020	¥0.56 ↓96%	¥1.12 ↓98%
输入 未命中缓存	¥1.000	¥2.80 ↓64%	¥5.60 ↓82%
输出	¥2.000	¥14.00 ↓86%	¥28.00 ↓93%

MiMo-V2.5-TTS 系列继续提供限时免费接入

MiMo-V2-Pro 与 MiMo-V2-Omni 的 API 价格维持原价不变

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

71 收藏

分享到:



写评论

请发表您的评论



表情



图片

发布评论

2 条评论



MobileUser2759

10小时前 中国安徽省

美国的哪些大模型很可能变成Tesla电动汽车一样，没有性价比的情况下，根本无法成为最终赢家，变成AI浪潮死在沙滩上的先行者

👍 0

↩ 回复



MobileUser2759

10小时前 中国安徽省

DeepSeek-V4-Pro

百万tokens输入（缓存命中） 0.025元

百万tokens输入（缓存未命中） 3元

百万tokens输出 6元

展开全部

👍 0

↩ 回复

