

摘要：

MiniMax半年报显示，其收入同比增长283.1%，ARR破8亿美元，B端收入占比达80%。创始人闫俊杰提出“最小化推理成本，最大化智能”的技术路线，认为推理效率决定智能迭代上限。通过自研MSA架构，其将长文本单位Token计算成本压至传统方案的约1/20，实现成本与智能的兼顾，为国产大模型探索出差异化竞争路径。

8月26日，中国AI大模型龙头企业MiniMax（稀宇科技）发布了其自港股上市以来首份半年报。

财报显示，MiniMax的收入**同比增长283.1%**，其半年收入已达到2025年全年收入的**1.5倍**；毛利**同比增长 464.8%**。



财报会上，MiniMax创始人、董事会主席、CEO、CTO闫俊杰透露，8月，MiniMax的ARR破了**8亿美元**，B端收入占比冲到了**80%**，7月的Token消耗量是1月的**20倍**。

除去数据，吸引我注意的，还有闫俊杰在昨晚的业绩会上说的一句话。他说：“**只有最小化单位智能成本，才有可能最大化智能水平。**”

要知道，过去两年，大模型基本就两条路：要么按照Scaling law堆参数冲智能，代价是成本高；要么是降低效率做普惠，但智能水平总差点意思。

行业似乎默认这是鱼和熊掌，不可兼得。

MiniMax为什么会选择一条与行业“反直觉”的路？这条路究竟能不能走通呢？

智能与成本，为何难以两全？

Scaling Law驱动了AI过去几年的叙事：**参数越大，智能越高。**

遵循着Scaling Law，目前模型的参数已经堆到了2-3T的级别，模型的智能也水涨船高，人人惊呼AGI即将到来。

在繁荣背后，这个规则也埋下了一颗雷：**当模型进入万亿参数量级，推理成本开始变得不容忽视。**


英伟达CEO黄仁勋在2026年GTC大会上做出判断：“**训练支出作为主要成本驱动因素的时代已经结束了。推理才是现在的工作负载，而且它正在快速扩张。**”

推理成本的膨胀，加上Agent工作负载的崛起，AI正在从一问一答走向多步骤自主执行。单次用户请求背后可能是十几次甚至几十次模型调用，这让整个行业的算力账单以指数级速度攀升。

结果，行业逐渐分成了两派：

一边是速度快、成本低，但智能表现中规中矩的小模型。

谷歌就是这条路的典型代表。2026年7月到8月，谷歌一口气推出了Gemini 3.7 Flash、Gemini 3.6 Flash、Gemini 3.5 Flash-Lite和Gemini 3.5 Flash Cyber三款轻量化模型。



3.5 Flash-Lite是3.5系列中速度最快、成本最低的模型，专为高吞吐量工作负载和大型AI代理系统中的较小任务而设计。Gemini 3.6 Flash的输出Token使用量比前代减少了17%。

但代价也很明显。谷歌至今仍未推出旗舰模型Gemini 3.5 Pro，这款原定于5月I/O大会上发布的产品，至今都没有见光。

另一边是智商在线，但部署贵、成本开始变高的大模型。

国产大模型厂商正在这条路上狂奔。2026年7月，月之暗面发布Kimi K3，参数规模达到**约2.8万亿**，是目前全球参数量最大的开源模型。

阿里紧接着推出Qwen3.8 Max，参数量**约2.4万亿**；百度文心5.0同样达到**2.4万亿**参数；DeepSeek V4-Pro参数量为1.6万亿。

参数规模带来的智能提升肉眼可见。Kimi K3在多项Agent榜单上**超越Claude Fable 5和GPT-5.6 Sol**。Qwen3.8 Max被描述为“参数规模最大、性能最强的开源模型之一”。

但成本也水涨船高。

Kimi K3的API定价，非缓存输入从每百万Token 6.5元涨到20元，输出从27元涨到100元，分别上涨208%和270%。官方建议采用64张及以上加速卡组成超节点部署。

发布仅两天后，月之暗面就宣布暂停C端新用户订阅，将全部算力投入保障已有用户。

智能越前沿，模型参数越大，调用越贵，部署门槛越高，算力越紧缺……这似乎成了一个难以解开的死结。

MiniMax，不做取舍

对于成本和智能二选一的难题，**MiniMax的选择是：我全都要。**

闫俊杰在财报会上基本把MiniMax的整套逻辑讲清楚了：

“算力对每家公司都是有限的。我们希望通过‘Minimize the Inference Cost, Maximize the Intelligence’实现‘Intelligence with Everyone’。这是我们一直坚持的技术路线，也是创业初心。”

“Minimize the Inference Cost, Maximize the Intelligence”，意思是“**最小化推理成本，最大化智能**”。MiniMax将降低成本和提高智能放在了同一个叙事框架里。

为什么这两件事可以放在一起说？因为MiniMax对“**推理**”的理解不太一样：

第一，推理是制造下一代智能的生产资料。

过去认为推理是“用模型”，训练是“造模型”。但现在，合成数据、强化学习的Rollout、模型评测和验证、Agent与环境的交互等等这些核心环节，本质上跑的都是推理负载。

后训练环节在整体训练算力中的占比越来越高。推理已经不是训练结束之后才出现的工作量，而是贯穿训练全过程的消耗。



所以，推理效率决定的不只是API的定价空间，更决定了下一代模型能训练到什么程度。

第二，推理成本优化是智能迭代的必要条件。

算力有物理上限，模型规模却在持续扩大。如果推理成本降不下来，越往后走成本越会反过来掐住智能提升的脖子。

在有限的算力预算里，能不能把每一块钱都转化成有效的智能产出，决定了模型迭代能走多远。

第三，用最低的单位智能成本，去追求最高的智能水平——这两件事是同一个目标的两面。

行业过去习惯把“智能优先”和“成本优先”当成两条不同的路线。但推理成本降不下来，再高的智能也落不了地。

简单理解，MiniMax的思路是把成本优化和智能升级当成同一件事来做。从模型设计的第一天就把推理效率当成核心指标，贯穿整个研发周期。

用闫俊杰的话说：“MiniMax追求的不是在智能与成本之间做取舍。追求更高等级的智能是目的，通过持续优化推理成本和效率来实现更高性价比是手段。”

计算成本降到1/20 MiniMax把“降本提智”做成了技术闭环

MiniMax一直以来就是遵循着这样的初心，建立起了一套技术底座。

最核心的是其自研的MSA（稀疏注意力）架构。简单说，它把百万字长文本的单位Token计算成本压到了传统全注意力机制的约1/20，也就是说M3在1M上下文下每Token计算量只有上代的1/20。



这个突破的关键在于：总参数量决定模型的知识容量上限，但激活参数量决定单Token推理成本。这两者可以解耦：参数规模扩张，不一定带来推理成本同比例上涨。

所以M3能在价格不变的前提下把智能水平提上去，M3 Pro能做到约3T参数量级的同时推进强化学习和长程任务训练。

基础设施层面，MiniMax的ETTR（有效训练时间比例）能做到97%，是国内最早建立规模化、长期稳定算力体系的独立大模型公司之一。



通过自主集群、云厂商和TokenFactory合作的组合方式搭建了算力供给网络，**现有及规划算力已经能支撑3T级文本模型和视频模型的持续迭代。**

结语：算力不占优 国产模型靠什么追？

每每谈到中美大模型的差距，硬件总是绕不开的话题。

过去大家默认，谁有更先进的芯片制程、更高的算力，谁就能做出更好的模型。按照这个逻辑，中国AI似乎将永远与美国AI保持着几个月到半年的差距。

难道就只能如此了吗？

MiniMax给出了一条新路：Minimize the Inference Cost, Maximize the Intelligence。

降低单位智能的成本，同样也是在推高智能上限。因为今天的后训练、合成数据、强化学习，本质上跑的都是推理负载。推理效率越高，同样算力下能做的实验就越多，智能天花板就越高。

谁能用更低的成本产出更高的智能，谁就能在有限的算力里跑出更远的边界，进而让更高的智能进入更广泛的生活中。

这或许是国产大模型参与全球竞争时，最有希望走通的一条路。而MiniMax，已经开始验证了。

本文来源：[智东西](#)

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

👍 82 ★ 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

