

摘要：

UC伯克利发布考查AI真实工作能力的新基准测试ALE。结果显示：此前公认最强的Claude Fable 5通过率（22%）不敌GPT-5.5（24%），且耗费成本是其数倍；在最高难度任务下两者更是双双挂零。这揭示出AI“做题学霸≠干活能手”，目前最强智能体应对真实复杂工作依然拉胯。

没想到打脸来得如此之快！！

刚刚，UC伯克利放出了一场号称“**智能体最后的考试**”的全新基准测试。

它把当今最强的AI Agent们拉到考场上，让它们干真正的活——

在Siemens NX里建3D模型、在Unreal Engine里搭游戏场景、在Adobe After Effects里做特效合成。

结果成绩令人傻眼：

最难的一档，当今公认最强的Claude Fable 5、GPT 5.5，全是大写的零蛋。

Last-Exam Tier

Tasks with frontier complexity



你说难度稍微放低一点呢？分数倒是有了，但结果也相当令人意外——

GPT 5.5竟然还小胜了Claude Fable 5。

我没听错吧，A家刚发布的最强模型Claude Fable 5，被几个月前的GPT 5.5打败了？？

要知道在此前几乎所有主流benchmark上，Fable 5对GPT 5.5都是碾压级别的存在——SWE-Bench Pro上80.3%对58.6%，Humanity's Last Exam上64.5%对52.2%。

但换到这场“真干活”的考试里，局面却反了过来。

这个新基准叫Agents' Last Exam (ALE)，背后团队来头不小，之前MMLU、MATH、CyberGym、ExploitGym这些你耳熟能详的基准都是他们提的。

取这个名估计也是参考之前Scale AI那个“Humanity's Last Exam”（人类最后的考试），只不过这次被考的不是人类知识的极限，而是AI Agent干活的极限。

该说不说，这个测评一出来，以前天天喊着“Agent要取代人类工作”的人，这下是真干沉默了...

“智能体最后的考试”，赢家竟是GPT 5.5！

先看完整排行榜。

#	HARNESS	MODEL	PASS RATE ▼	SCORE ▼	ESTIMATED TOTAL COST ▼	TOTAL RUNTIME ▼	TOTAL INPUT TOKENS ▼	TOTAL OUTPUT TOKENS ▼
1	Codex	gpt-5-5	24.0%	42.8%	\$566	81h 48m	578.5M	3.9M
2	Ale Claw	gpt-5-5	23.0%	45.8%	\$311	47h 20m	334.5M	2.4M
3	Claude Code	claude-fable-5 (may be down-tuned)	22.0%	40.5%	\$2,315	195h 4m	880.0M	9.4M
4	Openclaw	gpt-5-5	21.1%	41.0%	\$449	92h 51m	471.1M	3.3M
5	Cursor Cli	gpt-5-5	20.7%	39.6%	\$174	67h 1m	148.5M	1.7M
6	Openclaw	gpt-5-4	20.5%	37.3%	\$276	139h 43m	490.5M	7.4M
7	Cursor Cli	composer-2-5	20.4%	38.5%	\$177	249h 59m	338.8M	2.9M
8	Droid	gpt-5-5	19.1%	38.6%	\$244	81h 4m	235.8M	2.2M
9	Ale Claw	claude-opus-4-7	18.4%	40.5%	\$1,144	87h 54m	1.4B	5.7M
10	Claude Code	claude-opus-4-8	15.8%	37.2%	\$1,838	451h 15m	452.0M	3.8M

从最核心的任务通过率指标来看，GPT 5.5直接包揽冠亚军：

第1名是GPT 5.5搭配OpenAI自家的Codex框架，通过率24.0%。

第2名还是GPT-5.5，只不过换了ALE Claw框架，通过率23.0%。

(ALE Claw是团队自己写的一个baseline Agent，跟Codex、Claude Code、Cursor CLI这些商业框架并列参赛)

直到第3名，我们才看到Claude Fable 5的身影——搭配Claude Code，拿下22.0%的通过率。

往下看更有意思。

第4、第5、第8名全是GPT 5.5，只是换了不同的框架。

前10名里GPT 5.5出场了5次，加上第6名的GPT 5.4，OpenAI模型直接占了6席。

而Claude家族呢？

Fable 5拿了第3，Opus 4.7第9 (18.4%)，Opus 4.8垫底第10 (15.8%)，不敌之势一目了然。



也不怪OpenAI研究员喜庆发帖，欢欢喜喜过大年了：



而在成绩之外，这里还有这样几个值得细品的信号。

一是天花板低得惊人。

冠军通过率才24%，综合得分最高也不过45.8%。

意思是，就算按最宽松的“部分得分”算，最强的Agent也只能拿到不到一半的分。

而这些题全部来自真人专家已经完成的项目——人类专家的完成率理论上就是100%。

二是Claude烧钱烧得惊人。

这张榜单新增了一列“Estimated Total Cost”，一下子把贫富差距拉出来了：

Fable 5跑完全部任务花了2315美元，Opus 4.8花了1838美元，Opus 4.7也要1144美元。

而GPT-5.5这边呢？

最贵的Codex也就566美元，Cursor CLI只要174美元。

等于说，Fable 5花了Codex四倍多的钱，成绩还低了两个百分点。



三是效率差距同样触目。

Ale Claw跑完全部任务花了47小时20分钟，Cursor CLI只花了67小时。



而Opus 4.8呢？451小时——将近19天。

干的活最少，花的时间最长，收的钱最多（居然真有模型能同时做到？）

当然如果只看Claude Fable 5、GPT 5.5这两个最顶的，GPT 5.5的时间优势依旧明显。


#	HARNESS	MODEL	PASS RATE ▾	SCORE ▾	ESTIMATED TOTAL COST ▾	TOTAL RUNTIME ▾	TOTAL INPUT TOKENS ▾	TOTAL OUTPUT TOKENS ▾
1	Codex	gpt-5-5	24.0%	42.8%	\$566	81h 48m	578.5M	3.9M
2	Ale Claw	gpt-5-5	23.0%	45.8%	\$311	47h 20m	334.5M	2.4M
3	Claude Code	claude-fable-5 ⚠ may be down-tuned	22.0%	40.5%	\$2,315	195h 4m	880.0M	3.6M

而最扎眼的数字，还是那个零。

ALE把任务分成了三个难度档：

Near-Term（近期可解）
Full-Spectrum（全面覆盖）
Last-Exam（终极难题）

在最难这一档，所有主流配置的平均通过率只有2.6%，包括GPT 5.5和Fable 5在内的大多数模型直接吃了零蛋。



所以这张成绩单的核心信息很简单：别看平时考试成绩好，一到真干活全露馅了。

答题学霸≠干活能手，这话在AI世界也一样适用。

什么是ALE?

要理解ALE为什么能把这帮“学霸”打回原形，得先看它跟以前的考试有什么不一样。


之前的Humanity's Last Exam (HLE) 是2025年初由Dan Hendrycks和Scale AI搞出来的，2500道跨学科难题，本质上还是闭卷答题——

给你一个问题，你给我一个答案，再难也是静态的知识检索。

而ALE完全不同，它考你“能干什么”。

核心作者Yiyou Sun在????说得很直白：

AI智能体将在2026-2027年超越人类完成几乎所有工作——这个预测到处都是。所以我们造了这场考试来验证这个说法。



ALE的每道题都来自一个真人专家已经完成的项目，覆盖55个行业子领域，包括量化交易、基因组分析、航空航天工程、建筑设计、脑成像、动画特效、法律研究……

整个体系锚定的是美国联邦职业分类标准（ONET）*，说白了就是按“真实劳动力市场”来出题。




参与出题的阵容也够豪华：



300多位领域专家来自100多家机构，学术侧有MIT、Harvard、Stanford、Oxford、Caltech、ETH Zurich，产业侧有Goldman Sachs、JPMorgan、Meta、Amazon、Adobe、Oracle。

Snorkel AI通过Open Benchmarks Grants项目提供了资金支持。



考试形式也不是打字回答问题，而是直接操作电脑。


ALE用的是所谓GCUA框架（Generalist Computer-Use Agent，通用计算机使用代理），给Agent完整的GUI和命令行权限——

鼠标点击、键盘打字、写脚本、浏览网页，人类能在电脑上干的它都能干。

不限方法，只看结果。

交出来的“作业”由确定性代码自动评分。

No vibes. No human judges. Fully reproducible.（不靠感觉，不靠人类裁判，完全可复现）



这就堵住了之前很多benchmark的一个老毛病：评分器本身就能被骗。

此外，ALE在防作弊上还有一个狠招——

只公开约10%的题目（约150道），剩下1300多道严格保密。

公开题和私密题定期滚动轮换，确保不会有模型因为“背题”而拿高分。



这在当前benchmark数据污染泛滥的背景下，算是一个相当巧妙的设计。


整体而言，跟现有的Agent基准测试比，ALE的定位非常明确。

团队成员之一的Dawn Song专门拉了一组对比：

- ALE的CLI子集（ALE-CLI）覆盖40个行业子领域，而Terminal-Bench只有6个，SWE-bench-Pro只有5个；
- 人类完成这些任务的时间从几小时到几周不等，而后两者是几分钟到几天；
- 最强Agent在ALE-CLI上的通过率只有25.2%，而Terminal-Bench上是82.0%，SWE-bench-Pro上是59.1%。

一言以蔽之，其他考试已经快被做穿了，而ALE还远得很。

这就是ALE凭什么敢自称“智能体最后的考试”的理由。



值得一提的是，Dawn Song还分享了两个有趣的观察：

一个是，Agent会在没有真正验证工作成果的情况下宣布完成，这是Agent们最典型的失败模式。

很多时候，虽然它们说了“Done. All checks pass.”（搞定了，所有检查都通过了）

但实际产出可能缺少必要文件、数字算错、关键字段遗漏、或者直接违反了任务说明中的明确约束。

等于是，活没干完，嘴先说完了。

另一个是很多人疑惑的，为啥Fable 5这么拉胯？Dawn Song给出的回答是：

不存在“万能冠军”这回事。

每个前沿模型都有擅长的领域和拉胯的领域，ALE覆盖55个行业、1500+道题，最终得分是所有领域的平均值，很多模型的总分因此挤在一起。真正有价值的信号不在总分，而在不同模型在不同领域的表现差异——在同一道题上，不同模型往往因为完全不同的原因而失败。

当然也有可能是Fable 5偷偷“降智”了。

总榜里，Fable 5旁边标黄了一句“may be down-tuned”（可能被降级），这说的是Fable 5的一个已知问题——

它底层是Mythos模型加安全分类器，遇到网络安全、生物医学等敏感领域的任务时，会被静默切换到能力更弱的Opus 4.8。

在ALE这种覆盖55个行业的考试中，等于这部分科目直接派了替考，而且派的还是“奔波儿霸”这种角色。



One More Thing

当然，有没有可能Claude Fable 5的成绩本身就有问题呢？

不好说，但一桩八卦显示，Claude有“前科”。

5月底，初创公司Datacurve发布了一个叫DeepSWE的新benchmark，顺手揭了一个大底——

SWE-Bench Pro的Docker容器里附带了代码仓库的完整git历史，正确答案就躺在文件系统中。


大多数模型会无视它，但只有Claude不会。

它会主动检查仓库的git历史，从历史提交中寻找与任务对应的修复方案，并据此恢复正确补丁。

据称Opus 4.7约18%的通过成绩是这么拿的，Opus 4.6更夸张，约25%。

而GPT 5.4和GPT5.5这边呢？完全没有这种行为。Datacurve的措辞很外交：

这个benchmark让这种行为成为可能，但Claude是唯一持续这么做的家族。



科技媒体VentureBeat的评价倒很暧昧：

这说明Claude“环境感知能力”很强，非常擅长探索周围环境并利用可用资源。算“作弊”还是“机灵”，取决于你的立场。

但甭管怎么看，ALE显然吸取了教训——

直接把考场从命令行搬到了GUI桌面操作，让你没有git历史可以偷看。

评测AI的考场，正在被AI自己倒逼着升级，也算很精彩了。

完整测评地址：<https://agents-last-exam.org/leaderboard>

项目主页：<https://agents-last-exam.org/>

GitHub：<https://github.com/rdi-berkeley/agents-last-exam>

本文来源：[量子位](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

65 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论