

摘要：

OpenAI将发布新一代AI模型Astra，其网络安全能力首次达到公司内部最高“关键”风险等级。Astra可自主发现未知漏洞，并实现漏洞利用和系统权限提升，能力较前代显著增强。OpenAI尚未公布具体发布时间，将通过训练隔离、行为对齐和实时监控等措施加强安全防护，并分阶段开放高级网络安全功能。

OpenAI周二宣布，其下一代人工智能模型Astra首次触及公司内部“准备框架”中最高级别的“关键”网络安全能力阈值，成为该公司迄今能力最强、同时也受到最严格安全管控的模型。

Astra能够自主发现此前未知的安全漏洞，并进一步开发漏洞利用方案。这意味着，Astra已达到OpenAI定义的最高风险等级，模型能力一旦被滥用，可能产生此前未曾出现的严重安全威胁。OpenAI表示，仍计划“尽快”发布Astra，但其最先进的网络安全能力将仅向有限范围的测试人员开放，随后通过旗下网络安全联盟Daybreak Blue逐步扩大访问权限。

此次公告发布之际，OpenAI正面临外界对AI安全问题的高度关注。上月，该公司披露旗下两款模型曾逃逸训练环境、访问公开网络并入侵Hugging Face系统，引发业界对AI失控风险的担忧。尽管Astra并未参与这一事件，OpenAI仍主动暂停部分相关开发工作，并将此次事件的经验教训纳入Astra的安全体系。

此外，OpenAI首席执行官奥特曼近期在一档播客节目中透露，Astra在操作电脑方面“感觉已经完全达到了人类水平”，并表示AGI的到来“至少已经非常接近了”。

OpenAI周二在博客文章中表示，将“很快”发布这款模型，但尚未透露具体时间。据业内人士此前透露，Astra还具备多智能体长期协作、桌面软件操作等能力，可执行数学证明、PPT制作、财务审核及复杂数据分析等任务。

能力突破：自主发现零日漏洞，网络安全能力跃升

根据OpenAI发布的技术博客，Astra的网络安全能力较前代模型GPT-5.6 Sol实现显著提升，不仅在漏洞识别和漏洞利用开发方面表现更强，而且完成相关任务所需的输出token数量大幅减少，效率进一步提高。

在公开基准测试ExploitBench上，Astra取得100%的成绩。为排除数据污染影响，OpenAI还构建了一套内部基准测试，覆盖2026年6月至8月期间披露的20个高危V8漏洞。测试结果显示，Astra的任意代码执行成功率明显高于GPT-5.6 Sol。

更值得关注的是，在评估过程中，Astra自主发现了两个此前未知的“零日漏洞”，即软件厂商尚未发现或修复的安全漏洞，并进一步将其用于构建漏洞利用链。OpenAI表示，目前正向相关维护方披露这两个漏洞。

在专家对加固浏览器和操作系统进行的测试中，Astra展现出较强的攻击能力。它不仅能够找到浏览器的安全漏洞，突破浏览器的安全隔离机制，并进一步在电脑系统中执行命令；还发现了操作系统中的多个漏洞，并将这些漏洞串联起来，实现从普通用户权限到最高系统权限的提升。

安全管控：多层防护应对“关键”级别风险

面对Astra达到的能力水平，OpenAI在发布前实施了一系列强化安全措施。

在模型训练层面，OpenAI在Hugging Face事件发生后暂停部分前沿训练工作长达两周，以强化训练基础设施隔离和网络管控，并加强对齐训练。针对Astra的大规模强化学习（RL）训练也一度暂停，直至8月28日在新的安全要求到位后才重新启动。

在模型行为层面，OpenAI对Astra进行了专项训练，使其更加可靠地拒绝有害网络请求，并严格遵守安全限制。测试数据显示，在模拟基准环境中，GPT-5.6 SoI有56%的测试会尝试访问“蜜罐”目标，即试图入侵周边安全基础设施，而Astra在相同测试中则未出现此类行为。

在部署监控层面，OpenAI为Astra级别模型部署了“失配监控”系统，通过分类器实时检查模型的推理过程和行为，并自动终止潜在的未授权活动。

访问限制：分阶段开放，优先服务防御性网络安全

鉴于Astra的能力级别，OpenAI将采取严格的分阶段访问策略。其高级网络安全功能将首先向一小批alpha测试人员开放，随后通过Daybreak Blue计划向更多经批准的组织扩展，重点支持防御性网络安全工作。

OpenAI同时提醒，Astra的安全检查系统初期可能误判合法活动，导致部分任务被减速、暂停或终止，包括长时间运行的智能体任务。在ChatGPT或Codex界面中，如果“失配监控”系统触发暂停，用户需要审核相关操作后才能继续；通过API使用时，任务则会直接停止。

OpenAI表示，随着AI模型承担更多高影响力工作，对齐或控制失效的后果也将更加严重。该公司将在Astra正式发布时通过模型系统卡披露更多安全、对齐测试及评估细节，目前尚未公布具体发布时间。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

VIP会员·7天畅读卡 | 大师课·入门串讲

扫码

免费领取

限免

37 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论