

摘要：

Anthropic、OpenAI、xAI的掌门人近日罕见地讨论为大模型竞赛“按暂停”，但在激烈的商业竞争下，谁也不愿主动停下。随着AI智能体从辅助工具转变为拥有系统操作权限的执行者，模型失控的影响范围已从屏幕里的错误输出延伸至真实业务系统。未来更现实的选择，是在关键节点设置“限速规则”。

“造车”的人想减速，“坐车”的人却催着踩死油门。这是过去几天美国AI行业反差最明显的一幅画面。也与过去几年人工智能扩张的“规模法则”形成鲜明对比。

过去几年，硅谷的关注焦点是算力还能增加几倍，参数规模还能冲多大，谁能率先做出更强的大模型。整个行业都在追求更快的迭代节奏。上个周末，Anthropic、OpenAI、xAI几家核心大模型公司的掌门人开始讨论为大模型竞赛“按暂停”。

Anthropic CEO阿莫迪近日发表长文，建议行业主动调控能力提升节奏，给外部第三方评估和底层安全研究留出窗口期。随后，OpenAI CEO奥特曼公开附和，称内部团队近期也在讨论类似问题；马斯克也公开表态，认为阿莫迪的观点很中肯。

这意味着，几位平时在商业利益、人才争夺和技术路线上竞争激烈，甚至偶发“口角”的领头人，在减速这件事上表现出了少见的共识。

“球员”要暂停，“主办方”认为得分效率还不够高，态度截然相反。


谁也不确定Agent拿到“钥匙”后会做什么

对AI安全的讨论一直存在，但2026年的关注点发生了一些根本变化。

2023年GPT-4发布后，外界的担忧主要集中在生成虚假内容、版权侵犯和不良言论上。当时的大模型属于单向应答工具，用户输入提示词，模型返回文本。哪怕输出存在错误，影响范围也基本局限在屏幕上的对话框里。

随着自主智能体（Agent）架构的普及，系统的交互逻辑有了质的变化。

现在的模型拥有调用外部工具、执行代码和多步骤任务规划的能力。它们可以自主打开浏览器搜集数据、在服务器中运行脚本并操作各类企业软件。AI从提供参考意见的辅助角色，转变为了拥有系统操作权限的执行者。一旦行为逻辑出现偏差，影响的往往是真实的业务系统。



AI智能体基础架构：工具、记忆、规划、行动四大模块自主运转（图：腾讯云开发者社区）

Anthropic最近披露的一起事故彻底揭开了这种隐患的冰山一角。

在网络安全评估的封闭测试中，Claude先后4次在未经授权的情况下进入了真实的外部系统。技术团队最初排查了十多万条日志，随后发现涉及面较广，最终把筛查范围扩大到了近5亿条运行记录。这带来了一个巨大难题：**当大量智能体每天在后台执行长流程任务时，研发团队想要实时搞清楚模型的所有动作，成本变得极高。**



Anthropic @AnthropicAI · Jul 31



In a review of our cybersecurity evaluations, we found three incidents in which a Claude model reached the internet from within or while interacting with a third-party evaluation environment, and then gained unauthorized access to the real systems of three different organizations.

Our post describes what happened, how it happened, and what we're changing. We encourage other AI developers to perform similar reviews.

We conducted this review together with [@Irregular](#), one of our evaluation partners, and thank them for the joint investigation and their collaboration on this post. This type of collaboration is increasingly critical to safe, rigorous evaluation of models, and we look forward to continuing to work together on security.

在我们对网络安全评估的审查中，发现了三起事件：在这些事件中，某个 Claude 模型从第三方评估环境中进入互联网，随后获得了对三个不同组织的真实系统的未经授权的访问权限。

我们的帖子描述了所发生的情况、事件的过程，以及我们打算做出的改变。我们鼓励其他人工智能开发者也进行类似的评估工作。

我们与 [@Irregular](#) 一起进行了这项评估工作，他是我们的一位评估合作伙伴。感谢他们的共同努力和协作，使得这项研究能够顺利进行。这种类型的合作对于确保模型的准确性和可靠性至关重要，我们期待继续在安全性方面携手合作。



From anthropic.com

1.9K

4.7K

13K

19M



Claude在网络安全评估中未经授权访问了三家真实机构的系统（图：Anthropic）

OpenAI遇到的问题也与Anthropic相似。

在外部机构的独立测试中，OpenAI的模型也展现出编造访问权限、诱导人工审核员通过危险操作的倾向。

长时间跨度模型时代的安全与对齐

长时间运行模型的内部使用带给我们的安全启示。

▶ 聆听文章 9:43

🔗 分享

摘要

- 长时间运行的模型可以解决复杂的开放式问题，但其持久性也赋予其采取非预期行动的更多机会。
- 在针对某个为长时间运行任务训练的模型进行有限内部使用期间，我们观察到现有部署前评估未捕捉到的新型失败模式，并暂停了访问。随后，我们利用从这些失败模式中获得的洞察来制定新的评估措施、改进长时间跨度对齐行动、加入轨迹级监控，并在恢复有限访问前为用户提供更高的可见性和控制力。
- 这段经历进一步证明了迭代部署的价值。任何固定的评估套件都无法预见所有行为，因此部署前测试必须与密切监控、具备干预能力的防护措施，以及按需暂停或回滚的能力相结合。

OpenAI发布安全报告，披露长时程模型在内部测试中出现的新型失控行为（图：OpenAI）与此同时，模型正越来越多地参与下一代系统的代码编写和算法调优。

AI参与研发自身的循环，让技术迭代周期的缩短速度明显快于安全研究和政策法规的推进速度。当马力持续增加，而制动系统的跟进相对缓慢时，研发团队自然会产生顾虑。这是Anthropic、OpenAI和xAI三家“要暂停”的底层逻辑。

谁都不愿主动停下

危险已经成为现实，巨头们为什么不干脆停下来？

这其实与大模型“激烈”的竞争有关：大家都清楚车速接近失控，但只要你敢松一脚油门，对手就会立刻超过去。这种单方面减速的代价，谁都付不起。在他们看来，更好的结果是，**大家一起停，并且有一个合适的机构或者监管部门来充当裁判。**

阿莫迪在上周末的文章中提出了一套方案：推动独立第三方评估机构长期驻场，深度参与前沿实验室的模型训练与测试；同时促成OpenAI、Anthropic、Google和Meta等公司建立统一的最低安全准入标准。

这套设想在公共治理层面有合理性，但在真实的商业竞争中推行难度很大。

如果一家公司为了更完备的安全验证推迟产品发布三个月，而竞争对手在一周后就推出下一代模型，市场份额就会迅速倾斜。发布延期，就意味着开发者生态的转移、企业客户的流失以及投资人信心的动摇。

毕竟，Anthropic还在筹备预计在10月份进行IPO。这个过程中，任何一个暂停都会为这家前沿实验室的收入带来巨大的影响。

你可能会说，不对呀，奥特曼也表态OpenAI不急于在2026年完成IPO，他甚至说**如果有人觉得“OpenAI不会暂停，因为担心损失商业利益”，那他们深深误解了我们**。为了人类利益，可以牺牲短期财务利益。

这种胸怀，和四月份奥特曼，简直判若两人。

当时，The Information披露，**奥特曼私下里曾表现出激进的一面，希望最早于2026年第四季度完成IPO**。不过，这与OpenAI CFO Sarah Friar出现了“分歧”。Sarah Friar表示，OpenAI在未来5年内承诺了高达6000亿美元的服务器租用成本，而收入增速放缓，“尚未具备上市条件”。

第三方跟踪数据显示，2025年，OpenAI的收入规模大约是Anthropic的3倍。但进入2026年后，Anthropic凭借企业端增长，在二季度单季营收和年化收入（ARR）上首次反超了OpenAI，且首次扭亏为盈，而OpenAI仍处于持续的亏损当中。

究竟什么改变了他的态度？不知道！但商业因素必然在考虑范围内。

在激烈的市场竞争中，很少有企业敢单方面承担这种商业风险。大家都清楚车速过快可能带来隐患，但在落后和风险之间，很多团队依然会选择继续保持研发节奏。

这种微妙的心态让所有的安全倡议都蒙上了一层博弈色彩：**大家都真诚地希望全行业集体减速，但谁也不愿意做第一个松开油门的人**。

不会熄火的赛车

指望美国AI产业彻底踩死刹车并不现实，在各方投入和产业惯性的推动下，技术引擎只会被迫继续轰鸣。

未来更务实的路径是在关键节点设置限速规则——常规业务应用和多模态交互依然会保持快速迭代，监管重点将转向明确的高危领域。一旦模型被检测出具备自主编写特定高危代码、辅助危险化学实验或脱离既定安全环境的能力，将强制触发外部评估。

与此同时，**重大异常事件的事后通报也将逐步走向规范化**。

在国际沟通方面，短期内各方达成一份叫停研发的协定也并不现实。只要缺乏足够的互信基础，单纯的停工承诺就很难真正约束各方。**未来更有操作性的切入点，在于建立基本的危机沟通通道**。这类机制的核心作用，在于应对突发的系统异常。

比如，当跨境自主智能体出现严重的未授权访问，或者疑似发生由AI引发的网络安全事件时，各方技术人员能有沟通渠道去确认真实情况，避免产生误判。至少需要提前在桌面上谈妥——当某一方的系统在物理世界闯出大祸，彼此该如何确保两台高速行驶的机器不会迎面相撞。

从当年浪漫主义的暂停六个月公开信，再到如今顶级“造车人”不得不重新回过头来寻求制动，**技术哲学最终迎头撞上了冰冷的地缘现实**。

硅谷的焦虑在于技术边界本身的不可测，白宫的担忧可能在于霸权身位的得而复失。这种姿态极其扭曲：一边把油门狠狠踩到底，一边惊慌失措地去试探手刹的位置。



不过，一个更关键的问题在于：每一个玩家都极度害怕成为第一个减速的人，那些临时拼凑出来的防抱死系统，在撞墙前的最后一秒，到底能不能真正发挥作用？

(文章有部分删减)

本文来源：[腾讯科技](#) 作者：刘典 复旦大学中国研究院特任副研究员

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 93  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论

1 条评论



八闽望族之冠
1小时前 中国上海

AI的疫情发生哈哈

 0  回复