

摘要：

阿里云涨价34%背后，开源AI框架"小龙虾"正掀Token消耗革命。中国主流AI模型的输出定价普遍低于OpenAI GPT-5.4的20%，大多数甚至不足10%。瑞银、巴克莱认为，算力短缺加剧、云服务需求激增、中国企业AI SaaS变现模式呼之欲出，腾讯、阿里、百度等中概核心标的将是最直接的受益者。

阿里云最高涨价34%不过是冰山一角。一场由开源AI智能体框架OpenClaw引发的Token消耗革命，正在以远超市场预期速度重塑中国AI产业格局。

3月18日午间，阿里云官网发布公告，因全球AI需求爆发、供应链涨价，阿里云AI算力、存储等产品最高涨价34%。其中，平头哥真武810E等算力卡产品上涨5%-34%，文件存储产品CPFS（智算版）上涨30%。

调整范围

因全球AI需求爆发、供应链涨价，行业核心硬件采购成本显著上涨。经审慎评估，我们决定将于2026年4月18日起对AI算力、CPFS（智算版）等服务价格进行调整。

调整内容	地域	调整幅度
平头哥真武810E等算力卡相关服务	全地域	上涨5% - 34%
CPFS（智算版）	全地域	上涨30%

官方说辞是“全球AI需求爆发、供应链涨价”，但据知情人士透露，更深层的驱动力是——Token调用量暴涨。阿里云MaaS业务百炼在2026年1月至3月创下历史最高增速，算力资源正被优先向Token业务倾斜。

这场Token风暴的起点，是一款被中国网友亲切唤作“小龙虾”的开源AI Agent框架——OpenClaw。截至2026年3月15日，它已在GitHub上斩获超过31.5万颗星，并在中国互联网江湖掀起了一场史无前例的“ChinaClaw”集体会战。

瑞银和巴克莱17日发布专题研报，两份报告指向同一核心结论：算力短缺加剧、云服务需求激增、企业AI SaaS变现模式呼之欲出，腾讯、阿里、百度等中概核心标的将是最直接的受益者。

"小龙虾"席卷中国：从开发者玩具到全民AI基础设施

OpenClaw的颠覆性在于其架构逻辑——它不是一个在云端回答问题的聊天机器人，而是一个驻扎在即时通讯软件中、能够直接操控电脑执行现实任务的“AI执行者”。

它的生态核心是ClawHub技能平台，这个堪称“AI Agent版App Store”的技能库已积累超过20000个技能，覆盖文件管理、浏览器操作、邮件处理、代码生成等场景。

更关键的是，单个OpenClaw每天可产生数百甚至数千次模型调用，Token消耗量是传统AI聊天应用的数量级倍数。

这一特性直接推动了全球AI模型API市场的急剧扩张：通过API聚合平台OpenRouter的数据显示，近期每周Token使用总量已达约16万亿（16 trillion），相较于2026年1月（OpenClaw发布前）的水平大约翻了三倍。

与欧美市场相比，“小龙虾”在中国的传播呈现出截然不同的形态。欧美市场更多停留在技术开发者群体的小圈子里（技术设置复杂，需要Docker环境和API密钥管理），而中国互联网巨头已迅速将其改造成“一键部署”的云端服务，并批量推向企业和消费市场。

ChinaClaw百花齐放：巨头集体押注，SaaS化变现破茧

从2026年2月底至3月，中国主要互联网公司和AI大模型公司密集推出各自的“Claw”产品。

FIGURE 1. Chinese Claw products

Company	Product	Launch	On top of OpenClaw?	Run on cloud?	Model	Interactions (Product's own platform + chat channels)	Pricing (monthly subscribe + credits add-on)
Tencent	WorkBuddy (for work)	3/9/2026	Y	Hybrid	Hunyuan, DeepSeek, GLM, Kimi, MiniMax...	QQ (Tencent), Wecom (Tencent), Lark (ByteDance), DingTalk (BABA)	RMB 58 per month
Tencent	QClaw (for personal use)	Internal testing	Y	No info	No info	No info	No info
ByteDance	ArkClaw	3/9/2026	Y	Y	Doubao, GLM, Kimi, MiniMax...	Lark (ByteDance) and others	RMB 40/200 per month
Alibaba	JVS Claw	3/13/2026	Y	Hybrid	Qwen	DingTalk (BABA), Wecom (Tencent), Lark (ByteDance)	No info (free now)
Baidu	DuClaw	3/11/2026	Y	Hybrid	Ernie, GLM, DeepSeek, Kimi, MiniMax...	Wecom (Tencent), Lark (ByteDance), DingTalk (BABA) in the future	RMB 142 per month
Zhipu	AutoClaw	3/10/2026	Y	Local	GLM, DeepSeek, Kimi, MiniMax...	Lark (ByteDance) and others	Credits for now, monthly subscription in the future RMB 29/109/249/499
MiniMax	MaxClaw	2/25/2026	Y	Y	MiniMax	QQ (Tencent), Wecom (Tencent), Lark (ByteDance), DingTalk (BABA) Telegram, WhatsApp, Discord, WebSocket	\$19/69/129 per month in the US RMB 39/119 per month in China
Kimi	KimiClaw	2/15/2026	Y	Y	Kimi	Lark (ByteDance) and others	\$38 per month in the US RMB 199 per month in China

Source: Company data, Barclays Research; note Zhipu and Kimi are not covered by Barclays Research


腾讯WorkBuddy上线前已在内部供超过2000名员工使用，重点覆盖HR、行政和运营的数据分析与办公自动化场景。各家产品均支持通过企业微信、钉钉、飞书等主流工作通讯平台调用，直接切入企业工作流。

Token爆炸：数据揭示全球AI需求拐点

OpenClaw的普及，正在引发前所未有的Token消耗革命。


瑞银报告指出，通过API聚合平台OpenRouter监测的全球AI模型周度Token使用量，近几周已达到约16万亿（16 trillion），相较2026年1月（OpenClaw上线前）的水平几乎翻了三倍。

Figure 1: Total weekly token usage via OpenRouter



Source: OpenRouter. Note: The above token usage data refers to all apps usage on OpenRouter, including OpenClaw, Kilo Code, Claude Code, etc.

Figure 2: MiniMax's tokens processed (bn), and market share by token usage



Source: OpenRouter. Note: The above data is as of 8 March 2026.

这种爆炸性增长的底层逻辑清晰：相比普通AI聊天工具，使用Claw智能体所产生的Token消耗量要高出一个数量级——单个OpenClaw每天可产生数百乃至数千次模型调用，带来的Token量远超标准聊天场景。

中国模型是这场Token盛宴的最大受益方。据OpenRouter截至2026年3月9日的过去一个月数据：

MiniMax M2.5：Token使用量达7.5万亿，位居全球第一；

Kimi K2.5：4.2万亿，位居第二；



DeepSeek V3.2: 3.3万亿;

GLM-5: 2.2万亿;

从厂商自身数据来看，增速同样触目惊心：MiniMax披露，2026年2月其M2系列文本模型日均Token消耗量较2025年12月暴增超过6倍，其中编程计划（coding plan）的Token消耗更猛增10倍以上。MiniMax M2.5于2026年2月11日发布，12小时内即登上OpenRouter人气榜榜首，发布后一周内单周Token使用量即跳升至3万亿，超过Kimi K2.5、GLM-5和DeepSeek V3.2三家之和。

月之暗面（Kimi）的数据更为惊人：Kimi K2.5在2026年1月底发布后，20天内的营收超过了2025年全年，且海外营收高于国内。在此基础上，OpenClaw还将Kimi K2.5指定为其第一个官方免费核心模型。

中国模型的成本"核武器"：定价不足美国同类的10%

Token消耗量爆炸，叠加中国AI模型远低于美国同类产品的定价，正在重塑全球开发者的模型选择逻辑。

据巴克莱研究数据（截至2026年3月9日），中国主流AI模型的输出定价普遍低于OpenAI GPT-5.4的20%，大多数甚至不足10%：

FIGURE 7. Recent model update

					Prices per mn tokens		Price as of GPT-5.4	
Company	LLM	Launch	Open-source	Parameter	Input	Output	Input	Output
West:								
OpenAI	GPT 5.4	3/5/2026	N	/	\$2.50	\$15.00	100%	100%
Google	Gemini 3.1 Pro	2/19/2026	N	/	\$2.00	\$12.00	80%	80%
xAI	Grok 4.2 Beta	2/18/2026						
Anthropic	Claude sonnet 4.6	2/17/2026	N	/	\$3.00	\$15.00	120%	100%
Anthropic	Claude opus 4.6	2/5/2026	N	/	\$5.00	\$25.00	200%	167%
OpenAI	GPT-5.2	12/11/2025	N	/	\$1.75	\$14.00	70%	93%
Google	Gemini-3.0-Pro	11/18/2025	N	/	\$2.00	\$12.00	80%	80%
East:								
Alibaba	Qwen3.5	2/16/2026	Y	397bn 17bn activated	\$0.11	\$0.69	5%	5%
ByteDance	Doubao-Seed-2.0 Pro	2/14/2026	N	1trn MoE	\$0.46	\$2.29	18%	15%
ByteDance	Doubao-Seed-2.0 Lite	2/14/2026	N	/	\$0.09	\$0.51	3%	3%
Zhipu	GLM-5.0	2/11/2026	Y	744bn 40bn activated	\$0.57	\$2.57	23%	17%
Minimax	Minimax-M2.5	2/11/2026	Y	230bn 10bn activated	\$0.30	\$1.20	12%	8%
Moonshot AI	Kimi-K2.5	1/27/2026	Y	1trn 32bn activated	\$0.10	\$3.00	4%	20%
Alibaba	Qwen3-Max-Thinking	1/26/2026	N	1trn MoE	\$0.36	\$1.43	14%	10%
Zhipu	GLM-4.7	12/23/2025	Y	355bn 32bn activated	\$0.43	\$2.00	17%	13%
Minimax	Minimax-M2.1	12/23/2025	Y	230bn 10bn activated	\$0.30	\$1.20	12%	8%
ByteDance	Doubao-Seed-1.8	12/18/2025	N	/	\$0.11	\$1.14	5%	8%
Tencent	HY-2.0-Think	12/5/2025	N	400bn 30bn activated	\$0.14	\$0.57	6%	4%
DeepSeek	DeepSeek-V3.2	12/1/2025	Y	671bn 37bn activated	\$0.28	\$0.42	11%	3%

以MiniMax M2.5为例，以每秒100个Token的输出速率持续运行一小时，成本仅约1美元，仅为Claude Sonnet同等使用成本的1/10至1/20。这一价格优势意味着：即便用户最初使用Claude或GPT搭建自己的Claw智能体，当美国前沿模型的使用成本变得难以承受时，可以轻松切换至中国大模型以控制成本。

值得关注的是，尽管大幅降价，中国AI厂商的推理毛利率仍在持续改善。



MiniMax披露，其单位Token推理成本从2025年12月至2026年2月已降低逾50%，同期定价保持不变。瑞银调研显示，智谱和MiniMax的API及企业AI部署毛利率约为60%-70%，主要来自推理业务。

从"免费"到"订阅"：中国SaaS觉醒时刻

ChinaClaw最令资本市场兴奋的，或许不仅仅是Token消耗量的暴增，而是它正在撬开中国SaaS化货币化的历史性大门。

长期以来，中国消费级AI聊天产品几乎全部免费。而ChinaClaw的推出，将订阅制收费模式引入了普通用户和企业市场——月费普遍定价在每月40至500元人民币之间，并附带按量付费的点数套餐。

巴克莱研究将这一现象定性为"中国的SaaS时刻"——中国从未拥有真正意义上的SaaS产业，借助AI和ChinaClaw的浪潮，有望直接跨越，进入AI驱动的生产力订阅服务新时代。

算力短缺加剧，谁是最确定的受益标的？

算力供需矛盾在ChinaClaw浪潮的冲击下正在急剧恶化。

巴克莱渠道调研显示，腾讯和百度均在考虑上调Token价格，而阿里云的涨价已率先落地。更严峻的算力短缺，意味着更大规模的资本开支（Capex）投入不可避免。

综合瑞银与巴克莱的分析框架，"小龙虾"狂潮对中国AI产业链的影响可从三个层次拆解：

基础设施层：受益最为确定

阿里巴巴：国内最大云厂商，具备全栈AI能力。随着AI算力短缺骤然加剧，巴克莱预计阿里在业绩发布时将进一步上调资本开支。

金山云：AI工作负载占总收入比例超30%，与多家主要AI实验室建立深度合作；瑞银给予买入评级。

大模型层：Token红利直接变现

中国AI实验室（MiniMax、月之暗面、智谱、DeepSeek等）是Token用量暴增的直接受益者。其成本优势正吸引全球开发者切换至中国模型，尤其在ChinaClaw加速普及、单次任务Token消耗量呈指数级放大的背景下，模型API收入的高速增长逻辑已获数据验证。

应用平台层：SaaS货币化路径最令人期待

腾讯：腾讯QClaw（个人版）+WorkBuddy（企业版）组合覆盖了微信、QQ、企业微信等国内最广泛的即时通讯入口，AI智能体开发执行力持续提升。

百度：百度搜索在ClawHub技能下载榜排名第一，下载量超过36,000次，强劲的搜索原生技能需求正带动云服务合同主动续签。

巴克莱总结认为，AI算力短缺因Claw的出现骤然加剧——不仅因为Claw是全新的AI使用场景，更因为这一场景的Token消耗量比普通聊天高出一个数量级。一旦ChinaClaw在中国企业端站稳脚跟，将开辟全新且规模可观的TAM。更值得关注的是，这一货币化机会未必局限于国内——中国AI模型显著的成本优势，有望帮助中国科技公司在欢迎中国AI模型的海外市场展开有力竞争。

以上精彩内容来自[追风交易台](#)。

更详细的解读，包括实时解读、一线研究等内容，请加入 [【追风交易台·年度会员】](#)

追风

RISK CHASE

全球宏观研究 | 交易 | 配置

你 / 不 / 能 / 错 / 过

什么是“追风交易台”

追风交易台由顶流全球宏观资讯及研究团队联手打造。

我们的目标是给中国投资者提供专业、独到和适时的全球金融市场研究。

在这里，你将看到

最专业的解读

来自全球顶尖投行、研究机构、
一线从业者的最新解读



最独到的视角

以全球市场第一线的视角
感知市场动向



最适时的时机

快速、完整、准确
最终汇集成适时



如果你

关心全球宏观经济和资本市场

如果你

苦恼于没有合适的信息和研究



关注“追风交易台”
成为“追风会员”

你将身处全球市场第一线



公众号 · 追风交易台

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时0元领

* 同一用户免费领取一次

扫码

VIP会员·7天畅读卡 | 大师课·入门串讲

免费领取



限免

267 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

4 条评论



见闻用户

1小时前 中国北京

美国人工智能的大腿再断了就真的没后续了

0 回复



见闻用户

2小时前 中国广东省

光环新网，龙头

1 回复



MobileUser2426

2小时前 中国重庆

这玩意风险太大

0 回复



见闻用户

3小时前 中国四川省

网宿科技 CDN内容分发 token卖水最受益的

0 回复

