

摘要：

摩根士丹利报告认为，以OpenClaw为代表的智能体AI将需求从“生成答案”转向“完成任务”， workflows中频繁的工具调用与多步编排使CPU计算量猛增，贡献了主要延迟。同时，由于需频繁共享上下文与卸载KV缓存，DRAM取代HBM成为硬约束瓶颈。这移触发2026年Q2内存价格暴涨，大摩上调SK海力士与三星的盈利预期。

以OpenClaw为代表的智能体AI（Agentic AI）工具，正在将内存市场的需求逻辑推向一个全新范式。据追风交易平台消息，摩根士丹利3月18日发布的最新报告指出：**AI从“思考”跨入“执行”，将令DRAM取代HBM成为AI基础设施中最难突破的芯片瓶颈，内存周期由此迎来远超预期的生命延续。**

渠道调查显示，2026年第二季度服务器DRAM DDR5价格预计环比上涨逾50%，部分中国超大规模云厂商出价更高；DDR4合同价格涨幅预计达40%-50%，NAND企业级SSD报价涨幅料不低于40%-50%。摩根士丹利认为，**当前处于内存上行周期中段，且供应收紧程度超出此前判断——“华尔街的盈利预测将不得不追赶现实”。**

上述判断已直接体现在目标价调整中：SK海力士2026-2027年EPS预测分别上调24%及32%，目标价从110万韩元升至130万韩元，较当前价格隐含43%上行空间；三星电子普通股目标价升至25.1万韩元，两只股票均维持“增持”评级。

摩根士丹利的核心判断是：市场习惯于线性思维，而AI智能层的能力扩张正以指数级速度推进——当AI从“生成答案”转型为“完成任务”，内存需求的量级将随之跃变，而这场转变，才刚刚开始提速。

“做事”比“想事”更耗内存


摩根士丹利报告的逻辑起点，是一句看似简单却蕴含深意的判断：**“做事比想事需要更多DRAM。”**

传统大语言模型（LLM）的工作模式是GPU主导的线性流程：接收提问、批量处理所有输入Token（预填充阶段），再逐Token生成答复（解码阶段），CPU负责将结果转换为文本输出。在这一流程中，GPU算力是决定性瓶颈，DRAM只需配合完成缓存读写即可。

智能体AI的出现彻底改变了这一逻辑。以OpenClaw为例，这款开源自托管AI助手可同时接入WhatsApp、Telegram、Slack、Signal等逾50个消息平台，并拥有浏览器自动化、文件操作、命令行执行、API调用等系统级权限。它不是“回答问题”，而是“完成任务”——搜索网络、读取文档、调用外部工具、执行代码，最终输出一套经多步骤协作生成的行动结果。

这一范式转变的核心技术含义在于：**工作流从单次GPU推理扩展为多步骤的协调、工具调用与编排流程，CPU的计算时间对整体延迟的贡献往往超过GPU。**与此同时，多智能体之间须持续共享上下文、卸载KV缓存（Key-Value Cache）、存储和检索每个中间步骤的结果——内存从算力链条的后端，跃升至核心瓶颈位置。

Exhibit 1: Agentic AI – GPU centric parallel computation shift to CPU complex logic and workflow execution



Source: Morgan Stanley Research

OpenClaw：内存需求的极端放大镜

摩根士丹利对OpenClaw的内存需求进行了详细量化分析，结论是：在这类智能体工具中，DRAM压倒一切，其他硬件约束均退居次位。

该工具有两种截然不同的运行模式：

轻量网关模式（远程调用Claude或GPT-4等外部API）：即便如此，瓶颈已不在GPU或CPU，而在于Node.js运行时对DRAM的占用。实际使用最低需要2GB DRAM，生产级稳定运行建议配置4GB。

本地模型模式（直接在设备上加载运行AI模型）：DRAM与图形HBM成为双重约束。摩根士丹利建议配置32GB系统DRAM；运行70亿至80亿参数模型需额外8GB图形DRAM，130亿至700亿参数模型需16-24GB，Llama 3 70B、Qwen 72B等超大模型则需80GB以上。

报告特别指出：内存不足的后果并非性能下降，而是直接崩溃——JavaScript将抛出“heap out of memory”（堆内存溢出）错误，导致安装失败和运行中断。这一细节深刻揭示了内存在智能体场景下的硬约束属性：内存不足不是慢，而是“死”。

算力瓶颈迁移：从HBM到系统内存


OpenClaw的内存需求特征，是更大范围结构性转变的缩影。

摩根士丹利指出，AI算力瓶颈正在发生系统性迁移：**从算力本身转向数据移动，从HBM转向系统内存（DRAM），整个内存层级架构正从以HBM为中心演变为HBM、DRAM与NVMe NAND SSD相结合的多层结构。**

这一转变的技术推手之一，是长上下文（long context）需求的快速膨胀。KV缓存以线性方式随Token数量增长，且在分散式推理（prefill-decode disaggregation）场景下须通过网络传输，大幅增加了CPU的I/O管理负担。RAG检索、上下文管理等智能体核心操作，均涉及密集内存I/O。


市场层面的印证同样清晰。据摩根士丹利，Intel与AMD近期均确认，高核心数服务器处理器已出现实质性供不应求；AMD EPYC CPU营收占服务器CPU总收入的比例首次超过40%，搭载EPYC的云实例部署YoY增长逾50%。英伟达推出独立销售的Vera CPU，并与Meta达成多年期协议，首次在大规模场景下部署独立CPU以支持个人智能体运营。

Exhibit 6: DRAM Inventory



Source: TrendForce

Exhibit 7: NAND Inventory



Source: TrendForce

价格加速：周期中段，空间犹存


上述结构性转变在价格层面已出现实质性体现。

DRAM方面，2026年二季度服务器DDR5价格已有限量现货交易以环比+50%成交，超大规模云厂商已接受该价格，部分中国云厂商出价更高。2月底，64GB RDIMM合同价已升至910-920美元，较一季度均价800美元高出约20%。LPDDR及消费电子相关DRAM二季度报价涨幅预计至少40%-50%；DDR4合同价预计上涨40%-50%。此前预期降价20%-25%的HBM3E，在ASIC客户续约中已转为上涨中个位数百分比。

NAND方面，企业级SSD二季度定价预计环比涨40%-50%，消费端产品涨幅预计不低于60%，部分情景下eSSD价格可能在二季度再度翻倍。

摩根士丹利认为，YoY价格加速态势持续，当前仍处上行周期中段。一旦市场将盈利预测调整至反映当前空前产能约束的水平，相关标的存在显著修复空间；资本回报的潜在上调，可能进一步支撑超额表现。

Exhibit 8: DRAM Contract Pricing YoY vs. NTM P/B (average for DRAM companies)



Source: TrendForce, FactSet, Morgan Stanley Research
Note: Average DRAM Companies (Micron, Samsung Electronics, SK Hynix)

以上精彩内容来自[追风交易台](#)。

更详细的解读，包括实时解读、一线研究等内容，请加入 [【追风交易台·年度会员】](#)

追风

RISK CHASE

全球宏观研究 | 交易 | 配置

你 / 不 / 能 / 错 / 过

什么是“追风交易台”

追风交易台由顶流全球宏观资讯及研究团队联手打造。

我们的目标是给中国投资者提供专业、独到和适时的全球金融市场研究。

在这里，你将看到

最专业的解读

来自全球顶尖投行、研究机构、
一线从业者的最新解读



最独到的视角

以全球市场第一线的视角
感知市场动向



最适时的时机

快速、完整、准确
最终汇集成适时



如果你

关心全球宏观经济和资本市场

如果你

苦恼于没有合适的信息和研究



关注“追风交易台”
成为“追风会员”

你将身处全球市场第一线

公众号 · 追风交易台

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

138

收藏

分享到:

写评论

请发表您的评论

表情

图片

发表评论