

摘要：

2020年12月，一句“I love you all”后，七块屏幕骤然黑屏——Dario Amodei带着OpenAI核心团队出走，成就了AI史上最戏剧性的决裂。从26页论文到万亿估值的Anthropic，从指控Altman“两面派”到内部直言“OpenAI是邪恶的”，这场信任崩塌重塑AGI竞赛格局。

2020年12月，OpenAI一场全员视频会议的最后几分钟，彻底改变了AI行业的格局。

时任OpenAI政策负责人Jack Clark在聊天框里敲下“我爱你们所有人”，屏幕随即变黑——七名OpenAI核心成员被同时踢出会议，邮箱权限撤销，Slack账号注销，笔记本电脑被远程锁死。这不是意外，而是一场蓄谋已久的决裂的终点。

这七个人，是Dario Amodei带走的。当时他是OpenAI研究副总裁，GPT-2和GPT-3的核心推动者，也是那个在内部写了26页论文、奠定大模型技术路线的人。他离开的原因，不是钱，不是职位，而是他认为OpenAI的管理层——尤其是Sam Altman——根本不能被信任。

9月29日，据《大西洋月刊》记者Kevin Roose历时数年、采访逾150名相关人士后披露，这场决裂的根源，可以追溯到2017年一个被称为“Countries Plan”的内部方案，以及此后三年间不断累积的猜疑、争吵与背叛感。

五年后，那七个人创立的Anthropic，已拥有数千名员工，正与OpenAI并驾齐驱冲向AGI。但Dario和Altman之间的关系，据多名知情人士透露，至今仍是“互相鄙视”。



那份26页的论文，和Amodei的野心

2016年，Dario Amodei从谷歌离职，加入OpenAI。

他戴圆框眼镜，顶着一头棕色卷发，紧张或思考时习惯用手指绕着发卷转。同事们说他是“天才，但固执”。



Dario Amodei 视频截图

他表达观点的方式，是写长文。

2017年，他写了一篇26页的内部文章，题为《计算大团》（Big Blob of Compute）。文章提出：**机器学习本质上是规模的函数——模型越大，越聪明。**

这个判断，直接把OpenAI的研究方向推向了大语言模型（LLM），也为后来的GPT-2和GPT-3奠定了基础。

按理说，Amodei的职业生涯正处于巅峰。他的团队不仅提出了预测模型性能提升的“缩放定律（Scaling Laws）”，还开创了让模型远离有害输出的“基于人类反馈的强化学习（RLHF）”技术。

但他却越来越确信，自己不会留下来开发GPT-4了。

“Countries Plan”：让他彻底寒心的那个方案

Amodei对公司领导层失去了信心。

他认为Sam Altman是一个“两面派的操纵者”，而总裁Greg Brockman则是“贪恋权力且不计后果的”。他反感他们将OpenAI商业化的决定，认为这背离了“不受产生财务回报需求限制”的初衷。

更让他反感的，是内部的派系斗争。

一位曾与Amodei交流的人士透露，Amodei当时认为OpenAI就是“一场闹剧”，是“由缺乏诚信的人掌管”的。这位人士直言：“每天都有新的危机，如果Dario不发一顿绝对的脾气，Sam在24小时内就会做出新的疯狂举动。”

导火索在2017年就已埋下。

当时马斯克正撤出OpenAI，公司急需资金。据五位知情人士透露，Brockman和Ilya Sutskever构思了一个被称为“**国家计划**”（“**Countries Plan**”）的筹资方案：在包括美国及其他大国政府之间举行拍卖，出售OpenAI未来AGI技术的权利。

Brockman和Sutskever的逻辑是：**AGI具有极强的国家安全意义，迟早会被政府从私营企业手中夺走。既然早晚要交出去，为什么不现在卖掉换取发展资金？**

“这听起来就像科技人士在推销一个疯狂的初创公司，他们有一个古怪的计划，最后一步竟然是：我们会让政府来买单。”一位听过该计划陈述的人士回忆。



Amodei惊呆了。他认为，向政府兜售AGI与OpenAI的使命背道而驰。

2017年12月，他给Brockman、Sutskever及其他高管写了一封邮件，措辞直接：

“在我看来，这项计划非但不能减少，反而会加剧军备竞赛，有可能引发人权暴行.....并会破坏OpenAI的道德合法性。”他坚持，OpenAI应该为“造福人类”而优化。

OpenAI发言人后来对《大西洋月刊》表示，公司“曾短暂考虑过是否将OpenAI转变为一个国际合作项目”，但“从未考虑过向任何国家出售AGI”。

这个方案最终因微软入局而搁置。但Dario没有忘记，Brockman和Sutskever曾经认真讨论过一个他认为“道德上令人作呕”的想法。

信任一点点耗尽：暗藏的名单、被否决的收购条款和侃爷事件

在随后的两年里，裂痕不断扩大。Amodei开始记录他认为被Altman误导的时刻。

比如，在GPT-3的私人内测期间，Amodei向Altman索要了一份获批客户名单。Altman发给了他一份。但Amodei随后声称，他发现了另一份更长的获批名单，而Altman对此只字未提。

再比如，在与微软谈判10亿美元投资时，Amodei极力要求保留OpenAI章程中的“合并与协助条款”——即如果出现更安全的AGI项目，OpenAI应停止竞争并协助对方。他坚持微软无权否决OpenAI未来可能的被收购（这是实现合并协助的最可能方式）。

Altman告诉他，微软不同意这个条款。但Amodei坚信，Altman是为了急于达成交易而让步（或者根本没提），然后对他撒谎。

更有一些看似荒诞的商业决策让Amodei无法忍受。2020年，Altman会见说唱歌手Kanye West，并提议让他参与GPT-3内测。当时Kanye刚发布了疑似对着格莱美奖杯小便的视频，精神状态极不稳定。政策总监Jack Clark最终出面扼杀了这个危险的想法。

这些事单独看也许不足以让人辞职。但在Amodei脑海中，它们拼凑出了一个结论：绝不能把AGI这样强大的技术，交到这样的人手里。

“毛绒玩具顾问团”，和一个越来越孤立的安全派小圈子

Amodei的妹妹，Daniela Amodei也对OpenAI感到厌倦。

作为一名曾在政界工作、高情商的管理者，Daniela成为了哥哥技术狂热的补充。但随着她接管更多技术团队，她与管理层的冲突日益增加。



Daniela Amodei 视频截图

有趣的是，Daniela有一套独特的冲突处理机制——毛绒玩具顾问团。

她和董事会成员Holden Karnofsky收集了大量毛绒玩具，并为它们分配了角色：Jinji是一只懒惰的猫，鼓励她取消会议、少干活；粉红熊Maura是一个注重细节的A型管理者；熊猫Beary Bonds则是“慷慨和同理心的守护熊”。她用这种半开玩笑的方式来进行管理角色扮演。

到了2020年，Amodei兄妹开始在OpenAI内部建立自己的核心圈子。

他们建立了私密的Slack频道，满口都是非技术人员听不懂的“安全黑话”。前同事回忆：“Dario当时有个习惯，就是直接说：我们必须做X；这是道德上正确的事情。这就像是赢得任何争论的捷径——‘因为安全’。这让非安全团队非常恼火。”



19年，Amodei一度想放弃，甚至考虑过跳槽DeepMind。但负责缩放定律研究的物理学教授Jared Kaplan提出了一个更具颠覆性的想法：既然理念不合，为什么不带上所有注重安全的人，

自己开家公司？

2020年，GPT-3发布的同一年，Amodei凑齐了7名联合创始人。

在彻底摊牌前，Amodei向Altman提出了一系列留任条件，包括给予安全团队对新产品发布的“一票否决权”。他知道这多半会被拒绝，只希望借此逼迫Altman妥协。

谈判期间，这7个人建立了一个名为“BATNA”的秘密Slack频道——这是一个商学院术语，意为“谈判协议的最佳替代方案”，随时准备走人。

拔掉网线，屏幕骤黑

当确认Altman不会满足要求后，“BATNA”团队聘请了律师，开始谈判被称为“离婚”的条件。

双方达成协议：离职团队可以在几周内挖走想要的员工，换取此后一年内的不挖角承诺；可以带走部分内部研究文件；双方签署互不贬低协议，绝不在公开场合说对方坏话。

2020年12月，决定命运的OpenAI全员线上会议召开。

Altman像往常一样开场，通报研究进展。随后，他把发言权交给了Amodei。

Amodei平静地宣布，他和另外6名领导层将辞职，成立一家专注于安全的AI组织。会议聊天窗口瞬间被震惊的表情符号和感叹号淹没。大家都在猜测：谁来训练GPT-4？谁是我的新经理？

在满屏的错愕中，Jack Clark在聊天框里敲下了最后一句话：“我爱你们所有人。（I love you all.）”

紧接着，一瞬间，这7个人的屏幕全部黑了。



OpenAI直接将他们踢出了会议，撤销了电子邮件和Slack权限，并远程锁死了他们的笔记本电脑。

几个小时后，这批新失业的创始人召开了第一次视频会议。没有电脑、没有GPU、没有数据，甚至公司域名还没定好（原本想叫Sparrow Systems，最后改成了Anthropic）。但他们在屏幕前举杯庆祝，笑得比过去几个月都开心。他们自由了。

万亿估值与无法停止的怨恨



五年过去，现实与初衷开了一个巨大的玩笑。

在2021年Amodei撰写的成立愿景中，他设想的是一家大约50人的小型AI安全研究实验室，并预测构建AGI只需约100亿美元。

2023年夏天，这里还像个繁荣的邪教总部或大学植物实验室。160名痴迷于安全的员工挤在一起吃纯素三明治，用Liquid Death（一款气泡水）的空罐子堆起高高的王座。

但到了2025年冬天，Anthropic已经变成了一个指挥中心。

员工膨胀到数千人，搬进了安保森严的高层建筑。入口处站着十几个魁梧的保镖，训练新版Claude的楼层甚至对内部员工都要求特殊权限。

Amodei成了乘坐包机、有保镖簇拥的科技巨头。他曾经低调内敛，如今却要管理一家史上增长最快的资本巨兽，正冲刺着万亿估值的IPO。

Daniela Amodei将这一切称为“成功的灾难”：“在每一个维度上都充满压力。这让人害怕，因为我们随时可能失去它。这仅仅是商业方面。然后是我们的使命，我们在想，我们不会意外地让事情变得更糟？比如，我们以为自己弄懂了所有关于安全的事情，但真的懂了吗？”

唯一没有改变的，是他们与OpenAI的死敌关系。

据熟悉他们的人透露，Dario和Daniela依然鄙视Altman和Brockman。在Anthropic内部的Slack群里，Dario甚至直言Altman和OpenAI是“邪恶（evil）”的，以至于在2023年OpenAI董事会政变期间，公关高管甚至要求他删除这条消息，怕被泄露。

而在OpenAI这边，员工们私下将Amodei兄妹描述为“渴望权力的美德信号发送者”，指责他们虚伪——表面上警告AI风险，私下里却在加速这场竞赛。

这成了硅谷当下最深刻的黑色幽默：这两拨人都在倾尽算力，训练AI模型要保持善良、同理心与克制；但作为创造者的人类，却始终无法放下对彼此的深仇大恨。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

210 收藏

分享到:

写评论

请发表您的评论



