


摘要：


OpenAI首颗自研推理芯片Jalapeño在能效、吞吐量等核心指标上实测超越英伟达Blackwell，且开发周期远低于行业均值。更深远的意义在于：AI工具深度介入芯片设计本身，形成"AI造芯片、芯片跑AI"的正向飞轮，CUDA的软件护城河正面临结构性挑战。

OpenAI首颗自研芯片Jalapeño横空出世，以令人咋舌的速度颠覆了AI芯片行业的既有格局——这不仅是一次产品发布，更是一个信号：AI正在重塑芯片本身的设计方式。

据[华尔街见闻文章](#)报道，据彭博8月25日报道，OpenAI表示，Jalapeño在单位功耗可处理的AI工作量和响应速度两项关键指标上均领先英伟达GB300。该芯片由OpenAI与Broadcom合作开发，专为AI推理阶段设计，最快将于今年晚些时候投入实际使用。OpenAI芯片负责人Richard Ho表示，Jalapeño在700瓦低功耗下即可实现强劲性能，有助于大幅降低数据中心电力成本。



据半导体研究机构SemiAnalysis披露，这颗芯片从设计启动到完成流片仅历时约16个月，而其中关键的CoWoS封装流片节点完成于2025年11月，距今不过9个月，远低于行业惯常的18至36个月周期。



SemiAnalysis研究人员亲赴OpenAI实验室，使用其自研基准测试套件InferenceX对Jalapeño进行了实测，结论直接：**该芯片在每瓦性能（perf/W）指标上击败了他们此前测试过的所有英伟达、AMD及谷歌芯片。**

更值得关注的是，这一成绩是在Jalapeño尚未启用投机解码、未做预填充与解码分离部署等优化手段的情况下取得的，而参与对比的其他芯片均已开启各自最优配置。

难怪就连著名半导体分析师Dylan Patel也直言，“被掀翻的不只是Blackwell，就连英伟达Rubin芯片也被超越了”！




分析认为，这一结果对英伟达的市场地位构成直接挑战，也令市场重新审视AI芯片竞争格局。


实测数据：Jalapeño在多项关键指标上碾压Blackwell

SemiAnalysis的测试结果显示，Jalapeño在推理效率上的优势相当显著。

在**GPT-OSS 120B模型**上，Jalapeño每秒可输出约1459个Token，而英伟达GB200仅为535个；**端到端延迟**方面，Jalapeño完成一个任务仅需1.65秒，GB300则需接近6秒，差距达3.6倍。在高交互场景下，当GB300被推至其最快解码速度（每秒169个Token）时，Jalapeño的吞吐量是其104.3倍。




在每兆瓦每秒输出Token数这一衡量数据中心能效的核心指标上，Jalapeño在**GPT-OSS模型**上达到约5300万个Token/MW/s，而GB200 NVL72仅约1000万。



SemiAnalysis指出，这一指标本质上等同于每焦耳产生的Token数，直接决定了数据中心的收入天花板——在算力受电力约束的当下，这一维度的优势尤为关键。

从系统级成本来看，据SemiAnalysis将供电、散热、网络全部纳入计算后，Jalapeño每芯片每小时总拥有成本约为1.56美元，与H100的1.55美元几乎持平，而英伟达Vera Rubin则高达3.61美元。



值得注意的是，SemiAnalysis同时提出了若干重要保留意见。

其一，测试所用模型并非当前最前沿的模型，英伟达和AMD已在更大规模模型（如DeepSeek V4 Pro、Kimi K3）上发布了基于AgentX套件的成绩，而Jalapeño尚未完成AgentX测试——该套件更能反映多轮、长上下文等真实生产场景的性能表现。

其二，更公平的比较对象应是同样采用HBM4的英伟达Vera Rubin，而非Blackwell；Vera Rubin的每瓦性能较GB200 NVL72提升约5.4倍，与Jalapeño相比，两者在每Token总拥有成本（TCO）上几乎持平。

其三，Jalapeño目前仍处于工程样片阶段，量产预计要到2027年才逐步爬坡。

AI设计芯片：GPT-Astra与Codex的"飞轮效应"

Jalapeño之所以能以如此惊人的速度完成开发，AI工具的深度介入是核心原因之一。据SemiAnalysis披露，OpenAI在芯片设计过程中大量使用了内部AI模型，其中包括被外界广泛关注的GPT-Astra。

社交平台X用户Andrew Curran援引OpenAI信息指出，GPT-Astra深度参与了Jalapeño的研发全程：

"团队借助Codex与GPT-Astra，在两个月内将三个原本不在Jalapeño量产计划内的开源模型调优至高性能状态。"



Andrew Curran

@AndrewCurran_

显示翻译

GPT-Astra helped develop the Jalapeño chip.

'Supporting each new model family still requires new kernels and model-specific optimizations. Using Codex with GPT-Astra, the team brought three open-weight models that were not part of Jalapeño's original production plan to high performance within two months.'

We used AI to design the chip, and designed the chip so AI could program it


AI played a direct role in Jalapeño's development, enabling the team to move from initial design to tapeout in nine months by exploring implementations, shortening design, measurement, and verification loops, and continuously iterating on model workloads. AI also helped optimize the chip's arithmetic circuits, allowing the team to fit more compute performance into the chip on schedule.

上午3:39 · 2026年8月26日 · 9.8万 查看

这意味着，AI不仅在加速芯片设计本身，还在快速扩展芯片所能支持的模型范围。

SemiAnalysis的数据进一步量化了这一贡献：

AI辅助设计使SIMD单元面积缩减8%，矩阵引擎面积缩减10%，同时在时序和功耗表现上均优于初始版本。



在软件层面，OpenAI使用内部扩展版Codex编写Jalapeño内核，部分内核代码长达约3000行；在最吃性能的注意力机制和MoE模块上，AI生成的代码比人类顶尖工程师的实现快出1.5至1.8倍。

SemiAnalysis对此评价颇为犀利：跑在英伟达GPU上的OpenAI模型（如GPT-5.6 Sol），正被用来设计一颗对CUDA护城河构成真实威胁的芯片——“英伟达自己的GPU正在实时催生自己潜在的接班人”。

In a weird twist of fate, OpenAI models like GPT 5.6 Sol, which currently run on NVIDIA GPUs, have been used to design a chip that poses a real threat to the CUDA moat - NVIDIA's own GPUs are helping usher in their potential successor in real time.

架构解析：为何“通用”反而更快？

外界普遍预设Jalapeño是一颗专为OpenAI自家模型深度定制芯片，但SemiAnalysis的结论恰恰相反：Jalapeño是一颗面向AI推理的通用芯片，能够运行各类模型和工作负载，甚至包括用Codex移植的《毁灭战士》游戏。

在架构层面，Jalapeño的核心设计哲学是“消除固定延迟”。与GPU依赖复杂内存层级不同，Jalapeño将计算核心与HBM切片直接绑定，核心间通过专用高带宽集合网络同步，大幅降低了内存访问延迟。

此外，Jalapeño采用乱序执行（OoO）核心搭配L1缓存，而非其他加速器普遍使用的软件管理暂存器，这使其在小批量、低延迟场景下能够更接近硬件理论峰值。

在内存带宽方面，Jalapeño采用HBM4，实现了15.4TB/s的单封装内存带宽，每瓦HBM带宽达22，而英伟达Rubin为11.1，GB300仅为5.71。

OpenAI Jalapeno Chip Specs									
	FP16 perf	FP8 perf	FP4 perf	HBM capacity	HBM bandwidth	TDP	HBM bw per W	FLOPs per W	perf:bw ratio
H100	0.989 PFLOPS	1.979 PFLOPS	-	80 GB	3.35 TB/s	700W	4.79	2.8	591
H200	0.989 PFLOPS	1.979 PFLOPS	-	141 GB	4.80 TB/s	700W	6.86	2.8	412
M1355X	2.3 PFLOPS	4.6 PFLOPS	9.2 PFLOPS	288 GB	7.987 TB/s	1400W	5.71	6.6	1152
GB200	2.5 PFLOPS	5 PFLOPS	10 PFLOPS	192 GB	8 TB/s	1200W	6.67	8.3	1250
GB300	2.5 PFLOPS	5 PFLOPS	15 PFLOPS	288 GB	8 TB/s	1400W	5.71	10.7	1875
Jalapeno	-	3.4 PFLOPS	13.4 PFLOPS	216 GiB	15.4 TB/s	700W	22	19.1	870
Rubin	4 PFLOPS	17.5 PFLOPS	35 PFLOPS	288 GB	20 TB/s	1800-2300W	11.1 - 8.7	19.4 - 15.2	1750
M450X	10 PFLOPS	20 PFLOPS	40 PFLOPS	432 GB	23.347 TB/s	2500W	7.86	16	2034



SemiAnalysis指出，**Jalapeño的HBM4引脚速度达10Gbps，略高于英伟达Rubin的9.6Gbps，HBM供应商可能为三星。**

值得一提的是，Jalapeño选择不做预填充与解码分离部署（PDD）。SemiAnalysis对此给出了详细解释：

在真实生产环境中，输入输出比例、并发量、缓存命中率等参数持续变化，固定分池会导致全局利用率下降；而同构资源池可以灵活响应流量变化，在延迟敏感型请求和高吞吐批处理之间动态调配。

CUDA护城河：裂缝已现？

SemiAnalysis在报告中抛出了一个颇具分量的判断：CUDA的护城河可能已经死了。

其依据在于软件起步速度的对比。英伟达Rubin的CoWoS流片比Jalapeño早一个月完成，但迄今为止，外界能看到的Rubin公开基准数据仅来自CoreWeave的工程样片，英伟达并未像OpenAI那样开放第三方进入实验室自由测试。SemiAnalysis认为，这反映的不是硬件本身的差距，而是软件成熟度的差距。

从零开始构建软件栈，反而让OpenAI得以摆脱历史包袱，做出更干净的架构决策。OpenAI使用自研内核编程语言Gluon（基于Triton构建）以及内部推理引擎“Teacup”，并借助Codex快速完成内核调优。SemiAnalysis观察到，**在不到两周的时间内，Jalapeño在特定交互速度下的吞吐量提升超过2倍；在8天内，团队将张量并行从TP8扩展至TP32，实现了跨机架的全机柜规模部署。**

不过，SemiAnalysis也明确指出，目前的测试仅覆盖8k1k这一相对简单的工作负载，尚未完成AgentX多轮长上下文测试。在更复杂的智能体工作负载下，路由器、前缀缓存等组件的表现将成为新的考验。

下一步：B0已入厂，10GW版图徐徐展开

Jalapeño的故事远未结束。

据SemiAnalysis披露，目前公开测试所用的均为A0步进样片，而B0步进已进入晶圆厂，**预计在每瓦性能上较A0再提升约25%——B0单颗计算die的MXFP4算力将达13.4 PFLOPs，TDP维持在700W。**

在系统层面，OpenAI与Celestica合作设计了完整的机架方案：**每个ASIC机柜包含128颗Jalapeño芯片，双机柜系统总功耗约160kW，与英伟达GB300双宽机柜相当。**

OAI Jalapeno System (CPU + ASIC Rack)

43		43	
42		42	
41	ToR Ethernet Switch	41	
40	OOB 1Gbe MGMT Switch 02	40	
39	Rack Stiffener	39	OOB 1Gbe MGMT Switch 02
38	2U CPU Tray (2 Turin x86 CPU, 1.5TB RDIMM)	38	1U 33kW Power Shelf (6*6.6kW PSU)
37		37	1U 33kW Power Shelf (6*6.6kW PSU)
36	2U CPU Tray (2 Turin x86 CPU, 1.5TB RDIMM)	36	1U 33kW Power Shelf (6*6.6kW PSU)
35		35	1U 33kW Power Shelf (6*6.6kW PSU)
34	2U CPU Tray (2 Turin x86 CPU, 1.5TB RDIMM)	34	Rack Stiffener
33		33	1U Compute Tray (8 Jalapeno ASICs)
32	2U CPU Tray (2 Turin x86 CPU, 1.5TB RDIMM)	32	1U Compute Tray (8 Jalapeno ASICs)
31		31	1U Compute Tray (8 Jalapeno ASICs)
30	2U CPU Tray (2 Turin x86 CPU, 1.5TB RDIMM)	30	1U Compute Tray (8 Jalapeno ASICs)
29		29	1U Compute Tray (8 Jalapeno ASICs)
28	2U CPU Tray (2 Turin x86 CPU, 1.5TB RDIMM)	28	1U Compute Tray (8 Jalapeno ASICs)
27		27	1U Compute Tray (8 Jalapeno ASICs)
26	2U CPU Tray (2 Turin x86 CPU, 1.5TB RDIMM)	26	1U Compute Tray (8 Jalapeno ASICs)
25		25	2U 204.8T Global Scale Up Switch (2*TH6)
24	2U CPU Tray (2 Turin x86 CPU, 1.5TB RDIMM)	24	
23		23	1U 102.4T Local Scale Up Switch (TH6)
22	Rack Stiffener	22	1U 102.4T Local Scale Up Switch (TH6)
21	2U CPU Tray (2 Turin x86 CPU, 1.5TB RDIMM)	21	1U 102.4T Local Scale Up Switch (TH6)
20		20	1U 102.4T Local Scale Up Switch (TH6)
19	2U CPU Tray (2 Turin x86 CPU, 1.5TB RDIMM)	19	1U 102.4T Local Scale Up Switch (TH6)
18		18	1U 102.4T Local Scale Up Switch (TH6)
17	2U CPU Tray (2 Turin x86 CPU, 1.5TB RDIMM)	17	2U 204.8T Global Scale Up Switch (2*TH6)
16		16	
15	2U CPU Tray (2 Turin x86 CPU, 1.5TB RDIMM)	15	1U Compute Tray (8 Jalapeno ASICs)
14		14	1U Compute Tray (8 Jalapeno ASICs)
13	2U CPU Tray (2 Turin x86 CPU, 1.5TB RDIMM)	13	1U Compute Tray (8 Jalapeno ASICs)
12		12	1U Compute Tray (8 Jalapeno ASICs)
11	2U CPU Tray (2 Turin x86 CPU, 1.5TB RDIMM)	11	1U Compute Tray (8 Jalapeno ASICs)
10		10	1U Compute Tray (8 Jalapeno ASICs)
9	2U CPU Tray (2 Turin x86 CPU, 1.5TB RDIMM)	9	1U Compute Tray (8 Jalapeno ASICs)
8		8	1U Compute Tray (8 Jalapeno ASICs)
7	2U CPU Tray (2 Turin x86 CPU, 1.5TB RDIMM)	7	Rack Stiffener + Drip Tray
6		6	1U 33kW Power Shelf (6*6.6kW PSU)
5	1U 33kW Power Shelf (6*6.6kW PSU)	5	1U 33kW Power Shelf (6*6.6kW PSU)
4	1U 33kW Power Shelf (6*6.6kW PSU)	4	1U 33kW Power Shelf (6*6.6kW PSU)
3	1U 33kW Power Shelf (6*6.6kW PSU)	3	1U 33kW Power Shelf (6*6.6kW PSU)
2	1U 33kW Power Shelf (6*6.6kW PSU)	2	OOB 1Gbe MGMT Switch 01
1	OOB 1Gbe MGMT Switch 01	1	

规模化部署方面，单一扩展网络域最多可连接2048颗Jalapeno XPU，覆盖16个机架。量产方面，SemiAnalysis预计将于2027年逐步爬坡，下一个里程碑目标是100MW部署规模。

更大的战略图景是，OpenAI与Broadcom已签署10GW定制加速器合作协议，这一量级大致相当于十座核电机组的满发功率。

[华尔街见闻文章](#)写道，OpenAI芯片负责人Richard Ho表示，公司已达到能够切实降低基础设施成本的功耗和成本水平，“这只是第一步”。他同时强调，英伟达仍是重要合作伙伴，OpenAI对算力的需求极为庞大，短期内不会放弃现有供应商。

分析人士指出，Jalapeno的意义或许不在于它今天能替代多少英伟达芯片，而在于它证明了一件此前被普遍质疑的事：一家AI公司，用AI工具，在创纪录的时间内，造出了一颗真正具备竞争力的芯片。这个飞轮，已经开始转动。

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

VIP会员·7天畅读卡 | 大师课·入门串讲

免费领取



限免

333

收藏

分享到:



写评论

请发表您的评论




表情



图片

发布评论

2 条评论



正在加载 .

