


摘要：

AI军备竞赛的瓶颈，正从GPU与HBM向更隐蔽的基础设施环节蔓延。匿名分析员@bubbleboi指出，磷化铟光学器件已进入“灾难级”短缺，DRAM/HBM三大厂全面爆满，而真正被低估的下一站，可能是AI数据中心背后的“电网保卫战”——固态变压器与功率半导体。

AI基础设施的军备竞赛正在将供应链压力从芯片本身向外蔓延，覆盖光学器件、电源半导体乃至数据中心外围的电网管理设备。在HBM短缺和算力扩张已被市场广泛定价之后，新一轮供应瓶颈正在更隐蔽的环节悄然成形。

周六，AI圈研究博主Chris Barber与知名匿名分析员@bubbleboi讨论了AI供应链瓶颈与基础设施问题，系统梳理了AI供应链各层级的紧张程度，并点名了多个尚未被市场充分认识的潜在爆发点。



在@bubbleboi的排序中，磷化铟（indium phosphide）相关的激光与光学器件已是“完全的灾难”，DRAM/HBM短缺持续恶化，而电源半导体虽然目前尚不构成瓶颈，却是他最看好的“下一个爆发”方向——尤其是数据中心外围的固态变压器市场。

磷化铟：当前供应链的“灾难级”瓶颈

磷化铟是他措辞最为激烈的一个环节。“磷化铟的情况非常非常非常糟糕，”@bubbleboi表示，“很多人还没意识到有多严重。”

问题的根源在于CPO（共封装光学）技术的推进对激光器提出了更高要求——更高功率意味着更大的芯片面积，更窄的线宽和更好的噪声性能同样推高了对磷化铟晶圆的需求。与此同时，磷化铟的加工链条——从矿石到晶体、再到外延片、最终到激光器印刷——每一个环节都处于严重供不应求的状态。

这一短缺正在重塑光收发器市场的格局。

传统上，每一代收发器（如400G、800G）在初期以EML（磷化铟单片集成调制器）为主，随后逐步向硅光子（SiPho）迁移以降低成本。但这一次，1.6T收发器几乎从一开始就由硅光子主导——原因正是EML供应的严重短缺，以及制造商将产能向利润率更高的连续波（CW）激光器倾斜。

DRAM与HBM：三家寡头全线爆满

内存是@bubbleboi排名第二的供应瓶颈。

他的核心判断是：全球只有三家公司能够生产DRAM——SK Hynix、三星和美光——三家均已满负荷运转，短期内没有新产能上线的可能。

围绕HBM4的技术路线之争，他认为市场过度解读了其中的戏剧性。SK Hynix选择台积电12纳米制程制造HBM4基础芯片，三星使用自研SF4X逻辑节点，而美光坚持沿用内部DRAM制程，导致进度落后。

但他认为这些差异对财务影响有限：“三家都会以相当高的毛利率卖光所有产品，谁在乎呢？”他补充说，即便美光HBM4未能进入英伟达Rubin平台，也可以将产品卖给其他客户，或以高价出售普通DRAM。

他将DRAM和HBM视为同一类别，并表示相比NAND闪存，他更偏好DRAM，原因是NAND更容易出现供过于求的情况。

“电网保卫战”：AI尽头的固态变压器与功率半导体

相较于已经被市场高度关注的算力芯片内部竞争，分析师将最大的“想象空间”留给了数据中心之外的电力交付系统。

AI数据中心对电网构成了前所未有的挑战。当几万到十万张GPU在训练间隙停止计算、进行互联通信时，电网负载会发生剧烈的波动。“这对电网运营商来说是一个‘恶魔般的噩梦’(satanic nightmare)。”

访谈中披露了一个极具戏剧性的细节：

去年PyTorch团队甚至在代码中加入了一个名为“Power Plant No Blow Up（发电厂别爆炸）”的特殊标志。其作用是，当GPU不需要做数学运算时，强迫它以最大速度进行“垃圾计算”。

“假设你的芯片正常运行需要500瓦，不工作时本应降至200瓦。但现在不行，必须全程保持500瓦，因为我们不能让电网运营商生气。”负载的剧烈拉扯会反向传播并破坏电网稳定，这也是许多AI数据中心拿不到电力许可证的核心原因。

为了解决这一痛点，基于碳化硅（SiC）和氮化镓（GaN）等宽禁带材料的“固态变压器”正迎来产业拐点。传统变压器体积庞大且完全是被动器件，交付周期长达12到18个月；而固态变压器虽然昂贵，但可以通过晶体管进行动态“负载调节（Load regulation）”。“你可以动态编程，确保两侧的电流和电压基本一致……电网运营商会更高兴，你也能拿到供电许可。”

分析师预测，这项技术将在未来36个月内起飞，相关功率半导体公司（如Wolfspeed以及部分从光伏逆变器转型的公司）虽然目前处于周期低谷甚至亏损，但在AI电力调节需求的驱动下，具备极大的重估弹性。

逻辑晶圆与先进封装：边际改善，但仍紧张

相比磷化铟和内存，@bubbleboi认为逻辑晶圆的情况在过去六个月有所改善。

台积电产能依然紧张，但三星先进逻辑产线的利用率已从接近零回升，英特尔也开始接受外部客户。

他认为先进封装（CoWoS、EMIB）的紧张程度将低于市场预期，部分原因是英特尔在马来西亚的产能正在扩张，且台积电更倾向于将洁净室空间用于毛利率更高的N3制程。

CPU短缺与另类加速器：被忽视的隐患

@bubbleboi将CPU列为“大问题”，认为其短缺程度超出市场认知。

AMD面临GPU与CPU争夺台积电产能的两难困境，ARM自身没有晶圆配额，而他认为唯一有能力填补缺口的是高通——因为安卓手机需求下滑导致高通在台积电有闲置产能，可以转产数据中心CPU。但他对高通能否成功持怀疑态度，“他们已经失败了三次”。

在另类加速器领域，他对Positron和Cerebras持正面看法，但对Cerebras有明确批评：仍在使用FP16而非FP4是“愚蠢的错误”，IO设计限制了KV缓存卸载能力，且封装良率可能仅在20%至40%之间。

对于Taalas，他认为其将权重硬编码进芯片层的工程设计“非常非常聪明”，可将芯片设计周期从一年以上压缩至两到三个月，且无需HBM或任何先进封装，成本极低。但他对其商业前提持怀疑态度——AI模型权重更新频率极高，而Taalas要求50%至90%的权重固定不变，“我不认为AI公司会接受这个前提”。

最后，当被问及“如果你是黄仁勋，你会试图锁定什么供应链”时，分析师的一句原话为目前的AI硬件竞争做出了注脚：“**他已经锁定了所有东西的产能。**我本来想说光纤，但他已经去跟康宁谈交易了。我认为这个人神（the man is a god），他已经把能锁定的全都锁定了。”

以下是采访问答文字实录（由AI协助翻译）

Chris：三到五年后，哪些替代性加速器可能会承担非常大量的训练或推理任务？

@bubbleboi：训练方面，我认为它们基本上都不行。推理方面，我非常看好Positron和Cerebras，但原因截然不同。还有谁呢？MatX。问题是我没有足够的信息。所以它可能不错，但我对他们一无所知。所以简单回答就是Positron和Cerebras。还有Taalas，我不太相信他们的前提，但这很酷，我有点想为他们宣传一下，因为如果前提成立，那将非常惊人。但我认为AI领域的人不会容忍这个前提。是的，这些是我真正喜欢的三巨头，MatX在旁边，因为我不够了解。我仍在努力让他们同意和我谈谈。

Chris：你不同意的Taalas的前提是固定权重？

@bubbleboi：他们正在做的是使用上层掩模层来烧录权重。一旦你有了权重，就无法更改。鉴于AI模型变化如此之快，比如每两周就有GPT 5.5，然后是5.6。如果你和这些公司工作的人聊聊，模型内部在 constantly 变化。模型末尾有个十六进制数。每隔几周就有更新。权重在不断变化和微调。

Taalas表示他们支持微调。我认为他们的意思是，当前芯片支持对权重进行一些修改，但远未达到你想要的那么多。他们当前的芯片是三分之二硬编码权重，三分之一只是SRAM机器。他们能支持微调的原因是那三分之一是SRAM，你可以更改或微调一部分权重，或者做LoRA之类的事情。他们基本上是在跟客户说，你的模型硬编码越多，运行得就越快，但你需要做出权衡。在理想情况下，有人可以设计一个模型，其中90%的权重是硬编码的（我随便说的数字）。它会运行得超级快。然后10%用于LoRA或更新权重。我不知道是否有大客户会接受这种程度的限制。我认为不会。但Taalas背后的工程实际上非常非常聪明。

他们使用上层掩模层。现在的芯片大概有14层，姑且说是14或15层。他们用上层三分之一中的一层来编程和硬编码权重。所以你想一下，通常芯片设计最少需要三个月，通常更久，然后需要流片，再过五六个月芯片才能回来，然后还得验证。Taalas不得不为他们自己的编译器、验证栈和芯片设计制作了一堆定制EDA工具，他们声称一天之内就能完成一个新模型。最终目标是。目前大概需要一周。所以设计需要一周，然后因为他们只更改上层，其中一层，他们可以储存晶圆。所以如果你去台积电或任何晶圆厂，这在行业里很常见，你可以说，嘿，我希望你们把X数量的晶圆保持在70%的完成度，先别完成最后一部分，因为我們正在做研发之类的。所以Taalas的周转时间比我最初预期的要快得多。新设计需要一周，然后大概两个月。这是我的估计，肯定不是六个月。所以两个月内你就能拿回芯片并运行它。他们声称他们制作了一些非常聪明的Verilog编译器工具和线程仿真工具，与标准EDA工具对接，以很好地验证一切。所以后硅验证应该没问题，因为芯片的基础设施已经验证过了，你只是改变权重。他们把原本至少一年的流程从开始到结束，理论上缩短到了两三个月，这还不错。

从模型架构的角度来看，我更像一个硬件人。我不太懂模型架构。我努力想弄明白，好吧，如何实现大部分权重固定，只改变一部分权重，比如单层中的权重之类的。然后我发现了LoRA，我问了那些真正懂AI的人，他们告诉我，哦不，LoRA不能扩展之类的。这很蠢。只有失败者才用LoRA。但如果前提确实成立，如果他们找到一个愿意使用LoRA或其他算法的客户，其中很大一部分权重是固定的，并且我们会 constantly 服务这个模型，这样才经济，那么Taalas的经济效益将是惊人的。芯片非常便宜。它不需要任何HBM或任何类型的内存。不需要任何类型的先进封装。即使是PCB，他们在芯片到芯片通信上受到延迟限制，完全没有带宽限制。所以他们使用PCIe和CXL，他们目前的主要限制是他们的芯片上没有最新版本的CXL，显然CXL 3.0提供的一些功能会对他们有实质性的帮助。但他们目前也还好。所以你将拥有惊人的、不可思议的性能（在其他任何架构中都不可能实现），而且价格极其便宜。只是有这样一个限制：很大一部分权重，可能在50%到90%之间，需要是固定的，你不能更改它们。要更改它们，你将不得不扔掉所有或大部分芯片，然后等待两到三个月，而新设计的成本大约是25万美元。

拿Taalas的CEO来说。他在一次采访中说，新版本芯片的设计成本“相当于一台H100服务器”。假设你运营一个数据中心，用Taalas芯片服务某个模型，你决定扔掉所有Taalas芯片，因为模型需要更新。所以你必须注销这笔资本支出，付给Taalas额外的30到50万。最坏的情况是，他们在两三个月内为你制造新芯片，然后你部署它们。再说一次，没有内存问题。甚至没有PCB问题。你可以使用低质量的PCB材料，因为它们只是运行非常慢的PCIe。所以这可能行得通。我只是对模型了解不够，看不出它是否真能行得通。

Chris：在堆栈的不同层面中，你认为未来几年哪些最终会面临最严重的供应限制？

@bubbleboi：是的，几乎所有。如果你在一月或二月问我，我会给出截然不同的答案，但现在所有 都受限。

Chris：为什么市场从去年九月左右开始对此疯狂？

@bubbleboi：我不明白这点。有时候市场真的很奇怪，我跟很多对冲基金的人聊，我会说，你们很聪明，为什么现在才意识到这个？很奇怪。

Chris：宏观观点是不是大家都开始明白了，好吧，超大规模企业的资本支出将继续增加，至少绝对值上会增长？

@bubbleboi：是的，宏观情况是人们不断地来回摇摆。我给你举个有趣的例子。有人告诉我，传统能源投资者都在做空Bloom，因为他们觉得，哦，Bloom太贵了，天然气涡轮机更便宜，这是个泡沫。我说，哥们，这是关于通电时间的问题。你们完全错过了重点。

Chris：他们不了解这类客户面临的限制。



@bubbleboi：我知道。你不明白人们为什么选择这个。不是因为更便宜。每兆瓦的经济性可能差很多。但你现在就能拥有它。如果你必须将数据中心项目推迟至少六个月，.....我跟更多专注于AI和半导体的对冲基金聊过，他们说，哦，我们知道其他那些做空Bloom的能源对冲基金。为什么要自寻死路做空这个？金融世界里有很多奇怪的事情。所以我无法解释。

Chris：哪些其他层面最终会成为瓶颈？

@bubbleboi：磷化铟情况非常糟糕。简直不可思议。我不知道很多人会怎么办，但任何与磷化铟相关的事情都真的、真的、真的很糟糕。

磷化铟用于激光器和光学器件，因为硅无法产生光。人们仍然不明白情况有多糟，因为CPO对激光器的噪声性能提出了更高的要求。

Chris：比如Aixtron？

@bubbleboi：哦，是的。所以他们制造用于磷化铟生产的设备。他们某种程度上不是瓶颈，嗯，他们可能是，但他们正在制造更多的机器，而像Lumentum、Coherent和Sumitomo这些公司正在购买这些机器。我做多这些。更像是Lumentum和Coherent的产能问题。衬底领域，AXT、Sumitomo、IQE等等，这些才是瓶颈。

Chris：IQE是什么？

@bubbleboi：有家英国公司，我认为他们做外延。在这个磷化铟制造链中有很多名字。目前基本上都是一场灾难。

Chris：基本上就是没有足够的磷化铟供应全球？

@bubbleboi：是的，嗯，磷化铟矿目前我认为还好。但是将磷化铟加工成晶体，然后制成晶圆，然后在晶圆上做外延，再把激光器印制到晶圆上，所有这些，完全是一场灾难。因为CPO激光器的工作方式需要更高的功率，这意味着你的芯片尺寸必须显著增大，并且它们需要更窄的线宽和更好的噪声性能，这通常意味着你必须增大芯片尺寸。

这也是为什么SiPho和Tower Semi涨上天的部分原因。传统上，收发器世界的工作方式是，从EML开始，它基本上就是一个单一的 monolithic 磷化铟芯片，包含调制器（用于上下摆动光）和连续波激光器，都在同一个磷化铟芯片上。由于物理原因，EML的性能总是优于硅光。通常，在每一代收发器（如400G或800G）推出的一两年后，人们开始转向SiPho以节省成本。你设法让SiPho的性能足够好，然后省钱，因为现在你不再购买大的EML，而是购买一个更小的连续波激光器，然后把它放进SiPho模块里进行调制。

但无论如何，这次SiPho涨上天了，因为每个人都想，等等，EML短缺了，然后那些生产EML的公司也生产CW激光器，他们正将产能重新分配给CW，因为它的利润率更高，需求也更大。所以现在CPO的需求正在扼杀已经严重供应不足的EML供应。现在，1.6T收发器是第一代SiPho几乎从一开始就占据主导地位的产品。我认为在六个月内它就占据了多数份额。我不知道完整的数据，但这完全不同。如果你看看每一代收发器以及SiPho与EML的市场份额对比，这次完全不同。这是因为磷化铟严重短缺。

接下来，我认为是内存，因为没有洁净室产能。有人问我这个问题，也不是完全愚蠢的问题：哦，三星，他们有逻辑晶圆厂和内存晶圆厂，为什么不直接把逻辑生产线重新分配给内存？因为内存晶圆厂在使用的设备、工艺和所有上都完全不同。所以只有三家公司能生产DRAM。它们全部被订满了。短期内不会有新产能上线。

Chris：也就是Hynix、Micron和Samsung？

@bubbleboi：是的，这三家。所以这是第二严重的瓶颈。但人们对此非常清楚。

Chris：这三家内存制造商之间差距大吗？

@bubbleboi：我个人认为这不重要。有很多戏剧性和噪音。供应如此短缺。任何东西都能以80%的毛利率卖光。谁在乎？历史上SK Hynix明显领先，三星则有点自焚。情况非常糟糕。美光大概是第二。现在关于HBM4的 die 速度有很多内幕消息，来自供应链爆料人的各种噪音。基本上对于HBM，在HBM4、3E、3之前的所有HBM，其基础 die（包含许多接口逻辑电路）都是在内部DRAM工艺节点上制造的。这之所以重要，是因为它更便宜，因为DRAM厂商用自己的晶圆厂来制造。但晶体管质量差得多。DRAM是为慢速、微小的晶体管和巨大的电容设计的，而不是为逻辑设计，所以速度受限。

所以到了HBM4，所有人 某种程度上被迫放弃了这个策略。嗯，他们本应放弃这个策略。实际情况是SK Hynix去找了台积电，开始使用12纳米级别的工艺。这比他们用内部DRAM工艺拼凑出来的垃圾要好得多。但仍然是12纳米，不是很好。三星有自己的内部SF4X逻辑节点，不是4纳米，我最多说它能跟台积电N6打平，或者在台积电N6和N7之间。对于它需要做的事情来说相当不错。美光很蠢。他们说，不，我们要用我们自己的内部DRAM工艺。他们有点搬起石头砸自己的脚，耽误了自己。然后有很多 drama，哦不，美光进不了Nvidia Rubin。没人不在乎。他们只会以天价卖出更多的普通DRAM或HBM3E。这些都不重要。这三家公司都将以相当高的价格卖光他们拥有的所有产品。质量差距现在相当接近了。以前三星的HBM3非常差，没人能用。某些人无论什么价格都不会用三星的HBM3，因为有很多功耗问题。它太耗电了。但现在它们都足够接近了，好吧，假设英伟达标准更高，拒绝了美光的HBM4，他们会把HBM4卖给其他人，或者干脆以惊人的毛利率出售普通DRAM。这不会在财务上影响美光。所以这方面幕后有很多 drama，我认为坦率地说很愚蠢。

Chris：当你说内存时，你特指DRAM还是HBM和DRAM？

@bubbleboi：是的，我说DRAM时就把HBM包含在里面了。都是同类的。我把内存分为DRAM和NAND闪存。就这两类。DRAM就是所有不是NAND闪存的内存。

Chris：你说的第三大瓶颈是逻辑晶圆厂？

@bubbleboi：你可以看到英特尔涨上天了，问题正在解决。问题是台积电就是没有足够的产能。他们太保守了。六个月前，三星在先进逻辑上基本上没有利用率，几乎为零。而英特尔只供内部用。现在有外部公司涌入，三星的利用率也变得相当高了。所以有一些弹性空间，逻辑情况在二月份看起来非常糟糕。现在好多了。虽然仍然相当糟糕，但没有恶化。内存和磷化铟在过去六个月恶化了。逻辑有所改善，但仍然相当糟糕，因为建设这些生产线需要很长时间，而且再次强调，只有三个玩家：三星、英特尔、台积电。

Chris：过去六个月还有哪些瓶颈恶化了？

@bubbleboi：不，主要是那两个类别。我不认为功率半导体情况会变糟，但我认为它们是最有趣的类别，因为电动汽车情况不佳，所以有很多闲置产能。

Chris：你能解释一下功率半导体吗？

@bubbleboi：功率半导体将电力从一种电压转换为另一种电压。你可以这样想。你有一个几千伏交流电的电网。你需要将其转换为较低的交流电，然后最终需要将其转换为直流电压。800伏直流，400伏直流，240伏交流。最终经过几个步骤后，你的高端逻辑芯片消耗大约1.2伏左右。更准确地说，每个高端逻辑芯片，那些3纳米的芯片，标准电压大约是0.75伏。还有一些高压侧电压，比如1.1伏或1.5伏。所以你必须从非常高的电压降到芯片所需的低得多的电压。因此需要多个转换阶段。有些材料叫宽禁带材料，碳化硅和氮化镓，由于物理原因，它们比硅好得多。

Chris：效率更高，所以节省能源成本，并且需要更少的冷却？

@bubbleboi：是的，没错。效率更高。而且能承受更高的电压。你试着把硅芯片放在同样的位置，它会烧掉，会自毁。

Chris：在你提到的公司中，TI、Navitas、onsemi、Infineon，你最喜欢哪个？

@bubbleboi：嗯，这周末我会发帖。快写完了。目前在氮化镓领域，TI和Navitas并列第一，Infineon远远落后第二。onsemi声称他们有很厉害的东西叫垂直氮化镓。但只是幻灯片。没有数据表，没有实际规格。只是说，我们做了个东西，它会有这些惊人的数字。好吧，当然。所以onsemi，也许他们有东西，也许没有。在碳化硅方面我还没搞清楚，还需要几天。但碳化硅方面一个有趣的玩家是，它是一个 meme 股票，但也不是 meme 股票。那就是Wolfspeed。

Chris：给我讲讲Wolfspeed。

@bubbleboi：他们 massively 过度建设了产能。他们是纯碳化硅公司，并且垂直整合。他们制造晶圆、衬底，他们制造器件，所有 都在内部完成。

Chris：顺便问一下：对冲基金找你，只想听听你对某些事情的看法，你这样做是因为好玩，这样你也能了解他们问什么问题？

@bubbleboi：我也在学习。我了解到这些人的思维方式。因为我只是个小人儿。我不影响市场。这些人才影响市场。他们也分享想法。特别是Wolfspeed，就是从一次对冲基金谈话中得知的。

Chris：Wolfspeed是从对冲基金谈话中得知的？

@bubbleboi：那是从五个来源来的。这是一只非常有趣的股票。他们是垂直整合的，100%美国本土。他们过度建设了碳化硅产能，然后被中国竞争和电动汽车 downturn 打击了。他们真的破产了，第11章破产。他们不久前才从第11章破产中走出来，我想大概是四个月前。我得查一下。但确实是很近期的事。因为你的供应商破产了，所有人 停止从他们那里购买。所以他们的工厂利用率据称只有30%左右。非常非常低。现在他们回来了。问题是，如果市场有所好转，这只股票能涨5倍。杠杆率太高，太疯狂了。但它刚刚破产。而且它的毛利率是负的。你可以看他们最新的财报。他们的毛利率是负20%。他们的指引是，我们预计毛利率将继续为负。他们 literally 每生产一颗芯片就亏钱，因为产能利用率太低了。

现在有趣的是，也是人们一直找我的原因，是Wolfspeed推出了这个10千伏的碳化硅芯片。这些芯片 literally 就是一个晶体管，一个必须承受 insane 电压和电流水平的超级、超级强壮的晶体管。目前市场上额定电压最高的碳化硅晶体管在1700到2000伏范围内。Infineon有一个3.3千伏的器件。除了Wolfspeed，没有人有高于这个的。Wolfspeed说，哦，我们可以做一个10千伏的器件。我看着这个数据表，这东西简直是 insane。我不知道他们到底是怎么做到的。而且不是一眼就能看出，它到底是更好还是更差？因为晶体管只是开关，理想情况下，当你打开晶体管时，你希望它是一个完美的开关，没有电阻。但这从来都不是真的。总会有一些寄生电阻。所以当晶体管导通时，它就像一个微小的电阻（这是过度简化了）。我看着这个Wolfspeed器件的寄生电阻，以及损害开关速度的寄生栅极电容，并将其与竞争对手完全不同的器件，比如2000伏和3000伏的器件进行比较。寄生参数更差，但你只需要一个这样的器件，而不是三个。我不得不查看一些电路仿真来弄清楚。我认为这个10千伏的器件实际上相当不错。它将用于基础设施。在数据中心里完全没用。当我告诉这些基金的人时，他们说，哦不，它在数据中心没用。我说，兄弟，你错过了大局。固态变压器。你需要为高压交流电和数据中心之间的电网提供负载调节。

所以我更看好位于数据中心外部的电力输送，而不是数据中心内部的。我觉得每个人都在关注谁会在英伟达设计和OCP设计的电源架中胜出，物理上位于数据中心内部。这是个有吸引力的机



会。但位于数据中心外部、介于数据中心和电网之间的东西，也非常有趣。事实上，可以说更有趣。所以是的，我喜欢功率半导体。我认为这将是下一个爆发并成为瓶颈的东西。它不会成为主要瓶颈，因为电动汽车基本上不行了，所以有很多闲置产能。但它是最令人兴奋的，因为情况将会发生变化。

Chris：你更看好数据中心外部的电力输送，而不是内部的？

@bubbleboi：你有没有开车经过看到变电站附近那些圆形的东西，还有那些大箱子？那些是传统的变压器。它们的工作原理是，你有一个巨大的铁芯，然后一侧绕着一堆铜线圈，另一侧也绕着一堆铜线圈。这些基本上是无源器件，你可以将比如100千伏的交流电转换为35千伏的交流电，然后将35千伏的交流电转换为7千伏的交流电，然后再将其转换为240伏、120伏的交流电进入你家。或者转换为2000千伏的交流电供给工业用户，用于长距离输电。你想要极高的电压以减少电力损耗。但要实际使用它，你必须用变压器降压。这些变压器通常是被动的、笨重的东西，它们很糟糕，因为购买它们需要很长时间。你现在下一个订单（这还是在AI热潮之前），然后12到18个月后他们才会给你，因为它就是一大块金属。制造它需要很长时间。

我认为人们不理解的是，他们在AI数据中心方面遇到了一个大问题。想想看，假设你在电力公司工作，比如PG&E。你有新客户接入你的电网，你必须管理他们，他们的负载在剧烈地上下波动。这些客户会说，哦，我们现在需要一千兆瓦。然后五分钟之后，不，实际上我们只需要八百兆瓦。这对电网运营商来说简直是恶魔般的噩梦。我不知道你有没有看到，去年推特上流传，PyTorch团队添加了一个特殊的标志，叫做“电厂别爆炸”。这是个有趣的事情。那么这个标志是做什么的？当时发生的问题是，你有很多GPU，1万个，10万个。它们在为训练做大量计算，然后其中一些要么停止计算，要么以低得多的速率计算，因为它们在进行互联、互相通信、全归约等等。这导致了电网的不稳定。电网运营商说，无论你在做什么，停下来，否则我们就要切断你的连接。这很危险。你们在破坏电网。所以PyTorch中这个标志的作用是，如果GPU不需要做计算，也强制它以最大速度进行计算。就让它做垃圾计算，然后把垃圾结果发到 nowhere。假设你的芯片运行在500瓦。正常情况下，如果不工作，你会希望它降到200瓦。但在这里，不，我们不希望它降到200瓦。让它一直保持在500瓦，因为我们不希望电网运营商对我们发火。电网运营商生气的原因是，如果你考虑一个电力系统，当你有这些无源组件，这些无源变压器时，任何对负载的推拉都会反向传播到电网，使其不稳定。这在过去还好，因为电网人员会管理这些事情，并且有一些稳定电网的变通方法。但现在情况不再是这样了。

我们刚谈到了普通变压器。现在有固态变压器。我不知道为什么叫固态变压器，因为以前的变压器也是固态的，它们是无源的。与其用一大块铁和一堆铜线圈，不如用碳化硅芯片构建一些电路，你可以做同样的事情，将高压交流电转换为低压交流电，甚至直接将高压交流电转换为直流电。为什么人们以前不这样做？这东西从2020年就有了。它更贵。你可以尽情抱怨传统变压器，但它们便宜，你等上12个月就能拿到货。固态变压器贵得多，但它们有一个巨大的好处。那就是你可以进行负载调节。你可以动态地编程固态变压器，以确保两侧的电流和电压大致相同。你可以改变开关频率。所以如果负载增加，你可以以更高的频率开关，或者如果负载减少，你就以更低的频率开关。

Chris：他们在固态变压器中使用功率半导体。

@bubbleboi：是的，所以这些是有源器件。它基本上就是一堆晶体管。不再是无源器件，一堆电感、铜线圈和一些二极管，而是晶体管。你通过打开和关闭晶体管来管理电力，不仅仅是转换电力，还要管理它，以便你得到一个干净的800伏，而不是800伏正负20伏之类的。或者输送1000安培，而不是1000安培正负10%。你可以调节它。这非常重要，因为这样你就不用在PyTorch中使用“电厂别爆炸”标志浪费电了，你可以降低GPU功率，你就能获得巨大的效率提升。电网运营商也会对你更满意。很多时候，许可问题，比如你试图建一个数据中心，但许可没批下来，你会想，为什么会这样？这是因为电力公司会说，你会破坏电网稳定。我们不能这样做。然后现在你可以说，好吧，我会安装一些固态变压器，这是我将如何不破坏你的电网的方案。然后电力公司会说，好吧，我把电卖给你，你自己接进去。所以人们通过各种创造性的方式绕过这个瓶颈。但我认为现在是时候做固态变压器并承担成本了，因为价值就在那里。是的，你

为转换电力的那个箱子付了更多钱。但你获得了所有这些好处。我认为这将在明年开始加速。这更像是2027年下半年的故事。但股票的运作方式是，人们会搞明白然后提前买入。股票是 forward looking 的。所以这现在已经开始发生了，我认为在接下来的36个月里它会更加蓬勃发展。

Chris：相比于销售固态变压器的公司，你对功率半导体公司会更兴奋吗？

@bubbleboi：一般来说是的，因为至少我个人投资风格是理解工程，或者至少尝试理解，并且我能找出差异点。我在比较，我能看出谁的芯片比谁的好，谁能收取溢价。那些购买这些芯片并组装成箱子的公司，那里也确实有价值，因为涉及到控制方面。假设这个箱子有一千个非常强大的晶体管。如果没有保护电路和控制，那是极其危险的。你可能会烧毁连接到它的所有东西，产生电压尖峰。所以如何将这功率半导体组合在一起有 careful 的设计考量。这里有两家公司。很多人一直在向我推荐这个，我之前没当回事。然后当第15个人发给我时，我说，好吧，我会读一读的。这两家公司叫SolarEdge和Enphase Energy。它们的历史是为太阳能电池板制造微型逆变器。太阳能电池板部署的问题是，太阳能电池板是直流的，但显然你家是用交流电的，所以你需要将每个太阳能电池板从直流转换为正确的交流电。然后还有很多安全方面的事情，你必须控制它，等等。所以这些公司为家庭太阳能部署做这些微型逆变器。自从家庭太阳能的税收优惠政策变差以来，这些公司彻底完蛋了。你可以看看它们的股价。2021年左右有个泡沫，然后它们跌了90%。它们现在就是垫底的股票。这些公司正在转向固态变压器。他们看到了机会。我还没时间深入研究，但我实际上认为这是靠谱的。这是一个超级愚蠢的想法。但我认为作为股票它实际上会涨。因为他们在这类器件的组装和保护电路方面非常有经验。而且这可以说比他们在太阳能领域做的更容易，因为你不是把它分布在整个屋顶上，你只是把所有东西放在一个盒子里，你可以更容易地进行过流保护。他们甚至有一些差异化的技术。Enphase有一个22纳米的控制ASIC。他们自己设计了22纳米芯片来控制所有这些微型逆变器，因为你需要进行一定程度的计算，并向所有这些模拟部件发送一系列不同的信号。这是一个分布式系统问题。基本上，你必须告诉一万个晶体管它们需要以什么速度开关，然后还要检测故障等等。所以他们有一个控制ASIC，这简化了他们的工作。这是一个真正的竞争优势。

Chris：Delta Electronics怎么样？

@bubbleboi：是的，Delta是大玩家。所以有Delta、Vertiv、Eaton等等所有这些大公司。这是他们的核心业务。这是他们已经做的事。这些股票已经涨了不少。SolarEdge和Enphase有吸引力的地方在于它们已经被遗弃了，没人关注。这些股票，如果成功，能涨5倍。你是想追逐像Vertiv那样已经涨了很多的，还是想追逐这种有点 degenerate 的？所以这很有趣。这不是个坏主意。它可能成功。你想赌一把，就把投资组合的0.5%放进去。当然，为什么不呢。

Chris：对冲基金一般都问你什么？

@bubbleboi：他们通常想听听我对某些事情的看法，因为我的投资记录是公开的，而且我的表现超过了他们所有人，不过请注意，我承担了 insane 级别的风险。这些家伙很多是市场中性的，所以我的表现跟他们比并不公平。但我确实做得相当不错。他们会问我意见之类的事情，很多时候都是技术性问题，因为我对估值一无所知。有时候有新基金问我，哦，你对估值怎么看？难道你不读我写的东西吗？但，是的，工程类问题。例如，Wolfsspeed那个事。他们没人知道这个10千伏的碳化硅芯片到底好不好，以及会用在什么地方。我甚至觉得Wolfsspeed自己也不知道它会怎么用，因为他们把核聚变反应堆电力输送写在了数据表和新闻稿里。我就想，你们这真是扯得太远了。很多时候，公司管理层会告诉这些金融人士一些事情，他们会问，他们说的是真话吗？我会回答是或否，或者情况复杂，你应该追问这些问题。所以主要是技术性的，但不完全是。

Chris：Cerebras，你现在怎么看？

@bubbleboi：我喜欢它。我也有一些 harsh 的批评。Andrew Feldman 显然对此非常清楚。他们用的是FP16，这是个愚蠢的错误。如果他们实现FP4，仅此一项就能获得3到4倍的容量。这



是个容易实现的目标。这只是数字逻辑。他们还需要修复IO以卸载KV缓存。我不接受那种“哦，已经够好了”的论点。这是个糟糕的借口。如果你有机会把你的产品提升10倍，你就应该把它提升10倍。不要满足于平庸。最后，他们的毛利率表明他们的良率非常差。他们公开声称他们在晶圆级别的良率是100%，我相信他们，这意味着他们封装晶圆的良率是糟糕透顶的。大概在20%到40%之间。我不知道为什么这么差，但他们需要解决这个问题。我仍然对他们有批评，更像是我想成为一个积极的投资者。我正在买入他们的一些股票。我不会离开。我持看涨态度，但也很苛刻，因为它本可以好得多。Andrew Feldman 对IO问题持否认态度。我说，不，伙计，别再否认了，快修好它。你可以做得更好。就把产品做得更好。

Chris：你仍然看空 neo clouds 吗？

@bubbleboi：是的，有点。看看CoreWeave上个季度的情况。我认为基本上他们因为所有短缺（光学器件和内存）而面临更高的成本。所有的金融人士都问，你们通过合同把成本转嫁给客户了吗？CoreWeave的CEO试图回答这个问题两次，我完全不知道答案是什么。因为股价下跌了，我猜金融人士解读为，不，他们被坑了。他们签了长期合同，无法转嫁成本。

Chris：对最可能倒闭的 neo clouds 有什么看法？

@bubbleboi：那些小公司。CoreWeave足够大。Oracle足够大。Nebius可能也足够大。我不确定会不会倒闭，但最终会有问题。这里的债务水平。一旦出现 downturn，或者甚至如果加息，今年下半年可能会加息，那将对他们造成严重打击。这只是一个糟糕的生意。还有很多其他很棒的东西可以投资。就去投那些吧。我不明白为什么人们想拥有这些垃圾。

Chris：Terafab？

@bubbleboi：没有足够的信息，除了看起来他们可能在授权Intel 14A工艺。这是我对情况的猜测解读。没有信息。

Chris：CPO的推广会遇到很多问题吗？

@bubbleboi：我不认为会有问题。担心可靠性的人完全错了，并且不懂工程。问题将是磷化铟短缺，那非常非常严重。但部署方面，不，我不相信会有问题。如果你做得对，如果你做足了功课，就不会有问题。实际上它会比收发器更可靠。

Chris：对Amkor有什么看法？

@bubbleboi：没有，我不太关注封装领域的玩家。

Chris：那Ibiden或Unimicron呢？

@bubbleboi：没有，我不知道。没有看法。

Chris：Nokia还是Infinera？

@bubbleboi：哦，是的。它有潜力成为便宜得多的Ciena版本。所以如果你觉得，哇，Ciena涨了很多，估值很高，那么你可以买Nokia，他们也在尝试做同样的事情。所以我认为这是一个真正的价值投资。它是少数几个估值合理的东西之一。我目前没有持有，但我进进出出过，我需要更多时间来考虑。但，是的，我喜欢它。

Chris：你偏好的参与磷化铟的方式是什么？

@bubbleboi：主要是Lumentum。更冒险的做法是AXT，然后半导体设备方面是德国公司AIXTRON。就这三家。



Chris：你认为目前什么被炒作得最厉害？

@bubbleboi：我会说是microLED，因为我认为这是一个骗局。有大约七种microLED的替代方案，而且它们在客观上全都更好。所以，是的，我就是讨厌microLED。

Chris：GE Vernova。

@bubbleboi：我持有不少。我在一个只做多的账户里，大概在170的价位买了很多股。我的平均成本价大概在170到250之间。它已经涨上天了，嗯，我想我永远不会卖这个了。所以，是的，很棒。燃气轮机。我运气好，有人很早就给我透露了消息。他们的护城河质量很高。他们是少数能制造这个的公司之一。但到了这个地步，他们已经完全被订满了，股价也涨了这么多，我不确定股价还能怎么更高。产能从哪里来，或者涨价从哪里来？我不知道。

Chris：从你的只做多投资组合中选几个：Besi、Rigaku、台积电或Fujikura，哪个最令人兴奋？

@bubbleboi：Rigaku。

Chris：那是用于先进封装的X射线？

@bubbleboi：Besi已经涨了很多，所以在现在的价位买入，我不知道。但Rigaku，传统玩家是Camtek和Onto，他们做基于光学的先进封装检测。这些X射线机器传统上用于研发目的。假设你是台积电，你正试图开发你的2纳米节点，在研发部分，你需要真正深入地观察并弄清楚发生了什么，你会买几台这种Rigaku机器，把它们用于研发，然后再也不用了。现在情况已经发展到，由于全环绕栅极晶体管、背面供电以及下一代先进封装更严格的公差，你必须使用这些X射线机器。你用光学就完蛋了。所以Rigaku正从 niche 研发转向生产。Onto知道他们完蛋了，因为他们作为战略合作伙伴收购了Rigaku 27%的股份。基本上，在Rigaku机器上运行的软件就是Onto的软件。所以很多人说，哦，这对Onto是利好。不，不是的。他们知道自己造不出机器，所以就去买了能造机器的公司四分之一的市值，然后顺便卖点软件。所以，就买Rigaku。所以，是的，那是我最喜欢的专业 niche 半导体设备。我喜欢它。

Chris：从你的交易账户中：Tower Semi、Lumentum、Intel、Bloom、Semtech，哪个最令人兴奋？

@bubbleboi：Semtech。绝对是Semtech。其他的已经涨了很多。Semtech，我仍然认为人们没有完全理解他们做什么。

Chris：我非常天真的理解是它让铜线工作得更好？

@bubbleboi：那是真的，但那只是故事的一小部分。他们制造模拟放大器和模拟均衡器。美妙之处在于，这可以用于有源铜缆，可以用于PCB，可以用于线性可插拔光学器件，可以用于传统收发器，可以用于Arista XPO的东西，可以用于近封装光学器件。这他妈的是 所有。不仅仅是铜，是 所有。太棒了。而且他们拥有最高质量的部件。基本上是他们和MACOM之间的双头垄断。Semtech的部件就是更好。我看过数据表。我用过这些东西。所以很多金融人士，他们和一些业务人员做专家电话会议，哦，是的，我们有两个供应商，等等。我说，兄弟，比例是多少？大概是90% Semtech，因为Semtech的部件好得多。所以，是的，Semtech还有很大的上涨空间。这他妈太棒了。它无处不在。不仅仅是铜。

Chris：在不同的细分领域，低、中、高，你认为HBM紧俏程度如何？

@bubbleboi：是的，高。

Chris：硅光、光学器件、CPO。



@bubbleboi：也很高。考虑到Tower的情况。

Chris：Tower发生了什么？

@bubbleboi：人们提前为2027年、2028年的产能付钱给Tower。他们的股票涨了大概15%。那是几十亿美元的市值增长。他们被订光了。

Chris：你认为光学器件中哪个子集最重要？

@bubbleboi：磷化铟部分，激光器。

Chris：先进封装。

@bubbleboi：我不认为那会成为太大的问题，因为英特尔正在大量增加产能。我想英特尔在马来西亚有很多产能。

Chris：对EMIB的看法？

@bubbleboi：是的，EMIB很好。直观上你可以认为EMIB基本上和CoWoS-L是一样的。有一些技术细节，但从设计者的角度来看是一样的。18个月前EMIB的问题是英特尔在设计规则和客户服务方面有点愚蠢，非常糟糕。然后Lip-Bu Tan来了，解雇了一堆人，现在好了。现在人们正在把东西转移到EMIB，因为，第一，台积电没有足够的CoWoS产能，第二，台积电更愿意用他们的洁净室空间来生产60-70%毛利率的N3，而不是用来做CoWoS。所以我认为先进封装的情况，至少相对于其他东西，不会像人们想的那么糟。其他东西会更糟。

Chris：ABF基板。

@bubbleboi：我知道的不够多。

Chris：HBF。

@bubbleboi：我完全不喜欢高带宽闪存。我不认为这是一个好的解决方案，因为它会有耐久性问题。所以我就是不喜欢它。我甚至不想把它看作一个瓶颈。我只是觉得这是个坏主意。如果你要为此类应用使用闪存，那么你需要让它可插拔。如果它是可插拔的，你就不需要堆叠它。你可以把它放在CXL控制器周围，然后放在服务器的某个地方。

Chris：晶圆。

@bubbleboi：磷化铟晶圆，相当糟糕。碳化硅晶圆，不。普通晶圆也不，可能还好。

Chris：PCB。

@bubbleboi：很糟糕。支持200G SerDes的高速、最高质量的材料，是的，非常糟糕。所有人基本上都被订光了。

Chris：那里有偏好的投资标的吗？

@bubbleboi：我交易过TTMI，进进出出，但现在它涨太多了，我不想再碰了。所以，是的，我不知道该投资哪个。还有好多台湾的玩家我不关注。这是我不碰的领域之一。

Chris：电力和变压器。

@bubbleboi：感到兴奋，是的。瓶颈，不是。有很多闲置的晶圆厂产能。但是最兴奋，是的。

Chris：兴奋是因为它在技术上对你来说很有趣？

@bubbleboi：技术上很有趣，而且是下一个会爆发的东西。Lumentum的股票在财报后没涨的一个很大原因，它跌了然后又涨了，是因为Hurlston告诉所有人，好吧，我们未来两年的东西都卖光了，这告诉金融人士，好吧，就 upside 而言不会变得更好了。Wolfspeed有潜力涨5倍。它可能会真的疯狂。然后所有常规的功率半导体公司，Infineon、TI、onsemi、STM，它们都能翻倍。它们能翻倍。这还没有被定价进去。其他的已经被定价了。这个还没有。

Chris：网络交换机。

@bubbleboi：还好。它只是与逻辑晶圆竞争，并且需要一些CoWoS，但不多。还好。

Chris：光纤。

@bubbleboi：目前不太好。有一些问题。我不认为它像其他东西那么糟，所以姑且说是中等吧。特别是保偏光纤。在某些情况下需要的一种更昂贵的类型。

Chris：液冷。

@bubbleboi：还好。我没听说有什么问题。

Chris：组装和测试相关的东西。

@bubbleboi：那可以增加产能。正在增加产能。增加产能不具挑战性。

Chris：CPU。

@bubbleboi：大问题。是的，大问题。英特尔可以在一定程度上增加产能。这就是为什么它的股价涨了这么多。AMD，他们在一定程度上增加了产能，因为他们正在使用他们旧的基于N5的CPU设计，并重新增加那个的产能。但现在他们这样做了，如果CPU情况恶化，他们该怎么办？

如果我是AMD，我想利用我的台积电分配，卖GPU还是CPU？你必须选择。ARM没有晶圆。高通。尽管我讨厌承认，唯一能帮助解决CPU困境的是高通，因为他们在台积电有很多晶圆。

但问题是，高通是唯一有晶圆产能并且可以将其转向CPU的大玩家，因为如果Android继续断崖式下跌，他们仍然在台积电有那些晶圆的订单。他们可以告诉台积电去印制CPU设计来代替。这就是为什么高通涨了这么多，因为人们抱有希望。高通在数据中心CPU上已经失败了三次。这是他们的第三次或第四次尝试。如果他们这次还搞不定，那真的就没希望了。它只需要能用。如果能用，人们会买它，他们会从中赚很多钱，这将拯救公司于Android崩溃和苹果即将到来的诉讼。

Chris：CPU你更看好谁？

@bubbleboi：我更喜欢英特尔做CPU，因为没有什么能让我买高通。但是基金的人问过我，哦，我应该买高通做CPU吗？好吧，如果你想相信这些笨蛋，你可以买。但我不会。但是当然，如果你想投，那就投吧。我承认他们有很多产能，我承认他们有很多产能，而且他们有可能做成。

Chris：DRAM也是高瓶颈？



@bubbleboi：是的，我基本上把DRAM和HBM视为等同。

Chris：硬盘？

@bubbleboi：没有看法。我猜既然NAND短缺，硬盘可能也变得更紧张了。我对此了解不够。

Chris：数据中心厂房？

@bubbleboi：我不跟踪那些东西。没有看法。

Chris：功率半导体对你来说会是高瓶颈吗？

@bubbleboi：不，现在是低。目前还不是瓶颈，但一年后会成为瓶颈。所以这就是它最有趣的地方，因为它有上涨空间。

Chris：NAND。

@bubbleboi：我认为DRAM享有溢价。NAND也和DRAM一样短缺，但我认为NAND更危险，因为它比DRAM更容易出现供应过剩。但，是的，高瓶颈，不过我要说我更偏好DRAM而不是NAND。

Chris：是否有任何模型变化，比如长上下文、更多强化学习、世界模型，你预计会极大地改变硬件需求？

@bubbleboi：我真诚地认为所有人都在朝着更长的上下文长度发展。这其中有经济价值。人们愿意为更长的上下文长度付费。所以这会伤害所有内存，所有。这只是大概的高层次观点。我不太关注模型架构。但从经济方面看，是的，人们想要超长的上下文长度或长序列的token。

Chris：如果你是老黄，你下一步会锁定什么供应？

@bubbleboi：他已经锁定了所有东西的供应。我正想说光纤，然后他就去搞定了Corning的交易。我认为此人如神，他已经锁定了所有。我想他确实做到了。

Chris：哪一家公司你会推荐给你的父母，作为持有10年的投资？

@bubbleboi：英特尔，因为英特尔是一个疯狂的长期持有标的。还有博通、是德科技。SiTime，但也许不是在这个价位。英伟达，显然。台积电。这些都是长期的，可以闭眼买。

Chris：博通，我猜想他们所有的客户都积极希望摆脱对他们的依赖，还是这不是问题？

@bubbleboi：谷歌正在尝试。我告诉你，进展并不顺利。除了Lumentum，另一个磷化铟的大玩家实际上是博通。没多少人知道这个。博通有一个巨大的激光器部门。非常多元化的公司。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 327  收藏

分享到:  

 写评论



请发表您的评论




表情



图片

发布评论

2 条评论



正在加载

