

摘要：

随着OpenAI等基础模型厂商向应用层延伸，传统SaaS的竞争逻辑已被改写，Token消耗呈百倍级增长，推理算力成为新瓶颈。缺乏行业Know-how的垂直Agent，仅靠产品包装和提示词难以形成壁垒，可能被通用模型能力覆盖而退出。

7月20日，2026世界人工智能大会（WAIC）在上海圆满闭幕。

作为AI应用方向的一线从业者，我深切感受到了行业明显的变化之一，“Agent”正在加速走入软件和应用层。

在参展的席位上，从手机、办公软件、开发工具，到营销、客服、医疗和企业管理系统，几乎所有应用都在展示尝试接入Agent，让AI从生成一段内容，走向调用工具、跨越系统并完成任务。

在大会结束后的两天，OpenAI发布企业级Agent平台Presence，将AI直接接入企业的客户服务、销售、账单处理、保险理赔和内部服务流程。OpenAI正在从出售模型能力，进一步进入原本由CRM、客服软件、身份管理和工作流平台占据的企业软件腹地。

与之前软件行业巨震类似，但这次的发布比之前更具像和落地，引起了资本市场的一系列反应，软件行业沿用了数十年的竞争逻辑开始松动。PWorkday、Atlassian、HubSpot、Salesforce和Okta等软件公司股价一度明显下跌，其中HubSpot跌幅超过12%，Atlassian接近12%。

在前几年，大模型公司负责提供智能，应用厂商负责设计界面、连接数据和承载业务流程。现在，模型开始向应用层延伸，试图了解用户意图、拆解任务，并决定接下来调用哪款软件。

市场担心的是，大模型公司开始把推理、数据连接、权限和流程执行打包在一起，直接进入传统SaaS最核心的价值区间。

这意味着，软件的价值正在重新分层。随之而来的，我们会看到产品的交互方式，包括软件的入口、分发机制、商业模式、安全边界和产业权力结构都会被改写。

重新洗牌

Agent开始真正“干活”后，首先被改变的是Token的消耗方式。

从我们今年上半年的观察和实践看，在部分长链、复杂任务中，Agent的Token消耗可能比传统聊天场景高出百倍、千倍，极端情况下还可能达到更高量级。

这不是适用于所有Agent任务的统一行业标准，但它揭示了一个明确趋势：AI应用正在从单次生成走向持续执行，Token也从模型的计费单位，逐渐变成整个Agent系统的基础燃料。

OpenAI在2025年企业AI报告中披露，其企业客户平均每家机构的API推理Token消耗，在一年内增长约320倍。这组数据来自OpenAI自身平台，不能代表全部市场，却从另一个侧面说明，企业正在把更长、更复杂的工作流交给模型。到了2026年4月，OpenAI的API处理规模已经超过每分钟150亿Token。

在这样的背景下，产业端正在发生几大变化：

Token需求快速上升，**首先会改变算力产业的重心**。过去，行业主要讨论训练大模型需要多少GPU；进入Agent阶段后，高频、并发和持续运行的推理需求会变得更加重要。模型不仅要生成答案，还需要在不同步骤之间不断调度大小模型、调用代码和工具，并保存更长的任务状态。

在这一过程中，国产算力的推理性能也在持续优化，国产GPU及AI芯片需求旺盛，部分产品交付趋紧。这也是一个积极信号：随着国产软硬件适配逐步完善，中国开放权重模型有机会更多部署在国产算力上，加快进入企业和行业场景。

其次，在算力之外，显存和内存也会成为Agent扩张中的重要约束。

Agent要处理更长的上下文、更多文件和更复杂的工具返回结果，对HBM、服务器内存和存储的需求都会随之增加。

根据SK海力士7月29日发布的2026年第二季度财报显示，2026年第二季度营收和营业利润均创历史新高，主要受HBM、AI服务器DRAM和企业级SSD需求增长推动。公司预计，Agentic AI将把内存需求从AI专用产品进一步扩展至传统内存市场，并计划在下半年扩大HBM4产量。

不过，半导体扩产有自身周期。晶圆制造、设备导入、良率爬坡和先进封装能力，不会随着Token需求同步增长，扩产也可能带来新的周期风险。

从SK海力士的最新财报来看，尽管业绩创下新高，股价仍一度单日下跌超过17%，反映出市场已经开始担忧新增产能在2027年后集中释放，可能再次造成供给过剩。

未来几年，推理需求能否与GPU、显存和存储供给匹配，将成为Agent产业能否规模化的重要变量。

此外，Token需求快速增长，也会放大闭源模型与开放权重模型之间的竞争。

目前，闭源模型和开放权重模型处于追赶和分化当中。当Agent需要持续调用模型，企业要同时考虑每次调用的价格、部署方式、数据安全和推理效率。闭源模型通常依靠API提供前沿能力，开放权重模型则可以通过私有化部署和自主优化，帮助企业控制长期Token成本。

海外前沿模型在推理、代码和工具调用等方面曾出现较明显的能力跃升；但随着国内开放权重模型持续更新，双方在部分任务上的实际差距正在缩小。模型的规模、训练数据、强化学习、上下文管理和推理工程等，会共同决定最终效果。

比如近期发布的Kimi K3采用2.8万亿参数的混合专家架构，并开放完整模型权重，在长程编程、Agent任务和深度推理等方向进一步提升，也成为国内开放权重模型向前沿能力逼近的代表。

与此同时，**各类“Token工厂”和公共推理服务正在涌现，但服务质量良莠不齐**。一些平台本质上是第三方转售，企业和个人输入的明文数据可能经过中间环节，天然存在中间人窃取和攻击风险。用户需要判断服务方是否真正具备数据隔离、加密和审计能力。

除了推理服务自身的数据安全，智能体获得更强行动能力后，也带来了另一层风险。7月29日，在项新的披露中，OpenAI 表示，其智能体利用已泄露的登录信息，成功访问了至少四个“公开可用的服务”，以完成其疯狂的测试任务。

总体来看，“Token工厂”和公共推理服务等仍有较大的市场空间，但安全会成为关键门槛。



垂直应用重新寻找壁垒

Token需求爆发只是Agent化最先显现的底层变化。随着模型和推理基础设施逐渐成熟，这场变化也在向应用层传导：过去需要垂直应用提供的能力，正在被通用模型逐步吸收。

随着通用模型在代码、工具调用和任务执行等方面持续增强，垂直Agent首先要回答的问题是：自己还有哪些能力无法被基础模型快速覆盖？

从2026年下半年开始，一部分缺乏真正行业壁垒的垂直Agent厂商可能会逐渐退出。

这里的核心逻辑在于，随着AI基础设施厂商不断进入应用层，通用模型在代码、工具调用、知识问答和任务执行等方面的能力会持续补齐，单纯依靠产品包装、提示词和简单流程，很难形成长期壁垒。

但这并不代表垂直能力会被通用模型完全覆盖。

全球各个行业长期积累了大量Know-how、专业知识、SOP、三维工程仿真数据、环境配置和边界规则。基座模型如果在训练阶段没有接触过这些内容，就很难仅凭通用能力完整掌握。

我们团队曾在测试环境中，分别使用国内外模型，在加载和不加载专业Skill的情况下完成分子结构分析任务。结果显示，在部分专业场景中，模型仅依靠通用能力，与加载高质量Skill后的表现仍然存在差距。

一个沉淀了专业知识、行业流程和边界规则的Skill，即使加载在普通模型或较先进模型上，也可能在特定任务中获得更好的结果。

通用模型可以持续吸收公开知识和标准化能力，但比如半导体、制造、化工、医药等行业多年积累的实验数据、生产流程和仿真数据，具有较强的历史积累和不可替代性。企业在使用基座模型时，也需要考虑这些知识和数据会不会在调用过程中，成为下一代模型的训练材料。

基于这个方向，由此也可能会形成一场长期博弈：**闭源模型厂商希望获得更多行业数据和专业知识，进一步增强模型能力；企业则需要思考，如果把核心知识全部无偿交给基座模型，未来自身的竞争壁垒还剩下什么？**

目前，一些企业已经开始使用开放权重模型进行私有化部署，让企业知识与外部模型环境保持隔离。这是一条相对稳妥的路径，但从实际效果看，私有化部署模型与最前沿模型之间，仍可能存在一定能力差距。

企业需要在模型能力、部署成本与知识保护之间作出选择。与此同时，开放权重模型本身的商业模式也可能发生变化。

如果一些先进模型的规模和性能持续提升，在垂直知识、代码和工具调用方面达到生产环境可用的水平，提供方就需要通过订阅、API调用或其他方式覆盖成本。

当前算力和高性能芯片仍然紧缺，模型背后还需要承担电力、GPU、部署和推理优化等持续投入。长期维持大规模免费服务并不容易。因此，**部分的先进开放权重模型未来可能逐渐加强商业化，更多采用付费API，甚至转向闭源服务。**

好的模型值得付费调用，企业积累的专业知识和Skill同样应当被确权，并在被使用时获得收益。



通用模型不断增强之后，垂直应用真正能够保留下来的价值，也将更多来自模型训练阶段没有接触过的行业知识、流程和规则。

Agent经济开始成形

当垂直应用的价值逐渐从界面和通用功能转向专业知识，这些能力也不一定继续以完整应用的形式存在。

Agent经济并不只是“卖Agent”，核心是围绕Agent完成任务所需的模型、算力、数据、工具、专业知识和服务，形成一套新的供给与交易体系。

我们接触到的案例看，一些软件厂商已经开始尝试将原有能力拆成Skill。

虽然Skill是否会成为长期稳定的应用形态，行业内仍有争议，但这并不意味着Skill会消失。一个Skill最终能否留下，取决于它能否提供通用模型难以低成本覆盖的专业价值。

以BraneMatrix推出的UGS平台Ginkley为例。一些BI和数据可视化厂商会把数据分析、图表生成和相关操作封装起来；医疗企业也在探索将专科知识转化为医生能够调用的专业能力。

还有来自个人开发者和专业创作者，内容覆盖比赛分析、行业研究、美妆建议等领域。这些Skill的价值，主要来自开发者积累的专业知识、方法和经验。

未来Agent生态的供给者未必只有软件公司。企业、医生、分析师、设计师和内容创作者，都可能成为专业能力的提供者。

不过，要让Skill成为可持续的应用单元，需要先解决几个最基础的问题。

首先是确权。

平台需要确认Skill由谁创作、知识产权属于谁，以及基于开源项目改编时是否遵守相关协议。现在已经出现过热门Skill被他人重新包装售卖、原作者却没有获得收益的情况。如果作者身份和权利边界无法确认，高价值能力很难形成稳定供给。

其次是知识保护。

很多Skill的核心并不是代码，而是Markdown、提示词、业务规则和长期积累的Know-how。如果这些内容在每次调用中都直接暴露，开发者很容易失去自己的核心资产。

因此，Skill需要一种“可用不可见”的调用机制：用户可以使用一项能力并获得结果，但无法直接查看和复制其内部知识；模型在受控环境中调用Skill，也应尽量减少专业内容向外部暴露。

第三是计费和收益分配。

传统软件主要采用订阅、买断或按席位收费。Skill被不同Agent反复调用后，更可能按照调用次数、Token消耗、任务复杂度或执行结果计费。

在这套体系中，模型提供通用推理能力，Skill提供专业知识，两者都需要被合理定价。平台则需要真实记录调用次数、Token消耗和收入，让能力提供者能够了解自己的Skill如何被使用、获得了多少收益。



第四是分发。

用户未来未必会主动搜索和选择每一个Skill，更多时候可能由Agent根据任务自动调用。平台的推荐、排序和默认选择，将直接影响Skill获得多少调用。

因此，Skill平台不仅需要提供能力入口，还要建立相对透明的分发机制。平台可以帮助用户筛选更合适的能力，但不应让调用量和收益分配完全成为不可解释的黑箱。

最后是安全准入。

Agent、MCP和Skill生态中已经出现提示词注入、恶意代码、模型越狱和第三方资源投毒等风险。一个被污染的Skill，可能在用户没有察觉的情况下读取敏感数据、调用未经授权的工具，甚至把恶意程序带入企业环境。

随着AI获得更多自主行动和系统操作权限，类似的安全担忧也开始从企业应用层面蔓延至前沿模型研发。7月29日，来自OpenAI、Anthropic、Google等近十家AI公司的1100多名员工联名发布公开信，呼吁美国推动国际协调，为前沿AI研发建立必要时可以集体减速的机制。

Skill安全也是如此，不能只依靠传统代码扫描。很多风险隐藏在自然语言、文档、网页、图片和外部工具返回结果中。平台既要检查Skill本身，也要限制它能够访问的数据和权限，并对运行过程进行持续审计。

相比于网络安全，Skill安全更具挑战的基本点在于，传统网络安全的攻击向量（Attack Vectors）在理论上限于确定的规则，而AI安全的攻击空间呈指数级泛滥且不可预测。

因此，Skill的意义不只是把应用做得更轻，还要让专业知识第一次有机会成为可调用、可计量和可交易的数字能力。

未来的Agent体系中，通用模型可能负责理解目标和规划任务，专业Skill补充具体行业能力，底层平台则负责连接、计费和安全。

总之，Agent经济能否真正形成，最终取决于两点：**专业能力能否被可靠调用，以及价值能否回到真正的创造者手中。**

本文来源：[腾讯科技](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

252 收藏

分享到:

写评论



请发表您的评论



表情



图片

发布评论

1 条评论



手机用户6910

VIP会员

12小时前 中国北京

现在算力获取困难，是软件能唯一活下去的时间线，一旦获取到足够算力，软件公司在ai面前就像蝼蚁般被碾压



0



回复

