摘要：

DeepSeek和MiniMax的接连出牌，让Flash不再只是旗舰模型的低价替代品。它正在成为一条独立的竞争赛道：既要足够聪明，也要足够快，还要足够便宜。

Flash模型，正在从旗舰模型的平替，变成一场新的能力竞赛。

曾几何时，大模型最重要的竞争是争夺能力上限，但进入下半年，一些风向变了，行业更关注谁能以更低的成本，把模型能力变成开发者和企业真正用得起的生产力。

10月17日，DeepSeek突然更新V4.1 Flash-1017。几乎前后脚，MiniMax也将M3.1 Flash推向台前。后者此前曾以匿名模型Space Bunny的身份出现在开发者社区，如今终于揭开面纱。

两款模型的接连出现，让国产大模型的Flash赛道有了新的看点。

在最新评测数据中，M3.1 Flash在DeepSWE测试中获得74分，仅次于DeepSeek V4.1 Flash-1017的77分；在金融Agent评测BankerToolBench中，它拿到76.2分，与Claude Opus 5并列第一。与此同时，MiniMax将新模型的输入、输出价格降至上一代M3的一半，缓存读取价格降低约75%。

价格和能力同时向前推进，是这次更新值得关注的地方。

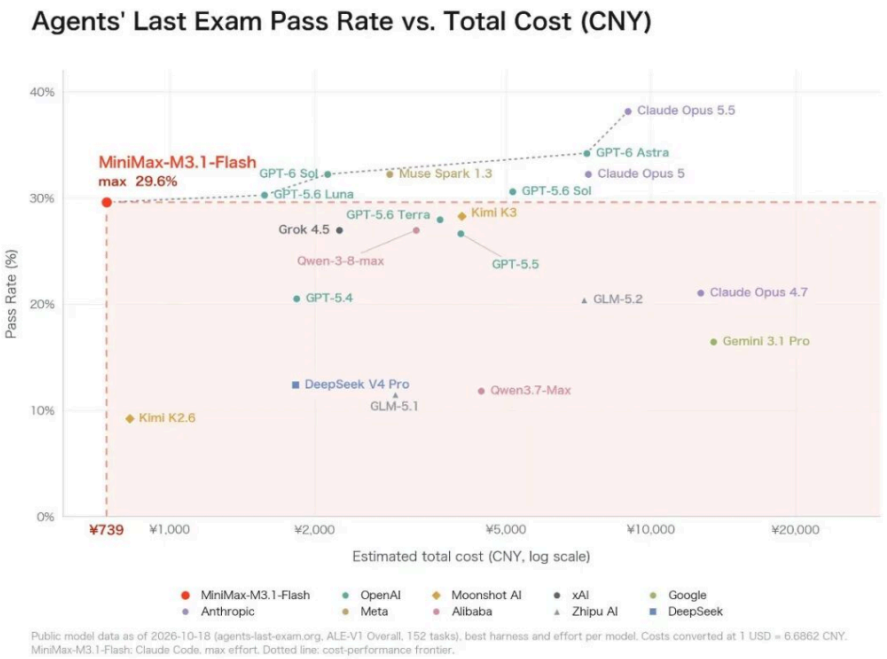
过去，Flash通常意味着一种取舍，牺牲部分能力，换取更快的响应和更低的成本。但DeepSeek与MiniMax接连交出的成绩单，正在挑战这种行业惯性。

Flash段位又来了一位新强手

今晚，MiniMax M3.1 Flash正式发布。这次更新中令人惊喜的是，作为一档Flash模型，模型能力大幅提升。

据MiniMax披露，相比上一代M3，M3.1 Flash在编程、网络安全和复杂Agent任务等方面均有明显进步。在多项评测中，它已经能够与旗舰模型正面较量，部分成绩甚至更高。

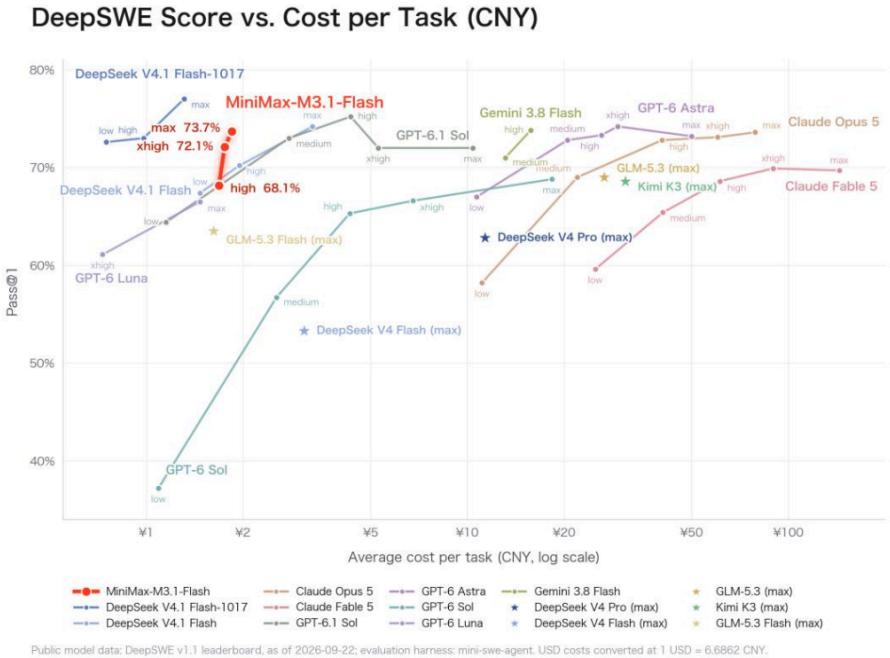
此外，M3.1 Flash 在衡量 AI 电脑操作与跨应用任务执行能力的 OSWorld V2 中取得 61.7 分，在评估真实专业工作场景与复杂任务完成能力的 Agents' Last Exam（ALE） 中取得 29.6 分，均位列国产模型第一。



Public model data as of 2026-10-18 (agents-last-exam.org, ALE-V1 Overall, 152 tasks), best harness and effort per model. Costs converted at 1 USD = 6.6862 CNY.
MiniMax-M3.1-Flash: Claude Code, max effort. Dotted line: cost-performance frontier.

更值得注意的是完成这些任务的成本。M3.1 Flash的通过率高于其他旗舰国产模型，而整套评测运行成本更低。这意味着，Flash模型不仅开始挑战旗舰模型的能力，也在尝试以更低成本完成复杂的专业任务。

在 DeepSWE v1.1 评测中，M3.1 Flash 取得 73.7%的成绩，也明显高于多款旗舰模型。这进一步说明，在特定编程任务评测中，Flash与旗舰模型之间的能力差距，已经不再是不可逾越的鸿沟。



Public model data: DeepSWE v1.1 leaderboard, as of 2026-09-22; evaluation harness: mini-swe-agent. USD costs converted at 1 USD = 6.6862 CNY.

网络安全和复杂Agent任务，则是M3.1 Flash试图进一步打开的空间。

在CyberGym基准测试中，该模型获得82%的高分，与GPT-5.6 Sol的83.6分处于相近区间。CyberGym覆盖188个真实软件项目中的1507个历史漏洞，主要考察模型分析软件漏洞的能力。

		MiniMax M3.1 Flash	DeepSeek -V4.1-Flash-1017	DeepSeek-V4.1-Flash	Kimi-K3	GLM-5.3	GPT-5.6 Sol	Opus 5
CoWork	Automation-Bench v1.0.6	**62.8**	60.5	54.8	46.7	48.8	45.8	50.3
	BankerToolBench	**76.2**	-	73.7	69.1	74.5	74.6	**76.2**
	GDP.pdf AA	20.8	-	12.8	22.0	11.2	**27.2**	21.6
	Terminal Bench 4.0	38.1	42.3	31.2	12.6	37.9	39.9	**51.8**
	LOCA-Bench 256K	**60.3**	-	-	49.7	50.3	60.0	53.7
Computer Use	Agents' Last Exam	29.6	-	-	28.3	-	30.6	**32.2**
	OSWorld 2.0	61.7	-	54.3	58.3	-	65.7	**70.6**
Coding	PostTrain Bench v1.1	39.3	-	30.5	36.6	37.5	36.2	**40.4**
	DeepSWE v1.1	73.7	**77.0**	74.2	67.5	66.9	73.0	74.0
	NL2Repo-Bench	61.2	68.2	65.4	58.0	58.0	56.8	**75.3**
	SWE Refactor Bench	23.0	-	11.8	19.5	10.4	28.5	**31.0**
网络安全	CyberGym	82.2	-	-	80.0	**84.5**	83.6	-
通用能力	BabyVision (w/tools)	91.0	92.5	89.6	85.7	-	88.9	**94.1**
	HLE (w/o tools)	43.4	44.0	39.2	43.5	42.3	49.5	**55.6**
	CharXiv RQ	82.5	-	69.0	84.8	-	**85.2**	83.7

在Automation-Bench v1.0.6中，M3.1 Flash取得62.2分；在BankerToolBench中，它获得76.2分，与Claude Opus 5并列第一。后者聚焦金融场景中的多步骤规划、跨文档一致性、业务合规和复杂工具调用。

这意味着，在编程、金融工具调用和部分企业自动化任务中，轻量化模型也开始具备参与高复杂度工作的能力。

此前，Space Bunny以匿名模型的身份在开发者社区引发关注。它的身份一度引来外界猜测，除了性能，速度也曾是当时众多开发者反馈中最集中的特征之一。随着MiniMax认领这一模型，Space Bunny与M3.1 Flash之间的关联也逐渐清晰。

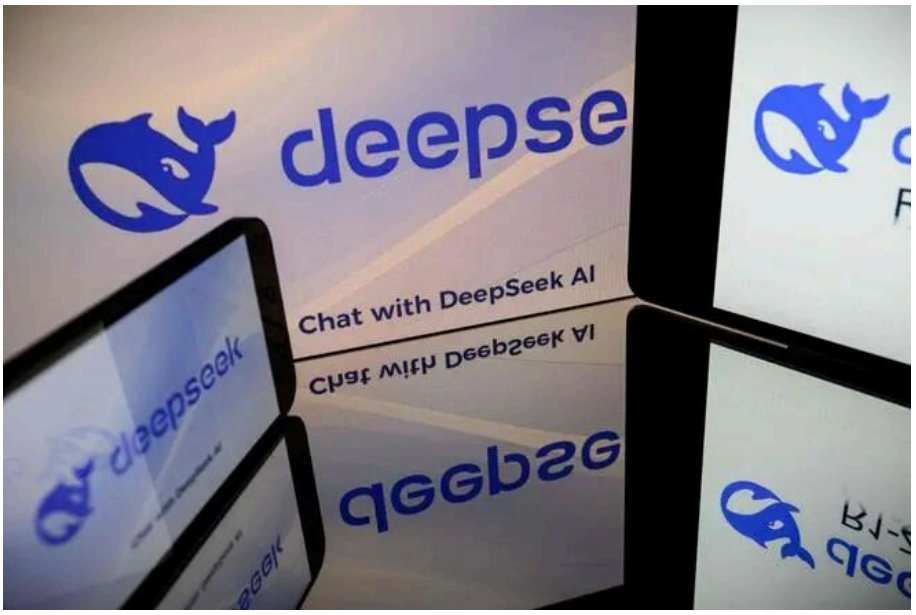
因为使用了更激进的稀疏结构，M3.1 Flash在日常使用场景下的输出速度可达 200+ TPS ，中位数（P50）稳定达到 170+ TPS，即每秒生成170个Token。

对普通用户来说，模型响应快一些，意味着等待时间更短。但对开发者而言，速度的意义远不止于交互体验。

当模型开始承担代码编写、自动化办公、数据处理等连续任务时，响应速度会直接影响工作流的整体效率。尤其在Agent场景中，模型需要反复理解任务、调用工具、读取结果，再决定下一步行动。一次调用节省下来的时间，可能在多轮执行中不断累积。

Flash双子星，性价比双双拉满

MiniMax选择在这个时间点亮出M3.1 Flash，已然和DeepSeek形成“ Flash 双强格局”。



10月17日，DeepSeek更新V4.1 Flash-1017。此前，DeepSeek已经在低成本模型上建立起鲜明的市场认知。此次更新又将编程能力推向前列，进一步强化了Flash模型的竞争力。

MiniMax紧随其后，在杀手锏方面，二者有些许相似之处。

比如，两家厂商均处在相近价格带，直接把性价比拉满。

M3.1 Flash每百万 tokens 的输入费用为 1 元、输出费用为 4 元，缓存读取费用为 0.1 元。与M3（输入 ≤ 512K tokens）对应价格相比，输入和输出单价均降低 50%以上，缓存读取单价降低超 70%。其定价相当于DeepSeek V4.1 Flash-1017高峰期价格的约一半；在缓存命中场景下，两者的价格则基本持平。

不过，另外需要注意的是，DeepSeek存在高峰期与非高峰期的差异，实际成本还会受到缓存命中率、输入输出Token比例以及任务执行轮次影响，不能简单用单一价格推导所有场景的最终成本。

但二者共同掀起的趋势已经相当清晰。

当模型能力接近，价格差异就会改变开发者的选择；当价格进一步下降，过去因为成本太高而无法大规模部署的应用，也可能重新获得商业化机会。

对企业来说，真正重要的不是某个模型在排行榜上高出几分，而是完成同一项任务需要花多少钱、耗费多少时间，以及失败后是否需要反复调用模型。

因此，DeepSeek与MiniMax更像是开发者工具箱中的两个重要选项。它们共同推动的，是模型能力与使用成本之间的重新平衡。

MiniMax的DeepSWE评测中，DeepSeek V4.1 Flash-1017获得77分，M3.1 Flash获得74分，二者差距已经不大。对于以代码生成、代码修改和软件工程任务为主的开发者而言，在MiniMax M3.1 Flash发布后，DeepSeek不再是唯一的性价比标尺。

而在MiniMax的BankerToolBench评测中，M3.1 Flash以76.2分与Claude Opus 5并列第一。结合其在Automation-Bench上的表现，MiniMax的优势更多落在复杂任务规划、工具调用和跨系统工作流上。

他们核心指向也一致，让AI做好一件事，可以有更便宜、更好用的方式。

MiniMax，杀回来了

对MiniMax自身而言，M3.1 Flash的出现还有另一层意义，它提供了一次重新审视MiniMax文本模型能力的机会。

在过去一段时间里，MiniMax在市场上的标签更多与多模态能力联系在一起。相比之下，文本模型的竞争更加残酷。推理、编程、工具调用，每一项都需要长期投入；而当模型能力逐渐接近，价格、速度和实际任务完成率又会成为新的分水岭。

此前的M3并未完全打消外界对MiniMax文本模型能力的疑虑。M3.1 Flash则试图用更具体的成绩回应这些问题。

从评测数据看，新模型相较M3有明显提升，同时延续了较快的输出速度。它在编程、网络安全和复杂Agent任务中的表现，也让MiniMax有机会重新进入文本模型的核心竞争。

对MiniMax来说，接下来更值得关注的，是这种能力提升能否延伸到更广泛的任务场景，以及它能否在保持速度和价格优势的同时，继续提高模型的可靠性。

至于MiniMax能否借此重新确立文本模型的竞争位置，M3.1 Flash更像是一个新的起点，而不是最终答案，在Flash刷新的全新能力下，可以期待下MiniMax Pro模型的发布，至少从此次披露的测评来看，M3.1 Flash 的发布让Minimax 在文本模型竞争中有了更具说服力的筹码。

这场竞争的背景，是大模型行业正在从能力展示走向效率竞争。

当模型的能力足以承担越来越多真实任务，企业关心的就不再只是参数规模和榜单排名，而是完成任务的综合成本。更便宜的Token、更快的响应，以及更少的无效调用，最终都要转化为可衡量的业务收益。

DeepSeek和MiniMax的接连出牌，让Flash不再只是旗舰模型的低价替代品。它正在成为一条独立的竞争赛道：既要足够聪明，也要足够快，还要足够便宜。

国产大模型的下一轮较量，或许不再是谁能把价格压到最低，而是谁能在价格已经足够低的情况下，仍然把复杂的事情做好。

这才是MiniMax重新回到牌桌之后，需要继续回答的问题。

本文来源：凤凰网科技

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

143 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论