摘要：

据DeepSeek介绍，DeepInfer集成高性能算子与优化推理引擎，支持分布式推理、推测解码、结构化输出等能力，并兼容英伟达与华为昇腾平台。基于该框架，DeepSeek已实现DeepSeek V4.1 Flash的高吞吐、低延迟大规模推理服务。

周二下午，DeepSeek宣布全面开源内部推理框架DeepInfer，进一步开放大模型推理基础设施，旨在帮助开发者和企业降低大规模AI服务的算力成本与能源消耗。



DeepSeek 开源推理框架：走向真正普惠的未来

原创 深度求索 DeepSeek 2026年10月20日 16:54 北京

大模型的能力边界由模型本身划定，但如何以合理成本提供超大规模的模型服务，还取决于一个长期未被公众了解的中间层：**推理框架**。

训练使模型学有所成，推理则让模型为人所用。面对如今海量的用户调用，推理框架负责统筹调度庞大的算力集群，其效率直接决定了 AI 服务的算力成本与电力消耗。

DeepSeek 长期致力于将推理性能推向极致。在此前开源一系列大模型、TileLang 编译工具及推理算子库的基础上，我们决定进一步**将内部推理框架 DeepInfer 全面开源**。

「为善与众行之，为巧与众能之。」我们希望通过分享内部的部署经验，帮助开发者与企业组织优化大规模推理的吞吐与延迟，从而高效构建私有化及公有云部署，降低算力成本、减少能源消耗，让智能以更低的价格触达更广泛的人群，实现真正的大模型普惠。我们也将继续支持社区进行大规模部署优化，欢迎加入我们的开源行列。

DeepInfer

基于 DeepInfer，我们已实现 DeepSeek V4.1 Flash 高吞吐、低延迟的大规模推理服务。未来，DeepSeek 新模型的推理代码及后续优化也将在此持续更新。

- **DeepInfer 推理框架**：集成高性能算子与深度优化的推理引擎，支持分布式推理、推测解码、SWA Bounded Replay、结构化输出等能力，兼容英伟达与华为昇腾平台。
- **deepseek-recipe 编解码组件**：同步开源的生产级 Token 编解码组件，与 DeepSeek 官方 API 处理逻辑完整对齐，确保社区获得与官方部署一致的 API 体验。

据DeepSeek介绍，DeepInfer集成高性能算子与优化推理引擎，支持分布式推理、推测解码、结构化输出等能力，并兼容英伟达与华为昇腾平台。基于该框架，**DeepSeek已实现DeepSeek V4.1 Flash的高吞吐、低延迟大规模推理服务。**

DeepSeek还同步开源生产级Token编解码组件deepseek-recipe，确保社区获得与官方部署一致的API体验。未来，DeepSeek新模型的推理代码及后续优化也将在DeepInfer持续更新。

DeepSeek表示，希望通过开放模型、算子库及推理框架，帮助开发者优化推理效率、降低部署成本，推动AI服务以更低成本触达更广泛的用户。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
* 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取



限免

84 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论