



摘要：

两笔约200亿美元交易引爆AI算力重构：英伟达收购Groq补齐推理芯片短板，OpenAI巨资采购并入股Cerebras并参与其IPO。随着AI算力从训练转向推理，芯片架构之争升级为产业控制权争夺，推理基础设施正成为新一轮AI战争核心战场。

2025年12月，英伟达悄悄花了200亿美元买下了一家叫Groq的AI芯片公司。

2026年4月17日，OpenAI宣布将向另一家AI芯片公司Cerebras采购超过200亿美元的芯片。同一天，Cerebras正式向纳斯达克递交IPO文件，目标估值350亿美元。

两笔钱，金额几乎完全相同。一笔是收购，一笔是采购。一笔来自全球最大的AI芯片卖家，一笔来自全球最大的AI买家。

这不是两件独立的事，这是同一场战争里的两个对称动作。战场的名字叫：AI推理。

绝大多数人没注意到这场战争。因为它没有爆炸声，只有一行行财务公告，和硅谷工程师圈子里流传的技术讨论。但它的影响可能比过去两年任何一次AI发布会都要深远——因为它在重新分配一个几乎确定会成为史上最大科技市场的控制权。

推理是什么，为什么2026年的关键词不再是"训练"

在讲两个200亿之前，需要先理解一个背景：AI芯片的战场，正在发生一次重心迁移。

训练和推理，是AI算力消耗的两个阶段。训练是造模型——把海量数据喂给神经网络，让它学会某种能力。这个过程通常只发生一次，或者定期更新。推理是用模型——每次用户发出一个问题，ChatGPT给出一个回答，背后就是一次推理请求。

2023年，全球AI算力支出的大头在训练，推理是配角。

但这个比例正在快速倒置。

根据德勤和CES 2026的市场研究数据，2025年推理已经占到全部AI算力支出的50%；2026年，这个比例将跳到2/3。联想CEO杨元庆在CES上说得更直白：AI支出的结构，将从"80%训练+20%推理"，完全翻转为"20%训练+80%推理"。

逻辑并不复杂。训练是一次性成本，推理是持续性成本。GPT-4训了一次，但每天要回答亿级用户的问题，每一次对话都是一次推理请求。规模化部署之后，推理的累积消耗远超训练。

这意味着什么？意味着AI产业最赚钱的那块蛋糕，正在从"训练芯片"移向"推理芯片"。而这两种芯片，需要截然不同的架构设计。

英伟达的问题：为训练设计的芯片，天生不擅长推理

英伟达的H100、H200，是为训练设计的怪兽。它们的核心优势是极高的计算吞吐量——训练需要对海量矩阵做大量乘法运算，GPU擅长这种"多核并行计算"。

但推理的瓶颈不是计算，是内存带宽。



当用户发出问题，芯片需要把整个模型的权重从内存里“搬”到计算单元里，然后才能生成回答。这个“搬”的过程，才是推理延迟的真正来源。英伟达的GPU用的是外接高带宽内存（HBM），搬运这一步不可避免地引入延迟——对于每秒要处理几千万次请求的ChatGPT来说，这个延迟在乘以规模之后，变成了真实的性能瓶颈。

OpenAI内部工程师注意到这个问题时，他们在给Codex（代码生成工具）做优化，发现无论怎么调参，响应速度都受制于英伟达GPU的架构上限。

换句话说，英伟达在推理端的劣势，不是努力程度的问题，是架构的问题。

Cerebras的WSE-3芯片走了完全不同的路线。这块芯片大到需要用晶圆级封装——面积46,255平方毫米，比人的手掌还大——把90万个AI核心和44GB超高速SRAM内存集成在同一块硅片上。内存直接贴在计算核心旁边，“搬运”的距离从厘米级缩短到微米级。结果：推理速度比英伟达H100快15到20倍。

需要补充的是：英伟达并没有坐以待毙。其最新的Blackwell（B200）架构在推理性能上比H100提升了4倍，正在大规模部署。但Blackwell追的是一个移动的靶——Cerebras同期也在迭代，而整个芯片市场涌现出的竞争对手，已经不只是Cerebras一家。

英伟达的200亿：历史最大并购背后的一张承认书

2025年12月24日，英伟达宣布了它历史上最大的一笔收购。

目标是Groq。

Groq是Cerebras的同类竞争对手，主打的也是为推理优化的SRAM架构芯片——它叫LPU（语言处理单元），当时在公开测评中是全球推理速度最快的芯片服务。英伟达花了200亿美元，把Groq的核心技术和创始团队全部买走，包括创始人Jonathan Ross和多位谷歌TPU团队出身的顶级芯片工程师。

这是英伟达2019年70亿美元收购Mellanox之后，规模最大的一次并购，整整翻了三倍。

在许多分析师看来，这笔钱背后传递的信息，远比金额更重要：英伟达认为自己在推理端有结构性缺口，而且这个缺口大到值得花200亿去堵。

如果英伟达真的相信自己的GPU在推理端无敌，它根本不需要收购Groq。这笔钱本质上是一张价值200亿美元的技术采购单——承认SRAM嵌入式架构在推理场景里有真实的技术优势，承认英伟达靠现有产品线无法自然覆盖这个优势，用最贵的价格买下了一个它自己填不上的技术缺口。

当然，英伟达收购后的官方叙事是另一套——“与Groq深度整合，提供更完整的推理解决方案。”技术语言的翻译版本是：我们意识到自己的东西不够用，所以买了别人的。

OpenAI的200亿：买芯片只是表面，入股才是关键

现在回到OpenAI这边。

2026年1月，OpenAI和Cerebras签了一份100亿美元的三年算力采购协议——当时媒体报道的重点是“OpenAI正在多元化芯片供应商”，语气轻描淡写。

但4月17日最新曝光的细节，让这件事的性质发生了根本变化：



第一，采购金额从100亿变成了200亿，翻了一倍。

第二，OpenAI将获得Cerebras的认股权证，随着采购规模增加，持股比例最高可达Cerebras总股本的10%。

第三，OpenAI还将向Cerebras提供10亿美元的数据中心建设资金——换句话说，OpenAI在帮Cerebras盖厂。

这三个细节放在一起，画出来的图景完全不同：OpenAI不只是在买芯片，OpenAI是在孵化一个供应商。

这个逻辑在科技史上有清晰的先例。2006年苹果开始与三星合作定制A系列芯片，最初也是大宗采购协议，但随着苹果不断加深参与、最终自研M系列芯片，供应链的控制权彻底从英特尔和三星那里转移到苹果自己手上。OpenAI在做的，有几分类似——但有一个重要边界：苹果从一开始就掌握芯片设计权，OpenAI目前仍然是采购者，Cerebras上市后也将独立发展、服务更多客户。这条路的终点未必是OpenAI完全掌控Cerebras，更可能是双方建立深度互依的生态共同体。

一方面用200亿和入股绑定Cerebras，确保非英伟达的推理算力持续供应；另一方面，OpenAI正在与博通合作研发自有ASIC芯片，预计2026年底量产。两条腿同时走，终点是算力自主。

Cerebras今天IPO，你买的是什么

4月17日，Cerebras正式提交纳斯达克IPO申请，目标估值350亿美元，计划融资30亿美元。

这个估值，距离它2025年9月还是81亿美元，涨了四倍多。今年2月刚完成新一轮融资，当时估值已升至230亿美元，IPO目标的350亿在此基础上又溢价了52%。

熟悉Cerebras历史的人知道，这是它第二次尝试上市。第一次，2024年，因为核心客户G42（阿联酋主权科技投资基金）占当年收入的83%~97%，CFIUS以国家安全为由介入审查，IPO被迫撤回。

这次，G42已经从股东名单中消失，取而代之的是OpenAI。

换句话说，Cerebras的客户集中度结构性问题尚未根本解决——大客户的名字换了，依赖大客户的格局还在。投资者要做的判断是：这个大客户是更好还是更糟？从信用角度看，OpenAI显然优于G42；从战略角度看，OpenAI同时也是Cerebras的竞争对手孵化者——它的自研ASIC一旦成熟，对Cerebras是真实的替代威胁。

公平起见，Cerebras也在积极拓展其他客户，招股书预计将列出更多元化的收入来源，集中度会有所改善。但在OpenAI自研芯片量产之前，这个问题的答案还没有揭晓。

买Cerebras的股票，你实际上是在同时押注：OpenAI会持续选择Cerebras，且 OpenAI的自研ASIC不会提前到来。这两条，都不是确定的。

当然，多头理由也是真实的：如果推理市场的规模按预测轨道增长，Cerebras哪怕只在这个市场里占到一个小份额，绝对数字也相当可观。问题不在于Cerebras有没有机会，而在于350亿的定价是否已经反映了最乐观的情形。

两个200亿，对称地出现在2025年底到2026年4月这段时间里。



一个来自全球最大的AI芯片卖家，买下了推理市场竞争对手的技术。

一个来自全球最大的AI买家，孵化了推理市场上挑战英伟达的公司。

英伟达的200亿是防御——它用最贵的价格堵住了一个自己填不上的技术缺口。

OpenAI的200亿是进攻——它在烧钱建设一条不依赖英伟达的推理高速公路，同时拿到了这条路上一个收费站的认股权。

这场战争没有枪声，但资金的流向从来不说谎。两笔钱告诉你的，比任何AI发布会都更清楚：AI推理基础设施的控制权，正在被争夺。而这块市场，2026年将占到全行业算力支出的三分之二。

Cerebras的IPO，是这场战争吹响的号角。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 217  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论