

摘要：

中信建投坚定看好AI产业趋势。K3是本周全球大模型行业的分水岭事件，也是另一个DeepSeek时刻，K3的发布意味着中国大模型第一次以“竞争威胁”身份进入全球大模型叙事。头部和第二梯队模型厂商的竞争均较为激烈，竞争维度已经从模型能力延伸至价格、产品力、场景拓展、成本优化等，认为利好应用层。

**坚定看好AI产业趋势。我们认为，K3是本周全球大模型行业的分水岭事件，也是另一个DeepSeek时刻：**K3的发布意味着中国大模型第一次以“竞争威胁”身份进入全球大模型叙事——2.8 万亿参数 + 100 万上下文 + Code Arena 登顶，证明**国产模型已在Agentic Coding主战场与美国前沿模型正面交锋**。**其他建议重点关注应用层机会：**1) K3提升了开源模型智能水平，应用层使用tier1模型的门槛、成本预计均将降低，利好后续应用场景进一步打开；2) 头部和第二梯队模型厂商的竞争均较为激烈，竞争维度已经从模型能力延伸至价格、产品力、场景拓展、成本优化等，我们认为利好应用层。

1) 国产开源模型在全球大模型叙事中的身位再进一步，K3的入局预计将加剧Tier1模型的竞争。

①**OpenAI、Anthropic动作不断以提升自身模型的吸引力。**本周OpenAI多次重置token额度，优化token消耗，以吸引用户使用，ChatGPTwork周活快速攀升至800万，3天增长200万；Anthropic 7月18日宣布Fable 5将从7月20日起包含在MAX和Team Premium计划，Pro和Team Standard用户将继续通过使用积分访问Fable。

②**本周端侧进展不断：**千问将接入Apple Intelligence，国行苹果AI落地；WAIC上多款AI手机发布，包括第二代豆包手机（努比亚NaviX Ultra）、阶跃星辰STEPX Neo和荣耀Robot Phone；OpenAI发布机械键盘Codex Micro，面向C端的消费级AI硬件——便携无屏音响预计今年底发布，2027年量产上市。

③**Meta&Google本周进展：**Meta拟聘AWS资深高管，向Meta基础设施负责人汇报；洽谈向Anthropic出租算力，两年最高100亿美元。彭博报道Gemini 3.5 Pro发布较原定计划推迟数月：编码性能未达内部标准，谷歌弃用2.5 Pro架构从头重建，未给出新发布日期。

2) 美国Hyperscalers预计7.22开始陆续发布财报，重点关注。

后续关注：

1、Q3模型发布预期：国内GLM 5.3/5.5、DeepSeek V4.1、Minimax M3大参数版本、Hy 4、Qwen 4；海外GPT6、Gemini 3.5等。


**大模型：Kimi K3开源SOTA，进入全球大模型Tier 1，Gemini 3.5 Pro再次跳票；继续关注Q3模型迭代**

Kimi K3于7月17日凌晨发布，是首个达到 2.8 万亿参数规模的开源模型，多项 agentic 榜单超 Claude Fable 5 / GPT-5.6 Sol，是中国大模型第一次以“竞争威胁”身份进入全球大模型叙事。K3基于 KDA 混合线性注意力机制（Kimi Delta Attention）和注意力残差（Attention Residuals）技术构建，1M上下文窗口，面向长程编程、知识工作和推理等前沿智能场景设计。据Code



Arena，以1679分登顶，多项agentic榜单超 Claude Fable 5 / GPT-5.6 Sol。官方坦承 JobBench、Toolathlon、GDPval-AA v2 等复杂职业任务仍有差距。

图 1:中美前沿模型 Code Arena 评分对比：今年显著追赶，K3 登顶



数据来源：Code Arena，中信建投证券

与此同时，谷歌Gemini 3.5 Pro再次跳票。7月16日，彭博报道Gemini 3.5 Pro发布较原定计划推迟数月：编码性能未达内部标准，谷歌弃用2.5 Pro架构从头重建，未给出新发布日期；此前宣布7月17日发布。

商业化：K3定价达到全球第一梯队，头部模型竞争同样加剧；本周端侧进展较快

本周Kimi K3重磅发布，开源模型领域SOTA，显著提价，定价位于全球第一梯队。K3每百万tokens输入/输出 \$3/\$15，较K2.7 Code提价3倍以上，远高于DeepSeek V4 Pro和GLM 5.2；对比海外，与Claude Sonnet 5一致，与GPT-5.6 Terra版基本持平（每百万token输入/输出 \$2.5/\$15）。我们认为：再次印证了模型能力是支撑定价的核心，模型定价分化将继续存在。

图 2:全球主流大模型定价梳理（统一划归为美金）


| 地区 | 厂商        | 旗舰模型                           | 发布时间      | 输入 (\$/M tok) | 输出 (\$/M tok) | 上下文  | 备注                                                                             |
|----|-----------|--------------------------------|-----------|---------------|---------------|------|--------------------------------------------------------------------------------|
| 国内 | 腾讯        | Hy 3 正式版                       | 2026/7/6  | \$0.14        | \$0.57        | 256K | 目前国内主流模型最低价，重点提升代码Agent能力，未SOTA，性价比很高                                          |
| 国内 | DeepSeek  | DeepSeek-V4-Pro                | 2026/4/24 | \$0.42        | \$0.83        | —    | ★模型4/24发布：5/22官宣永久降至原价1/4，6/1生效。原价¥12/¥24→¥3/¥6；缓存命中输入仅¥0.025/M。               |
| 国内 | 字节·火山引擎   | Doubao-Seed-2.1-Pro            | 2025/6/11 | \$0.83        | \$4.17        | 256K | 原人民币 6/30 元，较2.0 Pro提价约87.5%。                                                  |
| 国内 | MiniMax   | MiniMax-M3                     | 2026/6/3  | \$0.60        | \$2.40        | —    | 6月初发布，首发输入/输出价格较 M2.7 翻倍，目前已永久折扣：自演化 Agent 模型迭代。                               |
| 国内 | 智谱AI      | GLM-5.2 (旗舰，开源)                | 2026/6/13 | \$1.10        | \$3.52        | 1M   | 与GLM-5.1价格一致，GLM 5.1在GLM 5基础上涨价10% (GLM-5 原价 \$1/\$3.2)。                       |
| 国内 | 月之暗面      | Kimi K2.6 (旗舰，开源)              | 2026/4/20 | \$0.95        | \$4.00        | 256K | 美元原生 \$0.95/\$4.00；缓存命中输入 \$0.16/M。                                            |
| 国内 | 阿里·通义     | Qwen3.7-Max (旗舰，标准API)         | 2026/5/20 | \$1.67        | \$5.00        | 1M   | 5月最新旗舰：标准API ¥12/¥36；Preview s32K 档为 \$0.83/\$3.33；兼容 OpenAI/Anthropic 协议。     |
| 国内 | 月之暗面      | Kimi K3 (最新旗舰，开源)              | 2026/7/17 | \$3.00        | \$15.00       | 1M   | Code Arena 登顶，定价进入第一梯队；仅次于GPT 5.6 Sol & Claude Fable 5                         |
| 海外 | Meta      | Muse Spark 1.1                 | 2026/7/9  | \$1.25        | \$4.25        | 1M   | 官方测评显示Agent能力突出，编程仍落后。                                                         |
| 海外 | Google    | Gemini 3.5 Flash (最新，速度榜)      | 2026/5/19 | \$1.50        | \$9.00        | 1M   | I/O 2026 发布：非全球区为 \$1.65/\$9.90；Pro 版预计6月发布。                                   |
| 海外 | xAI       | Grok 4.5                       | 2026/7/9  | \$2.00        | \$6.00        | 500K | 定位 coding / agentic tasks / knowledge work                                     |
| 海外 | Anthropic | Claude Sonnet 4.6 (参考)         | 2026/2/17 | \$3.00        | \$15.00       | 1M   | Sonnet 4.8 预计本月发布；Batch=\$1.5/\$7.5。                                           |
| 海外 | Anthropic | Claude Opus 4.7 (旗舰)           | 2026/4/16 | \$5.00        | \$25.00       | 1M   | 与4.6同价；但新tokenizer可能多产 35% token，实际花费上行；Batch=\$2.5/\$12.5。                    |
| 海外 | OpenAI    | GPT-5.5 (旗舰)                   | 2026/4/23 | \$5.00        | \$30.00       | —    | GPT-5.5 Pro 另为 \$30/\$180；Batch压缩=\$2.5/\$15。                                  |
| 海外 | OpenAI    | GPT-5.6 (旗舰)                   | 2026/6/26 | \$5.00        | \$30.00       | —    | Terra版为 \$2.5/\$15；Luna为 \$1/\$6。                                              |
| 海外 | Anthropic | Claude Fable 5 / Mythos 5 (旗舰) | 2026/6/9  | \$10.00       | \$50.00       | 1M   | Mythos 版，价格为 Opus 4.8 的 2 倍；Fable=公开版，Mythos=Project Glasswing 受限版；最大 128K 输出。 |

数据来源：各公司官网，中信建投证券

全球头部模型竞争加剧，OpenAI、Anthropic动作不断以提升自身模型的吸引力，K3的入局预计将进一步加剧Tier1模型的竞争。1) OpenAI：ChatGPT work周活上周快速攀升至800万，公司多次重置token额度，优化token消耗，以吸引用户使用。2) Anthropic：多次延期订阅用户对 Fable 5 的使用，7月18日宣布Fable 5将从7月20日起包含在MAX和Team Premium计划，限额

50%，Pro和Team Standard用户将继续通过使用积分访问Fable，并将获得一次性100美元积分。

图 3:OpenAI Codex（现与 Work、Chat 整合）周活变化



本文来源：[中信建投证券研究](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

\* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

165 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

1 条评论



**MobileUser0967**  
2小时前 中国浙江省

还真把自己当大葱呢

0   回复

