

摘要：

摩根士丹利认为，中国大模型行业正经历从价格竞争到智能竞争的结构性转变：DeepSeek宣布大幅上调API价格，Kimi K3和Qwen3.8-Max以2.8万亿和2.4万亿参数进入大参数时代，开源模型授权条款也趋于收紧。这三重变化共同指向更健康的商业化环境：定价回归理性、变现路径拓宽、进入壁垒抬高。

定价触底回升，参数规模跃升，中国大模型行业的竞争主轴正在切换。

中国大模型市场长期被贴上“价格战”标签，但摩根士丹利在8月9日发布的最新研报中表示，这一判断正在失效。研报指出，行业正从价格竞争转向以智能能力驱动的商业化，三大结构性变化正在同步发生：**定价趋于理性、开源授权收紧、模型参数规模跃升。**

这一判断的直接触发点是DeepSeek的定价动作。DeepSeek于2026年8月8日宣布将大幅上调API价格，这对于一家长期以“高性能+极低定价”著称的厂商而言，意义远超单纯的价格调整——它被摩根士丹利分析师Gary Yu和Lydia Lin解读为**行业定价纪律改善的积极信号**。


定价转向的背后，是更深层的商业逻辑重塑。分析师认为，模型智能，而非价格，才是大模型竞争的终极壁垒。头部厂商可以向下推出低价轻量版本，但中等水平的厂商想要反向突破至顶尖模型，难度则大得多——这种不对称性，决定了纯粹的价格战并非可持续策略。**而谁能维持“更强模型→更多收入→更大投入→再次提升”的正向飞轮，谁才是真正的赢家。**

定价触底：DeepSeek涨价是信号，不是偶然

在过去很长一段时间，中国大模型的API均价持续走低，这也是市场担忧“价格战”将拖累整个行业盈利能力的核心依据。

但数据显示，拐点可能已经出现。据摩根士丹利研报，以字节跳动、阿里、百度、腾讯、MiniMax、智谱、月之暗面及DeepSeek为样本统计，**中国大模型平均API输出价格从2025年一季度的约12.2元/百万tokens，已回升至2026年二季度的21.9元/百万tokens。**

Exhibit 3: China LLMs average API pricing




Source: Company official listing price (incl. Bytedance, Alibaba, Baidu, Tencent, MiniMax, Z.ai, Moonshot and DeepSeek); Morgan Stanley Research

DeepSeek此次涨价，分析师认为背后有三个驱动因素：一是V4模型需求旺盛，支撑更强的定价能力；二是厂商需要在市场份额与毛利率之间寻求平衡，以持续投入前沿模型研发；三是更多使用国产芯片可能带来更高的推理成本。

分析师的结论是：价格战不是可持续的竞争策略。随着模型智能和规模持续提升，中国新一代大模型的定价将趋势性走高，竞争维度将越来越多地从价格转向能力与容量。

Exhibit 2: China frontier LLM price vs. intelligence



Source: Artificial Analysis, company data, Morgan Stanley Research

从上面的散点图中可以直观看到，模型智能指数越高，API输出定价也越高，K3和Qwen3.8-Max处于图表右上方的高价高智能象限，而V4-Flash则位于低价低智能区间——价格与能力的正相关关系正在逐步形成。

授权收紧：从“免费用”到“超规模就得谈钱”

开源模型是另一个变量。市场的普遍担忧是：开源权重模型的广泛传播，将进一步压低AI基础设施需求，加剧行业商品化。摩根士丹利对此持不同看法。

分析师指出，更便宜、更高效的开源模型应通过“杰文斯悖论”（Jevons Paradox）拉动更高的使用量——推理成本下降会催生更大需求，从而加速AI渗透。调查数据显示，63%的受访企业同时使用开源和闭源模型。

更重要的变化在于授权条款的演变。中国大模型厂商过去普遍采用Apache 2.0或MIT等宽松开源许可（L1级），允许第三方自由部署和商业化。但研报显示，厂商正加速向更严格的L2/L3授权迁移。

具体案例包括：月之暗面的K3许可要求，年收入超过2000万美元的MaaS服务商必须单独签署商业协议；据媒体爆料，阿里巴巴可能对大规模使用未来Qwen开源模型的用户引入收入分成要求。

这一变化意味着，大模型厂商的变现路径正在从单一的API直销（1P）扩展至与云服务商及模型聚合平台的收入分成（3P），可寻址的ARR池随之扩大。

Exhibit 5: AI foundation model license categories

Level	License Category	Definition	Weights Available	Commercial Use	Fine-tuning / Derivatives	Redistribution	MaaS / API Commercialization	Key Restrictions
L1	Permissive Open Source	Model weights are released under standard permissive licenses such as Apache 2.0 or MIT, allowing unrestricted commercial use, modification and redistribution subject to limited license requirements.	Yes	Yes	Yes	Yes	Yes	Minimal restrictions; typically requires retention of copyright/license notices; Apache 2.0 also includes explicit patent provisions
L2	Commercial Open-weight	Model weights are publicly available and commercial use is generally permitted, but custom license terms may impose revenue, scale, attribution, redistribution or MaaS-related restrictions.	Yes	Yes, with conditions	Yes	Yes, with conditions	Yes, with conditions	May include revenue, user-scale, attribution, redistribution, usage, or MaaS restrictions
L3	Non-commercial Open-weight	Model weights are publicly available for research or non-commercial use, while commercial deployment requires separate authorization or a commercial license.	Yes	No, unless separately licensed	Yes, for permitted non-commercial purposes	Usually limited	No, unless separately licensed	Commercial use is prohibited or requires separate authorization from the model provider
L4	Closed / API only	Model weights are not publicly available; third parties access the model primarily through first-party or authorized APIs and products.	No	Yes, through approved services/APIs	Generally no	No	Yes, through provider API	No access to model weights; usage governed by provider terms, API policies and pricing


Source: Morgan Stanley Research

参数跃升：中国大模型正式进入万亿参数时代

2026年上半年，中国主流开源大模型的参数规模普遍低于1万亿。7月，月之暗面发布的Kimi K3以2.8万亿参数打破这一天花板，成为首个跨越2万亿参数门槛的中国主流开源大模型。

紧随其后，阿里Qwen3.8-Max达到2.4万亿参数。据分析，2-3万亿参数将在2026年下半年逐步成为中国前沿模型的基准线，多款重量级产品正在路上：MiniMax M3 Pro（预计9-10月，2.7万亿参数）、智谱下一代GLM模型（预计10月）、以及可能发布的阿里Qwen4。据晚点LatePost 2026年8月6日的报道，字节跳动还在探索5万亿参数以上的模型。

Exhibit 9: China frontier LLM size vs. intelligence




Source: Artificial Analysis, company data, Morgan Stanley Research

参数规模提升的意义，不仅是性能指标的改善，更是竞争壁垒的系统性抬高。分析师指出，大参数模型的训练不只需要更多资金和算力，还对推理效率、基础设施优化、工程执行能力以及融资能力提出更高要求。

这与资本密集型行业的规律类似：越往高端走，进入门槛越高，强者越强。分析师认为，随着前沿模型规模持续扩大，行业将进一步向资源充裕的头部玩家集中。

Exhibit 8: Global SOTA model intelligence index ranking



Source: Artificial Analysis, Morgan Stanley Research

飞轮逻辑：商业化与AGI并非对立

分析师认为，商业化和AGI是相辅相成的，而非相互竞争的目标。


更强的商业化提供资金，支撑前沿模型研发；更强的前沿智能反过来推动商业化变现。两者形成正向循环——更好的模型 → 更强的用户采纳和变现 → 更多的训练和算力投入 → 持续的模型迭代。

分析师认为，真正的护城河不是暂时的排行榜第一，而是能否持续运转这个飞轮。头部厂商可以轻易向下推出低价轻量模型覆盖大众市场，但中等厂商想要向上突破至顶尖水平，难度完全不在一个量级。

智谱：飞轮正在形成，目标价升至1700港元

摩根士丹利将智谱目标价从990港元大幅上调72%至1700港元，并将2026年ARR预测从10亿美元上调至20亿美元，对应2027年市销率约42倍。

Exhibit 11: Z.ai ARR estimates



Source: Morgan Stanley Research estimates

智谱的飞轮正在加速形成，支撑这一判断的有三个维度：

模型性能：GLM-5.2已跻身全球顶级大模型阵营，不仅在基准测试中表现突出，在全球开发者社区中也获得正面反馈。据研报，智谱首席科学家唐杰（Jie Tang）于2026年6月16日在X平台发文表示，公司将在2027年一季度前发布一款达到当前最佳美国大模型水平的产品。分析师预计智谱将提前实现这一目标，时间节点为2026年10月。


算力供给：推理算力，尤其是海外算力，一直是制约智谱 ARR增长的瓶颈。目前智谱已与AWS展开谈判，GLM-5.2 API已完成AWS Marketplace的集成。摩根士丹利预计这一3P合作模式将进一步扩展至其他海外云服务商和API平台。

融资循环：2026年7月13日，智谱完成H股配股，募资314亿港元（约40亿美元），摊薄比例4.25%。公司计划将其中55%（约22亿美元）用于模型训练和算力扩张。此外，潜在的A股上市可进一步提供约150亿元人民币资金。

MiniMax：短期承压，但看多理由仍在

摩根士丹利将MiniMax目标价从1100港元小幅下调18%至900港元，维持2026年ARR预测10亿美元不变（与公司指引一致），对应2027年市销率约32倍。

Exhibit 14: MiniMax ARR estimates



Source: Morgan Stanley Research estimates

MiniMax近期股价承压明显：M3模型于6月1日发布后，因参数规模偏小（总参数4280亿，活跃参数仅230亿）、价格较M2.7翻倍，以及编程能力相对不足，在开发者社区引发负面反馈，股价从6月1日高点下跌最长达77%。7月8日，基石投资者及Pre-IPO投资者解禁，流通股比例从总股本的5.44%骤升至54.38%，进一步加大抛压。

但分析师表示对MiniMax“并不那么悲观”，理由有四：

M3 Pro是真正的催化剂：分析师将当前M3视为测试新架构（MiniMax稀疏注意力机制）的实验版本，而非完整产品。MiniMax已宣布M3 Pro将于9-10月推出，总参数达2.7万亿，有望成为届时参数规模最大的中国大模型，并展现定价能力。

大模型不只是编程：分析师认为，编程是AI场景中率先跨越技术和商业化拐点的领域，但不是全部。未来大模型将渗透至法律、金融、咨询、医疗等更广泛的知识工作者市场。MiniMax一直专注于垂直行业训练数据，并于2026年5月启动“10倍团队”计划，广纳各行业专家。

多模态被低估：视频模型市场商业价值可观，竞争相对大模型市场较低。MiniMax于2026年7月发布的H3视频模型，性能超越全球同类产品并获得正面反馈，有望重新加速MiniMax多模态ARR增长。

融资支撑：MiniMax于2026年7月10日宣布配股募资95亿港元（约12亿美元），同时发行1年期可转债募资65亿港元（约8亿美元），转换价格为335港元。公司计划将配股和可转债所募资金的80%（约16亿美元）用于模型训练和算力扩张，10%用于Harness产品的全球商业化。潜在的A股上市将进一步拓宽融资渠道。

MiniMax创始人兼CTO Dr. Yan Junjie在7月10日的内部信中表示，在公司达到AGI目标之前，他不会领取薪酬，并将在未来四年内从个人账户捐出公司4%的股份用于员工激励，另捐出1%设立专项基金支持开源社区。

研发投入大幅上调：高壁垒时代的必然代价

随着模型参数规模跃升，两家公司的研发投入预测均大幅上修。分析师将智谱和MiniMax的2027年研发费用预测均上调至10亿美元以上，以反映训练大参数模型所需的更高投入。

具体而言，智谱 2026-2028年收入预测分别上调37.3%、53.1%和56.7%；MiniMax同期收入预测分别上调104.2%、71.1%和99.2%。

两家公司均处于亏损阶段，摩根士丹利预计智谱最早在2028年实现盈亏平衡，届时云端部署业务收入的快速扩张将超越研发支出的增速。

~~~~~  
以上精彩内容来自[追风交易台](#)。

更详细的解读，包括实时解读、一线研究等内容，请加入 [【追风交易台·年度会员】](#)

# 追风

RISK CHASE

全球宏观研究 | 交易 | 配置

你 / 不 / 能 / 错 / 过

## 什么是“追风交易台”

追风交易台由顶流全球宏观资讯及研究团队联手打造。

我们的目标是给中国投资者提供专业、独到和适时的全球金融市场研究。

## 在这里，你将看到

### 最专业的解读

来自全球顶尖投行、研究机构、  
一线从业者的最新解读



### 最独到的视角

以全球市场第一线的视角  
感知市场动向



### 最适时的时机

快速、完整、准确  
最终汇集成适时



## 如果你

关心全球宏观经济和资本市场

## 如果你

苦恼于没有合适的信息和研究



关注“追风交易台”  
成为“追风会员”

你将身处全球市场第一线

公众号 · 追风交易台

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

\* 体验资格每人限申领一次

扫码  
免费领取

限免

125

收藏

分享到:

写评论

请发表您的评论

表情

图片

发表评论

1 条评论

MobileUser8587

24分钟前 中国重庆

扯淡要有限度

0

回复