

摘要：

大模型产业链利润正按“上中下”顺序依次兑现。上游算力底座率先吃尽稀缺红利，中游模型层因开源追平深陷价格通缩。在溢价流向上，中美呈现显著分野：美国AI增量价值沉淀于既有的高价软件订阅体系；中国因付费意愿差异，低价Token红利直接外溢至下游应用层。未来，下游厂商能否留住利润，将取决于其在业务场景中构筑的“迁移成本”。

大模型算力狂飙与变现迟缓的错位，正在重塑全球AI产业链的利润分配格局。过去两年，中国市场日均Token调用量暴增超千倍，但2025年公有云MaaS（模型即服务）全年营收仅停留在30亿元量级。海量消耗尚未转化为对等的账面收入，中美两国在算力瓶颈与商业化路径上已走向截然不同的方向。

东北证券分析师宋心竹在对Token经济产业链的剖析中提出，AI利润沉淀由稀缺溢价、代际溢价、一体化内部结算收益与迁移成本溢价四种机制构成。

表 3：Token 产业链四种利润机制及其收敛条件

利润机制	利润来源	主要发生环节	收敛条件	当前状态
稀缺溢价	受限供给的持有权	芯片与整机、算力持有与调度	供给宽松	已进入报表
能力代际溢价	与同期开源最优的能力差	模型层（frontier 位置）	开源追平，迭代清零	每代重新定价
一体化内部结算收益	自有流量与自有算力的内部消化	大厂与 CSP	并入既有利润池，不单独计量	不单独披露
迁移成本溢价	更换供应商的重置成本	应用层	随合作年限累积，不随降价周期收敛	尚未兑现

数据来源：东北证券整理

当前，利润正按上、中、下的顺序依次进入报表：上游算力底座率先兑现稀缺红利；中游模型层深陷同代能力商品化引发的通缩；下游应用层则承接算力降价红利，凭借时间累积的“迁移成本”构筑长期护城河。

在溢价流向的终局上，受制于两国市场付费禀赋差异，美国的AI增量价值正沉淀于高价软件订阅体系，而中国市场的低价Token红利则直接外溢至应用层，等待计价方式全面迁移后的价值重估。

算力投入逼近现金流边界，千倍调用量仅兑现30亿市场

Token经济仍处重资产建设期。需求端，中国日均调用量由2024年初的约1000亿次飙升至2025年底的100万亿次。然而，多数Token消耗发生在大厂自有场景内部，未形成外部交易；经外部交易的部分，成交价已被极度压缩；加之应用层收费尚未全面向Token计价迁移，导致千倍的用量增长仅换来30.7亿元的公有云MaaS市场规模。

与微薄的API收入对应的，是算力投入端的极度重载。资本开支强度已逼近经营现金流的覆盖边界。截至2026年二季度，美股四大云厂商的TTM（滚动十二个月）资本开支与经营现金流之比升至0.63至1.05。Alphabet首次出现单季负自由现金流，Meta自由现金流同比骤降91%。建设期的资金来源已从经营现金流外溢至资本市场。

中国市场投入节奏明显分化，阿里巴巴资本开支强度跃居中概第一，百度则是八家头部算力买家中唯一收入回落与资本开支加码并存的公司。

表 2：中美主要算力资本开支方 TTM 资本开支、同比与自由现金流（亿美元）

公司	TTM 资本开支	TTM 经营现金流	TTM 自由现金流	资本开支/经营现金流	资本开支同比
亚马逊	1,690.1	1,614.0	-27.2	104.7%	+70.6%
谷歌	1,324.0	1,856.8	-896.2	71.3%	+103.3%
微软	1,159.5	1,829.4	432.1	63.4%	+79.6%
Meta	893.3	1,303.0	-298.5	68.6%	+66.6%¹
甲骨文	556.6	319.8	-206.5	174.1%	+162.4%
阿里巴巴	182.2	110.1	77.1¹	165.4%	+52.1%
腾讯	120.6	465.0	147.6	25.9%	+20.6%
英伟达	65.7	1,256.5	867.4	5.2%	+60.5%
百度	21.7	8.1	21.6	267.8%	+111.6%

数据来源：Wind，东北证券整理


上游吃尽稀缺红利，中美算力瓶颈走向分野

上游是当前唯一将利润稳稳装进报表的环节。基于供给缺口的“稀缺溢价”，直接造就了英伟达 FY2026 财年数据中心 1937 亿美元的收入。面对同样的算力饥渴，中美两国在同一道管制下形成截然不同的出清方式与产业瓶颈。

美国的产业链瓶颈在于电力接入。ERCOT（德州可靠性委员会）等待接入批准的队列中，超 1800 个项目里约 90% 为数据中心，对应电力需求累计约 474GW。审批与电力接入周期拉长，导致北美数据中心空置率降至历史低位。美国的稀缺最终按价格出清，涨价收益归于英伟达等头部大厂。

中国的产业链瓶颈则直指算力芯片。在出口管制下，中国市场按管制配给出清，制度性拉动指向国产替代。2025 年，本土厂商在 AI 加速卡市场的份额已占四成以上。新增算力向“东数西算”枢纽节点集聚，建设主体由公共部门、运营商与私人资本并举，形成公共部门主导的算力体系。

图 9：2025 年中国 AI 加速卡市场份额（%）



数据来源：IDC（经路透社报道），东北证券

开放权重击穿代际壁垒，中游模型沦为标准化产能


同一能力档位的 Token 具备极强的可替代性，开放权重（开源）成为推平价格鸿沟的绝对主力。采购方更换供应商成本极低，竞争直接落在挂牌价上。测算显示，达到 GPT-4 同等能力的调用价格，每年降至约四十分之一。

同代能力的价格正在全球范围内迅速追平。在 AA 智能指数约 51 分的档位上，中美四个主力模型（GPT-5.6 Luna、GLM-5.2、MuseSpark 1.1、Gemini 3.6 Flash）的混合价全部落入 14 至 22



元/百万Token的极窄区间。该档位的最低价并非来自中国厂商，而是以API形态入局的Meta。一旦能力档位被开源追平，Token即告商品化，价格只随用量与成本变动。

图 13：当代主力模型 API 混合价（元/百万 token，对数轴）



数据来源：各公司官网，东北证券

中游由此陷入两端挤压。售价端，实际成交价往往比挂牌价低约一个数量级；成本端，单位推理成本中七成以上为折旧摊销，电费占比不足一成。成本压降的核心空间不在电价，而在于折旧年限与算力利用率。

在中国，Token商品化正被推向基础设施层面。通过算力券直补采购端、建立统一计量比价平台，中间加价空间被挤掉。流通环节注重量增而利薄，能持续赚钱的只剩两头：生产端靠极致的利用率赚成本差，场景端靠客户更换成本留住利润。

利润归宿分化：美国沉淀于订阅，中国外溢至应用层

通缩的Token价格将模型升级的红利释放到下游，中美两国承接红利的方式因付费意愿禀赋出现分化。

美国的AI增量价值被既有订阅体系吸收。美国用户习惯为软件订阅支付高价，前沿模型厂商与存量软件巨头争夺同一生态位。微软将AI功能打包进高价订阅，一次性的能力优势转化为持续的客户付费。

中国市场受制于较低的软件订阅付费意愿。同一款基础办公软件，中国市场定价通常为美国的五分之一甚至更低。因此，中国中游厂商普遍按算力成本定价，低价Token的价值直接外溢至应用层。

对中国应用层公司而言，计价方式的迁移决定了利润去向。若维持订阅计价，Token降价红利留在成本端，体现为毛利率与经营杠杆改善；若转向按Token消耗或按业务结果计价，红利则直接进入收入端。

但计价方式转变不等于利润落袋。下游能否留住利润，取决于在场景中建立的“迁移成本”，这是抵御买方压价收回红利的唯一武器。

产出价值的可归因性、场景资产的排他性、客户结构以及任务的消耗强度，决定了场景质地。场景内的护城河由三类载体维持：一是外部规则赋予的准入资质与采购制度（如政务、受监管行业）；二是时间累积形成的数据对接与口径沉淀（如金融数据治理、智能运维）；三是系统集成带来的重置成本。

随着旧有席位计费体系瓦解，按Token与效果计价模式将大幅缩短客户黏性的验证周期。过去需等一年一度续约见分晓的客户留存，现在通过逐季的Token用量即可清晰观测。最终能沉淀利润的，是那些用极高替换成本将客户绑定在自身业务流中的下游玩家。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

382 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

4 条评论



天天
3小时前 中国重庆

巨头把利润搭进去不说，在资本市场疯狂融资，他们可以继续，我们也可以选择等。

0 回复



GDAI
17小时前 中国浙江省

先真正解决就业吧

1 回复



MobileUser1265 VIP会员
17小时前 中国

这个是什么狗屁专家写的，专讲屁话和垃圾！

0 回复



MobileUser3850
17小时前 中国上海

忽略了一点，国内数据来源和使用成本很低，未来监管也很可能没有美国严。

1 回复

