

公司称，GLM-5.3与GLM-5.2在架构、总参数和激活参数保持一致的情况下，通过扩大后训练规模，端到端编码完成率提升超过50%。此外，公司正推进下一代基座模型训练，重点方向包括更大的有效规模、更长的原生上下文以及原生多模态统一建模。



Z.AI Co., Ltd.

北京智譜華章科技股份有限公司

(於中華人民共和國註冊成立之股份有限公司)

(股份代號：2513)

截至2026年6月30日止六個月的 中期業績公告

董事會欣然公佈本集團截至2026年6月30日止六個月的未經審計簡明綜合中期業績，連同2025年同期的比較數字。

本公告所載若干金額及百分比數字已作約整，或已約整至一位或兩位小數。任何表格、圖表或其他資料中所列總額與其內所列金額加總之間的任何差異，皆因約整所致。

財務摘要

	截至6月30日止六個月		同比變動 %
	2026年	2025年	
	人民幣千元 (未經審計)	人民幣千元 (未經審計)	
收入	953,892	190,877	399.7
毛利	251,611	95,424	163.7
研發開支	(2,131,171)	(1,594,661)	33.6
期內虧損	(2,071,992)	(2,357,852)	-12.1
經調整期內淨虧損	(1,964,138)	(1,751,974)	12.1

收入结构明显向MaaS倾斜

本次财报最显著的变化，是收入结构的快速调整。

报告期内，开放平台及API收入由去年同期的2910万元增至8.25亿元，同比增长2735.7%。与之相对应的是，企业级通用大模型收入由1.48亿元下降54.6%至6704万元。

这一变化意味着，随着模型能力提升，智谱AI的商业化模式正在从本地化部署逐步向云端调用迁移。公司将这一过程概括为“卖模型→卖调用→卖订阅→卖端到端任务结果”。

从运营数据来看，MaaS业务的增长已经开始形成一定规模。截至公告日期，平台付费日活用户数较年初增长603%，前十大用户日均调用量增长98倍，Token调用量增长超过40倍。同时，API平均售价较年初提升约101%，Coding Plan订阅价格也有所上调。

企业级智能体业务也保持增长，收入由1374万元增至5556万元，同比增长304.4%，但目前占整体收入的比重仍然较低。

云端业务毛利率由负转正

收入结构变化也对盈利能力产生了明显影响。

报告期内，公司整体毛利率由去年同期的50.0%下降至26.4%。主要原因在于，毛利率相对较高的本地化部署业务占比下降，而处于快速扩张阶段的开放平台及API业务占比大幅提升。

不过，从单项业务来看，云端业务的盈利能力正在改善。开放平台及API业务毛利率由去年同期的-0.4%提升至24.6%，实现由负转正。



公司表示，Token调用量增长、产品定价提升以及推理成本下降，是毛利率改善的主要因素。报告期内，公司单位Token推理成本较年初下降约80%，并通过“All-in-Infra”战略扩大国产芯片在推理算力中的应用。

成本端，公司销售成本由9545万元增至7.02亿元，同比增长635.4%，主要受到计算服务费用增加的影响。研发开支则同比增长33.6%至21.31亿元，仍然明显高于当期收入，研发费用率超过200%。

与此同时，销售及营销开支同比下降14.8%，一般及行政开支同比下降44.2%，显示公司在收入快速扩张的同时，部分运营费用有所收缩。

亏损仍高企，研发投入维持高位

尽管收入大幅增长，智谱AI目前仍处于亏损阶段。

报告期内，公司净亏损20.72亿元，同比收窄12.1%。剔除股份支付等非现金项目后，经调整净亏损为19.64亿元，较去年同期有所扩大，主要与研发投入增加有关。

从亏损结构来看，公司仍在将大量资金投入模型研发和算力基础设施。上半年研发开支达到21.31亿元，同比增长33.6%，约为同期收入的2.2倍。

因此，对于智谱AI而言，当前业绩的核心变化仍然不是利润端，而是收入规模扩大以及云端业务毛利率改善能否持续。随着MaaS收入占比快速提升，公司未来盈利能力将更多取决于模型调用规模、API定价、推理成本以及研发投入之间的平衡。

报告期结束后，公司于7月完成配售，以每股1588港元的价格募资约314亿港元，为后续模型训练、算力基础设施及产品研发提供资金支持。

模型迭代从“堆参数”转向强化后训练

技术层面，智谱AI在报告期内密集迭代GLM系列模型，发布GLM-5、GLM-5.2、GLM-5.3及GLM-5.3-Flash等模型。

其中，GLM-5.3与GLM-5.2的对比体现了公司当前的技术路线。公司称，在保持两款模型架构、总参数量和激活参数量一致的情况下，通过扩大长程任务环境和强化学习规模，GLM-5.3的端到端编码完成率提升超过50%。

这意味着，在当前模型规模不断扩大的背景下，公司开始更加重视后训练、强化学习以及任务环境建设，希望通过提高模型的实际任务完成能力，而不仅仅是继续增加参数规模来推动性能提升。

GLM-5.3-Flash则主要针对推理效率和成本。该模型总参数量为3200亿，激活参数180亿，采用稀疏注意力与线性注意力等架构，并使用30万亿级多模态预训练语料。公司称，其定价约为GLM-5.2的十分之一，同时在多项能力上实现提升。

在算力方面，智谱AI进一步推进国产芯片的规模化应用。公司表示，GLM-5.3-Flash已在10万级国产芯片规模的集群上提供推理服务，端到端服务性能较初始基线提升3倍。

从Coding向Agent和Co-work延伸

在商业化路径上，Coding是智谱AI目前重点突破的应用场景。



公司认为，大模型的商业化空间可以从Chat进一步向Coding、Agent、Co-work以及更高层次的自主化任务执行延伸。其中，Coding既是模型能力的重要验证场景，也是目前较容易形成付费模式的应用之一。

智谱AI表示，公司正在通过ZCode等产品，将模型能力从代码辅助进一步延伸至软件开发的完整流程，并尝试让模型承担更长链条、更复杂的工程任务。

网络安全则是公司向Agent和Co-work拓展的另一个方向。报告期内，公司在CyberGym基准上取得84.5%的成绩，并在ExploitGym完成130项任务。截至报告期末，公司联合多家安全团队累计发现漏洞2436个，其中中高危漏洞1097个。

相比Coding，法律、金融、教育等领域目前仍处于早期阶段，尚未形成规模化收入。随着模型能力进一步提升，这些场景能否从技术验证转化为稳定商业收入，将成为公司后续商业化的重要观察点。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

限免

787 收藏

分享到:


写评论

请发表您的评论

表情 图片

发表评论

2 条评论



正在加载 .