


摘要：

SemiAnalysis认为，AWS正在用一套独特的结构性逻辑，在云计算利润战中悄然拉开差距。Bedrock平台仅占AWS总收入4%，却贡献同比新增毛利润的30%，EBIT利润率高达55%。背后的核心逻辑是：从卖算力的IaaS模式，跃迁为拿模型分销权益的TaaS模式。Anthropic季度净新增ARR达210亿美元、API收入同比暴增13倍，成为这套杠杆结构的核心燃料。

AI云业务普涨的时代，利润率成了真正的分水岭。AWS凭借一套将Claude token需求转化为经营杠杆的独特结构，正在与Azure、Google Cloud拉开差距。

最新数据显示，AWS在2026年一季度EBIT利润率环比提升213个基点，而同期Azure利润率走弱，Google Cloud利润率改善有限且存在会计口径差异。**亚马逊是唯一一家将代币即服务(TokenaaS) 作为其人工智能业务主要组成部分的云服务提供商 (CSP)。**




研究机构SemiAnalysis分析师Jeremie Eliahou Ontiveros将这一分化归因于三点：“**AWS在第三方模型API支出中的更高份额、Anthropic/Bedrock交易结构，以及Anthropic在2026年一季度ARR超预期。**”这不是“AI需求强，所以利润好”的简单逻辑，而是一套从算力出租商向模型分销平台跃迁的结构性转变。

关键信号在于：Bedrock目前约为55亿美元run-rate规模，仅占AWS总收入约4%，却贡献了AWS同比新增毛利润的30%。只要Anthropic需求持续爆发，这一杠杆效应将继续放大。

结构差异：AI占比低，利润率反而更高

云厂商都在吃AI需求，但分化发生在利润率，而非收入增速。

从AI收入占总收入比例来看，AWS并不领先。测算显示，AWS的AI收入占比从2024年一季度的2%升至2026年一季度的10%，而同期GCP和Azure分别达到36%和27%。



但高AI占比没有自动带来高利润率。Azure和GCP的AI业务仍以AI IaaS为主，占各自AI业务组合超过80%。AWS的结构则在发生变化：Bedrock占AWS AI收入的比例从2025年一季度的9%，升至2026年一季度的37%。

这解释了一个表面矛盾——AWS的AI收入占比远低于竞争对手，利润率却跑出来了。问题不在“AI多不多”，而在“AI收入是哪一种”。


Bedrock模式：从卖算力到拿分销权益

Bedrock是AWS的模型调用平台，客户可通过统一账单、安全合规框架接入Claude等前沿大模型。它的竞争对手包括Microsoft Foundry、Google Gemini Enterprise Agent Platform，以及TogetherAI、Fireworks等偏开源模型的平台。

这类平台的核心差异不在模型数量或延迟指标，而在能否接入前沿模型。前沿大模型贡献了AI API行业的大部分收入，AWS、微软、谷歌相较其他endpoint平台的优势，正在于此。

但接入模型只是第一步。Bedrock对AWS利润率的真正意义，在于其交易结构。在AWS通过Bedrock分销Claude token的安排下，Anthropic作为seller of record确认完整的token销售收入；客户由AWS开票，模型部署在AWS基础设施上；AWS则获得两部分收益：类似EC2/IaaS的基础设施费用，以及分销或收入分成。


相比五年期take-or-pay式的IaaS合同，这类Token-as-a-Service（TaaS）业务收入锁定性更低，但利润率更厚。对Anthropic/Bedrock安排的测算显示，固定IaaS费用、收入分成与超量绩效门槛叠加，使Bedrock在2026年一季度实现了约55%的EBIT利润率。代价也很明确：若Claude token消费下滑，AWS承担的需求风险高于传统IaaS。



目前，亚马逊、微软、谷歌的TaaS业务ARR均已达到百亿美元以上量级，Oracle和neocloud在这一层几乎没有规模——这是超大云厂商与其他AI算力提供商差距被拉大的关键所在。

Anthropic爆发：AWS利润杠杆的核心燃料

Bedrock高度绑定Anthropic需求。测算显示，**Bedrock 80%至90%以上的客户使用Anthropic模型，Bedrock实质上是一个由Claude需求驱动的业务。**



Anthropic自身的增长数据极为突出。其2026年一季度净新增ARR为210亿美元，总ARR达到300亿美元；API收入同比约增长13倍，年底ARR有可能远超1000亿美元。Claude Code在企业客户中的快速铺开是重要驱动，消费者侧流量也开始向Claude迁移。

利润率同样大幅改善。Anthropic推理毛利率已升至60%中段，相比2025年的38%和2024年的-94%实现大幅修复。Anthropic越快增长，Bedrock上Claude token消费越大，AWS拿到的基础设施费和分销分成也越多。

这种借力关系在财务数据上已有体现。2026年二季度的路径假设更为激进：Bedrock占AWS AI收入比例有望升至53%，并为AWS总收入增长额外贡献9个百分点。

容量布局：提前锁电，才接得住TaaS需求

TaaS要做大，前提是有足够的推理算力按时交付。AWS在这一点上比多数同行更为激进。

数据中心模型显示，AWS在2025年至2027年的新增容量上持续领先；微软在2024年至2026年节奏接近，但到2027年被明显拉开。更重要的是，微软内部AI项目消耗的算力高于亚马逊，且大量AI算力通过长期合同锁定给了OpenAI——仅OpenAI相关积压订单规模，就是Azure全年收入的2.5倍。

AWS则更早将电力和容量当作市场份额问题处理，与Talen、Vistra、NiSource等独立电力生产商签下数十亿美元级PPA，并在印第安纳和密西西比推进接近2GW规模的建设。微软此前曾经历约一年的数据中心建设暂停，拉低了2027年容量预测；威斯康星大型AI集群进展也慢于AWS同类项目。若要追赶，微软只能从neocloud购买更多容量，成本更高，利润率也将承压。

AWS还在推进更高模块化和预制化比例的新数据中心设计。对AI推理业务而言，这直接关系到收入的交付能力。

自研芯片：在分销费之外压低底层成本

Bedrock模式对自研芯片天然友好——客户购买的是token，不关心底层跑的是英伟达GPU还是Trainium。这给了AWS一个额外的成本杠杆。

Trainium在高batch推理、强化学习等对内存带宽敏感的工作负载中具备较好的性能/总拥有成本表现。AWS CEO Matt Garman在2025年11月披露，Trainium已支撑超过50%的Amazon Bedrock token使用量。

CPU侧同样值得关注。前沿大模型训练和推理对CPU需求上升，尤其在强化学习和agentic工作负载中。AWS的Graviton4、Graviton5在性能/总拥有成本上具备优势，并将作为Trn3的head node集成，也可单独用于强化学习和agentic任务。AWS已与Anthropic、OpenAI、Meta签下大型CPU及Graviton相关合作，Bedrock客户基础越大，向其追加销售Graviton能力的摩擦越小。

同行落后：不是AI收入不够，而是结构没变

Azure的核心问题是AI收入仍高度IaaS化，Microsoft 365 Copilot和GitHub相关业务尚未形成同等规模的利润率拉动。

Google Cloud的Gemini API表现尚可，但没有复制Anthropic在编码市场的强势。更重要的是，Google Cloud存在会计口径差异——DeepMind的训练成本未计入GCP分部，导致其利润率与AWS不完全可比。

Oracle和neocloud的处境更为直接：主要在AI IaaS和算力租赁层竞争，TaaS几乎没有规模。一旦云业务利润低于预期，批发算力模式的脆弱性即刻暴露。

AWS这轮跑赢，依赖几条线同时成立：Anthropic需求爆发提供收入基础，Bedrock交易结构提供利润率，电力与数据中心容量提供交付能力，Trainium和Graviton压低底层成本。只要这几条线保持连接，AWS的AI业务逻辑就不只是“资本开支换增长”，而是“模型需求换经营杠杆”。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 **限时权益申领**

* 体验资格每人限申领一次

扫码 

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

 135  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发布评论

