

摘要：

Meta内部AI使用成本失控，员工为绩效考核疯狂消耗Token，推动公司2026年相关支出飙升至数十亿美元。面对不断膨胀的账单，Meta被迫设定使用上限、上线实时监控系统。AI行业正从“拼能力”转向“拼成本”，商业化逻辑面临严峻考验。

Meta内部AI使用成本失控、科技巨头集体踩刹车，正将一个长期被忽视的行业矛盾推至台前：AI的商业化逻辑，正在被它自己制造的账单危机所反噬。

据The Information报道，Meta本周向约6000名员工发送内部备忘录，宣布将对员工的Token使用量设置上限，并构建实时追踪平台，以遏制内部AI成本的指数级膨胀。

备忘录直言，Meta 2026年仅内部AI使用一项支出预计将高达数十亿美元。这一举措的背景是，Meta此前曾大力鼓励员工将AI工具嵌入日常工作，如今却不得不急踩刹车。

与此同时，据《华尔街日报》报道，OpenAI正考虑大幅下调Token费用以争夺企业客户，而反映市场AI付费意愿的Silicon Data LLM Token支出指数已连续7个交易日下跌，创今年1月以来最长连跌纪录。

这一系列信号叠加，令市场对AI商业化可持续性的疑虑骤然升温。对投资者而言，核心问题已不再是AI需求是否存在，而是：当科技巨头自身都开始精打细算Token账单，大模型厂商的利润率空间究竟还剩多少？

Token账单失控：Meta内部的“烧钱竞赛”

Meta此次收紧AI使用的直接导火索，是一场由内部激励机制催生的Token消耗狂潮。

去年11月，Meta曾明确告知员工，展示“AI驱动的工作成果”将成为今年的“核心考核要求”，表现最优者将获得奖励。这一导向在今年春季引发了意想不到的副作用——部分员工开始参与一种被称为“tokenmaxxing”的竞赛行为，争相登上公司内部名为“Claudeconomics”的排行榜，该榜单按Token使用量对前250名员工进行排名。

据The Information获得的内部数据，员工在某30天内累计消耗了60.2万亿枚Token，随后这一数字进一步攀升至73.7万亿枚，排行榜随即被下线。部分员工甚至刻意指令AI代理同时运行多项任务，以人为方式拉高Token消耗量。

Meta首席技术官Andrew Bosworth在4月的一份备忘录中已对此发出警告，称“没有人应该为了使用AI而使用AI”，并强调“Token使用量本身不是任何意义上的影响力衡量标准”。但显然，仅靠喊话难以遏制成本的持续攀升。

系统性应对：AI Gateway与内部工具替代

面对失控的支出，Meta正在构建一套系统性的成本管控机制。

根据内部备忘录，Meta已由产品开发和工程师团队搭建了一个名为“AI Gateway”的中央仪表盘，用于实时监控全公司的AI使用量与支出，并将推出针对异常消费峰值的自动预警功能。公司计划在未来数周内向更广泛的员工群体正式发布上述管控工具，并于2027年推进更结构化的Token预算分配机制。



与此同时，Meta正推动员工从第三方AI工具转向内部自研方案。据两位知情人士透露，Meta新成立的Applied AI Engineering部门已责成工程师改进内部编程助手MetaCode（前身为Devmate），目标是降低对Anthropic旗下Claude的依赖——后者目前是Meta工程师在编程工作中的主要工具。相关团队正通过生成编程挑战、训练强化学习数据的方式提升MetaCode的能力。

值得注意的是，Meta并未完全封锁第三方模型的访问权限，员工仍可使用来自OpenAI、Anthropic和谷歌的工具，但内部工具的优先级将被明确提升。

行业共振：大厂集体踩刹车

Meta并非孤例。Token账单压力正在科技行业形成共振。

据英国《金融时报》报道，亚马逊上月刚关闭了一项内部AI排行榜，原因是员工为了“刷分”而进行不必要的操作，导致公司的算力成本急剧上升。同时，亚马逊开始使用一种名为“标准化部署”的指标，来评估工程师是否定期使用 AI 生成有用的代码，而不是单纯的Token消耗量。

另据The Information，Uber和ServiceNow在2026年前几个月便已耗尽全年Anthropic工具预算；ServiceNow同样开始监控员工每日使用量以追踪和压缩成本；风险投资机构也在为员工设置AI使用上限，原因是每日Token费用动辄高达数千美元。

这一背景下，OpenAI的降价传闻更具深意。

据《华尔街日报》报道，OpenAI正考虑大幅下调向用户收取的Token费用，部分原因是为抢在Anthropic采取类似行动之前“占据先手”。

OpenAI首席执行官Sam Altman近期公开承认，AI使用成本已成为“一个巨大问题”，并表示将“帮助人们用更少的支出获得更多价值”。

这一表态的时机颇为微妙——OpenAI本周已秘密提交IPO申请，Anthropic同样处于上市倒计时阶段。价固然有助于争夺企业客户，但将直接侵蚀两家公司的利润率，而两者目前均因AI系统所需的庞大算力亏损数十亿美元。

Token指数下跌：市场在重新定价什么？

资本市场已率先感受到这股寒意。

Silicon Data统计的LLM Token支出指数截至6月11日已连跌7个交易日，创今年1月以来最长连跌纪录，过去12天中有11天录得下跌。

该指数衡量全市场每使用100万枚Token的平均付费水平，自去年12月以来曾翻逾一倍，并持续攀升至2026年5月，随后急转直下。

美国宏观策略师Andreas Steno Larsen将这张图称为“当前全市场最应关注的一张图”，并警告：若Token定价持续走弱，本轮周期中从内存到更广泛硬件及数据中心的相关交易逻辑可能面临终结。

华尔街对此解读不一。摩根大通将当前走势定性为“最小减速带”；Citadel则指出，AI落地的核心约束已从“模型能力最强”转向“成本与稀缺性”，用户正加速向廉价模型迁移。



这一分歧的背后，是一个更根本的估值问题：Token消耗量下降，究竟是AI需求见顶的信号，还是用户理性化选择低价模型的结果？答案将直接影响英伟达、云厂商乃至整条AI硬件链的资本开支预期与估值逻辑。

商业化叙事的转折点

从更宏观的视角看，Meta此次收紧AI使用，折射出生成式AI商业化叙事的深层裂变。

过去三年，AI行业经历了从补贴换用户、月包订阅隐藏成本，到按Token计费引爆企业账单危机的三级跳。如今，当“Token消耗越多越好”的增长叙事走到尽头，行业面临的不仅是一次降价决策，而是一个更根本的商业模式重构命题。

Meta此次投入高达1450亿美元的年度资本开支，部分用于扩张AI基础设施，包括数据中心、AI芯片和人才招聘。与此同时，公司正承受来自投资者的压力，要求其从庞大的AI投入中产生可见回报——Meta已在Facebook、Instagram和WhatsApp推出付费订阅层级，并计划向使用其AI商业代理的企业收费。

然而，若连Meta自身的内部AI使用成本都已难以为继，其企业AI代理业务的盈利前景同样面临拷问。对整个行业而言，下一个商业化故事如何讲述，仍是一个悬而未决的问题。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

417 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论