

摘要：

亚马逊云服务与芯片初创公司Cerebras达成多年合作，将在数据中心联合部署Cerebras与自研Trainium芯片，提供高速AI推理服务。Cerebras芯片推理速度号称比英伟达GPU快25倍，此次合作有助于其触达大量云端客户。

亚马逊云服务与芯片初创公司Cerebras宣布达成多年合作协议，将在其数据中心部署Cerebras芯片，用于AI推理计算。

3月13日周五，根据双方公布的协议，亚马逊云服务将把Cerebras芯片与自研Trainium芯片组合部署，以提供更高速的推理计算服务。

这也是继今年1月OpenAI与Cerebras签署逾亿美元合作协议之后，这家初创公司再度获得大型科技巨头背书。

Cerebras将其芯片标榜为“极速推理解决方案”，并表示它们可以处理被称为“解码”的复杂任务，即推理计算阶段，人工智能模型在此阶段对用户查询做出响应，速度比英伟达的GPU快25倍。

此次合作对Cerebras的商业版图具有重要意义。Cerebras首席执行官Andrew Feldman表示：

越来越多的人使用人工智能，使用频率也越来越高，并且用它来解决更复杂的问题。这使得Cerebras-Trainium解决方案能够接入最大的云平台，让我们有机会接触到大量的客户。

推理市场崛起，GPU主导地位受压

AI行业算力需求的重心正悄然转移。

随着AI工具和智能体的用户规模迅速扩张，训练阶段的算力需求趋于饱和，推理计算的重要性日益凸显。企业普遍认识到，GPU虽在模型训练中表现出色，但在要求极致响应速度的推理工作负载上并非最优选择，这促使各方加快多元化供应商布局。

AWS作为全球最大的云服务提供商，此前主要依赖旗下Annapurna Labs半导体业务设计的Trainium芯片为数据中心提供算力支持。

此次引入Cerebras芯片，意在弥补Trainium在高速推理场景下的局限，并在推理产品线上提供分层定价方案，速度较慢的纯Trainium服务将以更低价格提供，而Cerebras与Trainium的组合方案则定位高端。

AWS联合创始人、副总裁Nafea Bshara表示，该公司的目标是“持续推进速度提升并降低价格”。Feldman则直言：

如果你希望获得快速token输出，如果速度对你至关重要，如果你在从事代码或智能体工作，我们不仅是绝对最快的，而且我们意在设定行业标准。

英伟达压力加剧，定制芯片势力扩张

这笔交易是英伟达面临日益激烈竞争的缩影。

定制处理器设计商正以专项场景突破的方式蚕食英伟达的市场份额，客户对更快速度和更低成本的诉求也在倒逼芯片巨头加速产品迭代。

据报道，英伟达去年12月与芯片初创公司Groq签署了一项价值200亿美元的授权协议，并计划于近期发布采用Groq技术、专门面向推理场景的新型处理系统。

对于Cerebras而言，与AWS的合作发生在其业务高速扩张的关键节点。

今年2月，Cerebras宣布完成10亿美元新一轮融资，累计融资总额升至26亿美元，投后估值约为230亿美元。

今年1月，ChatGPT开发商OpenAI签署了一项价值逾百亿美元的协议，部署Cerebras芯片为其旗舰聊天机器人提供算力支持，OpenAI计划使用Cerebras芯片部署最高750兆瓦的算力。

这家初创公司背后汇聚了富达管理（Fidelity Management）、Atreides Management、Benchmark、Tiger Global和Coatue等一线机构投资者的支持，但此前曾一度面临融资困难。

Cerebras曾于2024年9月提交IPO申请，但约一年后撤回了上市文件。上市计划何时重启，目前尚无定论。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 88  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论