

摘要：

OpenAI旗舰模型Astra发布不到三周，再度出手推出GPT-6 Sol与Luna，API价格直接腰斩。其中Luna输入价低至每百万Token 0.10美元，约合0.67元人民币，输出价格0.50美元，相比之下，DeepSeek V4.1 Flash闲时输入价为每百万Token 1元，输出价为 4 元，高峰时段则升至2元和8元。按照普通新请求计算，Luna 已经更便宜，也没有峰谷定价带来的成本波动。

OpenAI在旗舰模型发布不到三周后再度出手，将两款新模型的API价格直接砍半，剑指DeepSeek的低价护城河，大模型竞争从“比能力”全面转向“比成本”。

美东时间9月22日，OpenAI正式推出GPT-6 Sol和GPT-6 Luna两款新模型，宣布其API价格较GPT-5.6促销定价再降50%。其中GPT-6 Luna的输入价格低至每百万Token 0.10美元，输出价格0.50美元，已直接切入此前被DeepSeek视为价格优势的区间，向中国竞争对手的核心阵地发起正面冲击。

此次降价并非单纯商业让利。OpenAI表示，价格下降源于缓存和推理效率的提升，公司将节省的成本直接传导至用户。与此同时，Anthropic同日推出Claude Opus 5.5并强调更低运行成本。两大头部AI公司在同一天以更具竞争力的价格入场，标志着AI行业竞争已进入性能、速度与成本“三线并进”的新阶段。

Astra发布不到三周，OpenAI火速补齐产品线

9月3日，OpenAI推出GPT-6旗舰模型Astra，称其在计算机操作、软件工程、网络安全及专业工作等领域达到新的能力前沿。彼时Astra需求之旺盛一度迫使OpenAI暂停新的Pro订阅注册。

仅仅不到三周，OpenAI已在Astra之下推出Sol和Luna，迅速向不同性能、成本和使用场景铺开产品线。OpenAI官方表示，Sol和Luna“建立在GPT-6 Astra背后的技术进展之上”，将Astra的诸多优势带入“更快速、更实惠的模型”，以支持规模化工作。



OpenAI

@OpenAI · 14h

Please welcome GPT-6 Sol and GPT-6 Luna to the GPT-6 universe.

GPT-6 Sol and Luna build on the advances behind GPT-6 Astra, bringing much of its strengths into faster and more affordable models to support work at scale.

We've also made caching and inference more efficient, and [Show more](#)

GPT-6

Astra



Our most intelligent model for the best results.

Input

\$10.00

Output

\$50.00

GPT-6

Sol



Complex coding and professional work at a lower cost.

Input

\$2.00

Output

\$10.00

GPT-6

Luna



Fast and efficient everyday work at scale.

Input

\$0.10

Output

\$0.50

1.8K

7.6K

49K

7.1M

这一节奏与AI行业愈发明显的产品策略相呼应：旗舰模型负责突破能力上限，更快、更便宜的版本则负责进入更多高频工作流。

API价格直接腰斩，Luna已进入DeepSeek价格腹地

价格是此次发布最明确的商业信号。

根据OpenAI公布的价格表，GPT-6 Sol输入价格从GPT-5.6 Sol促销价的4美元降至2美元/百万Token，输出价格从20美元降至10美元；GPT-6 Luna输入价格从0.20美元降至0.10美元，输出价格从1.20美元降至0.50美元。两款模型API成本均直接打五折。

GPT-6 API pricing			
Model	Input	Output	Price reduction
GPT-6 Sol vs. GPT-5.6 Sol	\$4 → \$2	\$20 → \$10	50% cheaper
GPT-6 Luna vs. GPT-5.6 Luna	\$0.20 → \$0.10	\$1.20 → \$0.50	50% cheaper

OpenAI解释称，降价主要来自缓存和推理效率的提升，而非单纯的商业补贴。公司同时进一步优化了提示词缓存机制，使智能体和长对话能够更多复用已处理的上下文，从而摊薄单次调用成本。

其中Luna的定价尤为激进，已切入此前被DeepSeek系列模型主打的超低价区间，令外界将此次发布视为OpenAI对DeepSeek价格护城河的正面挑战。

作为对照，DeepSeek V4.1 Flash 闲时的缓存未命中输入价为每百万Token 1元，输出价为4元，高峰时段则升至2元和8元。按照普通新请求计算，Luna已经更便宜，也没有峰谷定价带

来的成本波动。

但DeepSeek仍有自己的价格优势。它的闲时缓存命中输入只要每百万 Token 0.02 元，远低于 Luna。V4.1 Flash 的综合能力也明显更高，拥有 100 万 Token 上下文，并支持图文理解、工具调用和思考模式。

模型			deepseek-flash ⁽¹⁾	deepseek-v4-pro 深度搜索v4-pro
BASE URL (OpenAI 格式)			https://api.deepseek.com	
BASE URL (Anthropic 格式)			https://api.deepseek.com/anthropic	
模型版本			DeepSeek-V4.1-Flash	DeepSeek-V4-Pro-0813 DeepSeek-V4-Pro-0813。
思考模式			支持非思考与思考模式（默认） 切换方式详见 思考模式	
上下文长度			1M 100万	
输出长度			最大 384K	
功能	Json Output JSON 输出		支持	支持
	Tool Calls 工具调用		支持	支持
	Responses API 响应API		支持	支持
	Anthropic API		支持	支持
	对话前缀续写（Beta）		支持	支持
	FIM 补全（Beta）		仅非思考模式支持	仅非思考模式支持
	图像理解		支持	不支持
价格 ⁽²⁾	百万tokens输入 (缓存命中)	空闲时段	0.02元	0.15元
		高峰时段	0.04元	0.30元
	百万tokens输入 (缓存未命中)	空闲时段	1元	4.5元
		高峰时段	2元	9.0元
	百万tokens输出	空闲时段	4元	13.5元
		高峰时段	8元	27.0元
并发限制 ⁽³⁾			2500	500

Sol主攻复杂工作，Luna瞄准高频低成本场景

两款模型定位有所区分，并非“同一模型不同价格”。

Sol面向更高能力需求的任务，包括复杂专业工作、编码和智能体场景。在AutomationBench企业跨应用工作流测试中，GPT-6 Sol在xhigh effort下得分33.2%，高于GPT-6 Astra在low effort下的30.3%，也高于Claude Opus 5 max effort下的26.9%；OpenAI称，Sol完成每项任务的成本仅为0.27美元。

Luna则更突出成本效率。OpenAI称，在AutomationBench高强度测试中，GPT-6 Luna较前代提升5.4个百分点，同时单项任务成本降低58%；在DeepSWE v1.1中，Luna最高得分66.6%，与Claude Opus 5和Fable 5中等强度表现相当，但每项任务成本分别低93%和96%。

在事实准确性方面，OpenAI内部测试显示GPT-6 Sol的错误数量约为前代一半；Luna在更高推理强度下可达到GPT-5.6 Sol的水平，成本约为后者的百分之一。OpenAI提示，该测试基于用户此前标记为事实错误的匿名ChatGPT对话，不代表所有真实使用场景。



先进Work和Codex，免费用户可体验Luna

在产品覆盖上，OpenAI此次未立即将Sol和Luna推入ChatGPT普通聊天界面。

根据安排，Plus、Pro、Business、Enterprise及Edu用户可在ChatGPT Work和Codex中使用两款模型，并开放API调用；免费版和Go版用户则可在桌面端应用中体验GPT-6 Luna。

这一安排使首发场景明显偏向工作和开发，而非面向大众消费者。Sol和Luna的低成本、高效率，也更适合需要频繁调用模型的编码任务、智能体工作流及企业内部自动化。与此同时，将部分高频需求导向成本更低的模型，或有助于OpenAI在扩大使用规模的同时缓解基础设施压力。

行业竞争从"拼旗舰"全面转向"拼规模与成本"

值得关注的是，OpenAI推出Sol和Luna之际，行业内部正同时讨论“AI开发是否应当放慢”。

本月早些时候，Anthropic CEO Dario Amodei公开呼吁放慢前沿AI发展速度，并警告快速推进可能带来风险；OpenAI CEO Sam Altman随后表示认同行业需要放慢前沿模型发展步伐、加强安全措施；OpenAI首席科学家Jakub Pachocki也提出，通过协调放慢未来AI开发是确保自我改进型AI安全的重要路径。

然而与此同时，OpenAI自身的产品迭代并未放慢：Astra发布不到三周即再推两款新模型，并将API价格直接下调50%。同日，Anthropic也推出Claude Opus 5.5，同样以更低运行成本为卖点。

一边讨论如何放慢AI发展速度，一边加快模型迭代、压低调用成本，AI行业正在进入能力与成本同时加速下探的新阶段。

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取



限免

352

收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

8 条评论





路人
23分钟前 中国广东省

会不会是本来各家企业早就可以有低消耗的水平，本想着价格垄断，最后被deepseek 打破了他们的价格平衡现在不得不减下来

👍 0 ↩ 回复



MobileUser3738
57分钟前 中国上海

市场监管总局赶紧出马打击恶意底价

👍 2 ↩ 回复



广告推销勿扰 7分钟前 中国山西省

回复 MobileUser3738：



👍 0 ↩ 回复



MobileUser8175
1小时前 中国

Deepseek开源的节省token算法都被采纳了，再加上他们数据中心建的多..

👍 0 ↩ 回复



MobileUser5192
1小时前 中国陕西省

国内要加油哦

👍 0 ↩ 回复



LordS
1小时前 中国湖北省

快！反内卷！

👍 2 ↩ 回复

