

摘要：

苏姿丰盛赞中国是全球最具活力的AI生态系统，称“全球一些最优秀的工作正在这里诞生”。AMD宣布推出面向中国开发者的免费公共AI云，并携手零一万物打造企业智能体一体机。苏姿丰同时承诺，AMD将持续加大在华投资，深度融入中国AI生态。

今日，在AMD AI开发者日2026上，AMD董事会主席兼CEO苏姿丰发表主题演讲，分享AMD的战略聚焦以及对大中华区的承诺。




“中国生态系统令人振奋之处，在于它真正践行着开放式创新。”苏姿丰说，中国是全球最具活力的AI生态系统，AMD在中国已有30多年历史，有超过4000名工程师，将中国视为驱动其产品路线图的核心力量，在多地设立AI卓越中心，并已与中国头部云计算及企业级公司全面合作。

苏姿丰此次来华行程紧锣密鼓，昨天下午刚在人民大会堂与国务院副总理会见，表态愿**拓展在华业务，持续加大在华投资**，今天一大早就现身大会Demo区，与开发者群体交流。

AMD高级副总裁、大中华区总裁潘晓明在开场发言时谈道，这是AMD AI开发者日首次来到中国上海，也是**AMD在北美之外的唯一一场AI开发者日**，希望汇聚全球AI生态伙伴，共享经验，深度交流。

在开幕式上，苏姿丰与零一万物创始人兼CEO李开复展开对谈。随后，AMD高级副总裁、计算与图形总经理Jack Huynh分别与李开复，AMD人工智能事业部高级总监Nick Ni，阶跃星辰联合创始人兼CTO朱亦博，清华大学电子工程系教授、IEEE Fellow、无问芯穹发起人汪玉教授进行对话。

现场，Jack Huynh援引小米MiMo大模型负责人罗福莉的话：“Agent时代不属于烧掉最多算力的人，而属于用得最聪明的人。”




Jack Huynh进一步补充说，未来五年的赢家，不会是租用最多GPU云端算时的团队，而是从第一天起就以效率为核心来设计的团队。

Nick Ni称，他了解到中国头部开发者一年在复杂编码任务和日常智能体任务的API调用上要花费数百万元，如果能在桌上的一台AMD工作站上本地运行数据中心级基础模型，就能大幅节省成本。

凭借Ryzen AI Max+ 395和Radeon工作站配置，AMD针对小米MIMO、阶跃星辰（StepFun）、MiniMax等中国前沿模型进行了优化，使用vLLM在本地运行，速度超过人类的阅读速度，没有云端延迟，不用付API账单，且数据留在本地。



Nick Ni宣布，AMD正在推出首个面向中国AI开发者的公共AI开发者云，搭载Radeon GPU，而且是免费的。此外，通过与魔搭和阿里云的合作，AMD GPU现在直接能在魔搭创空间中使用




AMD与零一万物联合打造了**企业智能体一体机**。该设备基于Ryzen AI Max+ 395，采用统一内存架构，可在本地同时运行**数百个Agent**，实现安全私密的本地化部署。



苏姿丰：全球一些最优秀的工作在中国诞生

AMD董事会主席兼CEO苏姿丰在开幕演讲中谈道，AMD的使命是突破高性能计算与AI计算的边界，AMD的技术每天触达数十亿人，从数据中心、PC到边缘设备，AI正在重新定义计算的每一个层面。

她引述了一组数据：当前全球活跃AI用户数已超**10亿**，未来五年有望突破**50亿**。



“我在科技行业深耕逾30年，但从未有哪个时代比今天更令人心潮澎湃。”苏姿丰分享说。

AI正处于转折点。过去几年，大语言模型不断演进，推理能力与智能体愈发普及。无论哪个国家，无论大中小型企业，每一位CEO都在谈论如何更有效地利用AI。AI已遍布整个生态系统，从大型云平台到PC，从边缘设备到物理系统乃至机器人，无处不在。

Agent正在彻底改变我们使用AI的方式。技术的演进要求不仅要有大语言模型，还必须具备推理、学习和数据流转能力，而Agent统筹协调这一切。

未来GPU将无处不在，不只局限于云端，而是真正遍布整个生态系统。同时，完整Agent运行还依赖大量CPU算力。

而AMD的核心聚焦，正是提供全面的端到端计算能力，为AI时代构建计算基础。



“在中国，Agentic AI和本地AI领域正在发生如此之多的创新。我们看到全球一些最优秀的工作正在这里诞生，我们珍视这份合作。”苏姿丰说，“我们的目标是与生态系统携手，与中国所有开源项目合作，将模型能力与前沿硬件真正融合。”



2026年，AMD将加速发展势头，重心在于为AI提供最佳算力，扩展计算技术领导力和数据中心领导力，构建开放的软件生态系统，通过ROCm软件栈和开发者生态系统，与大家共同合作，致力于将AI带入整个生态系统的每一个角落。



李开复：2026年的核心问题，是“AI能运营一个企业职能部门吗”

苏姿丰与零一万物创始人兼CEO、创新工场董事长李开复展开对谈。



李开复提到当下AI行业两个清晰的变化：第一，编程能力已经远远跨越了那道槛，自主智能体便成为可能。第二，单一智能体能做的事有限，多智能体架构则能打破局限性。

一个多智能体架构可以包含：擅长规划的智能体、负责批判的智能体、执行的智能体、风险控制的智能体，它们协同工作、相互辩论、彼此补充。零一万物正专注于构建这样的平台。

李开复说，如果说2024年的问题是“AI能完成一项任务吗”，2025年是“AI能完成一个完整的工作流吗”，那么2026年的问题就是“AI能运营一个企业职能部门吗”，终有一天，问题会变成整个公司。

这种架构也正是“一人公司”趋势背后的逻辑。借助模块化的多智能体框架，任何一位开发者都能作为宏观架构师，启动一家高效运转的公司。

在以智能体AI为核心的新范式中，你不再给AI智能体一个提示词，而是给它一个**组织目标**，然后智能体会自动协调、执行、衡量、优化并形成闭环。

李开复进一步谈道，CEO真正应该聚焦的，是能够改变公司损益表的事情。未来的产业AI转型将围绕两个不可妥协的企业核心命题展开：**数据主权与可见的投资回报**。

他还提到中国开源崛起背后深层的结构性原因——**有限的硬件资源**。出于现实需要，中国开源社区找到了自己的路，充分发挥了中国工程师的效率和协作精神。

“如果说硅谷的AI巨头像是渴望获得诺贝尔奖的天才，中国的AI生态则更像一个充满活力的去中心化学习小组，大家共同面对考试，相互学习，共同构建，即便在商业上存在竞争，在开源层面依然共享成果。”李开复说。

Jack Huynh：拆解AI部署路径三阶段，AMD如何助攻AI开发者

AMD高级副总裁、计算与图形总经理Jack Huynh谈道，到2030年，将有**50亿人**使用AI，几乎覆盖地球上的每一个人。PC普及花了45年，互联网花了27年，智能手机花了15年，与以往任何技术相比，AI的普及速度都是史无前例的。

推理Token需求的激增正在推动服务成本飙升，**算力已从成本问题演变为战略资源的竞争**。





对于AI开发者而言，一套更高效的方案究竟应该是什么样的？AMD给出的答案覆盖AI部署路径三个阶段：**开发、规模测试、部署**。



1、开发

算力不再是唯一的决定性制约因素，**内存**所扮演的角色远比以往重要得多。内存大小决定了能运行的模型规模和上下文窗口的长度，内存带宽决定了解码速度。



这正是AMD打造**Ryzen AI Max**的原因——**128GB**统一内存，能在本地运行**200B**前沿模型，整个模型置于同一内存池中，无需分片，无需卸载，带来如云端部署般的体验。搭载它的设备轻薄到可以放入背包里。



目前市面上已有超过**35款**搭载**Ryzen AI Max**的系统，其中许多在中国上市，涵盖笔记本电脑、一体机和紧凑型工作站。

2、规模化测试

Radeon AI Pro R9700 GPU专为那些需要超越笔记本性能、但尚未准备好将一切推入生产基础设施的开发者而打造，用于原型开发、微调与推理开发，旨在为开发者提供工作站加速能力。

AI工作负载涉及调度编排、数据移动和工具调用，需要多Agent同时运行。这就要有一颗能够跟上节奏的主机处理器——**Threadripper Pro 9000**，AMD称它是“**世界最快的工作站CPU**”，提供**128条PCIe 5.0**通道，可从单一主机支撑多块**Radeon AI Pro** GPU协同运行。



这意味着AI开发者可以在本地构建，在规模化环境中测试与模拟，以极具成本效益的方式优化部署方案。

3、部署

在AMD上构建的产品，其软件栈会持续成熟与演进。过去18个月，AMD持续加速，让开发者更轻松地基于开放标准、跨异构系统进行开发，不断简化从开发、交付到部署的整个过程。

Ryzen AI Max用于本地开发，Radeon AI Pro配合ROCm用于规模化测试，开发者可以立即让数十个Agent投入运行，不再受制于公有云会话限制或云端容量瓶颈，一切由开源软件生态驱动。

“二十年前，PC意味着一个人与一台机器。未来二十年，则是一个人指挥一组Agent团队。”Jack Huynh展开说，数百个Agent在靠近工作发生的地方运行，实现更快的循环、更可预期的算力，以及在灵感迸发后立即付诸实践的自由。



Nick Ni：已适配DeepSeek、MiMo等国产模型，AMD用Agent辅助构建AI软件平台

AMD人工智能事业部高级总监Nick Ni着重分享了AMD的软件投入——面向所有AMD GPU的ROCm统一软件平台，让任何AI模型都能在AMD硬件上进行训练和推理，做到几乎零摩擦。



ROCm有三大战略支柱：开源、抽象层、AI助手。



开源方面，通过Hugging Face和魔搭社区，ROCm现支持超过300万个模型，对DeepSeek、阿里Qwen、MiniMax、Kimi、阶跃星辰、小米MiMo等的前沿开源模型做到了Day0支持。



抽象层方面，如果开发者想编写自定义GPU内核，ROCm原生支持OpenAI Triton，还有 Gluon、TileLang、FlyDSL等新项目，让GPU编程的体验更接近写Python。

AI助手方面，AMD正在使用Agent来帮助构建ROCm本身，AI编写GPU内核、分析性能瓶颈、自动完成“基准测试→优化”的闭环。



AMD有数千个Agent在持续监控开源项目，识别AMD支持中的缺口，自动生成完整的PR（Pull Request），在工程师早上起床前就已完成自动测试。其工程师从每周提交几个PR，提升到了每天提交几个PR。

AI还可以辅助做性能优化。每个模型、每个推理负载、每次训练运行都有不同的内核特征，手动探索优化空间极其缓慢。Agent能生成内核排列组合，自动做性能分析并迭代，速度远超单个工程师。

面向开发者，AMD推出了AMD AI Playbooks（AI实践手册）网站，提供涵盖各类热门AI工作负载的分步指南，包括本地推理、强化学习、视频生成到微调等，Windows和Linux都支持。



AMD AI开发者计划提供免费云端算力券、超过100小时的教学内容、专属会员社群及技术支持，还构建了一个有趣的积分系统。

朱亦博：笔记本跑近200B阶跃星辰大模型，解码速度比很多云端API还快

阶跃星辰联合创始人兼CTO朱亦博谈道，阶跃星辰今年2月发布的Step 3.5 Flash模型，从设计之初就以智能体任务为核心目标，能够可靠地进行工具调用、高效运行。

该模型拥有约1960亿参数，其在4位量化后能在AMD平台上流畅运行，包括搭载AI Max+ 395的AMD笔记本电脑。模型需要大约100GB内存，而Ryzen AI Max+ 395恰好有128GB统一内存。

通过与AMD工程师合作优化，Step 3.5在AMD笔记本上解码速度接近每秒100个Token，甚至比很多云端模型API还要快。



朱亦博透露说，很快阶跃星辰将发布一个智能体能力更强的新模型，它可以继续在AMD平台上流畅运行。

他相信未来AI模型一定是端云协同，今天开发者使用云端大模型的Token成本正在急剧上升，如果能在本地运行一个足够强的模型，Token成本将趋近于零。

汪玉：与AMD联合设计物理AI推理框架，4个月揽星3.3K

清华大学电子工程系教授、IEEE Fellow、无问芯穹发起人汪玉看到行业中有一个巨大的鸿沟：AI的需求在以指数级增长，但高效且可负担的算力供给远远落后。

他认为，弥合这个差距，需要从芯片架构到应用层的跨层联合优化。



因此，他提出一个公式：


AI生产力 = 智能规模 × Token生产效率 × Token价值转化

一是**智能规模**。目前智能的瓶颈在于算力限制。无问芯穹开发了跨区域分布式训练技术，能将来自不同数据中心的算力汇聚成一个大规模集群，从而突破单一地点的算力约束。

二是**Token生产效率**，也就是每秒生成的Token数，目标是用更少的能耗产出更多的Token。其平台在软件与硬件的深度协同上进行了优化，尤其是在AMD芯片上，以释放每一笔计算的最大潜力。

三是**Token价值转化**。Token只有在解决真实问题时才有价值。无问芯穹已在基础设施中集成了百川Baichuan、智谱GLM、月之暗面Kimi等顶尖模型，帮助行业从生成文字走向创造价值。

在汪玉教授看来，产业正经历三个AI时代的演进：感知AI、生成式AI、智能体AI。未来十年将属于物理AI，即把智能从数字屏幕中带出来，通过具身系统融入物理现实。



一个方向是**强化学习**，让AI通过交互来学习。另一条有前景的路径是**世界模型**，让机器人在大脑中预测和模拟物理结果，这使得学习速度快上千倍，也更加安全。

但目前这些模型仍处于早期阶段，缺乏足够的物理世界数据。不过汪玉相信，世界模型最终会扩展到更大规模，变得更加有用和影响力。

无问芯穹与AMD合作开发了一个专为物理AI设计的大规模开源推理服务框架**RLinf**。它在短短四个月内就获得了超过3300个GitHub Star，成为最受欢迎的物理AI框架之一，被业界超过20家公司所采用。该框架已与AMD ROCm系统集成。



面向下一代教育，汪玉给出三点建议：第一，要成为AI原住民，不要只是学习AI，而要使用AI；第二，要培养品味，当AI能提供所有答案的时候，最重要的能力是提出有价值的问题；第三，要解决真实的问题。真正的创新发生在顶尖研究者遇到现实世界的挑战之时。

结语：包揽AI软硬件开发需求，AMD积极融入中国AI生态

面向爆发式增长的AI算力需求，身为极少数能够提供全栈AI产品的厂商之一，AMD希望构建一条通往更高效构建的路径。

今天，面向中国AI开发者，AMD既提供从终端、边缘到数据中心的广泛AI产品组合，又提供加速开发的开放软件栈，还附送起步所需的各种资源，足见对中国市场及生态的看重。



近年来，中国AI生态在过去几年走出了一条与硅谷不同的路径，硬件资源受限催生了极致的开源协作和工程效率，模型迭代密度全球领先，落地场景更加复杂和下沉。

作为老牌芯片巨头，AMD如何深入中国本土，与中国AI开发者们碰撞出创新的叙事，值得持续期待。

本文来源：[芯东西](#)

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

VIP会员·7天畅读卡 | 大师课·入门串讲

扫码

免费领取

限免

114 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论