

摘要：

AI需求正以"垂直之墙"之势狂飙—Anthropic单季收入暴增130%至109亿美元，OpenAI一季度狂揽57亿美元超过去年上半年收入，谷歌Token处理量同比飙升7倍。然而算力瓶颈与人才稀缺持续，前沿模型成本不降反升，GPT-5.5定价直接翻倍。花旗表示，AI基础设施已成绝对卖方市场，供需错位正推动算力成本上行、定价体系分层。

AI行业正在经历一场史无前例的需求爆炸。

5月25日，据追风交易台消息，花旗（Citi）在最新发布的《推理前瞻》系列研究报告中，用一个词精准描述了当前态势——“需求的垂直之墙”（Vertical Wall of Demand），这一说法最初由OpenAI首席财务官Sarah Friar提出，如今已被一系列硬核数据所印证。

**报告揭示了一组令人瞩目的数据：**Anthropic预计2026年第二季度收入将达到**109亿美元（环比暴增130%）**，而OpenAI仅在2026年第一季度就实现了**57亿美元**的收入。然而，真正的市场博弈在于：

这种垂直爆发的需求，正迎头撞上增长缓慢的“倾斜式”供应曲线。**算力成本和推理成本正在显著上升**，OpenAI等头部企业开始通过1-3年的长期合同锁定客户算力，而顶尖人才的短缺更是加剧了供应链的紧张。

报告的核心结论非常明确——**AI基础设施和稀缺的推理能力已成为绝对的卖方市场**，科技巨头正通过激烈的定价分层来榨取利润，而谁能最终捕获AI的“生产力红利”（是传统软件供应商、AI平台、客户还是劳动力），将是下一阶段资本市场定价的核心主线。

## 需求端信号：企业级AI采用率呈“垂直墙”式爆发

各项使用量、算力承诺和企业人员调整数据均表明，AI需求仍在加速，且处于早期阶段。

### 。收入与使用量呈现指数级增长：

Anthropic预计2026年第二季度收入将从一季度的48亿美元飙升至109亿美元，环比增长130%；预计到2026年二季度末，其年度经常性收入（ARR）将达到约500亿美元，远高于3月份的300亿美元。

OpenAI同样表现惊人，仅2026年一季度就报告了57亿美元的收入，而2025年上半年的总收入仅为约43亿美元。

此外，谷歌目前每月的Token处理量高达**3.2Q（千万亿）**，同比**激增7倍**。

### 。劳动力市场的边际信号： Intuit、Meta和Cisco近期的裁员行动，成为了AI采用率产生实际影响的潜在信号。

这进一步引发了市场关于谁将真正获得AI“生产力红利”的激烈辩论，尤其是在基础设施容量受限已经开始在边际上影响需求的情况下。

## 供给端约束：算力商业化与顶尖人才成为绝对瓶颈

面对垂直的需求，前沿AI实验室正被迫以类似云计算的机制来商业化其稀缺的资源。

- **长期算力锁定模式开启：**OpenAI推出了全新的“保证容量”模型，允许客户做出1到3年的算力承诺，以换取按年度承诺规模递增的Token折扣。
- **巨头结盟与人才争夺：**Blackstone与谷歌云的合作，以及Anthropic近期的推理交易，都反映出算力即服务（compute-as-a-service）和预留实例模式的必然趋势。

同时，Andrej Karpathy加入Anthropic的事件提醒市场：在实现前沿AI能力方面，供应链最严重的瓶颈依然存在于顶尖劳动力层面。

## 推理经济学：定价分层加剧，前沿模型成本飙升

尽管基础访问层的竞争日益激烈，但前沿AI推理的成本毫无通缩迹象，供应商正通过订阅级别和高级推理的溢价来积极细分市场。

- **订阅模式的精细化收割：**谷歌将其顶级的AI Ultra订阅价格从每月250美元降至200美元，并针对“生产型消费者（prosumers）”推出了每月100美元的新层级（使用上限是Pro计划的5倍，并捆绑了YouTube Premium）。这一举措显示出Google在扩大用户基础与维护高端定价之间的精细平衡。
- **前沿模型成本不降反升：**GPT-5.5的价格是GPT-5.4的两倍，同时AI实验室正在逐步淘汰旧模型。这表明供应商正在通过订阅层级和高级推理溢价，更激进地对市场进行细分。

花旗的渠道调研显示，OpenRouter针对GPT-5.5的成本分析显示，按工作负载细分，成本增加了49%至92%，尽管这部分被完成Token数量减少19%至34%所抵消。

渠道调研表明，这种成本上升已经在边际上对企业的AI采用产生了影响，意味着企业在享受更强大大模型能力的同时，也面临更高的推理成本压力。

## 模型发布与监管前瞻：Blackwell模型将至，监管框架酝酿中

在技术催化剂和政策监管方面，市场即将迎来新的变量。

- **技术催化剂：**继Mythos之后，首批基于Blackwell架构训练的模型即将在近期发布，这将成为竞争格局中的下一个重要技术催化剂。
- **当前前沿模型排行榜**（基于Artificial Analysis智能指数）显示，OpenAI的GPT-5.5（xhigh）以60分位居榜首，混合定价为每百万token **4.35美元**；Google的Gemini 3.1 Pro Preview和Anthropic的Claude Opus 4.7（max）并列第二，均为57分，但Google定价更具竞争力，仅为每百万token **1.74美元**，而Claude Opus 4.7为**4.10美元**。


Figure 5. Frontier Model Leaderboard

| Model Provider | Leading Model                 | Artificial Analysis Intelligence Index | Speed (Output Tokens/ Second) | Blended Price (USD/ 1M Tokens) | Context Window (1K Words) | Release Date  |
|----------------|-------------------------------|----------------------------------------|-------------------------------|--------------------------------|---------------------------|---------------|
| OpenAI         | GPT-5.5 (xhigh)               | 60                                     | 68                            | \$4.35                         | 922                       | Apr. 23, 2026 |
| Google         | Gemini 3.1 Pro Preview        | 57                                     | 119                           | \$1.74                         | 1000                      | Feb. 19, 2026 |
| Anthropic      | Claude Opus 4.7 (max)         | 57                                     | 51                            | \$4.10                         | 1000                      | Apr. 16, 2026 |
| Moonshot AI    | Kimi K2.6                     | 54                                     | 81                            | \$0.70                         | 256                       | Apr. 21, 2026 |
| Xiaomi         | MiMo-V2.5-Pro                 | 54                                     | 57                            | \$0.71                         | 1000                      | Apr. 22, 2026 |
| DeepSeek       | DeepSeek V4 Pro (Max)         | 52                                     | 30                            | \$0.71                         | 1000                      | Apr. 24, 2026 |
| Z.ai           | GLM-5.1                       | 51                                     | 55                            | \$0.90                         | 200                       | Apr. 7, 2026  |
| Alibaba        | Qwen3.6 Plus                  | 50                                     | 52                            | \$0.43                         | 1000                      | Apr. 2, 2026  |
| MiniMax        | MiniMax-M2.7                  | 50                                     | 50                            | \$0.22                         | 205                       | Apr. 12, 2026 |
| Mistral        | Mistral Medium 3.5            | 39                                     | 164                           | \$2.10                         | 256                       | Apr. 29, 2026 |
| NVIDIA         | NVIDIA Nemotron 3 Super       | 36                                     | 168                           | \$0.28                         | 1000                      | Mar. 11, 2026 |
| Amazon         | Nova 2.0 Pro Preview (medium) | 36                                     | 144                           | \$1.47                         | 256                       | Nov. 27, 2025 |
| Inception      | Mercury 2                     | 33                                     | 779                           | \$0.14                         | 128                       | Feb. 24, 2026 |
| Arcee AI       | Trinity Large Thinking        | 32                                     | 125                           | \$0.24                         | 512                       | Apr. 1, 2026  |
| Meta           | Llama 4 Maverick              | 18                                     | 109                           | \$0.34                         | 1000                      | Apr. 5, 2026  |
| InclusionAI    | Ling-flash-2.0                | 16                                     | 83                            | \$0.18                         | 128                       | Sep. 16, 2025 |
| Baidu          | ERNIE 4.5 300B A47B           | 15                                     | 23                            | \$0.36                         | 131                       | Jun. 30, 2025 |
| Cohere         | Command A                     | 13                                     | 38                            | \$3.25                         | 256                       | Mar. 13, 2025 |
| IBM            | Granite 4.1 8B                | 12                                     | 118                           | \$0.06                         | 131                       | Apr. 28, 2026 |
| AI21 Labs      | Jamba 1.7 Large               | 11                                     | 56                            | \$2.60                         | 256                       | Jul. 7, 2025  |

© 2026 Citigroup Inc. No redistribution without Citigroup’s written permission.  
Artificial Analysis has not yet released output speeds for GPT-5.5.  
Source: Citi Research, Artificial Analysis

- 未来模型发布时间表方面，花旗预计2026年二季度将有多款重磅模型发布，包括Gemini 3.5 Pro、Claude Sonnet 4.7、Jamba2 Large等；三季度预计GPT-6.0和Qwen 4将亮相；四季度则有Claude Opus 5和Sonnet 5、DeepSeek V5等重量级产品。

Figure 4. Projected Model Releases



© 2026 Citigroup Inc. No redistribution without Citigroup’s written permission.  
Source: Citi Research

- 监管框架的介入： 报告指出，美国政府正在准备一项自愿框架，要求前沿AI实验室在公开发布前90天向政府提供符合条件的前沿模型，这种发布前访问权还可能扩展到关键基础设施提供商。

虽然这与Anthropic处理其Mythos模型的方法类似，但原定签字仪式的推迟表明该框架可能还会迎来修订。

以上精彩内容来自[追风交易台](#)。

更详细的解读，包括实时解读、一线研究等内容，请加入 [【追风交易台·年度会员】](#)



# 追风

RISK CHASE

全球宏观研究 | 交易 | 配置

你 / 不 / 能 / 错 / 过

## 什么是“追风交易台”

追风交易台由顶流全球宏观资讯及研究团队联手打造。

我们的目标是给中国投资者提供专业、独到和适时的全球金融市场研究。

## 在这里，你将看到

### 最专业的解读

来自全球顶尖投行、研究机构、  
一线从业者的最新解读



### 最独到的视角

以全球市场第一线的视角  
感知市场动向



### 最适时的时机

快速、完整、准确  
最终汇集成适时



## 如果你

关心全球宏观经济和资本市场

## 如果你

苦恼于没有合适的信息和研究



关注“追风交易台”  
成为“追风会员”

你将身处全球市场第一线



公众号 · 追风交易台

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 240     收藏

分享到:  

写评论

请发表您的评论

 表情     图片

发表评论