


摘要：

Anthropic发布Claude Haiku 5.5，输入Token最低价格降至每百万0.1美元，较上代下降90%，部分基准测试超过GPT-6 Luna。随着Agent规模化，小模型正成为降低调用成本的关键。

同志们，Anthropic 又来卷价格了。这次轮到 Claude 家族里最便宜的 Haiku。

10月7日，Anthropic 正式发布 Claude Haiku 5.5 ，号称自家迄今速度最快、能力最强、价格最低的小模型。

最夸张的是价格，每百万输入Token 最低只要 0.1美元，相比上代直接降价90%。



性能也没落下。按照 Anthropic 公布的测试结果，Haiku 5.5 在计算机操作、知识工作、Agent 编程等多个基准上超过 OpenAI 的 GPT-6 Luna，部分成绩甚至拉开了不小的差距。

而且，Haiku 5.5 还引入了可调节的推理强度，支持 100万Token 上下文窗口和最高 12.8万 Token 输出。

至此，Anthropic 在短短 15 天里完成了 Claude 5.5 全家桶的更新：9 月 22 日 Opus 5.5 登场，9 月 28 日 Sonnet 5.5 发布，如今 Haiku 5.5 也正式加入。

这次，Anthropic 把重点放在了那些调用量巨大、对价格极其敏感的 AI 任务上。


多项成绩超过 GPT-6 Luna，计算机操作成功率 72.4%

按照 Anthropic 公布的 Benchmark 成绩，Haiku 5.5 相比上一代实现了大幅提升，在部分测试中还取得了比 GPT-6 Luna 更好的成绩。

	Haiku 5.5	Haiku 4.5	GPT-6 Luna	Sonnet 5.5 For reference
Knowledge work GDPval-AA v2.1	1620	735	1437	1840
Knowledge work AA-Briefcase v1.1	1578	614	1336	1824
Computer use OSWorld 2.1	72.4% Offline subset	15.7% Offline subset	48.9% Offline subset	83.9% Offline subset
Multidisciplinary reasoning Humanity's Last Exam	45.9% no tools	10.2% no tools	—	56.9% no tools
	57.4% with tools	18.7% with tools	—	64.5% with tools
Agentic coding Terminal-Bench 4.0	39.2%	0.0%	16.4%	70.6%
Agentic coding FrontierCode 1.1 (Main)	46.4%	—	42.4%	52.1% Xhigh
Visual reasoning Chartography	46.4% no tools	6.4% no tools	29.1% no tools	61.6% no tools

其中最显眼的成绩来自 OSWorld。这是一项衡量 AI Agent 操作真实计算机能力的测试，要求模型完成跨应用、多步骤的操作任务。

在 OSWorld 2.1 离线任务子集上，Haiku 5.5 取得 72.4% 的成功率，上一代 Haiku 4.5 只有 15.7%，GPT-6 Luna 则为 48.9%。



知识工作方面，Haiku 5.5 在 GDPval-AA v2.1 中取得 1620 分，超过 GPT-6 Luna 的 1437 分。Agent 编程测试 Terminal-Bench 4.0 中，两者成绩分别为 39.2% 和 16.4%。

不过，这些数据还有一个重要细节。**Haiku 5.5 的最高 Benchmark 成绩，往往需要付出更多推理计算。**

Haiku 5.5 首次在 Haiku 系列中引入可调节推理强度，开发者可以通过 effort 参数控制模型投入多少计算资源。

媒体 VentureBeat 注意到，在 Anthropic 公布的 Terminal-Bench 测试中，39.2% 的成绩对应最大推理强度。切换至中等推理强度后，成绩降至约 20%，而中等强度正是 Haiku 5.5 的默认设置。

第三方评测机构 Artificial Analysis 也观察到了类似现象。在其 Intelligence Index 评测中，Haiku 5.5 最大推理强度获得 43 分，中等推理强度为 34 分。同一评测下，平均每项任务成本分别约为 0.21 美元和 0.05 美元。

也就是说，模型可以通过增加推理预算换取更好的任务表现，但实际花费也可能明显增加。

Artificial Analysis 在自己的 Terminal-Bench 4.0 测试中，测得最大推理强度 33%、中等强度 15% 的成绩。由于评测设置不同，这组数字与 Anthropic 官方结果存在差异。

这也是为什么看待小模型性能时，需要同时考虑推理强度、任务完成率和实际成本。

在更复杂的 Agent 编程任务上，Sonnet 5.5 依然具有明显优势：Terminal-Bench 4.0 成绩达到 70.6%。

Anthropic 也明确表示，**Sonnet 和 Opus 仍然更适合复杂的 Agent 编程任务，Haiku 的优势集中在高频、范围明确的工作中。**

价格直接砍到一折，和 GPT-6 Luna 正面竞争

如果说性能提升让 Haiku 5.5 有了竞争力，那么价格可能才是此次发布最重要的看点。Anthropic 为新模型设计了两档 API 价格。

Price per 1 million tokens	Haiku 5.5 prompts up to / over 100k	Haiku 4.5	Sonnet 5.5
Cache reads	\$0.01 / \$0.05	\$0.10	\$0.10
Cache writes	\$0.125 / \$0.625	\$1.25	\$2.50
Input tokens	\$0.10 / \$0.50	\$1.00	\$2.00
Output tokens	\$0.50 / \$2.50	\$5.00	\$10.00

对于提示长度不超过 10 万 Token 的请求，Haiku 5.5 的输入、输出单价都比上一代降低 90%。超过这个门槛，价格仍比 Haiku 4.5 低 50%。

Anthropic 表示，上一代 Haiku 约 90% 的请求都处于 10 万 Token 以内。结合不同请求长度和 Token 消耗变化，公司预计 Haiku 5.5 完成**同类任务的平均成本**下降约 75%。

这里还有一个容易忽略的细节——Haiku 5.5 换用了新的 Tokenizer。根据官方开发者文档，同一段文本在新模型中产生的 Token 数量，可能比 Haiku 4.5 多约 30%，具体增幅取决于内容。因此，API 单价下降 90%，并不代表每项任务的账单都能减少 90%。

另一个值得关注的对手是 GPT-6 Luna。OpenAI 给出的 Luna 基础定价同样为每百万输入 Token 0.1 美元、输出 0.5 美元，缓存读取价格也与 Haiku 5.5 的低价格档一致。

不过，两家公司的长上下文计费门槛存在明显差异。

Haiku 5.5 在提示超过 10 万 Token 后进入更高价格档；GPT-6 Luna 则在输入超过 27.2 万 Token 后才触发长上下文加价。**这意味着，在 10 万至 27.2 万 Token 之间的请求中，Luna 的单位 Token 价格具有优势。**



至于最终完成一项任务哪款模型更省钱，还需要结合实际 Token 用量、推理预算和任务成功率判断。

放到整个市场来看，Anthropic 也在向其他低价模型施加压力。

VentureBeat 列出的同期 API 价格显示，Google Gemini 3.5 Flash-Lite 每百万输入 Token 价格为 0.3 美元、输出 2.5 美元；Gemini 3.8 Flash 分别为 0.75 美元和 3.75 美元。

当然，不同模型的能力定位、缓存策略和任务表现各不相同，这些数字首先反映的是 API 价格竞争。

小模型价格战，正在进一步升级。

一周 800 万次调用，企业开始让小模型给大模型打工

Haiku 5.5 到底适合干什么？

Anthropic 给出的场景包括**文档摘要、信息分类、数据库查询、上下文压缩，以及在复杂 Agent 工作流中担任 Subagent。**

这背后有一个很现实的问题：如今的 Agent 越来越复杂，一项任务往往需要多次调用模型。如果每个步骤都交给大模型处理，成本会快速累积。

金融 AI 公司 Rogo 提供了一个例子。在它的工作流中，一个能力更强的大模型负责制作财务演示文稿。处理其中某张幻灯片时，Haiku 5.5 Subagent 进入企业 10-K 年报，找到需要的业务收入数据，再把结果交给主模型。

对这种任务，模型需要快速、准确地完成信息查找和提取。Rogo 认为，Haiku 5.5 在准确率、速度和价格之间达到了适合大量重复调用的平衡。

企业内容管理平台 Box 也给出了早期测试结果。相比 Haiku 4.5，**Haiku 5.5 的内部评测成绩提高 11 分，延迟下降约 50%。**

Box 表示，这让新模型适合成本报告、财务摘要、周期性审查等需要规模化运行的分析工作。不过，Box 没有公开完整的评测标准。

Asana 的测试则覆盖 Bug 分类、项目建立、大型项目组合搜索等 Agent 任务。根据其披露的结果，相比当前使用的模型，Haiku 5.5 让任务完成延迟降低超过 30%，单轮 Agent 推理速度最高提升 2.5 倍。

另一个更能体现成本价值的例子来自 AlphaSense。这家公司的 Ask in Document 功能每周需要处理约 800 万次调用，主要回答针对一份或几份文档的具体问题。

在 400 个测试查询中，Haiku 5.5 的内部评测得分达到 0.84，而 Haiku 4.5 为 0.76。

如果一款模型每周要被调用数百万次，哪怕每次只节省很少的钱，长期累积下来的成本变化也可能相当可观。

这些数据来自 Anthropic 披露的早期客户反馈，具体工作负载、对照模型及评价标准并不完全一致，还需要更多独立测试。



Sonnet 跟着降价，Claude 5.5 全家桶开始拼成本

除了 Haiku 5.5，Anthropic 还同步调整了 Sonnet 5.5 的定价。从 10 月 7 日起，Sonnet 5.5 的缓存读取费用降低 50%，从每百万 Token 0.2 美元降至 0.1 美元。

Anthropic 预计，这项调整可以让多数 Agent 工作负载的成本再降低约 20%，实际降幅取决于应用重复使用缓存上下文的程度。

对于需要反复读取长对话历史、工具说明和任务上下文的 Agent 来说，缓存成本会直接影响系统的长期运行开销。

Anthropic 同时为 Claude Max 和 Team 订阅用户推出每月 API 额度：Max 5x 用户 100 美元，Max 20x 用户 200 美元，Team 用户共享最高 500 美元。

这些额度可用于 Claude 平台上的模型调用，鼓励更多订阅用户尝试构建自己的 Agent 和应用。

开发者方面，Haiku 5.5 已通过 Anthropic API、Amazon Bedrock、Google Cloud 和 Microsoft Azure 等平台提供服务，API 模型 ID 为 claude-haiku-5-5。

Anthropic 也更新了 Python 和 TypeScript SDK，新增处于 Beta 阶段的浏览器操作与计算机操作支持。

至此，Claude 5.5 系列的产品分工已经相当清楚。

Opus 5.5 负责高难度、复杂推理任务，Sonnet 5.5 覆盖日常复杂工作与编程，Haiku 5.5 则主攻调用量大、成本敏感、要求快速响应的任务。

从 9 月 22 日到 10 月 7 日，Anthropic 用了 15 天完成这一轮产品更新，**三个型号都在强调性能和成本效率。**

Haiku 5.5 的发布，也让一个趋势更加明显。随着 Agent 逐渐从演示走向实际应用，开发者必须考虑整套系统的调用成本。一次任务里哪些步骤需要更强的模型、哪些可以交给小模型，以及不同模型之间如何分配工作，都会影响最终的商业可行性。

对 Anthropic 来说，Haiku 5.5 最有吸引力的地方，或许就在这里：**它让更多原本因调用成本过高而难以规模化的任务，开始具备经济上的可行性。**

小模型的竞争，已经开始深入 Agent 系统的每一个执行环节。

本文来源：[机器之心](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

151 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论