

摘要：

Kimi K3发布48小时后，月之暗面宣布算力紧缺，暂停C端新用户订阅。花旗和美银分别指出，K3的发布非但不会削弱硬件投资逻辑，反而可能促使算力消耗上升。招商证券指出，单颗芯片性能已经无法单独决定系统能力，芯片之间高效通信、内存资源统一等各个维度逐渐成为影响算力效率的关键因素。

开源大模型从未如此接近全球顶尖水平——但也从未以如此戏剧性的方式，证明算力需求远未到顶。

7月17日，月之暗面发布新一代旗舰模型Kimi K3。在权威的Text Arena综合排行榜中，该模型以1486分位列第9名，成为首个进入全球前十的开源模型。

更引人注目的是，在Fronted Code Arena榜单中，Kimi K3以1679分超越Anthropic的Claude Fable 5登顶第一，前端代码7个细分方向中的6个排名首位。

然而，K3发布后48小时内，因用户请求量大幅超出预估并逼近集群承载极限，月之暗面不得不在7月19日宣布暂停C端新用户订阅——一款开源模型的发布，竟以「算力不足」收场。

这种看似矛盾的现象，恰恰揭示了当前AI行业最核心的争论：更高效的模型，究竟是削减还是放大硬件需求？

从第38名到第9名：开源首次撕开前十防线

Kimi K3的排名跃升幅度极为显著。上一代Kimi K2.6在Text Arena仅排第38位，K3一举跃升至第9名。

招商证券策略研究在最新周报中指出，此前开源模型中排名最高的通义千问3.7-max-preview位列第18，K3的出现标志着开源模型首次在综合文本评测中与全球顶级闭源模型进入同一梯队。

分项来看，K3在创意写作、代码生成和指令遵循三个核心类别均进入前十，在物理与社会科学、法律与政府、医疗健康等专业领域排名第一，商业管理与金融运营排名第三。

技术层面，K3总参数2.8万亿，采用Kimi Delta Attention与Attention Residuals架构，配合Stable LatentMoE实现896个专家中每token仅激活16个的高稀疏度。据官方测算，整套架构的扩展效率较Kimi K2提升约2.5倍。

登顶即「熔断」：算力瓶颈的反向证据

K3发布后最戏剧性的一幕并非排名，而是订阅熔断。Kimi在公告中披露，过去48小时用户请求量逼近集群承载极限，公司即日起暂停C端新用户订阅，全力推进算力扩容。

这与高盛此前的预判形成了直接冲突。高盛合伙人Rich Privorotsky曾指出，一家无法匹配西方最大规模预训练算力的中国实验室，通过架构创新迅速缩小了与顶尖美国模型的差距，并据此警告「扩展不再是唯一制胜路径」。

但Kimi的订阅熔断提供了反向事实——当模型性能真正获得市场认可时，算力缺口反而以更猛烈的方式出现。

韩国Meritz证券在7月19日的报告中也明确回应了这一争论。报告将K3与DeepSeek冲击区分开来：DeepSeek核心叙事是600万美元极低成本训练，而K3并未披露训练成本，且官方建议至少64颗高性能芯片组成的超节点环境部署。

从使用成本看，K3每次任务处理成本0.95美元，与GPT-5.6 Sol的1.04美元及Claude Fable 5的2.75美元处于同一量级。

闭源护城河收窄，但「杰文斯悖论」正在生效

招商证券研究进一步指出，开源模型对闭源最直接的冲击来自性能追赶。

Stanford AI Index 2026显示，截至3月，顶级闭源模型相对顶级开源模型领先约3.3%，差距已不足以支撑闭源在所有场景维持高溢价。Epoch AI的研究则显示，最强开放权重模型平均落后最强闭源模型约4个月。

从token消费趋势看，Silicon Data LLM Token Expenditure Index自6月起持续回落，反映出AI服务正经历类似云计算的发展路径——通过成本下降推动使用规模扩大。

根据OpenRouter数据，截至7月6日全球周调用量已达52.6万亿token，以DeepSeek、通义千问为代表的开源模型凭借性价比多次在周调用量上领跑全球。

花旗分析师将K3视为AI产业链中「杰文斯悖论」的潜在案例：**技术效率降低单位成本后，使用量可能大幅增加，最终资源总消耗不降反升。**

美银证券也指出，若中国开源模型持续逼近，**美国前沿AI实验室更可能增加而非减少算力投入，以维持差异化。**

超节点崛起：进入系统级竞争

当算力需求持续扩张而单颗芯片性能已无法独立决定系统能力时，超节点成为AI基础设施演进的核心方向。

招商证券在周报中介绍，超节点是通过高速、低时延的Scale-up互联，将数百乃至数千颗AI加速芯片连接为统一逻辑计算单元的新型高密度算力系统。

2026年WAIC上，华为昇腾950超节点真机首次公开亮相，支持最高1024卡级别部署，提供1EFLOPS级FP8算力和256TB统一内存编址空间。

根据BCC Research预测，全球数据中心网络技术市场规模将从2025年的458亿美元增长至2030年的1030亿美元，年复合增速约17.6%。

Research and Markets预计AI高速互联市场规模将从2025年的103.1亿美元增长至2030年的301.7亿美元，年复合增速约23.9%，增速显著高于传统数据中心网络。

对投资者而言，Kimi K3的发布传递了一个清晰的信号：开源模型的能力突破不会削弱对底层硬件的需求，效率提升释放的新增工作负载正在将行业竞争焦点从模型本身，推向支撑模型运行的算力基础设施。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



写评论

请发表您的评论

 表情  图片

发表评论