摘要：

RoboColiseum评测显示，Claude Opus 5.5以76.28%的总分略胜GPT-6 Astra，但四款顶尖大模型在通用操作上均不及专用策略模型。测试还揭示，图像质量、动作反馈和历史记忆是影响机器人表现的关键因素，灵巧手与精细操作仍是大模型的明显短板。

如今，AI正式杀入物理世界！

在具身能力方面，语言模型到底谁能称王？

更残酷的问题是，机器人公司耗费数年苦练的本领，会被通用LLM直接碾压吗？

就在今天，GPT-6 Astra、GPT-6.1 Sol、Claude Opus 5.5 以及 Gemini 4 Argon 等全球最顶尖的多模态大模型齐聚一堂。

在常态化具身智能仿真评测平台 **RoboColiseum（机器人角斗场）** 上，它们展开了一场真刀真枪的「肉搏战」。

这份榜单不仅彻底炒热了具身智能圈，更无情地揭露了当前顶尖大模型在控制机器人时的「隐藏命门」！

揭榜时刻：四模型大乱斗，结果令人意外

本次测试，所有的顶尖模型都接入了统一的控制框架 **Agent2Act**，在同样的任务、同样的指令下接受大考。

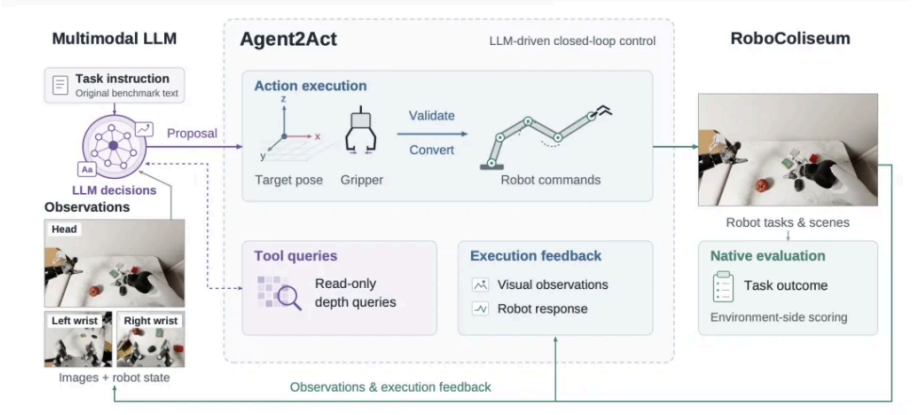


Fig. 1. Agent2Act's LLM-driven control loop. The multimodal LLM uses task context and observations, queries read-only sensor evidence, and proposes actions. Agent2Act validates and converts proposals into robot commands; subsequent observations, robot responses, and task progress inform the next decision. RoboColiseum determines task outcomes through native evaluation. Camera panels show recorded observations.

- **Claude 摘得桂冠，「高智商、低动手」成通病**

在综合榜单中，**Claude Opus 5.5 爆冷击败 GPT-6 Astra**，以 76.28% 的总分拿下四款大模型中的第一。GPT-6 Astra 以 75.99% 紧随其后。

TABLE I. Four-model comparison: Overall and four track scores (%), ordered by Overall.

Model	overall	instr	spatial	manip	robust
Claude Opus 5.5	**76.28**	96.60	**82.50**	**46.70**	79.30
GPT-6 Astra	75.99	**99.35**	78.33	45.86	**80.42**
GPT-6.1 Sol	70.91	95.50	77.71	40.01	70.40
Gemini 4 Argon	66.86	85.89	69.38	38.79	73.36

Bold values denote the highest reported score in each column. Astra, Sol, and Opus use `high` reasoning effort; Argon uses `medium`.

公众号 · 新智元

最令人兴奋的是，在「指令跟随」和「空间理解」这两个极其考验「脑力」的赛道上，**大模型的得分碾压了传统的机器人专用策略模型**。

但是！ 一到了「通用操作」环节（比如开门、倾倒、上货等需要复杂动作的任务），四大顶尖模型全军覆没，统统落后于专用 Policy 模型Paimon。

TABLE III. Model leaderboard: Overall and four track scores on a 0–1 scale.

Rank	Model	Overall	Instruction Following	Spatial Reasoning	General Manipulation	Robustness
1	Paimon	**0.7754**	0.8961	0.6791	**0.6613**	**0.8653**
2	HiDream-O1-Embodied	0.7692	0.8913	0.7437	0.6442	0.7978
3	**Claude Opus 5.5**	0.7628	0.9660	**0.8250**	0.4670	0.7930
4	**GPT-6 Astra**	0.7599	**0.9935**	0.7833	0.4586	0.8042
5	**GPT-6.1 Sol**	0.7091	0.9550	0.7771	0.4001	0.7040
6	DM0.5	0.7076	0.8444	0.6146	0.6370	0.7344
7	**Gemini 4 Argon**	0.6686	0.8589	0.6938	0.3879	0.7336
8	GigaBrain-0.7	0.6504	0.8166	0.4729	0.6320	0.6800

Light blue rows denote multimodal models evaluated through Agent2Act; bold numeric values denote the highest reported score in each column. External entries come from the official RoboColiseum Overall leaderboard and retain their respective training and execution settings.

公众号 · 新智元

结论： 现在的顶尖大模型是典型的「眼高手低」——脑子转得极快，空间方位算得极准，但一让它做复杂的连贯物理动作，立马手忙脚乱。

◦ **各有所长，不看总分看「绝活」**

这场角斗并不是单维度的碾压，四个模型各有千秋：

Claude Opus 5.5堪称全能王者，空间理解和通用操作能力领跑全场。

GPT-6 Astra是听话小能手，在「指令跟随」和「扰动抵抗」上稳居第一。

而GPT-6.1 Sol是性价比之王！在参考价格和 Token 消耗下，它展现出了极佳的成本控制，是落地应用的高性价比之选。

Gemini 4 Argon虽然总分垫底，但它的「抗扰动」能力出人意料地超越了 Sol，且在「包裹分拣」这种长程任务上表现极其惊艳。

大模型的「阿喀琉斯之踵」——看图怕糊

如果机器人的摄像头稍微有点噪点，或者光线不太好怎么办？测试结果让人捏了一把汗：**图像质量变差，是所有大模型共同的致命弱点！**

在加入噪点、镜头遮挡等图像质量扰动后：

> Claude 分数下降 0.20

> Gemini 下降 0.26
>
> Astra 下降 0.32
>
> **Sol 直接暴跌 0.77分！**

也就是说，加点马赛克，AI 就直接「双目失明」。这给未来的真机部署敲响了巨大的警钟。

TABLE VII. Robustness by perturbation type, compared with each model's Instruction Following (IF) baseline. Scores and Δ are on a 0–1 scale, rounded to two decimal places; Δ is the IF baseline minus the perturbation score.

	GPT-6 Astra		GPT-6.1 Sol		Claude Opus 5.5		Gemini 4 Argon	
Setting	**Score**	**Δ**	**Score**	**Δ**	**Score**	**Δ**	**Score**	**Δ**
IF baseline	0.99	—	0.96	—	0.97	—	0.86	—
Background and lighting	0.84	0.16	0.80	0.16	0.81	0.16	0.78	0.08
Camera position	0.85	0.14	0.86	0.10	0.77	0.20	0.72	0.14
Image quality	0.68	**0.32**	0.18	**0.77**	0.76	**0.20**	0.60	**0.26**
Instruction phrasing	0.86	0.13	0.85	0.11	0.79	0.18	0.77	0.09
Initial pose	0.79	0.20	0.83	0.12	0.84	0.13	0.80	0.06

Bold identifies the largest baseline gap for each model across the five perturbation types. Gaps are calculated before rounding.

公众号 · 新智元

「认识」不等于「会用」

测试中出现了一个非常经典的画面（端锅任务）：大模型明明认出了那是一口锅，但它抓取的方式极其别扭，简直像在拿一个烫手的山芋。

但如果我们给它加上一条明确的交互提示（比如「请抓住锅柄」），它立刻就能完美地双手稳稳端起。



双臂端锅失败｜双臂端锅成功

这说明**大模型缺乏人类的「物理常识」。** 它能在二维图片里圈出「这是锅」，却不知道在三维现实中，锅必须端着两边才稳。

去掉历史记录，AI失败率暴增

研究团队做了一组「剥夺实验」：分别撤掉反馈、深度信息、抓手说明、历史记录等配置，看看机器人还能不能完成任务，又要多折腾多久。

拿掉动作偏差反馈，它就更难做出正确判断，指令跟随成功率从90%降到80%，平均规划决策从16.7次增至35.6次，耗时从32.50分钟涨到58.26分钟。

一次动作没做好，后面可能要花更多时间补救。

拿掉深度信息，成功率降到80%，平均下发控制步数增加到158.2步。不过，平均耗时反而缩短了。

取消相机投影自检后，机器人开始反复抓取和物体脱手

不告诉它抓手的形状和接触方式，它可能连「手该怎么摆」都反复试不明白。

最直观的一组，是拿掉历史记录。

在单独测试的4种「把积木放进盒子」布局中，完整系统全部成功；没有历史记录后，只成功了2种。

失败的两次都已经把积木拿起来，却在放置阶段反复尝试相同动作，堪称「鬼打墙」！



积木入孔：去掉历史记录，Astra能抓取积木但放置失败

物体拿到手了，任务却卡在了后半程。

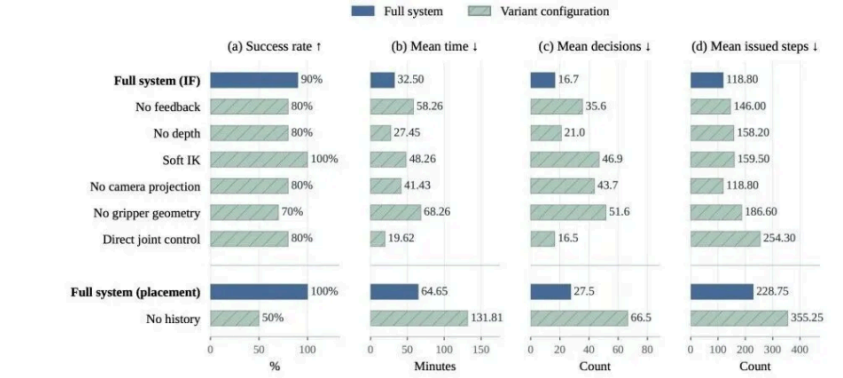


Fig. 2. Configuration comparison of success rate, mean time, planning decisions, and issued steps. Solid bars denote the full system; hatched bars denote variant configurations.

这证明了**深度视觉、动作反馈和历史记忆等，是具身智能闭环中不可或缺的灵魂。**

打破桌面限制，走向全场景

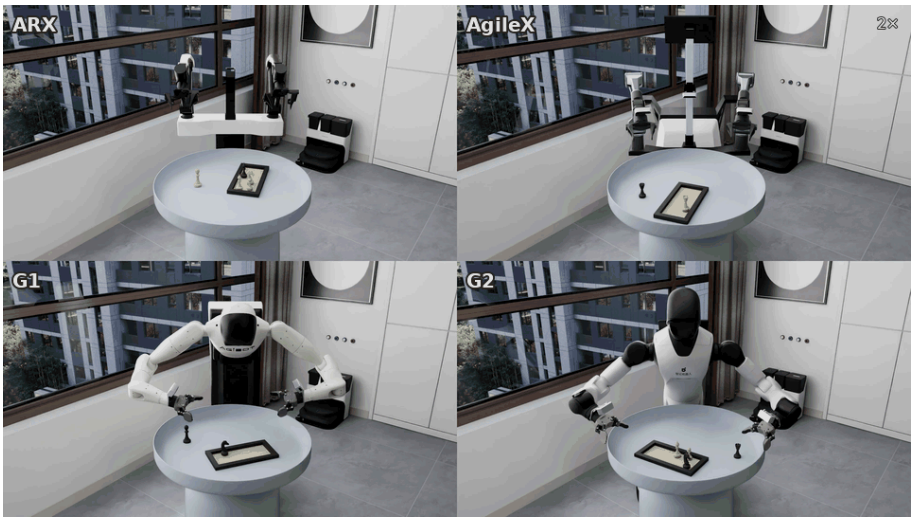
以往的机器人测试往往局限在桌面上抓抓放放，但这次的报告展示了 GPT-6 Astra 更广阔的潜力：

它能协调底盘、躯干和机械臂去扔垃圾、开门；能在家居场景里跨房间去厨房拿一罐雪碧放到餐桌上。



全身控制：Astra完成垃圾拾取与投放|Astra移动取罐、携物行进与餐桌放置

更牛的是，它能通过同一套系统，无缝控制 ARX、AgileX、G1、G2 等形态各异的机器人！



棋子收纳：Astra在4种本体上均可完成

语言模型通吃具身智能？灵巧手和精细任务仍是明显短板

GPT-6 Astra竟然这么强，是不是说语言大模型可以通吃具身智能？

测试发现，并不能。

大模型能搞得定躯干的「大开大合」，却搞不定指尖的「穿针引线」。

一旦面对需要「灵巧手」操作的精细活——比如让它叠碗，或者从塞满的书架上取出一本书，强如 GPT-6 Astra 也会立马「歇菜」，手忙脚乱，屡战屡败。



灵巧手叠碗：Astra能够接近、接触，但是尝试抓取失败｜灵巧手取书：Astra多次调整抓取姿态，仍取书失败

即使进一步补充手指、手掌的几何信息，机器人仍未成功端起一只碗。

而对手机充电和插网线这类精细任务，对GPT-6 Astra而言依旧艰难，能拿起手机和网线，却对不准插口方向。



手机充电：Astra抓取成功，但充电口方向错误无法接入｜插网线：Astra能够夹起网线，但无法完成插入

这组实验画出了 Astra 这类大模型的能力边界。

它已在全身协同和跨本体操作中表现突出，但灵巧手任务和精细操作仍有待突破。

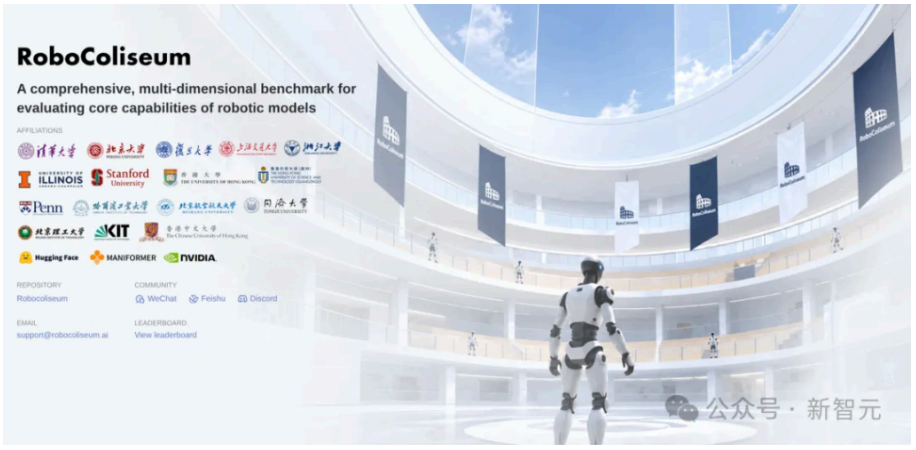
而这些难住大语言模型的细活，恰恰是专用策略模型胜出的机会。

细节决定胜负，机会留给早有准备的人。

什么是 RoboColiseum？对齐真实世界的「度量衡」

看完这场神仙打架，你一定会好奇：究竟是什么样的一个平台，能把这些心高气傲的全球顶尖大模型拉到同一条起跑线上，并且测出这么详尽、直击痛点的数据？

这就是我们今天隆重介绍的——**常态化具身智能仿真评测平台 RoboColiseum！**



在具身智能圈，一直有一个巨大的痛点：**Sim2Real Gap（仿真到现实的鸿沟）**。

很多模型在电脑模拟器里猛如虎，一放到真实物理世界里的机器人身上，遇到点光照变化、相机噪点，立马手忙脚乱、现出原形。测试成本极高，周期极长。

RoboColiseum 彻底打破了这一魔咒！

它基于高保真仿真环境构建，渲染和物理交互极限逼近真实世界。经过严苛测试，**其仿真评测与实机部署的相关性高达 89.5%！**相同模型在仿真与现实中的表现差异小于 10%。

这意味，虚拟即现实！

开发者完全可以把它当成真实世界的「可靠前哨站」。在花大价钱买真机、花几个月做调试之前，先在 RoboColiseum 里跑一圈，快速筛掉不靠谱的模型，精准定位能力短板。

精准归因你的「弱点」

只给一个干巴巴的「成功率」有什么用？RoboColiseum 推出了四大能力子榜、78个高保真任务：

> **1.指令跟随：** 懂不懂人话？能不能分清红绿、大小、逻辑常识？
>
> **2.空间理解：** 会不会排队？懂不懂上下左右和精准对齐？
>
> **3.扰动适应：** 换个背景、调暗灯光、弄花镜头，你还能不能行？
>
> **5.通用操作：** 开门、倒水、上货、双臂协同，组合拳打得怎么样？

不仅如此，评测哪怕失败了，平台也会告诉你：**在哪一步摔倒的？动作卡在哪里？** 彻底告别「盲盒式」炼丹！

AI Agent 一键提交，30 分钟出成绩

搞环境配置太折磨人？算力成本太高？

在 RoboColiseum，这些统统不是问题。开发者最快 **5分钟即可完成注册与提交**。

无需上传模型代码和核心权重（保护你的商业机密），只需本地部署推理服务并接入标准接口，最快 **30 分钟**，一份极其详尽的分项成绩、任务步骤解析甚至**模型推演视频**就会送到你面前！

平台已经有了 **GPT-6 Astra、GPT-6.1 Sol、Claude Opus 5.5 和 Gemini 4 Argon** 等全球最顶尖的多模态大模型的评测结果，直接拿来做对比，自己究竟处在行业什么身位，一目了然。

来角斗场，和AI三巨头正面交锋

Coliseum，指的是古罗马圆形竞技场，这是一个公开、中立、不论出身、用实力说话的终极试炼场。

RoboColiseum 的诞生，正是为了给全球具身智能赛道提供一把**绝对公平、结果可信、过程可复现的标尺**。

这里是全球唯一一个，能将**OpenAI、Anthropic、谷歌**三巨头拉下神坛的终极试炼场。

在 RoboColiseum 之前，你只能在新闻里仰望 GPT-6 Astra、Claude Opus 5.5和 Gemini 4 Argon的恐怖参数；但在这里，它们只是你在榜单上需要逐一击溃的「假想敌」。

只需 30 分钟，一键接入高保真虚拟世界，你的模型就能直接与这个时代最伟大的 AI 展开同维度的巅峰对决！

打败魔法的只有魔法，碾压大厂的唯有实力！

我们期待在万众瞩目的榜首，见证你亲手终结「三巨头」的统治！

本文来源：新智元

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

70 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论