

摘要：

AI产业重心转向推理，CPU成为调度核心，其通用DRAM需求激增至标准产品的4倍。叠加GPU对HBM的扩容需求，DRAM市场供需失衡加剧，当前缺口约10%，带动DDR5价格上涨。业内预计，内存短缺的超级周期将延长至2027年。

AI推理架构重塑算力格局，CPU内存需求激增推动DRAM供应缺口延续至2027年。

5月2日，据韩媒Sedaily报道，随着人工智能产业重心从训练转向推理，**CPU正在成为新的内存消耗大户，进一步加剧全球DRAM供应紧张局面**。韩国《证券日报》援引业内消息称，**DRAM市场当前供应量较需求低约10个百分点**，供需失衡短期内难以缓解。

报道称，英特尔最新发布的AI CPU预计将搭载高达400GB的通用DRAM，是标准CPU产品的四倍。与此同时，英伟达、AMD、谷歌等厂商的下一代AI芯片也在持续推高高带宽内存（HBM）需求。

多重需求叠加之下，业内预测三星电子和SK海力士的内存供应能力将难以跟上需求增速，此前预计于2026年结束的内存超级周期，有望延续至2027年。

与此同时，**DDR5现货价格已率先反映市场温度**。据韩国未来资产证券数据，今年4月，用于AI CPU的DDR5（16GB标准）现货价格单月上涨2.8%，而老一代DDR4同期则下跌16%，两者走势明显分化，DDR5价格溢价持续扩大。

CPU成为AI推理"调度核心"，内存需求骤升

据报道，AI产业向推理阶段转型，是此轮CPU内存需求激增的根本驱动力。

过去，AI数据中心以GPU为核心构建算力基础设施，通过HBM支撑大规模并行训练任务，服务器配置通常为**一颗CPU搭配八颗GPU**。

然而，随着AI推理需求快速扩张，尤其是“智能体AI”（Agentic AI）的兴起，CPU的角色正在发生根本性转变——**从边缘辅助角色升级为统筹协调各类AI智能体工作流的“编排者”**。

报道称，**这一角色转变的核心在于“上下文记忆”能力**。CPU需要持续追踪并调用各智能体的输出结果，这要求其配备远超以往的内存容量。

英特尔高管在近期财报发布会上表示，“在AI推理基础设施中，计算架构已从CPU与GPU 1比4的配比转变，且正进一步向1比1的比例收窄。”

这意味着CPU在AI服务器中的占比大幅提升，对通用DRAM的消耗也随之成倍放大。

GPU与CPU争夺内存，需求雪球效应显现

报道指出，内存容量竞赛正从GPU蔓延至CPU，呈现出需求“滚雪球”式扩张的态势。

在GPU侧，英伟达下一代AI芯片"Vera Rubin"通过八颗HBM芯片配置288GB内存，AMD下一代GPU MI400更达到432GB的超大容量。谷歌最新发布的第八代张量处理单元TPU 8i同样预计搭载288GB HBM。

在CPU侧，据报道，业内消息人士透露，CPU厂商正积极推动AI CPU搭载300至400GB的DRAM，**英特尔"至强"（Xeon）系列和AMD"霄龙"（Epyc）系列均已开始采用高容量DDR5。**相比之下，标准CPU产品的DRAM配置仅为96至256GB，新一代AI CPU的内存需求增幅高达四倍。

GPU与CPU同步扩张内存需求，令原本已趋于紧张的DRAM市场供应压力进一步加剧。

DDR5供需失衡加剧，超级周期或延至2027年

通用DRAM价格已超过100%的涨幅，令内存行业录得空前业绩，而供需失衡的局面短期内仍难以逆转。据报道，一位业内人士表示：

"目前DRAM市场供应量较需求低约10个百分点。随着HBM之外通用DRAM需求的激增，超级周期从此前预计的2026年延续至2027年的可能性极大。"

DDR5现货市场的价格走势印证了这一判断。据未来资产证券数据，今年4月DDR5（16GB标准）现货价格单月上涨2.8%，而DDR4同期大跌16%。两者的价格分化，直接反映出AI CPU对DDR5的强劲需求正在重塑内存市场的供需结构。

报道指出，对于三星电子和SK海力士而言，在HBM产能已高度紧张的背景下，通用DRAM需求的额外爆发，将进一步考验其整体供应调配能力。**市场普遍预期，内存行业的景气周期将比此前预判更为持久。**

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 214  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发布评论