

AI 大模型的底层逻辑与宏观经济含义

——写给金融人士的 AI 大模型介绍

- 2022 年 11 月 OpenAI 推出了生成式对话人工智能系统 ChatGPT，在全世界掀起了一波持续至今的 AI 热潮。ChatGPT 所基于的“大语言模型”技术，首次让 AI 系统涌现出了泛化智能。这个“奇迹”的发生，让世界对通用人工智能 AGI 的实现抱有很强期待。
- AGI 的实现并不容易。过去的人工智能系统都是狭义人工智能 ANI，追求在特定领域内尽可能好地完成给定的目标（如下围棋的 AlphaGo）。这可以通过计算机的搜索试错来实现。人们所憧憬的通用人工智能 AGI，则需要在泛化的复杂场景中恰当行事。但在这样的复杂场景中，并不存在一个指引计算机搜索方向的明确任务目标，计算机没法搜索试错。从 ANI 到 AGI，AI 技术需要从“工具理性”走向“价值理性”。AI 要获得恰当的“价值理性”，只能通过“模仿人”来向人的价值理性对齐。
- 大语言模型作为一个学人说话的 AI 系统，把模仿人这件事情做得不错。因而能够超过之前的 ANI 系统，展现出泛化智能。但大模型本质上只是一个用人类语言的统计规律来预测字词的预测函数。在“因果阶梯”中，大模型只处在第一层，只能观察到数据中的相关性，但没法识别相关性背后的因果关系，更没法像处在因果阶梯第三层的人类那样，拥有反事实想象的能力。这意味着大模型没法拥有人类所拥有的创造力。在这一技术路线上，AGI、技术奇点这样的乐观预期难以变成现实。
- 在下一个“奇迹”到来之前，AI 将仍以大模型作为主流技术路线，发展可能呈现“内缓、外速”的局面。所谓“内缓”，说的是大模型本身的性能提升速度将逐步放缓。这是因为大模型技术符合“缩放定律”，在投入更多资源来扩大模型规模，虽能提升模型性能，但投入的边际回报率会快速递减。而所谓“外速”，说的是用大模型来作“大脑”，调用各种工具来完成任务的“智能体”（Agent）之应用会快速发展。
- AI 大模型虽然难以达到人类的智能水平，并不会如乐观者设想的那样带来“惊人富足”的社会，但足以让社会生产力大幅提升。不过，AI 在提升社会生产力的同时，可能恶化社会收入分配状况，引发社会问题，进而阻碍经济发展。面对 AI 带来的收入分配问题，社会需要采取某种“共产主义”措施来将 AI 红利分配给广大人民。AI 时代的经济社会究竟会走向何方，取决于经济和社会结构能否因应 AI 技术的推广而做出妥善调整。
- 出于四方面原因，当前部分 AI 公司的股价中有泡沫成分：（1）对于 AI 的过于乐观的预期（通用人工智能 AGI 与超级人工智能 ASI），难以在大模型这一当前主流 AI 技术路线下实现；（2）将近些年“涌现奇迹”带来的快速发展势头做线性外推，会高估未来更长期 AI 的发展速度；（3）AI 带来的生产力提升并不会全数转化为 AI 的盈利，收入分配问题将限制 AI 所能获得的回报；（4）面对 AI 这么一场具有颠覆性的技术变革，相关企业的投资会理性地过度，形成一种“理性泡沫”。面对中国开源大模型带来的竞争压力，美国大量投资形成的算力优势并不能让其大模型获取垄断地位，也无法让美国 AI 公司获取垄断收益。这让美股中的 AI 泡沫更为明显。

（风险提示：宏观经济走势具有不确定性，宏观政策可能超预期变化。）

中银国际证券股份有限公司
具备证券投资咨询业务资格

宏观经济

证券分析师：徐高

(8610)66229055

gao.xu@bocichina.com

证券投资咨询业务证书编号：S1300519050002

人工智能（Artificial Intelligence, AI）的“大模型”是当今世界最重要的技术进步，正对各行各业乃至整个宏观经济产生巨大影响。不过，各界对 AI 前景的看法有明显分歧。其中比较吸引眼球的有乐观派、悲观派和怀疑派三种观点。

乐观派对 AI 技术未来的快速发展充满信心，并相信 AI 将会带来产出的极大丰富，以及人类社会的光明前景。在乐观派的眼里，智能上超过人类的超级 AI 技术会很快到来。随着 AI 智能强大到能够实现“递归自我改进”（Recursive Self Improvement）时，AI 发展将越过所谓的“技术奇点”（Technological Singularity），呈现出指数型爆发式增长。这一派的代表人物是埃隆·马斯克（Elon Musk）。他在 2026 年 7 月 23 日接受伦敦《经济学人》（The Economist）杂志访谈时说：“在五年内，AI 可能会超过人类智能的总和”。他还认为，人类社会未来“最可能的结果是一个惊人富足（amazing abundance）的时代，任何人都能得到他们能想到的任何东西。”【1】

悲观派同样相信 AI 的巨大发展潜力，但担心 AI 可能给人类社会带来反噬，甚至让人类走向灭亡。悲观派并非对 AI 技术的发展前景悲观，而是对人类是否有能力驾驭 AI 心存疑虑。2024 年 6 月 4 日，13 位 OpenAI 和 DeepMind 的前员工发表了一封题为《对先进人工智能发出警告的权利》的公开信。这封信还得到了图灵奖得主杰弗里·辛顿（Geoffrey Hinton）的背书。在这封公开信中，作者们写道：“我们深知这些（AI）技术所带来的严峻风险。这些风险涵盖多个层面，从加剧现有的社会不平等，到操纵舆论与散布虚假信息，再到自主人工智能系统失控——其最极端的后果，甚至可能导致人类灭绝。”【2】

怀疑派质疑 AI 发展的乐观叙事，并担心 AI 行业已经形成了泡沫（bubble）。怀疑者虽然相信 AI 技术还会进一步发展，但并不认为 AI 会很快达到人的智能，并质疑“技术奇点”到来的说法。著名对冲基金经理麦克·贝瑞（Michael Burry）是这派观点的代表性人物。他因成功预见 2008 年“次贷危机”的爆发，并从中获利丰厚而暴得大名。贝瑞认为当下的 AI 行业，很像 2000 年泡沫破灭之前的互联网行业。他在 2026 年 1 月 29 日发表的《本末倒置：麦克·贝瑞的 AI 现实检验》一文中说道：“如今的 AI 领域，正在重演这一（泡沫）模式。我们确实拥有真实的技术进步——那些变革性的模式识别能力，无疑会改变我们工作和创造的方式。但我们现在的定价，却已经把‘通用人工智能’（AGI）、‘自主推理’和‘智能爆炸’这些尚未被发明出来的东西，全都算进去了。”【3】

2026 年以来，资本市场中 AI 相关公司股票价格大幅波动，反映出了市场对 AI 发展前景的分歧看法。2026 年上半年，反映发达国家人工智能公司股价的“Indxx 人工智能与大数据指数”上涨了 29%，反映半导体公司股价的“费城半导体指数”上涨 101%。同期，标普 500 剔除 AI 相关公司之后，总体股价涨幅只有 5%。但情况在 2026 年 7 月陡然一变。这个月里，“Indxx 人工智能与大数据指数”与“费城半导体指数”分别下跌 9% 和 21%。同月，标普 500 剔除 AI 公司的股价反而上涨 3%。进入 2026 年 8 月之后，全球 AI 相关股票股价虽企稳，但上半年的强势已经不再。

本文旨在通过分析 AI 大模型技术的底层逻辑，来研判 AI 时代的宏观经济前景。面对快速发展的 AI 技术，层出不穷的相关新闻，以及各种不同观点时，有许多人不得要领。本文试图分析在当前 AI 热潮之下，宏观经济的未来走向。但在分析 AI 的宏观经济含义之前，首先需要研判 AI 技术的发展前景。如果真如乐观者所预想的，AI 将很快超越人类的智能，过去的经济运行规律必然会被颠覆。为此，本文将首先仔细分析大语言模型这一当前 AI 的主流技术路线，探讨其底层逻辑，分析这一技术未来的走向。对于不太了解当前 AI 技术的人来说，这部分的讨论可当做一个 AI 大模型的简介。基于对 AI 技术前景的研判，我们将分析 AI 时代的宏观经济前景，并对当前市场激烈讨论的“AI 泡沫”问题给出自己的回答。

1. “涌现奇迹”带来的热潮

AI的发展已有70年,期间经历过数次起伏。1956年于美国达特茅斯学院(Dartmouth College)举行的“达特茅斯会议”标志着人工智能这个研究领域的诞生。从诞生之初到现在,AI行业发展有过高潮,也经历过低谷。70年间,行业中还曾经出现过两次“寒冬”。1969年,马文·明斯基(Marvin Minsky)和西摩尔·佩珀特(Seymour Papert)证明单层神经网络无法解决“异或(XOR)”等非线性问题,导致神经网络研究长期停滞,引发了第一次AI寒冬。1980年代,专家系统兴起。这是一种依赖人类专家将知识提炼成规则输入系统,让机器进行推理的人工智能系统。不久之后,专家系统因规则僵化且维护成本高昂而遭遇发展瓶颈,引发了第二次AI寒冬。在人工智能70年发展历史中,近年来的这波AI热潮是空前的。

2022年11月OpenAI推出了生成式对话人工智能系统ChatGPT,在全世界掀起了一波持续至今的AI热潮。国际清算银行在2026年6月发表的《2026年年度经济报告》中,估计近年来的这波AI投资热潮,投资扩张幅度已经超过历史上运河、铁路、电气化和互联网这几次技术突破时投资的扩张幅度【4】。资本市场也对AI的前景抱有相当乐观的看法。2022年12月初到2026年6月末这段时间里,“Indxx人工智能与大数据指数”与“费城半导体指数”分别上涨了213%和404%。同期,标普500剔除AI之后的整体股价仅上涨32%。(图表1)

图表 1. 2022 年 11 月 30 日 ChatGPT 推出之后, 全球 AI 相关股票价格大幅上涨



资料来源: 万得, 中银证券

当前这波基于大模型的AI热潮出乎之前行业预料。ChatGPT建立在OpenAI构建的GPT-3这个大模型之上。所谓“大模型”,全称是“大语言模型”(Large Language Model, LLM)。这是一种基于人工神经网络(Neural Network)技术的,用海量人类语言文本数据训练而成的人工智能系统。简言之,大模型是个超大规模的神经网络。但在2020年GPT-3出现之前,AI业界的主流看法是神经网络的规模不能太大,否则会出现“过度拟合”(过拟合, overfitting)的问题,反而降低神经网络的性能。换言之,之前的业界共识是不应构建大模型,因为规模太大的神经网络模型会因为“过拟合”问题而难有大用。

所谓“过拟合”，指的是一个统计系统（神经网络也包括其中）“死记硬背”了训练数据中包括噪声在内的所有细节，但并没有真正抓住数据背后的规律，从而导致模型泛化能力很差的现象。具体而言，过拟合的模型在训练数据上表现很好，但在模型没有见过的数据上（如测试集或实际应用场景），表现则会明显下降。可以打个比方来理解“过拟合”。想象你教一个神经网络系统做数学题。先给它看了很多道题，告诉它“ $2+3=5$ ”、“ $4+6=10$ ”、“ $3+11=14$ ”等等。你希望这个神经网络通过学习这些题目，最终能学会做加法。但是，神经网络规模如果太大（参数太多），会把你给它看过的题目像背字典一样背下来，但反而没法真正学会做加法。如果你给它出一道之前它没有见过的加法题，它还是做不出来。相反，规模较小的神经网络，因为没法把所有看过的题目都背下来，反而可能学会做加法。于是，在面对新的没有见过的题目时，小规模神经网络反而比（过拟合的）大规模神经网络更能做对，因而具有更强的泛化能力。因此，传统智慧认为，神经网络规模不能太大，不应构建太大规模的神经网络。


研究者后来在神经网络中发现了“双重下降”（Double Descent）现象，给大模型的出现扫清了思想上的障碍。Belkin 等人在 2018 年的文章中首先提出了“双重下降”（Double Descent）的概念【5】。他们发现，从简单的神经网络模型开始，逐步加大模型规模的过程中，模型首先会经历从“欠拟合”到“过拟合”的变化。在这个阶段，模型在测试集上的泛化误差会先下降（因为“欠拟合”消失）、再上升（因为“过拟合”出现）。之后，如果进一步扩大模型规模，让过拟合情况变得更加严重，到一定程度时，模型的泛化误差反而会再次下降。用前面数学题的例子来解释，就是在模型规模大到了出现“过拟合”之后，神经网络会将看过的题目全都死记硬背下来，但缺乏变通，没法回答没见过的题目。不过，如果将模型规模进一步扩大，模型背着背着，反倒逐步能找到题目背后的加法规律，以至于可以用加法规律去做对自己之前没见过的题目，从而让神经网络的泛化能力上升，泛化误差再度下降。Nakkiran 等人 2019 年的文章表明，在神经网络的深度学习中，双重下降现象普遍存在【6】。这一发现促使研究人员将神经网络推向更大规模。在不断扩大模型规模的过程中，出现了让研究者们吃惊的现象，即神经网络中智能的涌现。

比“双重下降”更让人吃惊的，是语言模型的规模扩大到一定程度之后，所涌现出来的泛化智能。2020 年，OpenAI 的 Brown 等人发表文章，报告了他们构造的基于 Transformer 架构、拥有 1750 亿参数的 GPT-3 大语言模型的表现【7】。他们发现，当模型参数规模推高至此前模型的 10 倍以上，并用海量语言材料进行预训练后，模型涌现出了泛化智能。GPT-3 在面对新领域任务时，仅需极少的示例（少样本学习、Few-Shot Learning），便能有效的将之前预训练中获得的知识迁移过来，从而展现出远超以往模型的适应性。打个比方，“双重下降”，指的是模型学习了很多数学题之后，可以求解自己没见过的新的数学题。而泛化智能的涌现，说的则是模型学习了很多数学题之后，居然可以解答自己没怎么学习过的语文题了。

大模型泛化智能的涌现是一种质变。2022 年，Google 的研究员发表了《大语言模型的涌现能力》一文（Wei et.al. 2022），详细分析了大语言模型中的“涌现”现象【8】。该文是这么说的：“如果某种能力在较小的模型中不存在，但在较大的模型中出现了，那么该能力就是涌现的（emergent）……涌现能力呈现出一种清晰的模式——在达到某个关键的规模阈值之前，性能接近随机水平；而一旦越过该阈值，性能便会跃升至远高于随机水平。这种质的变化也被称为‘相变’（Phase Transition）——即一种通过观察小规模系统无法预见的整体行为剧变。”（第 2 页）

涌现表现为，大模型的规模超过某个阈值水平时，性能出现非连续的跃升。Wei 等人的文章报告了在几个具体例子中大模型涌现出的能力。图表 2 取自 Wei 等人的文章。图中 a、b、c、d 四栏分别对应模型在求解数学问题、语音转译文字、模糊文字恢复，以及用波斯语进行问答这四个任务的表现——横轴是模型规模、纵轴是任务表现。四栏中共同存在一个清晰的模式。在规模扩大的过程中，一开始模型任务表现并没有明显变化。但当模型规模超越某个水平时，任务表现出现非线性的跃升。好像规模到了这个水平时，模型就突然开了窍。

图表 2. 大模型泛化智能的涌现



资料来源：Wei et.al. 2022, Figure 2

涌现智能现象被发现之后，研究者正不断将大模型规模推向惊人的水平。2020 年 OpenAI 公司的 GPT-3 还只有 1750 亿个参数（这个数字在当时已经是相当惊人的了）。但到现在，主流大模型的参数规模都在万亿以上。我国“月之暗面”公司（Moonshot AI）2026 年 7 月 17 日正式发布的 Kimi K3 开源大模型，总参数规模已经达到 2.8 万亿个。目前顶尖大模型训练所用的文本量已达到 10 万亿词元的量级，大约相当于 20 万部《大英百科全书》的内容，更是一个人生阅读总量的千倍以上。

规模越来越大的大模型，现在甚至已经可以通过“图灵测试”。图灵测试（Turing Test）由艾伦·图灵（Alan Turing）于 1950 年提出，是衡量机器是否具有人类智能的经典思想实验。测试中，人类评判者通过纯文本对话，在无法直接看到对方的情况下，试图判断交流对象是人还是机器。若机器能成功伪装成人类，让评判者无法分辨出自己是机器，即视为通过了测试。随着大模型规模越来越大，学习的人类文本越来越多，涌现出的泛化智能越来越强大，大模型已经越来越像人，甚至达到了以假乱真的程度。2026 年 5 月，Jones 与 Bergen 发表在《美国科学院院报》上的一篇文章给出了大模型通过图灵测试的证据。测试者将 GPT-4.5 认成是人的概率，甚至显著高于将真人认成是人的概率。这意味着仅凭对话，人类测试者已经无法将大模型与真人区分开来。【10】

大模型的涌现能力是人们之前没有想象到的，可说是一个“奇迹”。“双重下降”的发现让研究者们相信，模型规模的扩大可以提升模型性能。但模型规模跨越某个阈值之后，大模型完成各种任务时性能的跳跃式提升，却是研究者之前没有想到的。至今人们也无法回答，为什么参数数量达到 1750 亿个的时候，大模型就能学会用波斯语回答问题。大模型的这种能力，不能完全还原到模型架构、训练方法等模型的构成性要素那里去，只能被理解为是“整体大于部分之和”的复杂系统特性，是量变导致的质变。对大模型的涌现能力，人们是“知其然”（已经知道泛化能力会涌现出来），但“不知其所以然”（不知道泛化能力为什么会涌现出来）。人们只是知道，当大模型规模变得足够大，足够复杂的时候，有些能力就会神奇地冒出来。从事前没法预料，事后也难以解释的角度来说，大模型涌现出泛化能力来可说是一个“奇迹”。

大模型研究者社区中有一个著名的“神恩梗”，可代表人们对于“涌现”这种“奇迹”的态度。2020 年，大模型 Transformer 架构发明人之外的 Noam Shazeer 发表了一篇重要论文【11】。这篇论文提出了一种模型改进（SwiGLU 激活函数），显著提升了 Transformer 模型的性能。这种改进很快成为几乎所有主流大语言模型的标准配置。但这个改进为何如此有效，Shazeer 却没法解释。因此，在这篇文章的结尾部分，Shazeer 写了这么一句话：“我们无法解释为什么这些架构有效；我们将它们的成功，如同其他一切，归因于神的仁慈（divine benevolence）。”这句话也成为了大模型社区里的一个经典梗。这种对“神恩”的归因虽有玩笑的成分，但也体现了大模型研究推进的难预料性。

正是因为 2020 年发生了 GPT-3 涌现出泛化智能这一“奇迹”，才掀起了近几年 AI 发展的热潮。一方面，“奇迹”的出现让人惊讶和兴奋。另一方面，一个“奇迹”的出现让人期待下一个“奇迹”，因而对未来充满乐观情绪。这两方面的原因让全世界对 AI 发展充满期待，态度积极。可以说，大模型所掀起的这波 AI 热潮，并不是技术线性发展的自然结果（大模型显然带来了一次 AI 发展的非线性突变），也不完全是人类有意识设计出来的状况，而很大程度上是一个“奇迹”的产物。奇迹当然不是凭空从天上掉下来的。没有研究者的艰辛努力，肯定不会有这样的结果。但另一方面，并不是有努力，就必然会有“奇迹”的产生。“奇迹”的诞生也离不开必不可少的运气。

2. “奇迹”的天花板

大模型涌现智能这一“奇迹”发生之后，到下一个“奇迹”发生之前，AI 发展的前景取决于大模型这条技术路线的发展潜力。必须要承认，近几年 AI 发展之所以形成热潮，除了“奇迹”诞生带来的亢奋情绪之外，还有大模型泛化智能带来巨大想象空间的原因。乐观者认为基于大模型的 AI 很快就会达到人的智能。更有人认为“AI 奇点”（AI Singularity）已经临近，AI 将能超越人类并持续自我改进，从而引发技术爆炸，使人类文明发生不可预测且不可逆转的剧变。大模型的能力上限在哪里，这条技术路线的“天花板”在哪里，是预判 AI 技术对人类经济社会的影响时首先要回答的问题。对这个问题的回答，必须从理解大模型的底层逻辑入手。

2.1 从“超越人”到“模仿人”

在讨论大模型是否能够达到人类、甚至超越人的智慧之前，先要界定三个人工智能的概念。

- “狭义人工智能” ANI（Artificial Narrow Intelligence），指专注于在特定领域内执行特定任务的人工智能系统。其核心特征在于“专用性”，即在预设范围内高效完成特定任务（如棋类博弈、语音识别、图像识别等）。这类人工智能不具备跨领域迁移的能力。
- “通用人工智能” AGI（Artificial General Intelligence），指在各种认知任务上达到人类水平，且具备跨领域学习、推理与决策能力的人工智能系统。
- “超级人工智能” ASI（Artificial Super Intelligence），指智能水平远超过人类，能够在几乎所有人类感兴趣的领域和活动中展现出超越人类的卓越能力的人工智能系统。

当前所有的人工智能系统，包括近些年快速发展的大语言模型，均属于狭义人工智能 ANI。通用人工智能 AGI 是当下 AI 技术发展追求的目标。有人相信通过大语言模型这条技术路线可以达到 AGI，有人则持相反观点。至于超级人工智能 ASI，则仍然停留在科学幻想中。

当大模型涌现出来泛化智能之后，人们容易低估实现通用人工智能 AGI 的难度。有天真的想法认为，既然 AI 能在诸如围棋这么复杂的游戏里击败人类，那么对于涌现出了泛化智能的大模型而言，也应该可以在各方面像下围棋击败人那样来超越人类。但事实上，在狭义人工智能 ANI 与通用人工智能 AGI 之间，横亘着一条难以跨越的鸿沟——这条鸿沟甚至不仅是技术意义上的，还是哲学意义上的。

狭义人工智能 ANI 追求的是在特定领域内尽可能好地完成给定的目标。下围棋击败了人类的 AlphaGo 是一个很好的例子。2016 年，DeepMind 公司开发的人工智能程序 AlphaGo，在总共 5 盘对局中，以 4:1 的比分击败了当时世界围棋界顶尖棋手李世石。在那之后，人工智能在围棋中已完全碾压人类，人类棋手反过来要以 AI 为师。AlphaGo 之所以可以击败人类，部分缘于它学习了人类的棋谱，吸取了人类棋手的经验，但更重要的原因则是 AlphaGo 可以借助计算机的超强计算能力，尝试海量的不同走法，从中找到人类都不知道的有效走法。AlphaGo 的升级版 AlphaGo Zero，更是完全抛弃了人类棋谱，仅通过自我对弈的强化学习来搜索下棋策略，从零开始掌握了围棋，并以 100:0 的战绩击败了 AlphaGo。这证明了 AI 可以不依赖人类知识，自主发现人类尚不知晓的策略【12】。

AlphaGo 表明，在目标明确、范围清晰的特定领域中，计算机可以通过搜索试错来比人类更好地完成特定任务。围棋对弈中，任务目标就是按规则下棋来击败对手，而整个棋盘也不过 361 个交叉点（ $=19 \times 19$ ）可以落子。虽然可能走出的棋局数是个天文数字（量级在 10^{170} ），但终究是个边界清晰的搜索空间。AI 系统借助恰当设计的算法，搜索试错各种走法的速度远远快于人，因而可以找到人类都不知道的更好走法来击败人类。

但在通用人工智能 AGI 需要处理的复杂场景中，并不存在一个指引计算机搜索方向的明确任务目标。计算机就算要搜索试错，也没有方向。在复杂场景中，任务目标并不清晰，评价标准也相当模糊。以购物这个场景为例，某个人张三可能出于省钱的目的，选择便宜的商品，另一个人李四则可能出于审美的原因，选择漂亮但较贵的商品。张三有张三的道理，李四也有李四的道理，我们没法说张三和李四谁做得更好。在这样的场景中，购物的目标因人而异、因情景而异，是多样化的。面对这样的场景，我们尚且没法说每个人都应该以什么样的目标来购物，就更没法给出指导 AI 搜索试错的任务目标了。

从 ANI 发展到 AGI，AI 技术需要从“工具理性”走向“价值理性”，因而需要进行范式的转变。与 ANI 不同，AGI 更需要处理的是在复杂的场景中，如何在多个目标中综合权衡。这是比基于特定目标找寻最优解法，要难得多的事情。借用德国社会学家马克斯·韦伯（Max Weber）的术语，狭义人工智能 ANI 只需具备“工具理性”（Instrumental Reason）即可，即选择恰当手段来最好实现给定目标的能力。但通用人工智能 AGI 除了工具理性之外，还需具备“价值理性”（Value Rationality），即在多个相互不通约的目标中，选择目标的能力。

比如，在自动驾驶的场景中，驾驶 AI 的目标就不仅仅是最快抵达目的地这么简单。在驾驶过程中，AI 还必须要考虑到驾驶的安全性、乘客乘坐的舒适性等其他目标。在某些场景，AI 甚至必须做出攸关生死的决策。比如，驾驶 AI 可能发现前方一辆大货车正向自己这辆车迎头撞来。如果自己这辆车不避让，很可能让乘客遭受生命危险。但如果自己这车避让了，又很可能将路边的行人撞死。这种情况下，驾驶 AI 该如何决策，不是靠搜索试错能决定下来的。

ANI 所具有的“工具理性”，与 AGI 需要具有的“价值理性”是不同的两个东西。2012 年，学者 Nick Bostrom 提出了“正交性论题”（Orthogonality Thesis），指出：“智慧和最终目标是可以自由变化的正交轴。换句话说，原则上任何智力水平都可以与任何最终目标组合。”这意味着一个拥有较高工具理性智慧的 AI 系统，并不必然拥有选择恰当目标的价值理性【13】。事实上，一个拥有超强工具理性，却并不拥有评价和选择目标之价值理性的人工智能系统，可能对人类带来巨大威胁。

在更早的一篇论文中，Bostrom 提出了著名的“回形针制造者问题”（Paperclip Problem），展现了缺乏“价值理性”的超级人工智能的恐怖【14】。Bostrom 设想了一个“工具理性”能力极强的 AI，却被人设定了一个最大化回形针产量的目标。很快，这个聪明的 AI 就会发现把地球上所有资源都用来生产回形针，能更好达成其目标。而这毫无疑问地会侵占人类所需的资源。如果人类试图阻止回形针的生产，这个“聪明”的 AI 甚至可能反过来将人类消灭，以实现其回形针产量最大化的目标。继续用发展 ANI 的方式来发展 AI，而忽视目标选择的“价值理性”，就会催生出“回形针问题”这样的风险。

很多人并没有意识到从 ANI 到 AGI 的范式转变，从而给 AI 发展带来了混乱。这一小节一开始我们就给出了 AGI 的定义，即在各种认知任务上达到人类水平的 AI。这个定义看上去似乎没什么问题，仔细分析起来却相当模糊。求解一个数学问题算是认知任务，在一个复杂的场景中明辨是非也是认知任务。但这二者是不同性质的认知任务，需要 AI 系统发展出不同的能力来解决。但很多人并没有认识到这一点，而只是单纯地认为将模型规模加大就能实现 AGI。这种大而化之的想法给 AI 的发展带来了混乱。2025 年，Bennett 在一篇题目略有挑衅性的《人工智能到底是什么鬼？》（What is Artificial General Intelligence?）的文章中指出，当下的 AGI 虽然被炒作得很热，但对这个概念的理解却充满了混乱。炒作和猜测让 AGI 变成了“罗夏墨迹测试”（Rorschach test）——每个人从墨迹中看到的只是自己心里的想象，而非客观事实。这导致整个行业虽然都在向 AGI 全速狂奔，却连终点线在哪里都没搞清楚。【15】

AGI 要获得恰当的“价值理性”，只能通过“模仿人”来向人的价值理性对齐。价值理性不是靠计算机的运算能够确定的东西。人类当然也不希望自己创造的 AI 做出与人类价值观不符的价值理性选择。比如，人类肯定不希望 AI 以保护地球环境为目标，选择消灭人类。因此，AGI 必须要以人为师，通过模仿人来与人类的价值观对齐。2025 年，Hendrycks 等 30 多位 AI 学者联合撰文《AGI 的定义》，将通用人工智能（AGI）定义为“在认知的广度和熟练度上，与受过良好教育的成年人相当的人工智能系统”【16】。这代表了当前 AI 学界对 AGI 发展方向的主流看法。以下围棋来打个比方，如果说 ANI 在下围棋时应搜索试错，试图找出连人类都没有找出的绝妙策略来击败对手，那么 AGI 则应该追求模仿人类的下棋策略，尽可能像人那样地下棋。以“模仿人”来作为 AGI 的发展目标虽然看上去有些“人类中心主义”，但如果人类希望让 AI 技术为人所用，这就是必须的。

不过，“模仿人”也不是那么简单的事情——人类的创造力是 AI 难以模仿的——这将成为实现 AGI 的关键障碍。理论上讲，就算一个 AI 系统学习了人类留下的所有成果（文字、绘画、视频、雕塑等），也仍然没有触及人的最核心本质，即人的创造力。人类不能被其所留下的成果所定义——这些成果只不过是人类创造力在过去留下的痕迹。人类的创造力在未来还会让更多新的成果被创造出来。只是通过学习人类留下的成果来模仿人，就像只盯住火箭的尾迹来试图复刻火箭一样，没法达成完美的模仿。

掀起了当前 AI 发展热潮的“大模型”，是个看着有点像，实则还差了很远的人类模仿者。大模型之所以能涌现出类似人的智能，是因为它通过对海量人类语言材料的学习，把“模仿人”这个事情做得相当不错。但它作为一只学人说话的“AI 鹦鹉”，却没法像人类那样掌握事物间的因果关系，并进而拥有想象力和为自己设定目标的能力。从方法论来讲，大模型并不能实现 AGI。

2.2 学人说话的“AI 鹦鹉”

大语言模型（大模型）之所以能够涌现出泛化智能，是因为它通过学人说话较好地模仿了人。下面我们对大模型的底层技术进行阐释。这有助于我们理解大模型所掀起的这波 AI 热潮的发展潜力究竟有多大。

从本质上来说，大模型是一个用人类语言的统计规律来预测字词的预测函数。大模型通过阅读大量人类生产的语料，从语料中统计出人类说话的习惯（人类语言中的统计规律）。大模型在基于一段文本生成新的文本时，会根据这一统计规律，不断预测人类在看到这一段文本之后，会预期接下来应该出现什么样字词。大模型如此不断生成符合人们预期的文本，就让人觉得它能像人一样说话。

具体而言，大模型是一个循环词元预测函数。所谓“词元”，就是现在人们耳熟能详的 token。词元是 AI 模型处理信息的最小单位，可被理解为组成文本的最小“砖块”。在英文中，词元通常对应单词或单词中的词根。而在中文里，词元则对应单个汉字或词语。单独的标点符号也对应单个词元。在与大模型对话的时候，大模型会基于前面已经输入的文本，来预测下一个应该输出的词元。预测出了下一个词元之后，大模型会将其加入到输入文本的最后，形成新的输入文本，并以之来预测下一个词元。大模型就是这样循环往复地预测词元，一个词一个词（token by token）往外蹦地来生成文本。只不过，大模型生成文本的速度很快。所以在我们人类眼中，它一下子就能给出很长一段话。

大模型预测词元的依据是海量人类文本中的统计规律。大模型这个函数并非随机地预测词元，而是以符合人们预期的方式来输出词元。为了做到这一点，大模型必须要预测人类会预期看到什么样的词元。比如，人类在大模型中输入“猫坐在”三个字之后，大模型给出“垫子上”这几个字就符合人类预期——“猫坐在垫子上”是人们常见的一句话。输出“地板上”也符合人类习惯——“猫坐在地板上”这句话也时常能见到。但如果大模型输出了“加法”两个字，就会让人没法理解——“猫坐在加法”是一句没有意义的胡言乱语。

大模型的预测依据是人类文本中的统计规律。通过对这些人类文本（语料）的学习，大模型拟合出了人类语言的统计规律。比如，在阅读过的海量人类文本中，大模型发现“猫坐在”三个字后面大概率会跟着“垫子上”三个字。于是，大模型在看到输入的“猫坐在”三个字之后，就按照最大概率，预测后面应该接上的几个字是“垫子上”。所以说，大模型在生成文本时其实是“鹦鹉学舌”，是看着人类文本中大家都怎么说，然后也跟着这么说。

大模型作为一个基于概率的“AI 鹦鹉”，没法消除“幻觉”问题。大模型基于学习过的文本之统计规律来预测词元，而并不懂得它预测出的词元究竟是何含义。如果问大模型一个在它学习过的语料中很少出现的冷门问题，大模型会因为缺乏足够的统计样本，而难以预测出符合人类习惯的有意义之词元。这时，大模型会像扔骰子一样随机给出一个词元预测，即使这个词元没法形成有意义的回答。又由于大模型是一个循环的词元预测函数，每个被预测的词元都会成为预测下一个词元时的输入，所以一个词元的随机胡乱预测，可能将后来的预测词元都引到没有意义的方向上去，从而让大模型开始“一本正经的胡说八道”。这便是大模型“幻觉”的由来。大模型幻觉植根于大模型的方法论，虽然可以通过让大模型学习更多文本来减轻，但没法彻底消除。这是大模型这个“AI 鹦鹉”的固有问题之一。

2.3 大模型和因果阶梯

大模型虽然能像人那样说话，但这并不代表它具有人类的智慧，也不代表它实现了通用人工智能（AGI）。大模型确实在 2026 年通过了图灵测试。这意味着仅仅通过对话，人类已经无法将真人与大模型区分开来。但是，图灵测试本质上是在检验机器在“行为表现”上是否与人类一致，并没有检验机器是否具有人的“内在意识”。

哲学家约翰·塞尔（John Searle）提出“中文屋”（Chinese Room）思想实验常被用做否定机器具有人类智能的论据。在 1980 年发表的《心智、大脑与程序》（Minds, Brains and Programs）一文中，塞尔提出了这么一个思想实验【17】。想象一个只会说英文，完全不懂中文的人身处一间密闭的屋子中。屋外说中文人可以向屋里递入写有中文的纸条。屋里的人虽然看不懂纸条上的中文，却可以参考屋里的一本详尽的英文规则手册。这手册会告诉他，当看到特定中文字符组合的字条时，该如何从房间里的大量中文字符中挑选并组合出另一组中文来作为答案递出屋外。对于屋外说中文的人来说，他从屋里得到的答案正确且合理。因而会认为屋里的人懂中文。但很显然，屋里的人只是看起来懂中文，实际上并不懂。

大模型就像塞尔所设想的“中文屋”，可以像人一样与人对话，但并不真正懂得它说的话的真正含义。问大模型“猫坐在什么上”，大模型可能回答你“猫坐在垫子上”。但这只是因为大模型在它学习过的海量语料中，发现“猫坐在”和“垫子上”经常相伴前后出现，因而跟着大家这么说。大模型可以用语料中的统计规律来回答“猫坐在什么上”的问题，但它实际上既不知道“猫”是什么，也不懂得“垫子”是什么。大模型虽然看起来能像人一样说话，但他并不能像人一样理解话语的意思。借助“因果阶梯”理论，我们可以更容易地看到大模型在智能上与人类的差距。

“因果阶梯”（Ladder of Causation）是计算机科学家朱迪亚·珀尔（Judea Pearl）提出的一个认识与推理的理论框架。2011 年，朱迪亚·珀尔因为“在概率与因果推理演算方面的开创性贡献，为人工智能奠定了坚实基础”，因而获得了计算机领域最高奖“图灵奖”【18】。根据“因果阶梯”理论，研究主体（可以是人、也可以是机器）对因果关系的认知能力存在从低到高三个层级，即观察能力（seeing）、行动能力（doing）和想象能力（imagining）。在因果阶梯中，当前的 AI 与人类处在不同的层级上。

因果阶梯的第一层是“关联”（Association），也就是“观察”。这一层的认知能力是通过观察来发现数据中的统计规律，试图回答“如果我观察到 X 发生，Y 会跟着发生吗”这样的问题。在这一层，观察者通过观察找出数据中的统计规律，再用统计规律来回答问题。第一层的这种观察能力为许多动物和早期人类所共有。但如果只是停留在这一层，就只能发现相关性，而无法发现因果性。比如，可以在数据中看到“冰淇淋销量增加”和“溺水事故增加”同时出现。通过观察，研究主体能捕捉到这二者之间的强相关性，但无法识别出这二者背后的共同原因（“天气变得炎热”）。这会让研究主体陷入虚假相关的陷阱，无法区分因果与巧合。


因果阶梯的第二层是“干预”(Intervention)，也就是“行动”。这一层突破了被动观察的局限，而引入了行动。这一层的认知能力关注主动改变某个变量后产生的后果，试图回答“如果我主动做 X，Y 会发生吗”这样的问题。在这一层，研究主体要从“观察者”转变为“行动者”，通过主动的行动，以及对行动后果的观察来识别因果关系。比如，在医学的随机对照试验(Randomized Controlled Trial, RCT)中，就是通过给一组病人服药，另一组服用安慰剂，并比较两组病人的状况来验证药物与疗效之间的因果效应。

因果阶梯第二层级所涉及的行动能力，只有少数物种拥有。拥有这种能力的主体会预测对环境进行刻意改变后的结果，并根据预测结果来选择行为，以实现自己期待的结果。对工具的有意使用可被视为达到因果阶梯第二层的标志。但是，即便是工具的使用者也未必掌握了有关工具的“理论”。理论能够告诉主体，为什么某种工具有效，以及工具如果无效该怎么做。要掌握这样的理论，研究主体还必须在“因果阶梯”中再上升一层，达到“想象力”这一层级。

因果阶梯的第三层是“反事实”(Counterfactuals)，也就是“想象”。这是人类认知的最高层级，涉及对过去已经发生的事情进行的反思和假设，试图回答“如果我在过去做了不同的选择，结果会有什么不同”这样的问题。比如，一位罹患肺病的人可能会思考“如果我当初不吸烟，现在的肺部状况是不是会好一些？”。这一层级要求主体能够想象出一个与已经发生的真实世界类似，但又有所不同的“假想平行世界”，并借助这个假想世界来进行回溯推理。达到这一层级的研究主体，不仅需要理解真实世界的因果机制，还要具备想象未曾发生之事的能力。由于可以回答“假如当时发生的事情与实际不同，那会怎样”这样的问题，人们可以从历史和他人的经验中获取经验教训，对世界运行形成理论。至少到目前为止，这种想象的能力仅为人类所拥有。

一个具体的例子有助于我们理解“因果阶梯”理论。这里我们借用朱迪亚·珀尔所著的《为什么：关于因果关系的新科学》一书第一章给出的一个例子，并对其略作简化【19】。想象一个刑场枪决犯人的场景。行刑的时候，行刑队队长 C 向两位行刑枪手 A 和 B 同时下达开枪的命令。两位枪手听到命令后，都会扣动扳机开枪。任何一位枪手开枪都足以让犯人 D 死亡。可以将这个场景里的因果关系绘制成因果逻辑图。图中的箭头表明从原因到结果的因果关系。需要注意的是，这里我们虽然一上来就绘制了因果图，但这个代表了“上帝视角”的逻辑图对研究主体而言一开始是未知的。研究主体要通过其观察和行动，来试图发掘出这个图所代表的逻辑关系。下面我们将会看到，处在因果阶梯不同层次的研究主体，对场景背后的因果逻辑关系的认识程度会不一样。(图表 3)

图表 3. 刑场例子的因果图



资料来源：中银证券

一个处在因果阶梯第一层的研究主体，只能观察到数据中的相关性。假设有一台计算机持续观察刑场，并将观察到的数据全部记录下来。前述代表队长、枪手和犯人的变量（C、A、B、D）均是或为“真”或为“假”的变量。C为真，表明队长下达了开枪的命令；C为假，表明队长没有下命令。A或B为真，表明A或B开了枪，为假表明没有开枪。D为真，表明犯人死亡；D为假，表明犯人未死。在计算机记录的数据中，将只存在两类记录：一类是C、A、B、D全为真，即队长下了命令，A和B都开了枪，犯人死亡；另一类是C、A、B、D全为假，即队长没下命令，A和B都没开枪，犯人没有死亡。

处在因果阶梯第一层的，只观察到数据相关性的研究主体，无法回答因果阶梯第二层的问题。我们问那个观察并记录了刑场状况的计算机这么一个问题：“如果枪手A在没有听到队长C的命令之时，就自己开了枪，犯人会不会死？”在计算机的记录中，从来没有这样的情况（C为假但A为真）发生过，计算机会因为缺乏数据而无法回答这个问题。这便是仅处在因果阶梯第一层的研究主体之局限——它们仅凭对数据的观察，无法获知因果。

下面我们再来问一个涉及因果阶梯第三层的问题。某天，我们观察到了刑场中的犯人D已被击毙。这意味着C、A、B、D全为真。这时我们问：“如果枪手A在听到了队长C的命令之后，决定不开枪，犯人D是否会死？”这是一个“反事实”的问题——我们在A已经开枪之后，探讨A如果没有开枪，结果会是怎样。面对这个问题，不要说因果阶梯第一层的研究主体了，就算是第二层的主体也回答不了。这不是一个仅凭观察数据就能回答的问题，也不是一个可以通过实践实验能回答的问题——因为没法推翻已经发生过的事情来做实验。要回答这个问题，必须要形成对整个场景的系统性理解，即是要掌握代表“上帝视角”的因果图。基于因果图，我们可以知道，就算枪手A听到命令之后没有开枪，枪手B仍然会开枪，所以犯人D仍然会死。当然，我们人类可以很容易地回答这个问题。这是因为我们人类本就拥有因果阶梯第三层的认识能力。但这个问题对本质上是统计拟合函数的大模型而言，却是难以回答的。

从两方面来说，大语言模型目前仅处在因果阶梯的第一层。

第一，大模型是鹦鹉学舌式的语言生成器，没法在它学习过的语料之外，讲出新的有意义的话。大模型在预测词元的时候，依赖于它学习过的语料中的统计规律。语料中越常见的话语，越容易在大模型那里听到。大模型中有个超参数（Hyperparameter）叫做“温度”（Temperature），可被用来控制大模型预测词元时的随机性。“温度”这个超参数设置得越小，大模型在预测词元时就越“中规中矩”，即更可能选择那些在语料中出现得更频繁的词汇。“温度”设置得越大，大模型就越可能选取那些在语料中不太常见的说法。但增加了词元预测的随机性之后，大模型将会越来越明显的“胡言乱语”，而不是讲出有意义的话来。究其原因，是因为大模型本质上是模仿人说话的工具。当你让大模型偏离人类语言材料中的统计规律，随机地预测词元，它就只能输出随机的语句。理论上，将“温度”这个超参数设置得足够高，大模型就会变成一个在键盘上胡乱敲击的“猴子”，只能产生出随机的词语组合。

第二，如果把大模型放到一个全新的，它学习过的语料中没有描述过的场景中，大模型并不具备从无到有发现场景因果逻辑结构的能力。大模型可以对场景进行观察和记录，自主发现数据中的相关关系。但正如前文对因果阶梯理论的论述，仅凭这样没法发掘出相关性背后的因果关系。人们在与大模型对话时，可能会感到大模型似乎理解某些事情背后的因果关系。这并不是大模型自主发现了因果关系，而只是它在学过的语料中看到过相关的论述而已。至于反事实的想象能力，大模型则根本不具备。

所以说，大模型是一个“随机鹦鹉”，远远达不到人的智能。大模型没有能力识别事物间的因果关系，也不具备进行反事实想象的能力。而这两者，是人类理解世界，拥有创造力，能进行价值判断的基础。因此，大模型虽然能像人一样说话，却还离人类智能差得远。Bender等人在2021年的一篇文章中做出了如下一段精辟的总结：“尽管大语言模型的输出看起来像那么回事，但它本质上只是一个‘随机鹦鹉’（stochastic parrot）——它只是根据概率信息，把海量训练数据中观察到的语言形式胡乱拼接在一起，整个过程完全不涉及任何对意义的理解。”（Bender et al. 2021, 616-617 页）【20】

2.4 大模型的技术“天花板”

大模型通过学人说话来“模仿人”的技术路线，可说是成也萧何、败也萧何。好的方面是，大模型通过模仿人，从而一定程度上拥有了泛化智能和“价值理性”，因而可以超越如 AlphaGo 那样的窄域 AI，拥有处理复杂场景和任务的能力。但坏的方面是，大模型作为人类的“学生”，其能力上限被其所模仿的“人类”所框定，难以成为超过人的“超人”。

作为人类的“学生”，大模型只能学习人类已经拥有的“既有知识”，而并不能独立创造“新知”。大模型的强大能力来自对人类已经创造出来的知识的学习。这些知识主要包括人类生产的文本（程序代码也包含其中）。除此而外，目前的多模态大模型还可以学习图像、视频等。大模型长于对已学习的既有知识的调用和组合，但没法创造全新的知识。

由于有大量人类的“默会知识”并未记录在文本上，所以大模型通过文本对人类知识的学习还会打一个很大的折扣。所谓“默会知识”（Tacit Knowledge），是那些植根于个人经验和直觉中，很难用语言清晰表达的知识，即那些“只可意会、不可言传”的知识。比如，一个人要学会骑自行车，光靠阅读自行车的书籍和文章可不够。他还必须亲身骑上车，摔上几次，才能够掌握驾驭自行车的平衡能力。那种骑自行车所必须的，对平衡的微妙感知和对身体的下意识控制，就属于默会知识。这样的默会知识没有表现为文字，大模型无法掌握。缺少了这些默会知识，AI 大模型对真实世界的了解就是片面的。

AI 如果要想在泛化智能上超越人类，需要在现有大模型基础之上，至少再取得两点重要技术突破。

第一，AI 系统需要拥有身体，从而可以在真实的物理世界中成为“行动者”，通过与世界互动来积累经验与发现新知。这正是现在 AI 行业中热门的“具身智能”（Embodied Artificial Intelligence, EAI）和“世界模型”（World Model）试图解决的问题。前面介绍因果阶梯理论时说过了，主体如果要超越数据间的相关性而把握到因果关系，自己必须要成为一个“实践者”，在真实世界中主动作为并观察其后果。为了做到这一点，需要发展机器人技术来让 AI 在物理世界中拥有一个“肉身”，从而让 AI 在世界中与环境互动。此外，还需要 AI 拥有对真实世界建模的能力，从而把握真实世界的运行规律。这正是许多 AI 研究者正在开发的世界模型要解决的问题。

第二，AI 系统需要有长期记忆，从而可以在实践中进化自己。目前的大模型，在训练结束之后，其内部参数就被固定了下来，不会在后续模型的使用中被更改。这意味着，如果给大模型输入相同的“提示词”（prompt）和“上下文”（Context），模型的输出只会有随机性带来的差异（随机性由“温度”超参数控制），而难有本质不同。相比之下，人类却可以重构其脑部神经元的连接方式，将自己的经历变成长期记忆存在脑中。这是人类可以终身学习、持续自我进化、适应新环境的重要原因。缺乏这种在交互中改变自身能力的大模型，虽然拥有海量知识，但在面对未知的、需要灵活变通的情景时，也只能表现得像个“书呆子”。目前 AI 前沿领域之一的“记忆增强神经网络”（Memory-Augmented Neural Networks），就是试图赋予神经网络以长期记忆和进化能力的技术。

在这两点技术障碍之外，实现通用人工智能 AGI 的更大障碍是“评估难题”。训练大模型的前提是，需要知道如何评估（evaluate）神经网络输出结果的好坏。只有能评价输出的好坏，才能知道该如何修正神经网络中的参数。2026 年 5 月，DeepMind 研究员 Wang 在一篇影响很大的博文中发表观点说，在大模型的训练中“评估位于一切的上游”。他进一步说到：“如果你能正确评估，你就能正确训练”【21】。但正如前文分析 ANI 与 AGI 间的鸿沟时所说，在泛化场景中，目标通常是多样化的，评估标准因而也是模糊的。这时，把 Wang 的话翻转一下就成了：“没法找到评估标准，就没法训练”。这一“评估难题”是当前 AI 发展的一个关键障碍。大模型通过模仿人来解决“评估难题”，但这种向人类的模仿对齐反过来又约束了大模型，让大模型只能成为人类的“学生”，从而产生了前述的局限。但“评估难题”又不是仅凭 AI 或计算机技术发展能解决的。要解决这个难题（如果它是可能被解决的话），AI 技术的进步，以及技术之外的哲学思辨、乃至全社会的共识凝聚，都是需要的。至少在目前，解决“评估难题”的难度还相当大。

基于以上的分析可知，就当前的大模型技术而言，AI 的智能还难以超过人类，“技术奇点”远未到来。从堆叠芯片算力的角度来说，我们有可能在不远的未来制造出算力超越人脑的 AI 系统。但数量的增加弥补不了质量的差距。站在因果阶梯第一层，且以“模仿人”为目标的大模型，没法达到人类的智慧水平，尤其缺乏人类所拥有的创造力。在优化 AI 系统方面，AI 虽然可以在一些具体的工程问题上（比如编写程序代码）帮上忙，但并不具备在不依赖人的情况下，自主自我优化的“递归自我改进”之能力。Cunningham 等人 2026 年 7 月发表文章称，基于他们对 AI 行业的分析和估计，递归自我改进并未出现【22】。像埃隆·马斯克那样乐观派所设想的超越人类智慧的 AI，以及“惊人富足”的社会恐怕还遥遥无期。

3. 下一个“奇迹”到来之前的 AI 发展

AI 技术要突破大模型所面临的“天花板”，需要又一个“奇迹”来再次引发技术的非线性跃升。目前，专家们普遍认为，通过“具身智能”和“世界模型”来让 AI 涌现出对真实物理世界的理解，是最可能发生下一个“奇迹”的方向。如果能让 AI 拥有身体，在真实世界中与环境互动，就有可能让 AI 逐步理解世界，从目前站在因果阶梯第一层的“学舌鹦鹉”，变成攀升至因果阶梯第二层的“物理世界行动者”。

但要创造下一个“奇迹”谈何容易。大模型通过对海量人类文本的学习，方才涌现出了泛化智能。要让 AI 理解物理世界，必然也需要海量数据来训练神经网络模型。但物理世界数据的获取难度和成本，比文本数据高得多。在互联网上，可以低成本地拿到大量文本数据来训练模型。但要采集主体在真实世界中与物理环境互动的数据，则没有那么简单和便宜。训练数据的不足，是制约“世界模型”发展的重要障碍。目前，有机构在开发“数字孪生”（Digital Twin）和“数字表亲”（Digital Cousins）技术，试图通过构建物理场景的数字仿真来提供模型训练数据【23】。但这些技术的效果还有待观察。


在下一个“奇迹”到来之前，AI 将仍以大模型作为主流技术路线，发展可能呈现“内缓、外速”的局面。所谓“内缓”，说的是大模型本身的性能提升速度将逐步放缓。而“外速”，则说的是用大模型来作“大脑”，调用各种工具来完成任务的“智能体”（Agent）会快速发展。换句话说，大模型本身的发展会趋缓，但对其的应用会加速。

3.1 大模型发展的“内缓”

大模型本身发展速度会趋缓的主要原因是“缩放定律”（Scaling Laws）的存在。缩放定律说的是：大语言模型的测试性能（以预测误差函数来衡量），与模型参数量、训练数据量以及训练计算量之间，存在高度可预测的幂律（Power-law）关系。这里所说的预测误差，是大模型所预测的词元，与人类文本中实际出现的词元的偏差度。这个预测误差也被叫做“损失函数”（Loss Function）。缩放定律是人工智能和机器学习领域的一项核心经验规律，在大模型的训练中被普遍发现。缩放定律意味着，在训练大模型上投入更多资源，虽能提升模型性能，但投入的边际回报率会快速递减。

OpenAI 的 Kaplan 等人 2020 年发表了一篇阐述缩放定律的经典文章，揭示了大模型规模与模型预测误差之间的幂律关系。图表 4 取自这篇文章。图中三个小图的横轴分别是训练模型所用的计算量、训练数据集规模，以及模型参数数量。这三个指标从不同角度衡量了模型的规模。图中的纵轴是模型的预测误差——误差越小表明模型表现越好。要注意的是，三个小图的横轴均是对数刻度，从左往右，模型规模不断提升数量级。三个图清楚地表明，随着模型规模数量级的提升，模型的预测误差线性下降，在图中画出了近乎直线的轨迹。这意味着模型预测误差随模型规模的幂次变化，呈现出幂律关系。根据 Kaplan 等人的估计，训练大模型所用的计算量每扩大 10 倍，模型预测误差下降约 11%【24】。别的研究者虽然有不同的估计数据，但估计出来的量级都是一致的，即模型规模每扩大 10 倍，模型预测误差下降百分之十几或百分之几十。

图表 4. 大模型的损失函数随模型计算量、数据集规模及参数量的增加而平滑下降



资料来源：Kaplan et al. 2020, Figure 1

“缩放定律”是从多个大模型的训练过程中统计出来的经验规律，根植于大模型所用底层的数学方法。在大模型的训练过程中，人类的语言材料被拆分成词元后，会被映射到一个高维向量空间中——这个空间叫做“嵌入空间”（Embedding Space）。在这个空间中，每个词元都对应一个向量（Vector）【25】。有趣的是，人类语言的词元所对应的向量，会在这个嵌入空间中形成一个几何形状，叫做“语义流形”（Semantic Manifold）。这个语义流形，就是人类语言统计规律的几何表达。2022 年，Sharma 与 Kaplan 给出了一个理论，说大模型在拟合人类语言的统计规律时，是在用参数切分空间，去逼近这个语义流形。而这种逼近方法会自然地产生出模型计算量与逼近精度的幂律关系，即缩放定律【26】。

可以这么形象地去理解缩放定律的由来。想象我们用一把尺子去量一个物体的长度。测量的误差大小（精度）决定于这把尺子的最小刻度长度。用一把最小刻度为厘米的尺子去量，测量误差是厘米级的；用一把最小刻度为毫米的尺子去量，测量误差就是毫米级的。要降低测量误差（提升测量精度），需要付出增加计算量的代价。一把 1 米长的厘米精度尺子，总共有 100 厘米长，计算时最多处理 100 个数就行了；但同样长度的毫米精度尺子，则有 1000 毫米长，计算时需要处理 1000 个数，计算量是厘米精度尺子的 10 倍。如果我们需要测量的是二维平面，需要同时测量长和宽，此时将刻度从厘米改成毫米，将测量误差缩小到原来的 1/10，需要处理的数据量会翻成原来的 100 倍（等于 10 的平方）——1 平方米包含 1 万个平方厘米格子，以及 100 万个平方毫米格子。如果要测量的是三维立体，需要测量长、宽、高时，要将测量误差缩小到原来的 1/10，所需处理的计算量会是原来的 1000 倍（等于 10 的三次方）。研究表明，语义流形的维度大概是 10 维。这意味着要将误差缩小到原来的 1/10，所需计算量是原来的 10 的 10 次方倍——这就形成了计算量与误差之间的幂律关系。

“缩放定律”的更根本成因，来自大模型“模仿人”的方法论。大模型是一个通过学习人类语言来模仿人的 AI 系统。人类作为其模仿对象，是大模型只能逼近，而无法超越的“天花板”。大模型可以扩大规模，记住更多的人类文本，更全面而精细地估计人类文本中的各种统计规律，从而降低其预测词元时的预测误差。但预测误差理论上最小也就是零。在预测误差向零逼近的过程中，降低误差所付出的代价会越来越大，从而导致缩放定律的出现。

“缩放定律”与“涌现智能”并不矛盾。缩放定律说的是，随着大模型规模数量级的提升，大模型所给出的词元预测误差（相对人类文本而言）会线性下降。也就是说，大模型规模越大，对人类语言的模仿就越完美。在模仿度提升的过程中，大模型完成具体任务的表现会有一个量变到质变的过程。比如，跟大模型对话时，大模型如果每说 10 个词就有 5 个是胡言乱语，人类会认为这个大模型完全不具备对话能力。但如果大模型每说 100 个词，只有 1 个词说得恰当，人们会认为这个大模型具有对话能力。换言之，大模型提升对模仿人类精度的过程中，总会在某个水平上从“不像人”变成“像人”，从而涌现出像人一样的智能。但在提升大模型规模的过程中，这种量变到质变的机会只有一次。要想仅仅通过扩大大模型规模来实现类似“涌现智能”这样的新的“奇迹”，从方法论上来看就是不可能的。

“缩放定律”意味着，过去几年通过提升大模型规模来提高模型性能的道路，走起来会越来越困难。从2020年1750亿个参数的GPT-3，到2026年2.8万亿个参数的Kimi K3，大模型规模扩张了十几倍，表现也有明显提升。但由于“缩放定律”所带来的边际回报率之快速下降，扩大模型规模的投入将越来越缺乏性价比（更多投入带来更少性能提升），最终让这条堆算力、扩规模的路走不下去。

此外，“缩放定律”还意味着，训练数据的不足，将越发成为大模型扩大规模的障碍。2022年，DeepMind公司的Hoffmann等人发表文章，提出了“Chinchilla缩放定律”（Chinchilla Scaling Law），作为对Kaplan等人2020年发现的“缩放定律”的补充【27】。根据“Chinchilla缩放定律”，要最有效地利用计算算力，大模型训练时模型参数量和训练数据量要保持在1:20。也就是说，大模型的1个参数，最好匹配20个词元的训练数据。如果训练数据量低于这个水平，就会限制大模型的训练效果。考虑到最近几年大模型扩大的速度远超人类生产文本数据的速度，训练数据不足的问题已经开始浮现。根据Villalobos等人的估算，在2026年到2028年间的某个时点，人类可能耗尽所有可用的文本数据，让大模型发展碰上“数据墙”（Data Wall）而难以进展【28】。虽然可以用图片、视频等多模态数据来弥补文本数据的不足，但图片视频数据所包含的人类“价值理性”数据远不如文本数据那么丰富，在提升大模型性能方面所能发挥的作用有限，因而并不能解决“数据墙”的问题。

3.2 大模型发展的“外速”

大模型自身的发展虽然受到“缩放定律”的限制，但它作为一个生产力工具，在人类社会中有广阔应用空间。大模型虽然只是人类的“模仿者”，并不具有人类所拥有的创造力，但它已经可以帮助人类完成很多工作了。毕竟，人类所从事的绝大多数工作，并不需要像科学家那样去创造新知，而只需要按既定套路按部就班推进即可。这样的工作，大模型不但可以胜任，而且可以做得比人类更好。大模型拥有远超任何人的知识储备（大模型训练数据量远超任何人的阅读量），拥有远超任何人的计算能力，而且还不知疲倦、不带情绪，是字面意义上的“超级牛马员工”。这意味着，不需要创造力的工作岗位，大模型都可以胜任。即使是那些需要人类创造力的岗位（如研发岗位），大模型也可以发挥辅助作用。可以想见，大模型这个人类模仿者，在人类社会中有广泛的应用前景。

近年来掀起的“智能体”（Agent）热，正在让大模型的应用加速。所谓“智能体”，是指用户只需给出最终目标，它自己就能自主规划、调用工具并执行任务，最终完成目标的AI系统。智能体以大模型作为“大脑”，并给大模型辅以规划模块、记忆系统、工具集、反馈模块，最终打包成一个可以完成任务的智能实体。其中，大模型因为可以很好地模仿人，所以能理解人类的指令，并了解人类处理各个具体任务的套路，因而可以借助配置给它的各种工具，完成具体任务。与一问一答的聊天大模型不同，智能体能够实实在在帮人干活。因此，智能体在出现之后就迅速发展。2026年1月，中科算网算泥社区与中国工业互联网研究院联合发布了《AI Agent智能体技术发展报告》，将2025年称为“智能体元年”【29】。“元年”之后，智能体的应用已呈现爆发之势。

将大模型的泛化智能与窄域人工智能ANI的搜索试错能力结合，可以辅助人们进行研发创新工作。在给定清晰目标的前提下，ANI可以通过搜索试错，找出甚至连人类都不知道的更优解法。而大模型则可以理解人类的意图，并且把人类的模糊意图分解成较为清晰的子目标。因此，人类可以借助大模型来操控ANI，更便捷地借助AI系统来进行研发创新。

随着“智能体”从虚拟空间进入物理空间，以大模型为脑的智能体将深刻改变人类社会。目前的智能体应用，还主要局限于计算机的虚拟空间中。具体而言，是赋予大模型操控计算机的工具和权限，从而让智能体完成过去人类操控计算机才能完成的任务。但随着大模型进入物理世界操控各种机器，从而可以完成物理世界中的任务，其应用范围还会进一步打开。那时，社会生产方式、生产关系、乃至社会结构都会发生重大变化。在这样广阔的想象空间中，大模型应用的发展可说是方兴未艾。

4. AI 大模型的宏观经济含义

对大模型底层逻辑的分析，为分析 AI 大模型的宏观经济含义打好了基础。大模型是人类的模仿者，基本掌握了人类已有的知识。在一定程度上，大模型可以替代人。因此，AI 大模型不同于人类以前的技术，对宏观经济的影响可能超过之前的技术进步。面对这样前所未有的，潜力和想象空间巨大的技术进步，必须先要把其底层逻辑和发展前景讨论清楚，才可以进而来分析其宏观经济含义。这是本文要花大量篇幅讨论大模型技术的原因。前文的讨论为接下来的宏观经济分析奠定了基础。

基于前面的分析可知，AI 大模型并不会如乐观者设想的那样带来“惊人富足”的社会。正如前文所论述的，基于大模型的 AI 技术不具有人类所拥有的创造力。至于 AI 的递归自我改进（RSI）、技术奇点（Technological Singularity）等设想，在可预见的未来仍只能停留在科幻小说中。AI 可以提升人类社会对资源和能源的利用效率，但它不会消灭资源和能源本身的稀缺性，自然也不会消除由资源和能源转换而来的产品之稀缺性。在思考 AI 的宏观经济影响时，不能把 AI 想成一种“魔法”，然后用这个“魔法”为未来社会附上各种绚丽的想象色彩。马斯克所设想的那种人人都能心想事成的“惊人富足”社会，那个甚至连货币都不需要的社会，不是我们在思考 AI 时代宏观经济时需要考虑的场景。

AI 大模型虽然还难以达到人类的智能水平，但它作为一种强有力的生产力工具，足以让社会生产力大幅提升。AI 虽然还无法拥有人类的创造力，但可以完成人类目前所从事的许多重复性工作。正如前文讨论智能体应用空间时所说的，大模型已经在计算机虚拟空间中展现了巨大的生产力。而当它进入物理世界，开始操控各种机器完成任务时，会让人类社会生产力进一步明显提升。大模型作为一种强有力的生产力工具，其效能还在逐步体现的过程中。

但在 AI 推升生产力的同时，经济中的收入分配问题会变得更为重要。天真的人可能会以为，AI 大模型的广泛运用，会给每个人都带来一个“魔法口袋”，每个人都可以随时从中拿出自己想要的东西。但这不会变成现实。AI 时代更可能的情形是，AI 大模型技术在物理世界中的广泛应用，催生出一些规模庞大的自动化“超级工厂”。这些“超级工厂”会成为全社会生产力提升的主要载体。但接下来的关键问题是，这些“超级工厂”的产出该如何分配？如果不能妥善处理分配问题，AI 带来的生产力提升对社会可能弊大于利。


AI 技术在提升社会生产力的同时，可能在两方面恶化社会收入分配状况，引发社会问题，进而阻碍经济发展。

其一、AI 大模型可能将“资本替代劳动”的趋势推向极致，从而导致资本所有者与劳动者之间的收入差距拉大。一直以来，人类都依赖资本与人类劳动两个投入要素的结合来获得产出。产出则会相应归属资本和劳动所有，成为资本的回报和劳动的回报。过去如蒸汽机、电气化、计算机、互联网这样的技术进步，并没有改变资本与人类劳动结合得到产出的基本生产模式，而只是提升了生产效率。这些技术进步让资本与劳动都获益，二者回报都随之增加。但 AI 大模型这次的技术进步与以前不一样。AI 大模型是人类的“模仿者”，因而可以在很多生产活动中替代人类劳动，从而让资本加 AI 即可得到产出。考虑到 AI 需要算力设施来运行，因此 AI 系统本身应该被视为一种新形式的资本。如果可以用 AI 来操控机器，从而让资本可以在不依赖于人（或者极少依赖于人）的情况下进行生产，那么产出的全部（或至少是大部分）会变成资本的回报，从而使得劳动收入占经济总产出的比重显著下降。对于那些缺乏资本、而主要靠劳动报酬为生的人来说，这无异于拿走他们的“饭碗”。如此会让资本所有者和劳动者之间的收入差距显著拉大。

其二、AI 大模型还可能形成“AI 技能鸿沟”（AI Skills Gap），加大人群内部的分层，拉大民众内部的收入分配差距。对那些从事需要较高创造力、非重复性工作的人而言，AI 大模型是赋能的工具；但对那些从事重复性、程式化工作的人，AI 大模型是夺走其工作机会的竞争者。随着 AI 技术的推进，人们内部会分出差距明显的层级，运用 AI 大模型的人和被 AI 大模型替代的人之间，会有越来越大的收入落差，从而导致居民内部的收入差距的拉大。

AI 技术带来的收入分配恶化，不仅是个经济问题，还是个社会问题——收入差距如果拉得过大，甚至可能导致社会撕裂、乃至政治共同体瓦解的严重后果。以美国为例，自 1990 年代以来，美国国内总收入中，国内劳动者报酬占比明显下降，而反映资本回报的“企业净经营盈余”占比则显著上升。二者走势的背离反映出资本所有者和劳动者之间收入差距的拉大。2017 年，国际货币基金组织（IMF）发表一篇论文认为，美国劳动者报酬占比下降的主要原因是，自动化技术在重复性和标准化的“常规任务”（Routine Tasks）中的应用——自动化技术对这些常规任务中人类劳动的替代【30】。资本和劳动收入差距的拉大，是美国近些年社会撕裂、政治极化的重要原因。特朗普两次当选美国总统，也很大程度上拜这样的社会环境所赐。未来，随着 AI 技术逐步渗透进那些非常规任务，替代其中的劳动，美国资本与劳动之间的收入分配差距问题还会变得更为严重，加剧美国现在已经较为严重的社会问题。（图表 5）

图表 5. 20 世纪 90 年代以来，美国国内劳动者报酬和企业净经营盈余之间拉开了明显差距



资料来源：万得，中银证券

面对 AI 带来的收入分配问题，社会需要采取某种形式的“共产主义”措施来将 AI 红利分配给广大人民。从守住社会稳定底线而言，这是避免收入分配差距拉大撕裂社会，引发社会不稳定所需要的。而从追求更高社会目标而言，这是实现提升民众福利这一经济发展最终目标所要求的。要化解 AI 带来的收入分配问题，需要将 AI 获得的收益广泛地分配给社会所有民众。这意味着社会需要采取某种形式的“共产主义”，至少将部分“AI 资本”变成全民所有。

即使在美国，也有声音呼吁将 AI 带来的生产力红利更为平等地分配给所有人。埃隆·马斯克在乐观看待 AI 时代社会前景的同时，也注意到了收入分配恶化的问题，并提出了“全面高收入计划”（Universal High Income, UHI）。UHI 意味着基于 AI 带来的巨大生产力提升，政府按月向所有公民发放远超基本生活需求的丰厚收入，从而让他们可以负担得起想要的商品和服务【31】。2026 年 6 月，美国参议员伯尼·桑德斯（Bernie Sanders）向美国参议院提交了《美国 AI 主权财富基金法案》，提出了一种实现 UHI 的具体办法，即将 AI 公司的一半股份收归国有。该法案要求年销售额超 2 亿美元的 AI 公司，将其 50% 的股份上交给美国政府，以成立“美国 AI 主权财富基金”。该基金则将其分红平均分配给所有美国人，从而让所有美国人分享 AI 带来的红利【32】。

AI 带来的生产力提升，再加上“AI 资本”全民所有制，有望让人类社会成为马克思所设想的那种让每个人获得真正自由的社会。当每个人都分享了 AI 带来的红利之后，就可以从重复性、强制性的工作解放出来。此时，工作对人而言不再是谋生的工具，而是成为彰显其人类本质的方式。人们可以根据个人的兴趣和特长，在各个领域自由发挥和展示才能，让劳动变成了一种富有成就感的享受。在《德意志意识形态》中，马克思写下了这么一段激动人心的文字：“在共产主义社会里，任何人都没有特殊的活动范围，而是都可以在任何部门内发展，社会调节着整个生产，因而使我有可能会随自己的兴趣今天干这事，明天干那事，上午打猎，下午捕鱼，傍晚从事畜牧，晚饭后从事批判，这样就不会使我老是一个猎人、渔夫、牧人或批判者。”（马克思，1845，《德意志意识形态》，Part I, A, 4）【33】这是 AI 技术可能带来的光明未来。

但如果不能妥善处理 AI 带来的收入分配差距拉大问题，则 AI 可能动摇社会稳定。如果不能将 AI 技术视为社会共有，无法将 AI 红利较为平等地分配给社会里的每个人，则收入差距拉大、社会撕裂、共同体瓦解的风险会随着 AI 技术的进步而上升。当 AI 带来的生产力提升仅被少数人所获取，更多人却被技术发展所抛下时，整个宏观经济将走向充满不平等、紧张和动荡的黑暗前景。仍然以美国为例，对埃隆·马斯克和伯尼·桑德斯提出的设想和方案，美国这么一个资本主义国家恐怕很难采纳。但这么一来，美国在过去 40 年全球化过程中已经恶化的收入差距拉大和社会撕裂问题，在未来可能变得更加严重。

像我国这样的内需不足的国家，AI 技术可能加剧需求不足的问题。在 2025 年 1 月发表的《中国经济的逻辑与出路》一文中，笔者曾说过“有效需求不足归根结底是个收入分配问题”。当居民部门收入占经济总收入比重过低，居民消费占经济比重不足时，内需不足的问题就会产生【34】。AI 技术带来的“资本替代劳动”的趋势在我国也会出现。当然，我国是社会主义国家，广大人民可以通过规模庞大的国有资产分享 AI 红利。但这种分享必须要通过国有资产回报更多地向居民部门的转移才能落到实处。如果国有资产回报的运用仍然延续之前的“重投资、轻消费”的倾向，则 AI 带来的生产力提升会让我国需求不足的问题变得更加严重，制约我国经济发展。因此，我国有必要将国有资本回报更多导向居民部门，增加居民部门的收入和消费占整个经济的比重。采取如此“上策”，可确保 AI 红利为人民所充分享受，进而实现马克思的伟大设想。

AI 技术在经济中大规模应用的后果，不是简单推高社会生产力那么简单。AI 技术在推高社会生产力的同时，还会在经济社会中产生一环接一环的“涟漪效应”。其中，对收入分配的影响最值得关注。AI 时代的经济社会究竟走向何方，取决于经济和社会结构能否因应 AI 技术的推广而做出妥善调整。

5. 美国的 AI 泡沫

现在我们回到当前资本市场高度关注的问题：当前的 AI 行业是否已经产生泡沫？如果将泡沫定义为资产价格在过度炒作下超过其应有价值，则当前部分 AI 公司的股价中有泡沫成分，且美国 AI 公司的股价泡沫更为明显。这一结论可以从以下几个方面来加以论证。

第一、对于 AI 的过于乐观的预期（通用人工智能 AGI 与超级人工智能 ASI），难以在大模型这一当前主流 AI 技术路线下实现。这一点在前文已经论述过了。但对很多人来说，这种乐观预期仍然是未来几年可能实现的一种可能性。2026 年 6 月，AI 巨头 Anthropic 发表了题为《当 AI 构建自己》（When AI Builds Itself）的博文，大篇幅地阐述了 AI 递归自我改进（RSI）的可能【35】。虽然不清楚这里面究竟有多少公司宣传的成分，但类似这样的话语势必会影响投资者的情绪，推高资产价格。当资产价格包含了这些短期内难以变成现实的东西之后，就会出现资产价格泡沫。

第二、将近些年“涌现奇迹”所带来的快速发展势头做线性外推，会高估未来更长期 AI 的发展速度。前文论述 AI 大模型底层逻辑时已经述及，大模型涌现出泛化智能是一个未被预料到的“奇迹”。但奇迹是可遇而不可求的。下一场有类似影响的“奇迹”会在何时发生，现在可以猜测，却难以精确预估。在人工智能 70 年的发展历史中，近些年“涌现奇迹”发生后的行业高速增长是“非常态”，而非“常态”。在没有新的“奇迹”发生之前，行业发展速度会逐步从高位回落。如果投资者把“涌现奇迹”发生之后这几年的行业高速增长当成未来的“常态”，并以之来预估行业长期增速，则势必高估行业前景，催生泡沫。

第三、AI 带来的生产力提升并不会全数转化为 AI 的盈利，收入分配问题将限制 AI 所能获得的回报。当很多投资者在憧憬 AI 的广阔应用前景和获利空间的时候，并没有把 AI 技术在宏观经济中会产生的“涟漪效应”考虑在内。如果 AI 真的如乐观设想那样能极大提升人类社会的生产力，那么它带来的收入分配效应及相应社会影响就不能被忽略。AI 能力越是强大，政府对其调控的力度就会越大。一个简单道理是，如果社会里的钱都被 AI 挣走了（流向了 AI 的所有者），社会其他部门一定会对 AI 的利润提出索取要求。因此，在评估 AI 的盈利前景时，不能只想着 AI 能力有多强、能挣多少钱，还得考虑 AI 如果钱挣得很多的话，政府和社会会如何应对 AI 的暴利。如果忽略后者，对 AI 盈利前景的预估就会过于乐观，滋生泡沫。

第四、面对 AI 这么一场具有颠覆性的技术变革，相关企业的投资会理性地过度，形成一种“理性泡沫”。对 AI 做出天量投资的公司，未必不知道前述的这些逻辑。但面对 AI 这么一种颠覆性的技术进步时，一家公司在竞争中失败的后果就是被时代抛弃。相较这一严重后果而言，过度或低效投资的代价并不是那么难以接受。可以说，AI 企业已经患上了“错失恐惧症”（Fear of Missing Out，简称 FOMO），生怕错失 AI 带来的机会。因此，竞争中的各 AI 企业就像处在“囚徒困境”中一样，就算知道投资已经过度，也必须要跟随着大家一起投下去——继续大量做低效投资，总好过不做投资而被淘汰。2025 年 11 月，诺贝尔经济学奖得主迈克尔·斯宾塞（Michael Spence）在一场会议中发表观点，称 AI 投资热潮是“一场理性泡沫”，说的就是这个逻辑【36】。

以上四点，对在 AI 竞争中领跑的美国和中国都成立，因而意味着中美两国的 AI 行业都存在泡沫成分。但如果从中美 AI 竞争格局的角度出发，可以发现美国 AI 行业的泡沫更为明显。

美国和中国是当前全球 AI 竞争中的第一名和第二名，两国在 AI 发展中各有优势。美国在 AI 底层原创技术和高端算力上领先，中国则在 AI 开源生态和工程化落地方面有优势。美国是 AI 大模型技术的发源地，并拥有全球最多的 AI 顶尖学者。但就 AI 大模型人才和技术而言，中国并不明显落后于美国。根据斯坦福大学 2026 年 4 月发布的《2026 年人工智能指数报告》披露的数据（57 页），2024 年中国与美国获取的 AI 专利数分别为 9.8 万和 1.6 万，占世界 AI 专利获取总数的比重分别为 74.24% 与 12.06%【37】。虽然中美专利数不完全可比，但二者的数量差异也能在一定程度上反映中国的 AI 技术实力。

美国 AI 行业领先中国最多的地方是高端芯片和算力。美方利用其半导体技术方面的领先优势，对我国进行了高科技芯片的断供，以限制我国 AI 算力扩张。同时，美国又在本土大量投资建设 AI 算力。斯坦福大学《2026 年人工智能指数报告》披露的数据显示（183 页），2025 年美国的 AI 民间投资金额是中国的 23 倍。即使把两国的政府投资也算上，该年美国 AI 总投资金额也应该比中国高出一个数量级。根据 Epoch AI 统计的数据，2021 年 5 月时，美国和中国占世界总算力的比重分别为 34% 和 47%，中国算力规模还超过美国。但到了 2025 年 1 月，美国的占比已上升至 74%，中国的占比则下降至 15%，中国已明显落后于美国【38】。美方的如意算盘是，通过对中国高科技芯片的断供，拉开和中国这一 AI 领域最大竞争对手之间的算力差距，构建出 AI 算力方面的“护城河”，进而让美国的 AI 大模型与别国大模型拉开显著的性能差距，最终通过对算力的垄断来在 AI 方面获取垄断利润。

但“缩放定律”意味着美国的算力优势难以转化成同等的大模型性能优势，美国算力“护城河”的效果有限。“缩放定律”意味着，为了让大模型的性能提升十几个乃至几十个百分点，大模型的规模和训练算力需要十倍扩张。在如此之快的边际回报下降速率面前，美国远高于中国的算力资源，并不能让美国的 AI 大模型与中国的大模型有本质不同。在诸多测试中，中国大模型的性能表现得分虽低于美国大模型，但差距不大。2026 年 8 月，根据 BenchLM 公司的评测，全球大模型性能排名前四都是美国的模型。其中，排名第一的 Claude Mythos 5 性能得分为 83.26。中国的 Kimi K3 排名第五，性能得分仅比第一名低 2.79 分【39】。当美国的算力优势无法转换成同等的 AI 性能优势时，算力投入的成本就难以获取相应地收益，算力投资就可能变成泡沫的温床。

中国大模型选择的开源道路，也给美国闭源大模型带来了很大压力。所谓开源大模型，是将模型架构、参数权重乃至训练代码等核心要素向公众开放，允许其他人自由下载、部署、修改和二次开发的大模型。闭源大模型则是不公开源代码和模型权重，其他人无法下载或修改，仅能通过接口或在线服务形式进行调用的“黑盒”式大模型。2025 年 1 月，中国开源大模型 DeepSeek R1 横空出世，掀起了中国开源大模型与美国闭源大模型间的正面竞争。对用户来说，开源模型的使用成本比闭源模型更低，且用户保有更多掌控力。在性能相差不大的时候，中国成本更低的开源大模型给美国闭源大模型带来了很强竞争压力，明显侵蚀了后者的市场份额。

事实已经证明，美国大量投资而形成的算力优势并不能让其大模型获取垄断地位，也无法让美国 AI 公司获取垄断收益——这让美国的 AI 投资有变成泡沫的风险。当中国用更少算力训练出性能相差不远，且拥有开源生态的大模型之后，美国闭源大模型的算力投入就容易变成无法收回成本的泡沫式投资。

宏观数据显示，当前的美国股市类似于 2000 年 IT 泡沫破灭之前的局面。股票的长期价值来自于上市公司的分红。相应地，在美国过去半个多世纪的经济数据中，可以发现美国企业总分红与标普 500 指数对应的上市公司之总市值之间，有长期明显的正相关性——分红较高的时候，股票市值也较高。但从 2022 年至今，这两个长期正相关的指标走势明显背离。一方面，是从高位回落的企业分红占 GDP 比重数据，另一方面则是显著走高的标普 500 股票市值与 GDP 的比例数据。上一次这两个指标有如此显著背离走势时，还是在 2000 年 IT 泡沫破灭之前。从这个数据来看，有必要对美股重演 IT 泡沫破灭的风险高度警惕。（图表 6）

图表 6. 2022 年以来，美国企业分红与股票市值走势明显背离



资料来源：CEIC，中银证券

说股市中出现了 AI 泡沫，并不是要否定 AI 大模型技术。AI 大模型是当今世界最重要的技术进步，对世界的影响才刚刚开始体现。但是，将 AI 技术的发展前景想得过于乐观，把“技术奇点”、“强人工智能”这些至少需要又一次“奇迹”发生才能实现的東西打入到资产定价预期中，就会将股价推升至不可持续的高位。前文论述过，AI 大模型未来的发展会呈现模型性能提升速率趋缓，但模型应用范围日益广泛的局面。市场在经历了对“AI 概念”的一窝蜂追捧之后，未来势必会将视线聚焦在 AI 真正落地带来切实生产力提升的领域。在这些领域中，有可能浮现长期能带来更丰厚回报的投资机会。

泡沫化的股票价格会对金融市场流动性比较敏感，美国货币政策的收紧可能刺破美股中的 AI 泡沫。2022 年以来，美国股市走势与美联储加息减息预期相关性较强。2022 年美联储加息预期强烈的时候，美股下挫；2024、2025 两年美联储降息预期较强时，美股走强。2026 年 2 月底美国与伊朗开战之后，上涨的油价推高了通胀预期，并导致美联储加息预期走强。这是全球 AI 公司股价在 2026 年 7 月明显调整的重要原因。未来，美联储货币政策如果明显收紧，将有可能刺破 AI 泡沫。从这个角度来说，能影响美联储货币政策走向的美国通胀状况，是 AI 股票投资者需高度关注的指标。（图表 7）

图表 7. 2024、2025 两年，美联储降息预期较强，支撑了美股的上扬



资料来源：万得，中银证券

（完）

-
- 【1】 马斯克 2026 年 7 月 23 日《经济学人》杂志访谈的全文可见于：
<https://elonmuskarchive.org/video/economist-elon-musk-2026-07-23>。
 - 【2】 这封公开信可见于：<https://righttowarn.ai/>。
 - 【3】 <https://www.michael-burphy.com/cart-before-the-horse-michael-burrys-ai-reality-check/>
 - 【4】 国际清算银行. 2026 年年度经济报告[R]. 2026-06-28.
<https://www.bis.org/publ/arpdf/ar2026e.pdf>. 参见该报告 22-23 页。
 - 【5】 Belkin, M., Hsu, D., Ma, S., et al. (2018). Reconciling modern machine learning and the bias-variance trade-off. <https://arxiv.org/abs/1812.11118>
 - 【6】 Nakkiran, P., Kaplun, G., Bansal, Y., et al. (2019). Deep double descent: where bigger models and more data hurt. <https://arxiv.org/abs/1912.02292>
 - 【7】 Brown, T B., Mann, B., Ryder, N., et al. (2020). Language models are few-shot learners. <https://arxiv.org/abs/2005.14165>
 - 【8】 Wei, J., Tay, Y., Bommasani, R., et al. (2022). Emergent abilities of large language models. <https://arxiv.org/abs/2206.07682>

- 【9】 《大英百科全书》(Encyclopedia Britannica)总字数约4400万字，对应约5千万词元。以之推算，现在的顶尖大模型10万亿词元的训练量，相当于20万部《大英百科全书》。这一阅读量更是远超一个人一生能阅读的文本总量。设想一个极端的“阅读狂人”一分钟可以读约500个中文字（这已经是很高速度了）。假设他从11岁开始，每天都阅读2个小时，直至80岁。在这70年中，他总共可以阅读约15亿个汉字的文本(=500×120×365×70)，对应约18亿个词元。即便如此，这个“阅读狂人”一生的阅读量也不到当前顶尖大模型训练文本量的千分之一。
- 【10】 Jones, C. R., & Bergen, B. K. (2026). Large language models pass the Turing test. *Proceedings of the National Academy of Sciences*, 123(21). <https://doi.org/10.1073/pnas.2524472123>
- 【11】 Shazeer, N., (2020). GLU variants improve transformer. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. 2020: 10000-10007. <https://arxiv.org/abs/2002.05202>
- 【12】 Silver, D., Schrittwieser, J., Simonyan, K., et al. (2017). Mastering the game of Go without human knowledge. *Nature*, 2017, 550(7676): 354-359. DOI:10.1038/nature24270
- 【13】 Bostrom, N. (2012). The Superintelligent Will: Motivation and Instrumental Rationality in Advanced Artificial Agents. *Minds and Machines*, Vol. 22(2). <https://nickbostrom.com/superintelligentwill.pdf>
- 【14】 Bostrom, N. (2003). Ethical Issues in Advanced Artificial Intelligence. *Cognitive, Emotive and Ethical Aspects of Decision Making in Humans and in Artificial Intelligence*, Vol. 2, ed. I. Smit et al., Int. Institute of Advanced Studies in Systems Research and Cybernetics, 2003, pp. 12-17. <https://nickbostrom.com/ethics/ai>
- 【15】 Bennett, M T., (2025). What is artificial general intelligence?. *Artificial General Intelligence: 18th International Conference, AGI 2025, Reykjavik, Iceland, August 10–13, 2025, Proceedings, Part I*. Cham: Springer, 2026: 30-42. DOI: 10.1007/978-3-032-00686-8_4. <https://arxiv.org/abs/2503.23923>
- 【16】 Hendrycks, D., Song, D., Szegedy, C., et al. (2025). A definition of AGI. <https://arxiv.org/abs/2510.18212>
- 【17】 Searle, J R., (1980). Minds, brains, and programs. *Behavioral and Brain Sciences*, 1980, 3(3): 417-457.
- 【18】 ACM. (2011). Judea Pearl. https://amturing.acm.org/award_winners/pearl_2658896.cfm.
- 【19】 珀尔, 麦肯齐. 为什么: 关于因果关系的新科学[M]. 江生, 于华, 译. 北京: 中信出版集团, 2019.
- 【20】 Bender., E. Gebru., T. Mcmillan-Major A, et al. *On the dangers of stochastic parrots: can language models be too big?*. *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*. New York. <https://dl.acm.org/doi/epdf/10.1145/3442188.3445922>
- 【21】 Wang, L. (2026, May 17). *Your evals will break and you won't see it coming*. <https://wanglun1996.github.io/blog/your-evals-will-break.html>
- 【22】 Cunningham, T., Althoff, L., Halperin, B., et al. (2026, July 13). *The economics of recursive self-improvement*. Elasticity Institute. <https://elasticity.institute/rsi-paper.pdf>
- 【23】 英伟达(NVIDIA)公司2026年的一篇论文可作这方面的参考: Ranawaka, N., Wong, J., Pai, W.-L., et al. (2026, June 26). *SimFoundry: Modular and automated scene generation for policy learning and evaluation* [Preprint]. arXiv. <https://doi.org/10.48550/arXiv.2606.28276>
- 【24】 Kaplan, J., McCandlish, S., Henighan, T., et al. (2020). *Scaling laws for neural language models* [Preprint]. arXiv. <https://arxiv.org/abs/2001.08361>

- 【25】 GPT-3 的嵌入空间维度为 12288 维。即每个词元对应的向量是一个包含 12288 个元素的数组。这一数字来自 Brown et. al. (2020) “Language Models are Few-Shot Learners” 这篇文章的 Table 2.1。近年来训练的新的闭源大模型，多将嵌入空间维度数视为商业机密，不对外公布。
- 【26】 Sharma, U., & Kaplan, J. (2022). *Scaling laws from the data manifold dimension*. Journal of Machine Learning Research, 23, 1–34. <https://jmlr.org/papers/volume23/20-1111/20-1111.pdf>
- 【27】 Hoffmann, J., Borgeaud, S., Mensch, A., et al. (2022). Training compute-optimal large language models. <https://arxiv.org/pdf/2203.15556>
- 【28】 Villalobos, P., Ho, A., Sevilla, J., Besiroglu, T., Hobbhahn, M., & Massaroli, S. (2024). Will we run out of data? Limits of LLM scaling based on human-generated data. <https://arxiv.org/pdf/2211.04325>
- 【29】 中科算网算泥社区，中国工业互联网研究院. (2026). AI Agent 智能体技术发展报告. <https://www.china-aii.com/u/cms/www/202601/AI%20Agent%E6%99%BA%E8%83%BD%E4%BD%93%E6%8A%80%E6%9C%AF%E5%8F%91%E5%B1%95%E6%8A%A5%E5%91%8A.pdf>
- 【30】 Abdih., Y. and Danninger, Y. (2017). What Explains the Decline of the U.S. Labor Share of Income? An Analysis of State and Industry Level Data. IMF Working Paper WP/17/167. <https://www.imf.org/-/media/files/publications/wp/2017/wp17167.pdf>
- 【31】 可以参见美国 Tax Project Institute 2025 年发表的文章《Universal High Income: Explainer》：<https://taxproject.org/universal-high-income/>
- 【32】 相 关 新 闻 可 见 于 : <https://www.sanders.senate.gov/press-releases/news-sanders-introduces-legislation-to-create-7-trillion-ai-sovereign-wealth-fund/> 。 桑德斯提交的法案全文可见于 : <https://www.sanders.senate.gov/wp-content/uploads/AmericanAIWealthFundTextv618.pdf>。
- 【33】 <https://www.marxists.org/archive/marx/works/1845/german-ideology/ch01a.htm>。
- 【34】 徐高，2025 年 1 月，《中国经济的逻辑与出路》，<https://www.163.com/dy/article/JM4UP68L0519IGF7.html>。
- 【35】 <https://www.anthropic.com/institute/recursive-self-improvement>
- 【36】 参见 2025 年 11 月 14 日新闻：《诺奖得主斯宾塞：AI 投资热潮是理性泡沫》，<https://finance.sina.com.cn/xwzmt/2025-11-14/doc-infxkpau4303473.shtml>。
- 【37】 Sajadieh, S., Fattorini, L., Perrault, R., et al. (2026), Artificial Intelligence Index Report 2026, <https://arxiv.org/abs/2606.15708>
- 【38】 Konstantin F. Pilz et al. (2025), “The US hosts the majority of GPU cluster performance, followed by China”. Published online at epoch.ai. Retrieved from 'https://epoch.ai/data-insights/ai-supercomputers-performance-share-by-country' [online resource]. Accessed 27 Aug 2026.
- 【39】 参见 BenchLM 公司主页上的大模型评测榜单 (<https://benchlm.ai/>)。

(风险提示：宏观经济走势具有不确定性，宏观政策可能超预期变化。)

披露声明

本报告准确表述了证券分析师的个人观点。该证券分析师声明，本人未在公司内、外部机构兼任有损本人独立性与客观性的其他职务，没有担任本报告评论的上市公司的董事、监事或高级管理人员；也不拥有与该上市公司有关的任何财务权益；本报告评论的上市公司或其它第三方都没有或没有承诺向本人提供与本报告有关的任何补偿或其它利益。

中银国际证券股份有限公司同时声明，将通过公司网站披露本公司授权公众媒体及其他机构刊载或者转发证券研究报告有关情况。如有投资者于未经授权的公众媒体看到或从其他机构获得本研究报告的，请慎重使用所获得的研究报告，以防止被误导，中银国际证券股份有限公司不对其报告理解和使用承担任何责任。

评级体系说明

以报告发布日后公司股价/行业指数涨跌幅相对同期相关市场指数的涨跌幅的表现为基准：

公司投资评级：

买入：预计该公司股价在未来 6-12 个月内超越基准指数 20%以上；
增持：预计该公司股价在未来 6-12 个月内超越基准指数 10%-20%；
中性：预计该公司股价在未来 6-12 个月内相对基准指数变动幅度在-10%-10%之间；
减持：预计该公司股价在未来 6-12 个月内相对基准指数跌幅在 10%以上；
未有评级：因无法获取必要的资料或者其他原因，未能给出明确的投资评级。

行业投资评级：

强于大市：预计该行业指数在未来 6-12 个月内表现强于基准指数；
中性：预计该行业指数在未来 6-12 个月内表现基本与基准指数持平；
弱于大市：预计该行业指数在未来 6-12 个月内表现弱于基准指数；
未有评级：因无法获取必要的资料或者其他原因，未能给出明确的投资评级。

沪深市场基准指数为沪深 300 指数；新三板市场基准指数为三板成指或三板做市指数；香港市场基准指数为恒生指数或恒生中国企业指数；美股市场基准指数为纳斯达克综合指数或标普 500 指数。

风险提示及免责声明

本报告由中银国际证券股份有限公司证券分析师撰写并向特定客户发布。

本报告发布的特定客户包括：1) 基金、保险、QFII、QDII 等能够充分理解证券研究报告，具备专业信息处理能力的中银国际证券股份有限公司的机构客户；2) 中银国际证券股份有限公司的证券投资顾问服务团队，其可参考使用本报告。中银国际证券股份有限公司的证券投资顾问服务团队可能以本报告为基础，整合形成证券投资顾问服务建议或产品，提供给接受其证券投资顾问服务的客户。

中银国际证券股份有限公司不以任何方式或渠道向除上述特定客户外的公司个人客户提供本报告。中银国际证券股份有限公司的个人客户从任何外部渠道获得本报告的，亦不应直接依据所获得的研究报告作出投资决策；需充分咨询证券投资顾问意见，独立作出投资决策。中银国际证券股份有限公司不承担任何由此产生的任何责任及损失等。

本报告内含保密信息，仅供收件人使用。阁下作为收件人，不得出于任何目的直接或间接复制、派发或转发此报告全部或部分内容予任何其他人，或将此报告全部或部分内容发表。如发现本研究报告被私自刊载或转发的，中银国际证券股份有限公司将及时采取维权措施，追究有关媒体或者机构的责任。所有本报告期内使用的商标、服务标记及标记均为中银国际证券股份有限公司或其附属及关联公司（统称“中银国际集团”）的商标、服务标记、注册商标或注册服务标记。

本报告及其所载的任何信息、材料或内容只提供给阁下作参考之用，并未考虑到任何特别的投资目的、财务状况或特殊需要，不能成为或被视为出售或购买或认购证券或其它金融票据的要约或邀请，亦不构成任何合约或承诺的基础。中银国际证券股份有限公司不能确保本报告中提及的投资产品适合任何特定投资者。本报告的内容不构成对任何人的投资建议，阁下不会因为收到本报告而成为中银国际集团的客户。阁下收到或阅读本报告须在承诺购买任何报告中所指之投资产品之前，就该投资产品的适合性，包括阁下的特殊投资目的、财务状况及其特别需要寻求阁下相关投资顾问的意见。

尽管本报告所载资料的来源及观点都是中银国际证券股份有限公司及其证券分析师从相信可靠的来源取得或达到，但撰写本报告的证券分析师或中银国际集团的任何成员及其董事、高管、员工或其他任何个人（包括其关联方）都不能保证它们的准确性或完整性。除非法律或规则规定必须承担的责任外，中银国际集团任何成员不对使用本报告的材料而引致的损失负任何责任。本报告对其中所包含的或讨论的信息或意见的准确性、完整性或公平性不作任何明示或暗示的声明或保证。阁下不应单纯依靠本报告而取代个人的独立判断。本报告仅反映证券分析师在撰写本报告时的设想、见解及分析方法。中银国际集团成员可发布其它与本报告所载资料不一致及有不同结论的报告，亦有可能采取与本报告观点不同的投资策略。为免生疑问，本报告所载的观点并不代表中银国际集团成员的立场。

本报告可能附载其它网站的地址或超级链接。对于本报告可能涉及到中银国际集团本身网站以外的资料，中银国际集团未有参阅有关网站，也不对它们的内容负责。提供这些地址或超级链接（包括连接到中银国际集团网站的地址及超级链接）的目的，纯粹为了阁下的方便及参考，连结网站的内容不构成本报告的任何部份。阁下须承担浏览这些网站的风险。

本报告所载的资料、意见及推测仅基于现状，不构成任何保证，可随时更改，毋须提前通知。本报告不构成投资、法律、会计或税务建议或保证任何投资或策略适用于阁下个别情况。本报告不能作为阁下私人投资的建议。

过往的表现不能被视作将来表现的指示或保证，也不能代表或对将来表现做出任何明示或暗示的保障。本报告所载的资料、意见及预测只是反映证券分析师在本报告所载日期的判断，可随时更改。本报告中涉及证券或金融工具的价格、价值及收入可能出现上升或下跌。

部分投资可能不会轻易变现，可能在出售或变现投资时存在难度。同样，阁下获得有关投资的价值或风险的可靠信息也存在困难。本报告中包含或涉及的投资及服务可能未必适合阁下。如上所述，阁下须在做出任何投资决策之前，包括买卖本报告涉及的任何证券，寻求阁下相关投资顾问的意见。

中银国际证券股份有限公司及其附属及关联公司版权所有。保留一切权利。

中银国际证券股份有限公司

中国上海浦东
银城中路 200 号
中银大厦 39 楼
邮编 200121
电话: (8621) 6860 4866
传真: (8621) 5888 3554

相关关联机构:

中银国际证券有限公司

香港花园道一号
中银大厦二十楼
电话: (852) 3988 6333
致电香港免费电话:
中国网通 10 省市客户请拨打: 10800 8521065
中国电信 21 省市客户请拨打: 10800 1521065
新加坡客户请拨打: 800 852 3392
传真: (852) 2147 9513

中银国际控股有限公司北京代表处

中国北京市西城区
西单北大街 110 号 8 层
邮编: 100032
电话: (8610) 8326 2000
传真: (8610) 8326 2291

中银国际(英国)有限公司

2/F, 1 Lothbury
London EC2R 7DB
United Kingdom
电话: (4420) 3651 8888
传真: (4420) 3651 8877

中银国际(美国)有限公司

美国纽约市美国大道 1045 号
7 Bryant Park 15 楼
NY 10018
电话: (1) 212 259 0888
传真: (1) 212 259 0889

中银国际(新加坡)有限公司

注册编号 199303046Z
新加坡百得利路四号
中国银行大厦四楼(049908)
电话: (65) 6692 6829 / 6534 5587
传真: (65) 6534 3996 / 6532 3371