

摘要：

开源AI正在以肉眼可见的速度逼近闭源天花板。OpenRouter梳理出2026年6月最值得押注的四个开源模型：DeepSeek V4 Flash以GPT-5.5百分之一的成本跑出同级智能体表现；GLM 5.2代码规划能力登顶开源榜首；MiniMax M3独揽多模态赛道；英伟达Nemotron则打出本土企业级王牌。开源与闭源之间，那层窗户纸已经薄如蝉翼。

OpenRouter梳理了截至2026年6月最值得关注的4个开源模型



OpenRouter

@OpenRouter · 19小时

翻译自 英语 显示原文

四个开源权重模型已经跨越到了一个新领域，在那里它们正在驱动真实的代理管道。

我们在洞察博客中发布了一篇文章，讨论为什么公司在六月选择它们：openrouter.ai/blog/insights/...

Model	AA Index (v4.1)	Price (in/out per M)	Throughput	Reach for it when
DeepSeek V4 Flash	44 (Pro)	\$0.054 / \$0.242	~84 tok/s	You want frontier-class agentic coding at the lowest cost on the board — the cost/performance Pareto frontier.
GLM 5.2	51 (top open)	\$0.447 / \$3.31	~78 tok/s	Planning quality and long-horizon coding matter more than rock-bottom price; the closest open drop-in for Opus-style work.
MiniMax M3	44	\$0.098 / \$1.21	~59 tok/s	Your agent needs native image or video input over long context — screenshots, UI states, diagrams, documents.
Nemotron 3 Ultra	48	\$0.423 / \$2.61 (+ :free)	~75 tok/s	You want a U.S.-built, fully-open model on the NVIDIA stack and the vendor/deployment story matters as much as the ran

在过去长达18个月的时间里，开源与闭源的差距稳定保持在3到6个月之间。至少就目前来看，闭源大厂完全没有甩开开源阵营的迹象。

随着企业AI用量激增，控制成本成了各大团队的核心诉求，这也让开源模型迎来了真正的高光时刻。

把业务从闭源模型迁移到开源模型，能省下一笔巨款。闭源模型的前沿能力当然会继续进化，但只要你对智力水平的需求是固定的，使用成本就会一直往下降。

新模型发得快，各项能力长短不一，新玩家又多，普通开发者很难搞清楚到底该用哪个模型。站在2026年6月的时间节点上，OpenRouter认为目前真正具有决定性意义的开源大模型，只有下面这四个。

模型	智力指数得分	价 格 (百万token输入/ 输出)	生成速度	适用场景
DeepSeek V4 Flash	40	0.054 美 元 / 0.242美元	约84个/ 秒	追 求 极 致 性 价 比 用白菜价跑出闭源头部级别代码能力
GLM 5.2	51 (开源第一)	0.447 美 元 / 3.31美元	约78个/ 秒	任 务 极 度 复 杂 看重逻辑规划和长代码质量胜过看重
MiniMax M3	44	0.098 美 元 / 1.21美元	约59个/ 秒	智 能 体 必 须 看 图 看 视 频 且需要处理超长上下文
Nemotron 3 Ultra	48	0.423 美 元 / 2.61 美 元 (有免费通道)	约75个/ 秒	看 重 供 应 商 背 景 和 企 业 级 部 署 需要融入英伟达技术栈

DeepSeek V4 Flash 跨越智能体分水岭

DeepSeek V4 Flash是第一个被开发团队直接塞进智能体工作流的开源模型，大家完全把它当成了Anthropic或OpenAI同级别闭源模型的完美平替。

大杯版本的V4 Pro在SWE-bench Verified测试中拿下了80.6%的成绩，刷新了开源模型的最高分，直接看齐GPT-5.5级别的智能体表现。但真正引爆市场的是Flash版本，它保留了绝大部分核心能力，同时把性价比推向了极致。

Flash版本采用MIT协议，是一个拥有2840亿总参数和130亿激活参数的MoE模型，支持百万token上下文。它的SWE-bench Verified得分是79.0%，和Pro版以及那个1.6万亿参数的超大杯相比，差距都在1.6分左右。2026年4月发布。

大家疯狂用它，主要还是因为太便宜了。在DeepSeek官方API上，Flash版本的输入和输出价格分别是每百万token 0.14美元和0.28美元。如果算上缓存折扣，输入价格还能降到0.029美元。官方在五月份把这个号称打了骨折价固定成了永久价格。对比下来，它的输出成本大概只有GPT-5.5的150分之一。

也可以选择西方的第三方托管平台，价格大概是官方的两倍，但考虑到它的智力水平，这依然白菜价。DeepSeek官方带头打价格战，直接把这个智力级别的模型价格彻底打了下来。

避坑指南：日常使用中，它干技术活很利索，但写文章和语气把控一般。提示词需要写得非常具体，它更吃指令，不能过度依赖它自己的发挥。

适用场景：需要用极低成本跑出闭源头部级别智能体或写代码。首选Flash版本，如果真的需要那一点点极限性能提升，再上Pro版。

GLM 5.2 复杂规划与代码能力的顶级平替

GLM 5.2在6月中旬才刚刚发布，初期的口碑已经炸裂。DeepSeek靠价格杀出重围，GLM 5.2的核心杀手锏则是任务规划和超长上下文代码编写。

在Artificial Analysis最新的4.1版本智力指数榜单上，GLM 5.2拿下了51分，稳坐开源模型第一名，距离闭源的Claude Fable 5只差了5分。在真实的智能体基准测试中，它同样领跑开源阵营，基本和GPT-5.5 xhigh版本打平。

虽然刚发布不久，很多第三方平台已经火速上线。它的均价是每百万token输入0.447美元输出3.31美元。单看token价格比GPT-5.5或Opus便宜，但这个模型在输出时非常喜欢深入思考，消



耗的token量大，跑起来还是会有点费钱。

这背后还有一个助推因素。美国刚出了出口管制新规，迫使Anthropic大规模禁用了Fable 5和Mythos 5的海外访问权限。作为一个采用MIT协议且代码能力极其接近闭源头部的模型，它成了很多追求业务稳定性的企业的香饽饽。

避坑指南： 同样是纯文本模型，不支持图像和视频。思考过程会消耗大量输出token，比较费钱。刚发布不久，各家托管平台的质量参差不齐。最高生成速度大约每秒78个token，比DeepSeek V4 Flash的84个略慢。

适用场景： 完美替代闭源模型做智能体规划和代码生成。非常适合处理架构设计、整个代码库级别的重构或是耗时很长的智能体任务。

MiniMax M3 把多模态和长文本做到极致

在这四个模型里，MiniMax M3是唯一一个原理解文本图表和视频的模型。如果你的智能体需要看屏幕截图、分析UI界面、读懂架构图或者看视频，M3是首选。

在智力指数榜单上，它和DeepSeek V4 Pro并列拿了44分，落后于GLM和英伟达。但它的核心竞争力是多模态能力，单纯看分数意义不大。在真实的智能体测试中，它的表现基本和Claude Sonnet 4.6持平。

价格诱人，每百万token输入0.098美元输出1.21美元，当然如果上下文超过51万token价格会上浮。和GLM类似，单价便宜不代表总价低，M3也是个话痨，推理过程很长。

避坑指南： 没用MIT协议，用的是自家的社区协议。商业使用需要加署名，大型商业产品还要书面授权。文本代码能力不如GLM 5.2。各家服务商对全量上下文的支持程度不一样。

适用场景： 需要处理原生图片或视频的长文本智能体。适合UI自动化测试、看图写代码、图文文档解析、视频工作流或是混合了代码和文档的复杂任务。是谷歌Gemini Flash在多模态理解领域的强力竞争对手。

NVIDIA Nemotron 3 Ultra

英伟达的Nemotron 3 Ultra是美国本土最能打的开源模型。它是一个专为企业部署打造的严肃推理模型，背后有整个英伟达软硬件生态撑腰。

它的跑分很稳，智力指数排名第二，拿到48分，仅次于GLM 5.2。

它的核心差异化优势在于极高的部署效率。现在的加权平均价格是每百万token输入0.423美元输出2.61美元，它还有一条免费测试通道，目前极其火爆。

参数方面，它是一个5500亿总参数和550亿激活参数的Mamba-2与Transformer混合MoE模型。使用了NVFP4精度，支持百万上下文和多token预测技术，采用OpenMDW协议。英伟达这次连同模型一起把训练数据、配方、评估工具和强化学习基础设施全给开源了。

英伟达的算盘打得很响，开源模型用得越多，市场对他们家各种芯片计算卡以及软件生态的需求就越旺盛。Nemotron不仅仅是个模型，它更是用来给整个英伟达AI全家桶拉客的招牌。英伟达不差钱，他们有足够的财力持续投入研发，在这个赛道里卷下去。

避坑指南： 纯文本模型。基础智力比不上GLM 5.2，极限代码能力也略逊于中国开源头部。免费通道只能用来测试玩玩，不能支撑正式的商业产品。协议是OpenMDW，不如MIT开放。

适用场景： 当企业对运行速度、私有化部署、数据控制权和供应商背景的看重程度超过了对极限跑分的追求时，选它最合适。

总而言之，DeepSeek证明了开源大模型完全能胜任前沿智能体工作，而且只收个零头。GLM拿下了质量榜单的铁王座。MiniMax成了平价多模态领域的扛把子。英伟达则带着深厚的家底，给出了一个完全开源的美国本土企业级方案。开源和闭源的差距确实存在，但这层窗户纸已经非常薄了。弄清楚自己的业务到底需要极限低价、顶级质量、多模态能力还是企业级部署，对号入座去挑选测试，这才是最靠谱的做法。

本文来源：[AI寒武纪](#)

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

117 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论