

摘要：

智谱发布7000亿参数旗舰模型GLM-5.3，通过后训练扩展在编程与网络安全领域实现重大突破。其智谱 Code Bench编程能力提升50%，在部分高难度任务上超越Claude Opus 4.8；网络安全挖掘能力“涌现”，现实代码库中已累计识别2436个漏洞。模型权重将在两周内开源，在DeepSeek上调价格之际进一步强化其市场竞争力。

智谱最新旗舰模型GLM-5.3正式亮相，在编程能力和网络安全漏洞发现方面取得重大突破，向Anthropic、OpenAI等AI头部企业发起新一轮挑战。

据智谱官方声明，GLM-5.3基于与[前代GLM-5.2](#)相同的7000亿参数基础模型构建，所有性能提升均来自后训练阶段的持续扩展。在自研评测基准智谱 Code Bench上，GLM-5.3的编程能力较GLM-5.2提升50%；在开源编程基准Terminal-Bench 3.0上，得分从4.6跃升至28.3。

智谱介绍模型时表示：**GLM-5.3专为编程而生，随时迎接网络防御挑战。**GLM-5.3在网络安全漏洞挖掘能力上亦出现超预期的“涌现”式跃进，在现实代码库中累计识别出2436个安全漏洞。

智谱表示，模型权重将在发布两周后公开，届时将完成安全评估与加固工作。此次发布恰逢DeepSeek昨日上调旗下V4模型定价，进一步加强其在国内AI市场的竞争地位。

Introducing GLM-5.3: Built to Code. Ready for Cyber Defense.

- Top-tier coding and agentic capabilities, achieved through post-training on the 743B base model
- A major leap in cybersecurity, setting a new standard among open models

Tech Blog: z.ai/blog/glm-5.3



下午1:17 · 2026年8月14日 · 1.3万 查看

编程能力大幅跃升，超越Claude Opus 4.8

GLM-5.3的核心突破集中于复杂编程与长链路任务。智谱官方数据显示，在智谱 Code Bench的最高难度设置下，GLM-5.3以约7.5万个输出token完成了34.5%的任务，而GLM-5.2在消耗更多token（9.6万）的情况下，完成率仅为23.4%。在高难度设置下，GLM-5.3以约5万个token达到31.4%的完成率，超越了Anthropic的Claude Opus 4.8（29.5%，耗用12万token）。不过，GLM-5.3目前仍落后于Claude Fable 5——后者在最高难度设置下完成率为39.5%。

Performance across comparison models


Benchmark	GLM-5.3	GLM-5.2	Kimi K3	DeepSeek-V4 Pro-0813	Qwen3.8-Max	Opus 4.8	Fable 5 (w/ fallback)	GPT-5.6 Sol
CODING								
Terminal Bench 2.1	88.2	81.0	88.3	87.9	86.6	85.0	88.0	88.8
Terminal Bench 3.0	28.3	4.6	17.4	-	-	21.1	33.7	34.6
DeepSWE v1.1	66.9	46.2	67.5	62.7	56.6	58.0	69.7	72.7
NL2Repo	58.0	48.9	58.0	61.1	55.9	69.7	-	-
ProgramBench Almost Solved	19.0	9.5	17.5	-	10.5	15.5	33.0	23.0
FrontierSWE	78.1	67.5	-	-	-	66.5	88.2	-
SWE-Marathon v1.1	42.5	19.4	48.1	-	-	48.8	33.1	42.5
PostTrainBench	39.8	31.7	32.0	-	-	32.9	41.8	36.2
CYBER								
CyberGym	84.5	77.2	80.0	83.3	78.5	78.1	83.8	83.6
ExploitGym 2h / 6h	105 / 130	29 / 39	36 / 70	-	14 / 26	80 / 120	181 / 247	216 / 293
ExploitBench	54.4	24.4	32.2	-	28.8	40.0	78.0	76.5
AGENTIC								
Toolathlon Verified	73.0	59.9	76.5	74.1	72.5	76.2	74.7	74.9
AutomationBench v1.0.6	48.2	26.2	46.7	43.2	39.8	41.0	46.2	45.8
Agents' Last Exam ALE-CLI	28.5	23.8	27.6	25.7	27.0	25.7	23.8	28.6
HLE w/ Tools	62.5	54.7	59.8	60.0	56.2	57.9	63.9	64.5
GDPval-AA v2	1769	1508	1682	1590	1739	1588	1743	1730

在公开基准测试上，GLM-5.3同样表现亮眼：DeepSWE v1.1得分从46.2升至66.9，Agents' Last Exam得分从23.8升至28.5。

为实现上述进展，智谱在后训练阶段大幅扩展了训练环境的规模与多样性，引入更贴近真实工程场景的任务——部分任务的工作量相当于一名经验丰富的工程师数天的工作量。智谱还构建了自动化流水线，用于端到端合成训练环境及强化学习奖励信号。

Agentic Coding Performance by Effort Level

Z.ai Code Bench v1.0, evaluated on Claude Code 2.1.207



网络安全能力“涌现”，已披露逾两千个漏洞

在网络安全领域，GLM-5.3展现出超出预期的能力跃升。在智谱引入漏洞发现数据和训练环境后，模型不仅能够识别单一缺陷，更开始跨多个漏洞利用阶段进行综合推理，形成完整的利用链路规划。

在CyberGym基准测试中，GLM-5.3以84.5%的得分超越Anthropic的Mythos 5（83.8%）和OpenAI的GPT-5.6 Sol（83.6%），位居榜首。在要求更深层漏洞推理的ExploitBench上，GLM-



5.3得分从GLM-5.2的24.4%跃升至54.4%，涨幅超过一倍；但与Mythos 5（78.0%）和GPT-5.6 SoI（76.5%）相比，仍有明显差距。在ExploitGym测试中，GLM-5.3在两小时内完成105项利用任务、六小时内完成130项，而GLM-5.2的对应数字仅为29项和39项；Mythos 5则以181项和247项保持领先。

智谱表示，这些能力已延伸至真实世界的实际应用。自GLM-5.2以来，智谱与中国多个安全团队合作，针对现代代码库运行模型测试，经专家审核、筛查与去重后，在269个项目中识别出2436个漏洞，其中中高危漏洞1097个，涵盖系统内核、操作系统、浏览器引擎、开源基础设施、Web应用及网络协议等领域，部分漏洞在代码库中已存留数十年，最早可追溯至约40年前。智谱已为此建立“智谱安全披露账本”，持续公开披露进展。

开源策略叠加竞争格局变化，市场空间打开

在商业层面，GLM-5.3的发布时机颇具战略意义。DeepSeek于本周四宣布将旗下V4 Flash和Pro模型[价格上调最高四倍](#)，尽管V4 Pro的综合定价仍低于GLM-5.2，但此举客观上为智谱争取用户和开发者提供了窗口。Artificial Analysis给予DeepSeek顶级模型与GLM-5.2相同的智能评分53分，两者均落后于Kimi K3以及Claude Fable 5、GPT 5.6等模型。

智谱计划以宽松许可证开放GLM-5.3的模型权重，以吸引更多广泛的开发者群体。这一策略与GLM-5.2的路径一脉相承——后者发布后，智谱市值一度冲至1370亿美元，超越拼多多和网易（NetEase）等互联网巨头，此后虽回落至约800亿美元，但较今年1月在香港上市时仍增逾十倍。

据彭博此前报道，智谱已完成一座数据中心的建设，部署了至少1万枚国产芯片，用于GLM系列模型的研发与推理。其年度经常性收入（ARR）于今年7月达到10亿美元。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码 免费领取

241 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论