


摘要：

Claude Mythos在METR评测中直接“爆表”——16小时长时任务达成50%成功率，远超当前评测框架的上限。AI能力正以超指数级狂飙，已超过2027年AGI奇点的预测线。自主攻防、漏洞挖掘等能力提前降临，旧规则失效，奇点不再是预言，而是正在倒计时。

刚刚，Claude Mythos干爆METR评测上限！超指数级进化已经逼近AGI奇点。

就在今天，一张趋势图刷屏全网。



国际最权威的AI评测机构METR惊恐地发现，他们的「温度计」要被Mythos撑爆了。

Claude Mythos Preview的能力，已经捅破了人类评测框架的天花板，进入了「失真区」！

OpenAI超级对齐团队前成员Leopold Aschenbrenner曾预测2027年是AGI的奇点，但现在的最新数据显示：Mythos的表现已经略高于2027情景的趋势线。

01:35



帖子



Chase Brower


@ChaseBrowe32432

关注

由 Grok 翻译自英语

Mythos 略高于 AI 2027 情景的趋势线

评价此翻译: 1 0



01:05 · 2026/5/10 · 11万次查看

31

111

1085

304



相关

查看引用



Chase Brower @ChaseBrowe32432 · 1天



Additionally, according to SemiAnalysis (newsletter.semianalysis.com/p/ai-value-cap...) we are very far above the predicted ~26B\$ annualized revenue for Q2 2026

发布你的回复




公众号 · 新智元



「外星文明」，已经强行着陆，阴影已覆盖整片天空。评测界的大地震 当「满分」不再有意义

在METR最新的测试中，他们试图衡量AI完成长周期复杂任务的能力（Time Horizons）。

METR设置了一个名为「50%成功率时间线」的指标——即模型有50%的概率，成功独立完成一项人类需要耗费X小时才能完成的任务。



此前，此前的模型，成绩是几十分钟或几个小时。

但当Claude Mythos站上考场时，数据直接爆表了：它在人类需要16个小时才能完成的极其复杂的长线任务上，轻松达到了50%的成功率！

你可能会问：那测试32小时、64小时的任务呢？

METR给出的答案让人惊恐：「我们测不了了。」

 **METR** 
@METR_Evals

We evaluated an early version of Claude Mythos Preview for risk assessment during a limited window in March 2026. We estimated a 50%-time-horizon of at least 16hrs (95% CI 8.5hrs to 55hrs) on our task suite, at the upper end of what we can measure without new tasks.

我们在 2026 年 3 月的一个有限窗口期内，对早期版本的 Claude Mythos Preview 进行了风险评估。根据我们的任务套件评估，其 50%时间线至少为 16 小时（95%置信区间：8.5 小时至 55 小时），这已处于我们无需新增任务即可测量的上限范围。

 公众号 · 新智元

在METR精心构建的228个魔鬼级测试任务中，只有区区5个任务是被归类为「16小时及以上」的。这意味着什么？


这意味着人类现有的、引以为傲的难题库，已经被AI彻底掏空了。

就像用刻度只有1米的卷尺去量一栋摩天大楼，除了知道它「爆表」了，我们对其真实的深度一无所知。

「外星文明」已降临？


在16小时以上的区间，METR根本没有足够的样本来对Mythos进行准确的定量比较。

METR坦言，在这个阈值之上，数据的测算变得「不稳定且失去意义」。



当前的AI技术已如「清晰可见的外星飞船」一样悬浮在人类文明的天空中。

人类已经无法理解AI的超指数增长！




这不再是实验室里的数据，标志着AGI的征兆已经完全显现！

超指数，比指数增长还快

把METR那张趋势图拉出来细看。

纵轴是AI能自主完成的编码任务时长，从8秒到5年，对数刻度。横轴是模型发布时间，2021到2028。每一个点是一个模型版本。

把点连起来，画出来的不是一条直线，不是一条指数曲线，而是一条比指数还陡的弧。



AI在超指数增长，AI增速本身在加速。

- 2021年，最好的模型能自主完成8秒级别的任务——写一行代码，修一个拼写错误。
- 2023年初，推到了1分钟量级——一个小函数、一段简单调试。
- 2024年中，冲到了大约1小时——一个完整feature的实现、一次多文件重构。
- 2026年4月，Mythos Preview落点：**16小时**——一个完整的工程子项目，读代码、理解架构、制定方案、编写实现、调试测试，一气呵成，不需要人类盯着。

每一代的跃升幅度都比上一代更大。间隔时间都比上一代更短。



本图由AI生成

人类的演化是为了让我们在草原上计算果实和猎物的距离，大脑天生是线性的。

我们好不容易理解了「指数增长」，现在却被迫面对指数之上的指数。

猿类的大脑面对超指数，直接集体宕机。



本图由AI生成

METR在图上画了几条参考线。


基于多家机构联合预测，假设AI能力按目前最主流的预期持续增长，大约在2027年前后触达通用人工智能门槛。

Mythos的数据点落在这条线的上方。



不是偏了一点。是在时间轴还没走到2027的位置上，能力值已经超过了2027的预测值。

AI基础设施从业者Chase Brower看完METR报告后在推特上判断：那个预计在2026年初出现的"Agent-1"描述，其实有点低估了当前最好模型的能力。整个行业对AI发展速度的预估都偏保守了。



这里有个细节容易被忽略。

METR的纵轴不是跑分，不是准确率，不是某个benchmark上的百分比。那条曲线目前没有任何减速的迹象。

安全圈原子弹时刻 从「助手」到「自主攻击者」

如果说METR的烦恼还是学术性的，那么Palo Alto Networks的预警则是带血的实战报告。

METR says it can barely measure Claude Mythos, Palo Alto Networks warns of autonomous AI attackers



Matthias Bastian [in](#) May 10, 2026



公众号 · 新智元

近期，Palo Alto获得了Mythos、GPT-5.5-Cyber等前沿模型的早期无限制访问权限。

测试结论让所有防御者脊背发凉：AI已经跨过了那道名为「自主」的门槛。

当模型能自主工作16小时的时候，它在安全领域能干什么？

时间坍缩：3周=1年

Palo Alto的报告中有一个令人震撼的数据：使用Mythos辅助进行漏洞分析，仅仅3周时间，其完成的工作深度和覆盖广度，等同于一整个顶级渗透测试团队整整1年的工作量。

A New Era of Security: Frontier AI Defense

By Sam Rubin



May 07, 2026 · 4 minutes

这直接是降维打击。



本图由AI生成

以往的AI只能帮你写个脚本、搜个代码片段。但Mythos展现出了一种近乎恐怖的「软件漏洞直觉」。



- **大规模漏洞发现：**Frontier AI 在识别庞大、复杂的代码库中的漏洞方面表现出色。在我们的测试中，三周的模型辅助分析相当于一整年的人工渗透测试，且覆盖范围更广。
- **漏洞利用链式分析与综合：**比单独发现漏洞更重要的是模型能够像攻击者一样思考。它们将多个低危漏洞关联起来，形成单一的关键漏洞利用路径，从而洞察包括 SaaS 和面向公众的接口在内的全栈逻辑，这是传统扫描器无法做到的。
- **攻击周期压缩：**在人工智能辅助的场景中，从初始访问到数据泄露的时间已缩短至最短 25 分钟。以小时为单位的检测和响应已不再是可行的标准；个位数的平均响应时间 (MTTR) 才是新的最低标准。
- **无监督攻击面：**人工智能的快速发展和去中心化创新正在实时构建一个庞大的无监督攻击面。随着本地人工智能代理的普及，每台桌面电脑实际上都变成了一台服务器，然而大多数组织却无法了解其员工正在生成和部署的代码。

公众号·新智元

它能识别出上百万行代码中那些零散、低危的小漏洞。

更要命的是，它能像顶级黑客一样，将这些原本不起眼的漏洞串联成一条致命的攻击链。

从初步入侵到数据拖库，在AI辅助下，整个过程被压缩到了25分钟。

而在过去，这种级别的攻击可能需要一个团队潜伏数周才能完成。




本图由AI生成

在奇点撞向我们之前，如何自救？

Anthropic曾因为觉得Claude Mythos「太危险」而拒绝全面发布，一度被嘲讽为PR手段。但现在看来，这更像是一种对未知的敬畏。

Mozilla已经开始行动，他们利用Mythos扫描Firefox浏览器，仅在2026年4月一个月内就修复了破纪录的423个安全问题。



这说明，AI也是最强的盾，但前提是你要比攻击者跑得更快。

我们必须接受一个残酷的现实：旧时代的防御节奏已经彻底失效。

检测响应时间不能再以「小时」计，必须缩短到「分钟」甚至「秒」；安全不再是人的审计，而是「用AI对抗AI」的自动化博弈。


与此同时，资本侧也已经allin。

在过去5个月里，英伟达向自己的客户注资约400亿美金：

300亿给OpenAI，20亿给算力商CoreWeave，32亿给光纤商康宁……

英伟达400亿美元的AI金融闭环

参考网络关系图风格，展示投资如何流向生态伙伴，并最终回流到英伟达芯片采购



本图由AI生成、数据来源于网络由AI收集

这些钱转了一圈，最后全部变成了英伟达芯片的订单。

显然，黄仁勋正在用钱投票，强行拉拽全产业链加速撞向奇点。

但这套永动机最可怕的地方在于，它在奇点坠落前根本无法停下。

Chase Brower指出，Anthropic的年化收入已经远高于此前260亿美元的预测线。资本市场已经在用脚投票——钱在押注那条曲线不会拐弯。

2027年，按照METR趋势图上那条中央轨迹线，是多家机构联合预测的AGI门槛年份。Mythos已经跑在这条线的上方。

如果接下来18个月不出现根本性的技术断崖——不是减速，不是瓶颈，而是物理定律级别的硬墙——那么2027不再是一个需要辩论的预测。



本图由AI生成

它是一个需要准备的倒计时。

AGI的奇点不再是预测，而是正在发生的冲击。外星文明已经来临，我们能做什么？

本文来源：[新智元](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

VIP会员·7天畅读卡 | 大师课·入门串讲

扫码

免费领取



限免

85 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

2 条评论

Jackie
55分钟前 日本
地毯文学风
0 回复

hjliong18
1小时前 中国广东省



危言耸听，不解决实际问题的AI，一文不值，全是泡沫

👍 1 ↩ 回复