

摘要：

9月8日，DeepSeek V4.1 Flash的中间版本开启内测，采用新模型结构并原生支持多模态，主打更强能力、更快速度和更低成本，价格与V4 Flash持平。网友实测输出速度最高达507 tokens/s，或预示DeepSeek新一轮模型迭代周期开启。

9月8日，DeepSeek宣布，**DeepSeek V4.1 Flash**的中间版本开启内测。该模型采用了**新模型结构**，原生支持多模态、能力更强、速度更快且成本更低。

开发者保持base\_url不变，将模型名设置为**deepseek-v4.1-flash-expires-on-0910**即可调用，当前计费与DeepSeek V4 Flash相同，每账号**限流20并发**。



DeepSeek小助手@深度求索


DeepSeek V4.1 Flash 的中间版本内测，欢迎试用。采用了新的模型结构，原生多模态支持、能力更强、速度更快、且成本更低。

您保持 base\_url 不变，将模型名设置为 deepseek-v4.1-flash-expires-on-0910 即可调用，当前计费与 deepseek-v4-flash 相同，每账号限流 20 并发。

您可以通过以下问卷填写反馈，期待您的宝贵意见：<https://trtgsjkv6r.feishu.cn/share/base/form/shrcnpC1zXjnmVnj7yKZKQc1Ywe?from=navigation>

与DeepSeek V4 Flash相同，DeepSeek V4.1 Flash当前内测版本的价格为空闲时段每百万tokens输入（缓存命中）0.05元，输入（缓存未命中）1.5元，输出4.5元；高峰时段对应价格为每百万tokens输入（缓存命中）0.1元，输入（缓存未命中）3元，输出9元。  
根据模型名称，此次内测**9月10日会自动过期下线**。

社交平台X上已经有一些开发者晒出了自己的体验，其中最高的输出速度达到**507 tokens/s**。



一位开发者让模型创建HTML，内容是SVG绘制一个鹅鹅骑自行车的2D动画，DeepSeek V4.1Flash输出速度达328 tokens/s。



另一位开发者也体验了鹅鹅骑自行车的测试，下图就是生成的效果，他透露输出的平均速度超过300 tokens/s。另一位网友称，手动添加该模型后发现，速度非常非常快。



DeepSeek系列模型近段时间更新频繁。

7月31日，DeepSeek V4 Flash正式版API率先上线公测；8月13日，DeepSeek V4 Pro正式版API发布；同日，DeepSeek Harness的开发者预览版（v0.1版本）正式公测，并同步开源。8月19日，DeepSeek Harness迭代至v0.1.0-rc.8版本。

紧接着，8月21日，DeepSeek V4 Flash Vision Exp上线DeepSeek API平台，并于8月31日正式开源。

如今，DeepSeek V4.1 Flash开启内测，或意味着其将开启新一轮的模型更新周期。



风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

\* 体验资格每人限申领一次

扫码  
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

287 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

2 条评论

御

2小时前 中国新疆

我并不看好

0 回复

MobileUser2579

2小时前 中国上海

不如ASTRA

0 回复