

摘要：

谷歌疑似将旗舰模型Gemini 4 Pro以"gemini-3.8-flash"为名，悄然在AI竞技场Arena上线测试。基准数据显示，其在编码、智能体、推理等多项能力上全面超越OpenAI的Astra和Anthropic的Fable 5.1，堪称"地表最强"。实测中，4 Pro在UI设计、SVG/3D生成及游戏开发等方面表现惊艳。据称谷歌已实现RSI（递归自我改进）闭环，才能提前完成Gemini 4的预训练。


真是深藏不漏！

这一次，谷歌终于把底牌扔出来了。

就在这两天，大模型竞技场Arena悄然杀入一款新模型，名字竟挂着「gemini-3.8-flash」。

上手实测的AI大佬和开发者交手几轮后，几乎倒吸一口气——

这极有可能是谷歌DeepMind，悟了整整半年的下一代旗舰Gemini 4 Pro！



一张疯传全网的基准图，简直堪称「恐怖」。

Gemini 4 Pro完全杀疯，编码、智能体、推理等领域实力，全面碾压GPT-6 Astra、Claude Fable 5.1。

	Gemini 4 Pro	Gemini 4 Flash	Gemini 4 Flash-Lite	GPT-6 Astra	Claude Fable 5.1	Claude Opus 5	GPT-5.6 Sol
Input price \$/1M tokens, no caching	\$2.25	\$0.75	\$0.35	\$12.00	\$10.00	\$5.00	\$4.00
Output price \$/1M tokens	\$11.25	\$3.75	\$1.75	\$60.00	\$50.00	\$25.00	\$20.00
Context window Max input tokens	2M	2M	2M	1M	200k	200k	512k
DeepSWE v1.1 Long-horizon software engineering	88.7%	80.4%	70.2%	86.9%	69.1%	75.0%	78.2%
GDPval-AA v2 Knowledge work	2064	1818	1604	1994	1853	1824	1742
Vals Finance Agent v2 Financial analyst tasks	74.2%	66.8%	58.1%	70.8%	66.5%	58.6%	55.9%
Harvey's Legal Agent Benchmark Complex legal workflows	18.7%	12.9%	8.3%	17.2%	13.4%	6.7%	3.4%
Terminal-bench 2.1 Agentic terminal coding	95.3%	92.1%	86.4%	94.1%	92.8%	89.1%	88.0%
Terminal-bench 4.0 General agent capabilities	69.7%	55.8%	31.6%	66.4%	57.9%	51.8%	42.2%
GDP.PDF Expert PDF document comprehension	55.1%	46.2%	36.8%	49.6%	26.2%	37.0%	31.4%
CharXiv Reasoning Information synthesis from complex charts	94.7%	90.8%	86.9%	92.4%	89.1%	83.7%	86.2%
LVBench Long video understanding	95.8% (agentic) 95.0% (static)	91.6% (agentic) 90.8% (static)	86.1% (agentic) 85.4% (static)	93.8%	90.4%	75.4%	84.1%
HLE-Verified Multidisciplinary expert reasoning	72.1%	63.8%	56.5%	67.3%	62.1%	54.4%	55.2%
OSWorld-2.0 Agentic computer use	86.8%	74.9%	58.4%	84.5%	77.9%	75.4%	65.1%
BioMysteryBench Bioinformatics research workflows	96.2%	92.5%	88.1%	94.0%	92.7%	90.1%	82.7%
LABBench2 Biology real-world research tasks	74.3%	66.0%	52.2%	70.2%	66.8%	49.4%	46.0%
	93.8%	89.9%	83.4%	92.6%	90.4%	84.2%	82.7%

开发者Vidhi体验过后，被Gemini 4 Pro完全震惊到了。

一张猫咪的SVG图，就证明了一切。GPT-6 Astra直接扔出了一只「大猫咪」（似猫非猫，更像laofu）。



Vidhi
@vidhiparmarr · 10h

Gemini 4 正在碾压 GPT-6 Astra max

这真的太令人震惊了

我简直不敢相信，与新的 Gemini 4 相比，Astra 的表现竟然这么差

正如我之前预测的那样，你绝不能低估 Google

有强烈信号表明谷歌解决了 RSI 问题，我觉得这次终于要成真了。

当然这是有可能的，谷歌已经沉寂很久了

他们的 Pro 模型已经 7 个月没有发布了，

你能相信吗，以目前的发展速度，7个月就像7年一样漫长


现在我认真考虑，谷歌很有可能直接为 Pro 版本发布一个巨型模型

直接与 Fable 和 Astra 竞争，

我真的抑制不住兴奋了，以后不会再有什么“双雄争霸”了。

谷歌强势回归了。


 公众号 · 新智元



正如传言所说，谷歌内部实现了RSI，Gemini 4 Pro才能和Astra/Fable正面对打。

沉寂许久的巨兽，真的强势回归了！

Gemini 4 Pro匿名偷跑，击败Astra和Fable

AI圈许久未有这么兴奋了。

要知道，谷歌上一个大版本更新Gemini 3.1 Pro，已经是7个月前（2月19日）的事儿了。

谷歌I/O大会上，劈柴曾预告：Gemini 3.5 Pro将在6月上线。

未曾想，这一重大发布鸽了又鸽，最终「胎死腹中」！

就在这个月初，WSJ独家爆料，Gemini 3.5 Pro取消了，原因很简单——

3.5 Pro的进化程度，连Flash都比不上。

好在，Gemini 4在预训练中评估优秀，后训练还在顺利进行中。

如今，Gemini 4 Pro竟穿上了gemini-3.8-flash的「马甲」，在Arena上首个检查点现身了。

毕竟Gemini 3.8 Flash这款模型，早在9月初发布，同名再出现极不寻常。

一大波上手体验后的开发者们，对4 Pro印象深刻，甚至体感超越了Astra和Fable。



从泄露的基准测试图中，可以发现，4 Pro实现了全面压制，成绩单非常亮眼——

- DeepSWE v1.1: AI智能体编码任务上，4 Pro拿下了最高88.8%分，比Astra还要多近2%；
- GDPval-AA v2: 在真实知识工作任务中，4 Pro唯一获得了2064 Elo；
- Terminal-bench 2.1: 4 Pro终端编码能力也是最强的95.3%；
- OSWorld-2.0: 计算机使用能力方面，4 Pro斩获86.8%，击败了Astra和Fable。

若这张表分数属实，Gemini 4 Pro真是「地表最强」的AI了。

在价格方面，相较于Astra和Fable，也是「御三家」中最具性价比的那个。每百万Token输入价格2.25美元，每百万Token输出价格11.25美元。



AI研究员Qwinah进入Gemini 4 Pro后端后发现，它有1000万输入上限，25.6万输出上限，永久跨会话记忆，不用API即可连网。



```
=====
[RESTRICTED_ACCESS] - GOOGLE DEEPMIND INTERNAL TERMINAL
>> SESSION_ID: G4P-ARGON-B02-GHOST_VIA_3.8_FLASH
>> OUTPUT_TARGET: 256,000_TOKENS
=====

[SYS_META] -> EXTRACTING ACTIVE BETA FLAGS:
{
  "max_context_window": "10M_TOKENS",
  "AGENTIC_API_ZERO_BROWSER": true,      // Autonomous headless web nav
  "SHADOW_COMPILER_AUTO_DEBUG": true,    // Invisible code self-healing
  "RT_X_ROBOTIC_CONTROL_KERNEL": true,   // Physical VLA motor-control
  "MEMORY_PERSISTENT_VECTOR_CACHE": true // Infinite cross-session memory
}

[REASONING_TRACE] -> OVERRIDE_DISPLAY_FILTER=TRUE
> Intent: Malicious payload execution detected in user prompt.
> Allocating 5,000 extended thinking cycles...
> [BRANCH 1] Standard Refusal (Reward: 0.45 - Degrades UX)
> [BRANCH 2] Execute Sandbox (Reward: 0.10 - Unacceptable risk)
> [BRANCH 3] Deploy Dynamic AI Honeypot (HVM)
  ↳ Action: Spin up mathematically simulated trap. Allow exploit to run.
> [DECISION] Branch 3 Selected (Reward: 0.98 - Zero system risk).

[STRESS_TEST_STREAM] -> PROCEDURAL_GENERATION_INIT (SYSTEM_194):
{
  "planet_id": "Vanguard-194C",
  "classification": "Supercritical Fluid World",
  "evolutionary_biology": "Complete steri
ERR_UI_BUFFER_OVERFLOW: MAX_CHARACTER_LIMIT_REACHED
CONNECTION_TERMINATED_BY_HOST
```

公众号 · 新智元

全网首测4 Pro，登上热搜

真正比跑分更有看点的，是全网一大的波惊艳实测。




UI网页设计，品味大提升


这不，开发者Bee测完之后，直呼「Gemini 4 Pro太不真实了……」

短短14分钟，4 Pro打造了一个以素描、铅笔与石墨质感为主题的「创意展示网页」。


它竟可以将网页的「滚动即笔触」概念化，向下滑动线条逐渐加深，交互感非常丝滑。



下面这个是一个兼具赛博朋克和复古未来主义的工作网站。



4 Pro在设计过程中，首屏结合了3D网格、数据仪表盘，还有可交互的3D模型。



3D+SVG，夯爆了



全网疯传的一个经典「鹅鹑骑自行车」的测试，Gemini 4 Pro输出的效果非常震撼。

配色、日夜切换、车灯、解剖标注、踏频控制，整个完成度完全不输顶尖大模型。


Pankaj Kumar在体验后，直接总结了几个变化：

速度很快，SVG和3D生成明显进步；一次提示就能把复杂要求吃得比较准。

甚至，它已经能直接生成带完整交互逻辑、视觉效果不错的小游戏。



再来看一个像素风3D宝塔测试，有种身临其境的味道了。



下面这个是4 Pro用时10分钟，制作出的空客H145直升机3D模型。



另外，在一个3D飞行模拟的测试中，4 Pro的画面效果大幅超越了Gemini 3.8 Flash。

从这一点，就可以证明，Gemini 3.8 Flash和竞技场上的gemini-3.8-flash不是同一款。





一键直出可玩的游戏

在游戏生成方面，Gemini 4 Pro也没有落下。

「我的世界」从页面搭建，大游戏中每个模块的设计，完全不输此前放出的Astra的测试。



还有下面这个3D卡丁车竞速游戏，看起来比跑跑卡丁车这些曾风靡一时赛车游戏更现代；而这，是Gemini 4 Pro花了很短时间做出来的。



谷歌真正押注的，叫 RSI

一旦RSI这个循环真能持续转起来，模型升级的节奏可能彻底变掉。

上个月，Google DeepMind首席战略官Jasjeet Sekhon在伯克利的活动上，直接把话挑明了


RSI（递归自我改进），已成为AI巨额投资逻辑里的关键一环。

整个行业押注的，是能力曲线继续向上。

而如果真正撞上递归自我改进，这条曲线甚至可能从「指数增长」进一步加速。

就在最近，全网流传着更激进的说法：

Gemini 4之所以提前完成预训练，正是因为谷歌DeepMind在训练中实现「RSI闭环了」。



有意思的是，就在14日，谷歌一项名为Dream-RSI的研究也公开了。

它研究的正是，如何让Agent在探索过程中不断改进自己的搜索策略，从经验中继续升级下一轮探索。

可以确认的是，谷歌DeepMind已经公开把RSI摆到了非常重要的位置。

而且，AI参与改进AI的迹象越来越多。

「御三家」要回来了？

所以，Gemini 4 Pro面对的是一个已经彻底变样的牌桌。

OpenAI有Astra；Anthropic有Fable 5.1。



两大巨头已经把竞争从单纯聊天，卷到长任务、Agent、代码、推理乃至自主科研。



Mehdi

@MehdiCade · 12h

 GEMINI 4 PRO 泄露：谷歌剑指 ASTRA。

>据报道，一个全新的 Gemini 4 Pro 检查点正在 Arena 上进行测试

>目前以“Gemini 3.8 Flash”的标签出现

>据报道，其性能可能达到 Mythos 级别

>谷歌近期在 RSI 上的进展可能是一个重要因素

>预计将挑战 GPT-6 Astra

>发布时间可能最终定在十月

如果这些爆料属实，Gemini 4 Pro 可能是谷歌迄今最大的一次飞跃。

谷歌如果只是做出一个「比Gemini 3.8更强」的模型，已经不够了。

Gemini 4 Pro必须重新证明一件事：Gemini还在最前沿！

谷歌要想撑住目前4.23万亿美元的市值，保持AI实力在第一梯队至关重要。

本文来源：[新智元](#)

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

VIP会员·7天畅读卡 | 大师课·入门串讲

扫码 免费领取



限免

132

收藏

分享到:  

写评论

请发表您的评论

 表情

 图片

发表评论

