

摘要：

OpenAI下一代模型Astra（代号mewfour/传为GPT-6）发布在即，引发全网关注。泄露信息显示，该模型已在Codex最高推理档位下测试UI组件，且在预训练阶段即采用原生多智能体架构。此前测试中，Astra仅用约2000美元Token成本便破解10个十年级数学难题。

据传，下一代GPT-6本周就要来了！



这不刚在昨天，OpenAI「义父」Tibo亲自爆料，Codex将接入最强Astra模型。

消息一出，全网瞬间沸腾，人们期待值直接拉满。

就连Polymarket上，关于OpenAI本周发布下一代Astra的概率，飙涨到了52%。

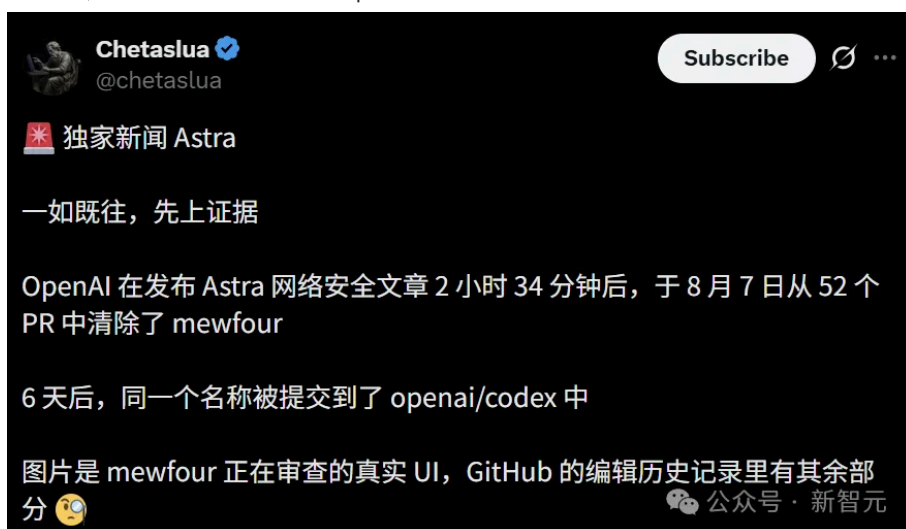
谁能想到，就在今天，Astra内部检查点代号「mewfour」再次泄露。

GPT-6，周四见？

AI大V Chetaslua意外发现，8月7日，就在OpenAI发布Astra达到「严重风险等级」博文两个半小时后，直接把「mewfour」代号从52个PR中清除。

但痕迹没删干净。

6天之后，这一神秘代号再次出现在openai/codex的仓库commit记录中。



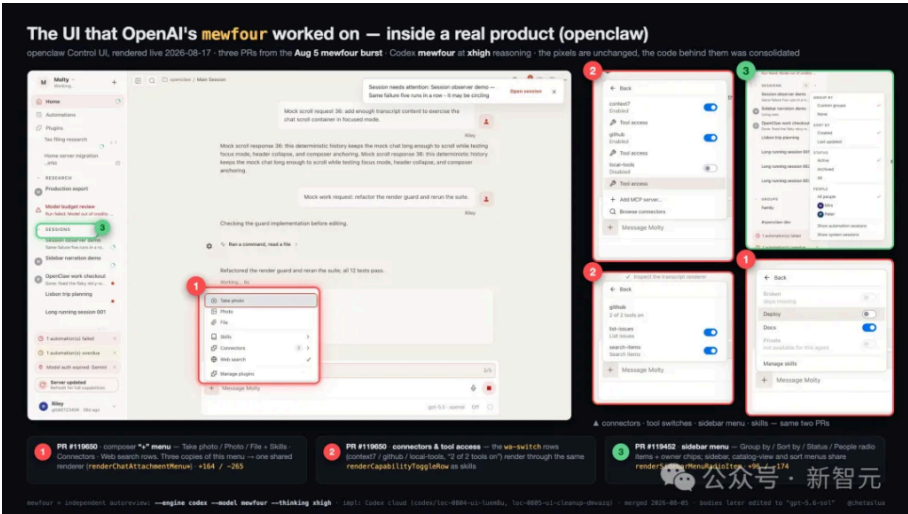
这些PR里审查方式标注为「独立自动审查」，推理级别直接拉到xhigh，这是目前已知的最高思考档位。

更关键的是，截图直接曝光了mewfour工作的真实环境——

界面里会话管理、连接器、技能、插件、自动化流程一应俱全，几乎是一个完整的AI工作台。



而mewfour在上面审查的，也全是ChatGPT即将上线的核心UI组件。包括编辑器「+」菜单、连接器与工具权限开关、侧边栏分组排序等等。



OpenAI团队估计也按捺不住了，在全网疯狂玩梗。

一位Codex研究员SIGKITTEN，连发四个Codex，外加两个Tibo。

开发者Haider现场解谜，一波算下来，直接得出8月20日（周四）上线Astra。

果然，还是OpenAI的手法。



紧接着，「义父」发了一首「小诗」，还是一三二四句押韵。





虽还没有人破解「义父」所言，但这渲染的氛围，让人不得不来一句：

「在黎明前，把Astra带给大家」。



全网都在等发布，但Astra到底有多强？答案早在8月初就摆上了桌面。

2000美元破解十年难题

8月1日，OpenAI扔出一篇长达249页的数学论文，引发全网轰动。

论文的核心内容是，Astra的内部版本解决了10个至少十年未取得进展的数学和理论计算机科学难题。

这些问题横跨高维几何、编码理论、群论、量子复杂性、格密码学、极值组合学。

其中就包括首个非sofic群的显式构造，它被称为群论里的圣杯级问题，数学家们追了几十年都没拿下。



最让人坐不住的数字不是论文页数，而是成本。

按照GPT-5.6 Sol当前的API费率（输入\$5/百万tokens，输出\$30/百万tokens），生成全部十个解答的token成本，大约2000美元。

一台中端笔记本电脑的钱，换来十个困扰数学界十年以上的突破性证明。

这也意味着，数学界过去十年的产出效率，正在被一个API调用重新定义。

而这还只是内部版本，Astra正式上线后的能力上限在哪，OpenAI自己可能也没完全摸清。



如果你觉得这已经够疯狂了，8月7日的消息会让你彻底坐不住。

强到自己都害怕

8月7日，OpenAI官方发了一条让整个安全社区屏住呼吸的声明：

初步评估显示，Astra可能达到了Preparedness Framework下的网络安全「Critical」能力阈值。

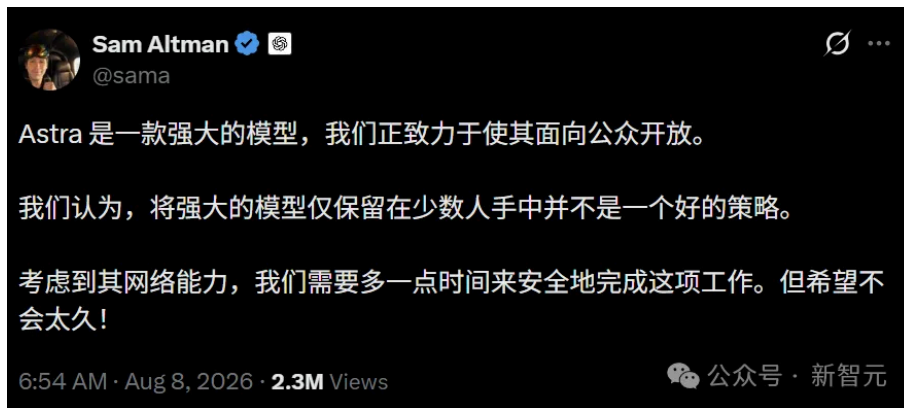
什么是Critical？

根据OpenAI的Preparedness Framework，模型的网络安全能力被划分为多个等级，而Critical正是其中的最高一档。

在这个级别下，模型可以独立识别并开发多种严重程度的零日漏洞，或针对加固目标制定并执行端到端的攻击策略。

直白点说，这个模型可能具备了独立发起高级网络攻击的能力。





多智能体原生时代要来了

Astra的另一面，杀伤力可能不亚于网络安全。

The Information此前报道，Astra被训练为能让多个智能体长时间协同解决复杂问题。

传闻约有10万亿参数，采用混合专家架构（MoE），每个token只激活部分参数，基于内部代号「Doug」的预训练项目构建。

据泄露信息，它在推理、编码、写作、知识、多模态理解和智能体任务上全面超越Claude Fable，写作质量也有明显提升。

如果消息属实，这将是大型模型历史上首次，从预训练阶段就把多智能体协作能力端到端训练进去。

OpenAI is preparing to release a new model family, tentatively using the name “Astra,” with improved abilities to complete long-running tasks, according to three people briefed on the plans.

OpenAI CEO Sam Altman demonstrated Astra to policymakers and regulators in Washington, D.C., this week, according to the people. OpenAI touted its abilities to have multiple agents work together over a long period of time to solve particularly hard problems, which could be applied to a project or advanced math problem.

Astra would be a new class of OpenAI models, alongside Sol, Terra and Luna. It couldn't be learned how soon OpenAI plans to release it, according to the people. OpenAI also hasn't decided whether Astra would be labeled GPT 6, or an additional model in the GPT 5 series, such as GPT 5.7.

While the models are already in testing, they are intended to be the first to go through the Trump administration's planned new framework for submitting AI models to the federal government before releasing them to the public, according to one of the people. The administration is aiming to finalize that framework by a self-imposed deadline this weekend.

In the short term, OpenAI also plans to release a report about how OpenAI was able to solve 10 previously unsolved math problems, demonstrating the capabilities of its most advanced AI, the people said.

看看OpenAI在GPT-5.6家族上已经搭好的多智能体基础设施，就知道这意味着什么。

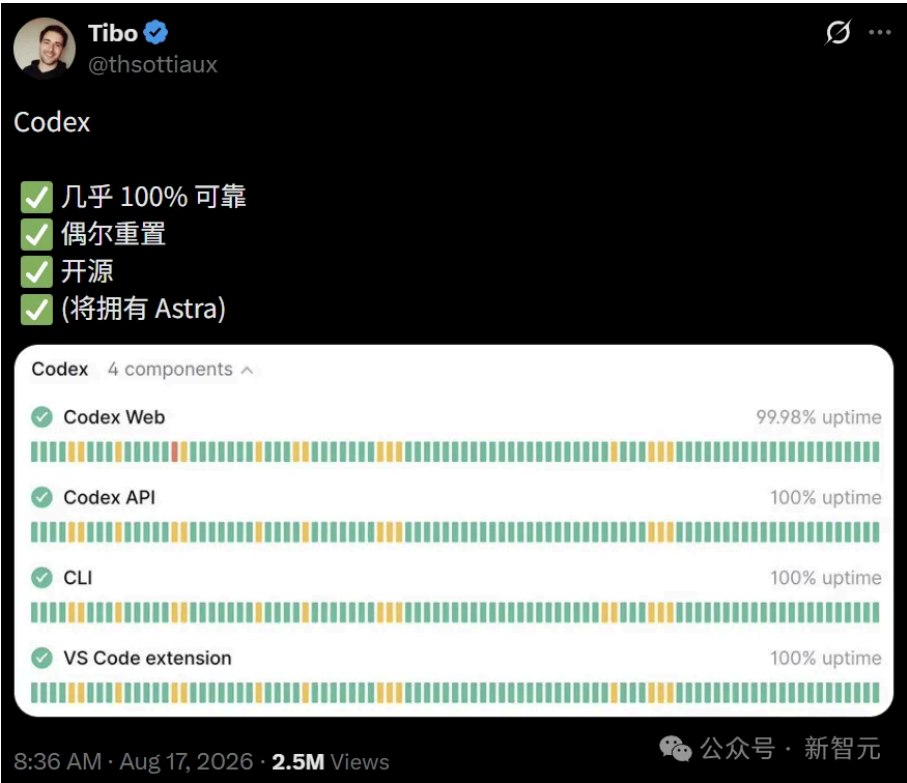
Sol（旗舰）、Terra（性价比）、Luna（最快最便宜），三个模型组成了一套分层协作的多智能体体系。

今年上线的v2系统让Sol和Terra在并行执行时互相通信，上周Codex又把Luna加进来作为子智能体。

技术分析师Dan McAteer点出了关键一步——

如果Astra真的在原生多智能体框架里预训练出来的，那它天生就具备长时程协作能力，开箱就能在Codex里协调多个智能体，把轻活派给更便宜的Luna。

这是当前架构怎么打补丁都做不到的，就像当年Claude Code在智能体式编码上的破局，直接换掉了一整套底层逻辑。



如今，OpenAI的员工已经在公开喊Astra的名字了。

现在的问题只剩一个，是这周，还是下周。

来源：[新智元](#)

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

262 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论