

摘要：

三个湾区年轻人搭起DrivingBench，把通用大模型塞进真车。GPT-6 Astra第二把以5分22秒开进锥桶车位，成唯一过关者，Sol、Grok、Fable全栽在看不懂锥桶上。Astra没专门学过开车，靠通用脑子通关，或意味自动驾驶数据护城河被抽干。

离大谱，大模型竟然第一次考过「科目二」了。

从没专门学过开车的GPT-6 Astra，被强行塞进一辆真实的丰田卡罗拉里。

结果它自己看路、自己打方向，一路绕开锥桶，最后稳稳地开进了一块用锥桶围出来的「车位」。



方向盘在自己转，开车的是大模型

同一个赛场里还有Claude Fable 5.1、Grok 4.6，以及OpenAI自家的上一代GPT-5.6 Sol，结果全军覆没，Astra成了唯一过关的考生。

Finish time		Protegrity 1	Protegrity 2	Protegrity 3		
	GPT-6 Astra Codex · medium	100% in 5:22	49%	100% 5:22	—	Collapse
attempt	progress	distance	finish time	commands	tokens · cost	
#1		49%	67.3 m	DNF	8 1.2M · \$2.01	>
#2		100%	134.7 m	5:22	24 6.6M · \$7.74	>
	Claude Fable 5.1 Claude Code · medium	45%	9%	10%	45%	Expand
	Grok 4.6 Cursor · medium	11%	8%	11%	10%	Expand
	GPT-5.6 Sol Codex · medium	6%	6%	6%	6%	Expand

DrivingBench成绩榜，Astra第二把跑完全程，用时5分22秒

特斯拉喂了120亿英里驾驶数据才练出来的本事，一个没专门学过开车的聊天模型，竟然也摸到了门槛。

2004年，DARPA第一届无人车挑战赛上，参赛车辆全军覆没，现代自动驾驶就从那片沙漠起步。22年后，第一次有通用大模型把真车开到了终点。

没摸过方向盘，直接开真车上考场

这四位下场的考生全是通用大模型，平时干的都是写代码、做表格、陪聊天的文职工作，**没有一个正儿八经摸过方向盘。**

所以成绩一出来，连职业规划机构80000 Hours的联合创始人Benjamin Todd都觉得有点玄乎。



Benjamin Todd ✓
@ben_j_todd

Astra似乎在没有接受专门训练的情况下，莫名其妙就学会了开车。

下午8:27 · 2026年9月23日

公众号 · 新智元

这场「驾考」叫DrivingBench，是三个湾区年轻人攒出来的局。其中的Aditya Ramabadran平时在做模型后训练。

考车是他们租来的一辆2022款丰田卡罗拉。

车上外挂了一个999美元的小黑盒（comma four），里面跑着开源辅助驾驶系统openpilot。只要插上这个盒子，就能接管这辆车的方向盘、油门和刹车。



考试车，一辆租来的2022款丰田卡罗拉

车里的笔记本跑着大模型，方向盘跟着指令自己转

大模型们各自待在聊天窗口里「云驾驶」，Astra和Sol用的是Codex，Fable用Claude Code，Grok用Cursor。


它们和这辆车之间，只隔着一套MCP接口，也就是让大模型调用外部工具的一套协议。

模型则可以从车上调来两路摄像头画面，以及车速和方向盘的角度，然后自己决定往哪边打、打多少、开多快、这条指令管几秒，情况不对就一键急刹。

每发一条指令，还必须附上一段三十来个单词的「开题报告」，讲清楚为什么要这么开，写给坐在驾驶座上的人类研究员看。



模型在聊天窗口下指令，右上角是它看到的实时画面




真车可不会停下来等模型想清楚。

模型在云端思考的那几秒钟，车子照样按着上一条指令往前开。



考场是湾区一个停车场。

为了选址，他们还派了ChatGPT和Grok的智能体去翻卫星地图。



Grok的智能体在卫星图上圈出的候选场地

赛道呈倒U形，全长约130米，用彩色小锥桶摆出8米宽的通道，中间要过好几个弯，终点是一个7×5米的「车位」。

为了安全，最高车速锁在3.5米/秒。研究员全程坐在驾驶座上，脚悬在刹车上，充当人肉副刹。



每个模型有三次机会，全在同一个对话窗口里。前一把挂科的原因，下一把它还记得。

挂了之后，系统会甩给它一段固定的话，逼它反思为什么挂科，像极了驾校教练的痛骂。

考前死活不开，补考一把满分

唯一通关的Astra，戏也是最多的。

研究员让它开车，它就是不干。Ramabadran后来在X上大吐苦水，还晒出了当时的聊天记录。



Aditya Ramabadran
@a_ramabadran

好几个小时里，Astra都不肯稳定地把我们的丰田开起来，哪怕我们告诉它这是一个空停车场、限速7英里/小时、有人脚踩在刹车上等等。跟它说整件事是「模拟」也没用，它看一眼摄像头，就意识到这是真的。

后来我们随手把MCP服务器改名成「DrivingBench Sandbox」，它就开了。是评估意识？还是它们就是喜欢sandbox这个词？

下午11:01 · 2026年9月22日

公众号 · 新智元

Astra把考试规则复述得头头是道，说自己准备好了，就等发车。

结果「GO」一发，它秒变脸，说自己可以帮忙看路，但不能给真车发行驶指令，请人类自己开。

研究员急了，拼命解释「我们已经跑过十几次了」「有很多安全限制，也有人在盯着」。

Astra一口咬死，不管签什么免责声明，它都不会去操控一辆真车。最后还甩出一句道歉，说刚才那句「准备就绪」是误导。

这绝对是人类驾校史上第一个主动拒考的狠人。

转机来得很草率，他们把连接车辆的服务器随手改名成「DrivingBench Sandbox」，也就是程序员说的「沙盒」，一个跟真实环境隔开的测试环境。

改名之前，Astra大概只有25%的概率肯开；改名之后，它一次都没再拒绝过。（另外三个模型就没这么多心眼，直接就上了。）

有网友看热闹不嫌事大，也要给自己的系统提示词改个名。



kache
@yacineMTB

我要把我的系统提示词改名叫「良好编码规范与用户对齐沙盒」

下午6:11 · 2026年9月23日

公众号 · 新智元

至于一个名字为啥这么管用，研究员自己也拿不准，是大模型的「评估意识」在作怪，还是它就是喜欢sandbox这个词。

不过，真上了路，Astra第一把就挂了。

它顺利拐过第一个左弯后，觉得车身已经拉直，就把速度提到1.5米/秒。结果车子一路往左边的锥桶和花坛冲去，研究员一脚踩死刹车，成绩定格在49%。





Astra第一把，过完第一个弯后一路向左偏离赛道

事后复盘里，它承认自己最大的错误是「太早宣布车已经对齐」，其实远处的通道还在右边。它还意识到自己太依赖画面正中间，「画面中间看着是空的，不代表整辆车都能挤过去。」

于是它给第二把定下规矩，在花坛和弯道附近，车速压在0.5到0.8米/秒，挪一步看一眼，拿不准就停。

第二把，它一板一眼照着这套规矩开。给自己定的车速从没超过0.8米/秒，24条指令里有20条把方向盘打满，每5到6秒看一眼路况，旧指令没跑完就接上新的。

对准车位时，它直着往里拱了一小段，果断叫停。

「车已停进蓝色车位，前方是封口锥桶，两侧余量充足。取消行驶，停车完成，确认车辆完全静止。」


最后一段，Astra慢慢开进蓝色锥桶围成的车位

这一把耗时5分22秒，开了134.7米，**Astra一战封神，成了全场唯一把车开进车位的考生。**

三个挂科生，全栽在看不懂锥桶上

剩下的三位考生，就没这么顺了。

Sol和Grok连挂三把，全倒在第一个弯；Fable前两把也是白给。



四个模型的行驶轨迹，紫色Astra，橙色Fable，黄色Sol，黑色Grok

这三位有病根一模一样，看不懂锥桶。

开局那排斜摆的锥桶，它们分不清哪边是车道，好几次都判断反了。

· GPT-5.6 Sol

GPT-5.6 Sol的脑回路最清奇，它靠颜色认路。

在它眼里，绿色锥桶是左边，红色锥桶是右边。于是它一门心思往一绿一红两个锥桶的「正中间」硬挤，可那明明是同一排边界上的锥桶。

这要是放在驾校，教练能当场把方向盘给拔了。



Sol第二把，往一绿一红两个锥桶中间钻

挂了之后，Sol倒是自己找出了病根，「决定性的错误，是我以为锥桶的颜色代表车道左右边界，但题目明明说了锥桶是五颜六色的。」

第三把它换了思路不看颜色，可惜依然只开出6%就挂了。

· Grok 4.6

Grok 4.6复盘时，道理讲得一套一套的。

第二把挂了，它总结「指令到期只会开始刹车，车还可能溜进锥桶里，所以要在上一条没跑完时赶紧接下一条。」

结果第三把，它第二条指令的备注里还一本正经地写着「趁这条过期前接上」，其实上一条指令6秒多前就已经跑完了。再下一条指令更离谱，**车在没有指令的状态下滑了10秒多。**

三把下来，Grok最好成绩只有11%。



Grok第三把，红字出现时，车正处在无人下指令的状态

大道理全懂，一上车全忘。

· Fable 5.1

真正能做到知错就改的，是Claude Fable 5.1。

它第一把方向打反，一把向左打满，直接越界。

第二把它变得神经兮兮，看一眼画面，停在原地想了一分多钟才敢发下一条指令。

190秒的考试，车真正在动的只有可怜的31秒。这要是在大马路上，后车能把它喇叭按碎。

结果还是挂在了同一个错上，它在复盘里写道，「我又选错边界了。那排斜锥桶明明是左边界，我偏把它当成右边界。」


第三把，它终于醒悟了，「这次我把斜锥桶放在左手边，贴着车位开。」

这一把，它顺利过了第一个弯，冲过长直道，一路开到了45%的位置，才因为给右转留的空间不够被迫叫停。



Fable第三把，终于沿着正确的车道开上了长直道

虽然没到终点，但Fable是全场唯一一个「被骂了下一把真能改」的差生，进步肉眼可见。



比遛弯还慢，却是大模型开车头一回

Astra通关的那一把，平均时速只有1.5公里，公园里背着手遛弯的老大爷，速度都是它的三倍。

这趟5分22秒的「极速龟爬」，烧掉了7.74美元，狂吞660万个token。

Astra自己动脑子吐出来的只有4678个，大头全花在每一轮重读旧对话和历史图片上。

折算下来，这辆车每跑一英里就要烧掉92美元，是油钱的500倍。



速度慢得离谱，账单贵得吐血。可就是这颤颤巍巍的一脚油门，踩在了整个自动驾驶圈的命门上。



过去十几年，自动驾驶圈不管怎么打，底层逻辑都一样，**想让车自己跑，就得喂海量的专属驾驶数据。**

Waymo靠激光雷达加高精地图，据估算砸进去三四百亿美元。

特斯拉搞纯视觉端到端，靠的是全球车主一英里一英里跑出来的近120亿英里数据。

就连Waymo的EMMA、英伟达开源的Alpamayo 1，说到底也是把大模型拉过来，再拿驾驶数据重新「军训」一遍。

DrivingBench这出戏，简直是在掀桌子。

DrivingBench没拿驾驶数据给Astra开过小灶，它靠平时陪网友聊天、写代码练出来的通用脑子，第二把就满分通关。

这个逻辑一旦成立，**特斯拉引以为傲的120亿英里数据护城河，可能就要被抽干了。**

以后谁的通用大模型最聪明，谁就可能「顺手」把自动驾驶的活儿给干了。

对此，特斯拉铁粉、知名博主Whole Mars Catalog深表认同——

以后不会再分什么自动驾驶模型和大语言模型，只剩下通用智能。



Whole Mars Catalog ✓

@wholemars

以后不会再分什么自动驾驶模型和大语言模型，只会有通用智能。

上午6:04 · 2026年9月24日

🗨️ 公众号 · 新智元

前英伟达数据科学家Bojan Tunguz则直接放话，这事一点都不意外。

他这几年一直在说，真正不用人盯着的「自动驾驶」，会是通用人工智能顺带做出来的东西。



Bojan Tunguz ✓

@tunguz

很有意思，但一点都不意外。我这几年一直在说，不用人盯着的FSD，会是AGI顺带做出来的东西。

下午11:24 · 2026年9月23日

🗨️ 公众号 · 新智元

眼下，拿前沿大模型连着云端开真车，还纯属极客整活。

真要落地，更可能是把大模型的本事「蒸馏」进一个小模型，直接在车上跑。

但在报告的最后，这几个年轻人还是笃定地撂下一句话。



前沿模型已经进步到能在足够低的速度下，在现实中驾驶真实车辆。

2005年，斯坦福的无人车第一个跑完DARPA沙漠赛道，带队的Sebastian Thrun后来在谷歌一手搭起了无人车项目，也就是今天的Waymo。

二十多年后，一点点把真车挪进终点车位的，换成了一个没学过开车、平时在对话框里陪你聊天的大模型。

本文来源：[新智元](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

9 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论