

摘要：

Token价格指数连跌7天，引发华尔街对AI账单失控的焦虑。摩根大通称这不过是“最小减速带”，Citadel却直指AI落地核心约束已从“模型最强”转向“成本与稀缺性”，用户正加速向廉价模型迁移。这究竟是AI需求见顶还是用户疯狂涌向低价模型？答案将直接重写英伟达、云厂商乃至整条AI硬件链的估值逻辑。

一张Token指数图，点燃了AI增长和账单失控的焦虑。

这张图是Silicon Data统计的LLM Token支出指数。6月11日，它已连跌7天，创下今年1月以来最长连跌纪录；过去12天里，有11天是下跌的。

这个指数衡量的是全市场每使用100万枚Token平均支付多少钱——可以理解为市场愿意为AI“付多少钱”的晴雨表。它自去年12月以来翻了一番以上，并在2026年5月前持续攀升，但近期急转直下。

它触动的不是一个小指标，而是整条AI交易链：如果企业开始控制Token账单，GPU、DRAM、数据中心和云厂商的资本开支预期，会不会被重新定价？

美国宏观策略师Andreas Steno Larsen在6月9日直接把这张图称为“当前全市场最应关注的一张图”，并警告：如果Token定价持续走弱，本轮周期中从内存到更广泛的硬件及数据中心交易可能宣告结束。

这句话戳到了投资者最敏感的神经。但华尔街的看法更为复杂和多面，Token定价走弱可能并非单纯的AI需求见顶。



指数下跌是不是需求见顶？这张图到底表达了什么

这张图不能简单读成“AI没人用了”。

它不是Token总需求指数，也不是Token总支出金额。它量的是每百万Token的加权平均价格——也就是说，它反映的是用户在用什么价位的模型。

算一笔简单的账就清楚了：假设前沿模型10美元/百万Token，便宜模型1美元。某个月100单位用量全跑在前沿模型上，指数是10。下个月需求翻倍到200，但新增的全是便宜模型跑的批量任

务，指数直接掉到5.5。

需求翻倍，指数腰斩。

这意味着，指数下跌有两种完全不同的解释：一是需求真的在萎缩；二是用量在爆炸，但用户在主动向低价模型迁移。

这正是当前争论的核心：指数下跌，到底是需求见顶，还是用量结构下沉？

Citadel证券发布《Tokenomics》报告认为，AI落地的核心约束已从“模型能力”转向“成本与算力稀缺”，用户正加速向廉价模型迁移。

“采用趋势越来越不取决于前沿模型的功能，而更多取决于价格……Token指数的近期下跌可能反映了这种向更便宜模型转变的部分迹象。”

摩根大通TMT分析师Mark Schilsky则在6月11日把近期市场讨论概括为：“AI账单失控了。”同时，该行认为当前的Token支出乱象只是“通往更高支出的最小减速带”。



Andreas Steno Larsen
@AndreasSteno



This is the chart that everyone should be watching.

If the Token Pricing rolls over, everything from the memory trade to the broader hard-ware and data-centre trade is over for this cycle imho.

The whole setup depends on this..

这是每个人都应该关注的图表。

如果代币定价机制继续沿用下去，那么在我看来，从这个周期来看，从内存交易到更广泛的硬件和数据中心相关业务，都将陷入停滞状态。

整个系统都依赖于这个部件。



1:53 AM · Jun 9, 2026 · 263.4K Views

Citadel的判断：AI的“性价比与稀缺性”变得更重要了

Citadel证券在其最新发布的《Tokenomics》报告中，给出了一个明确的方向性判断。




核心论点是：**AI落地的核心约束，已经从“模型能力”转向了“成本与稀缺性”。**

Citadel的表述是：“技术落地的核心不再是前沿模型理论上能做什么，而是规模化实现AI运行所需的投入品的价格与稀缺性。算力、电力、冷却、内存带宽和推理预算，都是真实存在且具有约束力的限制条件。”

报告援引经济学基本原理：价格有三大功能——传递稀缺信号、催生替代动力、将资源配置到价值最高的用途。这三条在AI领域正在同时发生。

结论是：**未来最好的回报，不会来自那些构建最强模型的公司，而是来自那些降低AI成本、提升效率的公司。**

同时，推理密集型前沿AI不会消失，但会越来越集中在少数有能力承担成本的大型企业手中。对整个经济体而言，在物理约束缓解之前，更简单的模型可能是更具生产力的路径。



低价模型正在改变账单结构

高盛One-Delta部门负责人Rich Privorotsky曾提到，DeepSeek下调75%的定价，小米MiMo接近99%的降价幅度，基础设施瓶颈缓解正在触发价格战。

Coinbase首席执行官Brian Armstrong预测，未来12至18个月，80%的AI工作负载会迁移到成本更低99%的模型上，只有20%需要极致智能的任务会继续留在前沿模型上。

Hugging Face首席执行官Clement Delangue援引斯坦福大学数据称，本地模型在真实世界查询中的准确率已升至71.3%，且成本极低。

这与Citadel的判断相接近：前沿AI不会消失，但可能集中在少数能承受算力成本、具备研究深度、且能把高难度问题转化为规模化收益的企业手中。

对更广泛的经济体而言，在物理约束缓解前，更简单的模型可能是更便宜的生产力工具。

也就是说，AI使用可能走向分层。

高价值、复杂任务继续使用前沿模型。日常任务、批量任务、低回报实验，则转向便宜模型或本地模型。

摩根大通：优化账单，不等于AI需求见顶

摩根大通的判断则是：现在的账单焦虑，可能只是AI需求早期阶段的小减速带；一年后Token支出可能明显更高。

如果每百万Token平均成本下降，但美国公司AI付费渗透率仍在上升，总Token用量在算术上就必须大幅增加。也就是说，“单位价格下降”和“总使用量爆发”可以同时发生。

企业内部的情况也类似。已经大量使用AI的公司会优化Token预算，减少浪费；还没完全上车的公司，会因为模型更便宜、更容易部署而开始使用。

智能体AI还会放大Token消耗。一个任务过去只需一次调用，现在可能被拆成多步执行、反复规划、调用工具、读取上下文，单任务Token消耗会明显增加。素材中提到，有中小企业案例显示，业务agent化后，每个任务的Token消耗变成原来的3.5倍。

所以，市场争论的关键不是“Token会不会继续增长”，而是“增长的单位经济模型是否健康”。

大家都在增加对 AI 的投入

AI spend per employee per month



数据来源：Ramp AI 指数，企业支出数据由 Ramp 提供。AI 支出涵盖 LLM 订阅、编程助手、API 令牌及 GPU 云服务费用。百分位排名基于每位员工的 AI 支出计算。获取数据

ramp

当下，企业已经开始管账单

企业端最先暴露的问题，不是AI没人用，而是用得太过随意。

Axios援引一位AI顾问的消息称，其一家企业客户近期单月在Claude上花费5亿美元，原因只是没有对员工使用量设置上限。

在企业内部，把AI使用量当作考核指标，也开始产生副作用。

此前美国部分公司内部把AI使用量当成排名或考核指标，结果诱发了“Tokenmaxxing”：员工为了刷高使用量，让AI执行低价值任务。

亚马逊旗下开发者平台Kiro曾设有内部排行榜“Kiorank”。亚马逊高级副总裁Dave Treadwell承认，员工为了刷榜让AI做无意义任务，推高运营成本。他随后要求员工“不要为了用AI而用AI”，相关测试版仪表盘被下线。

亚马逊后续改用“归一化部署”指标，追踪AI生成代码的实际价值，而不是单纯追踪Token消耗。Meta内部也出现过类似拉高Token消耗量以占据排名优势的情况。

这类调整的含义很明确：**企业不是停用AI，而是开始区分“有效Token”和“无效Token”。**

摩根大通提到，Cloudflare推出AI Gateway这类产品，目的就是帮助企业控制Token预算。OpenRouter等工具也长期存在，本质都是在不同模型之间做路由和成本管理。

定价端也在变化。

6月1日，**GitHub Copilot正式从按请求收费切换为按Token用量计费**。Reddit社区有用户表示，其月度费用预计将从不到45美元升至超过847美元。

GitHub首席产品官Mario Rodriguez此前称，随着智能体AI兴起，旧有定价模式已不可持续。

Gartner分析师Arun Chandrasekaran在接受Business Insider采访时称，随着高级推理模型推高算力消耗，更多企业将转向按用量计费。

这意味着，过去靠固定订阅或补贴隐藏的成本，正在被摆到企业财务表面。

多空分歧：硬件交易的逻辑还成立吗？

这场争论的终极问题，是AI基础设施的投资逻辑是否还成立。

多头的依据是：高盛的Jim Schneider测算，到2030年，代理式AI将推动Token消耗量增长24倍，云服务商毛利率将在短期内转正。Mark Schilsky也认为，Token支出的短期乱象不会改变长期趋势。

空头的依据是：高盛半导体分析师Jim Covello认为，当前产业链繁荣是以牺牲上游消耗为代价的，几乎所有价值都流向了半导体公司，这种状况不可持续。投资人Tommy Shaughnessy警告，AI大厂利润率深度为负，一旦企业直面按量计费的真实价格，支撑GPU采购和模型训练的资本流动将面临逆转。

近日接受采访时，Anthropic CEO Dario Amodei、博通总裁Hock Tan、《大空头》原型Steve Eisman等也都谈到类似问题：企业目前对AI工具存在过度支出，也就是“Token最大化”现象；随



着成本意识增强和计费模式转向按Token收费，未来更需要看实际投资回报率。

社交媒体上，也有声音直接质疑这张图的叙事框架。有用户指出，“六天连跌去年在采用高峰期发生过四次”，“更便宜的模型反而会加速部署，因为成本门槛降低了”。

toni

toni

✓

@tonitrades_ · 6小时

Price correlation!= causation here.

↻

⋮

Six-day drops happened 4x last year during peak adoption phases.

If anything, cheaper models accelerate deployment since cost barriers fall.

Enterprises don't pause AI rollouts over 6-day pricing dips.

💬

↻

❤

📊 127

🔖

↑

也有人反驳：“不管多便宜，每次新模型发布都会指数级消耗更多Token。”

the wide mermaid from one piece

@widemermaid · 7小时

doesn't matter how cheap when the models use exponentially more tokens with every release

↻

⋮

💬

↻

❤

📊 285

🔖

↑

目前，这场争论没有定论。但有一点是确定的：Token支出的边际变化，通过GPU算力、DRAM内存及数据中心需求的传导链条，直接影响英伟达、存储芯片厂商及云服务商的资本开支预期。这张图，投资者不得不盯着看。

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

VIP会员 · 7天畅读卡 | 大师课 · 入门串讲

扫码

免费领取

限免

👍 443

★ 收藏

分享到:

写评论

请发表您的评论

😊 表情

🖼 图片

发表评论

4 条评论

那小孩

VIP会员

2小时前 中国北京

这就证明AI发展进入快速发展期了，不再说是代替人的故事的概念期了。当前的ai相关产业链上的公司，按苹果、Google相关阶段的模型估就行了。差不了数量级了。



👍 0 ↩ 回复



Mr. 杜
4小时前 中国广东省

不用说那么多，当出现这种情况的时候，就是获利了结跑路的的时候，等以后清晰了，有了定论再进来

👍 1 ↩ 回复



MobileUser0712 VIP会员
4小时前 中国上海

因为ai并不是必需品， ai只是资本需要的

👍 5 ↩ 回复



金木鱼
5小时前 中国广东省

Deepseek斩杀线，昇腾加速！

👍 2 ↩ 回复