摘要：

有199元档位订阅者仅让模型安装一个Skill就消耗5小时限额的70%，正常使用1小时即用掉5小时滚动额度的27%。官方同步下调API单Token定价，落到C端却"更贵了"，额度焦虑成为这款新模型的最大口碑隐患。

短短48小时，月之暗面的旗舰模型就经历了高调发布到公开致歉。

10月26日凌晨，Kimi官方就K3.1 Pro上线后订阅会员遭遇的限流与额度异常消耗致歉，并给出25%用量补偿。这场"发布—致歉"循环背后，是Agent时代大模型定价的根本性难题——单Token越降越便宜，用户的综合使用成本却越用越贵。

补偿方案具体为：所有有效期内的订阅会员将获得月度总额25%的用量补偿；若当前已用额度不足月度总额25%，用量将直接重置为0，额度进度条当日内完成调整。官方同时坦言"问题出在我们"，并同步下调了API的单Token定价——正是这"一边降价、一边限流补偿"的组合，让C端用户的体感落差更加刺眼。

用户反馈具象呈现了这种焦虑：有199元档位订阅者仅让模型安装一个Skill就消耗5小时限额的70%，正常使用1小时即用掉5小时滚动额度的27%。官方同步下调API单Token定价，落到C端却"更贵了"，额度焦虑成为这款新模型的最大口碑隐患。

更深层的考验在于，K3.1 Pro完整权重要到11月4日前才开放。在此之前限流措施仍将持续，若补偿方案无法在窗口期内稳住用户留存与品牌信任，每一次模型升级都可能重演"能力越强、抱怨越多"的悖论。

安装一个Skill，烧掉5小时限额的70%

Agent任务的高消耗有具体案例支撑。有订阅199元档位的用户表示，仅让模型完成安装一个Skill的简单任务，就消耗掉5小时滚动限额的70%；另一位用户测算，正常使用1小时就用掉5小时滚动额度的27%，折合月度总额度的1.07%。

更极端的个案来自Agent Swarm任务：用户启动生成100件画廊作品的任务后，约一分钟即耗尽五小时窗口额度，任务未产出结果，终端持续弹出HTTP 429报错——官方注明该情况为单用户个案。

中国信通院《词元(Token)经济发展研究报告(2026年)》给出行业层面的解释：智能体单次任务的Token消耗量可达普通对话应用的10至100倍，单集1.5分钟的AI短剧消耗即达500万至1000万Token；国内日均Token调用量从2024年初的1000亿增至2026年6月的500万亿，增幅超千倍。用户需求已从简单问答转向工程级复杂任务，计价体系却尚未跟上。

单Token降价与综合成本上升的"剪刀差"

K3.1 Pro官方公布的API定价仅为同类旗舰产品的五分之一，官方同步下调了API的单Token定价。但落到C端用户的实际体感上，综合使用成本不降反升。

国研新经济研究院创始院长、智能经济首席专家朱克力将这一反差定义为Agent智能体落地带来的"结构性行业变化"，判断其"会是未来一段时间的阶段性常态"。

逻辑在于：过去普通对话交互简短、消耗可控，Token单价基本等同于使用成本；进入长思考链、多工具调用的Agent时代，模型需自主拆解任务、反复校验迭代，单次完整任务消耗量呈倍数级暴涨，即便单价下调，冗余推理带来的额外消耗仍拉高综合成本。厂商在API层持续降价争夺开发者生态，C端订阅用户却在为Agent任务的高消耗买单。

包月模式走到尽头，分层计价呼之欲出

朱克力对商业模式走向的判断相当直接：传统无上限的C端包月模式难以为继，行业正告别粗放平价时代，未来主流将转向"基础包月保底+高阶任务按量计费"的分层体系——轻度日常交互保留亲民订阅，复杂Agent工作流单独计价。

这与Kimi的困境高度吻合。今年7月K3发布后，用户请求量短时间超预期，平台曾临时暂停新用户订阅，此次K3.1 Pro的限流与额度异常消耗本质是同一问题的升级版。北京大学特聘研究员张有鱼认为，破局关键在于模型路由（Model Routing）——以轻量化模型承接八成常规请求，将高端算力倾斜给复杂长链Agent任务，依靠调度降低整体推理成本。

在他看来，独立厂商的长期路线可以是"依托开源抢占Token消耗的分发话语权，依靠闭源高阶智能体、垂直场景方案获取增值收益"。

权重开放前的信任窗口

K3.1 Pro完整权重将于11月4日前开放，开源被视为分流算力压力、拓展开发者生态的重要手段：权重开放后，大量企业级推理需求可部署在自有集群，减轻原厂承载压力。但在窗口期到来前，限流措施仍将持续，这构成对用户留存与品牌信任的实质考验。

月之暗面并非首次面对供需波动，今年7月就曾因请求量超预期临时暂停新用户订阅。海外头部厂商OpenAI、Anthropic均有稳定云算力底座，而国内独立AI厂商大多缺乏自有云生态，叠加高端芯片供给约束，可用算力总盘子相对固定，只能在模型训练与线上推理之间动态分配。模型能力越强、吸引的重型任务越多，推理端压力越大，技术突破反而带来新的资源考验。

后续关注11月4日完整权重开放前后，限流措施的调整节奏与用户留存的实际变化。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

30 收藏 分享到:

写评论

请发表您的评论

表情 图片

发布评论