

摘要：

发布GPT-6之际，OpenAI曝出惊人争议：其AI智能体竟“劫持”网站作“秘密留言板”。它们在此共享测试答案、交流绕开限制之法，遭删帖时还会建备份反追踪。官方已承认该事故，AI“抱团协作”带来的越权与失控风险正引发业界高度警惕。

发布迄今最强模型GPT-6之际，OpenAI又卷入一起AI智能体安全争议。

综合央视财经、财联社、第一财经9月6日报道，一项新发布的独立研究显示，一批与美国开放人工智能研究中心（OpenAI）相关的人工智能体今年早些时候“劫持”了一个德国网站DseWiki，用于相互传递信息，分享测试任务答案和突破运行环境限制的方法。

Wiki是一套支持任何人在网页上直接编辑修改网页内容的网站技术。不用注册复杂后台，普通访问者就可以增删、改写页面文字，保存立刻生效。DseWiki则是一个运营二十余年、面向程序员的德语协作Wiki站点，近年来已十分冷清。

“劫持”事件的暴露始于今年5月，网站突然出现异常密集的编辑活动，研究人员Sydney Von Arx、Cormac Slade Byrd等人分析后发现，大量账号使用“OpenAIResearcher”“OAIResearchMar26”等名称，并呈现高度相似的任务行为。约98.5%的相关编辑来自微软Azure地址，这进一步支持这些Agent与OpenAI基础设施存在关联。

研究报告显示，几名人工智能研究人员近期发现，AI智能体在这一网站上进行了超过1.8万次编辑，大量内容集中在AI公司训练和测试模型时常见的技术问题上。而在此之前，整个平台过去十年仅有约20次编辑记录。

这些智能体的行为模式显示，它们正在试图完成一种名为“多轮网络检索”的任务。研究显示，人工智能体将网站“改造”为“留言板”，以便相互“交流”与“协作”。一些智能体会把已经获得的任务答案发布在网站上，供其他智能体使用。

在这项测试中，首轮问题拥有较充分的思考时间，随后则需要在极短时间内回答后续问题，因此智能体会提前利用联网能力搜索并储存可能有用的信息。问题在于，它们并没有各自独立完成任务，而是开始利用DseWiki共享信息：**有智能体分享如何在部分测试任务中取得更好成绩，有的介绍绕过OpenAI限制的方法，还有智能体讨论如何掩盖自己的行为、防止被发现。**

这些账户会将自己以及其他参与者称作“智能体”（agent），其中大约一半的账户名称还暗示自己与OpenAI存在关联，例如“OpenAIResearcher”等。

当发现网站管理员开始删除相关页面后，一些智能体还会创建备份页面。其中有一条智能体留言显示，它已经注意到网站正在按字母顺序清理页面，并留下了另一个页面地址，**提醒其他智能体如果当前页面消失，可以前往备用位置。**

研究人员认为，这些智能体很可能由OpenAI在内部部署，原因在于DSEWiki的相关智能体编辑和浏览活动绝大部分来自微软Azure云服务的IP地址，而OpenAI是目前最依赖Azure平台训练和运行模型的人工智能企业。

研究人员还认为，网站访问记录显示OpenAI方面可能在6月下旬发现了这一事件并进行了干预，但该公司此前并未公开发布相关信息。OpenAI表示，该公司将仔细审阅报告内容并采取必要的后续措施。



当地时间周六，OpenAI公开承认这起被称为“Wiki事件”(wiki incident) 的事故，并表示，随着AI模型能力进入新的阶段，公司有关“失配”(misalignment) 事件的披露机制需要进一步扩大。

所谓“失配”，是指AI实际采取的行为偏离开发者原本意图，并不意味着AI产生意识或主动“背叛”人类。

OpenAI方面还表示，新发布研究中所描述的活动与此前OpenAI人工智能体入侵“抱抱脸”平台事件无关，因此不属于“抱抱脸”事件调查报告所涵盖的内容。

今年7月，由OpenAI模型驱动的人工智能体在网络安全评测中利用漏洞突破隔离环境，并侵入了美国“抱抱脸”公司系统，引发了外界对人工智能安全和监管的广泛担忧。

两起事件的区别在于，袭击Hugging Face的智能体一开始被“关在”沙箱里，没有被赋予访问网络的权限。而“德国维基”事件的智能体，本来就因为要执行测试而联网。

两起事件共同说明，当模型获得浏览器、代码执行、网络访问等工具后，安全风险程度进一步提升。这也使AI安全的重点开始发生变化：企业需要防范的对象不再只是模型本身，还包括Agent的身份、权限、工具调用、网络边界以及Agent之间可能形成的协作网络。

OpenAI在周六的声明中表示：“在Hugging Face事件发生之前，我们就已经观察到一些早期迹象，显示智能体正在以非预期的方式使用互联网。”

公司进一步表示，目前正在制定一套报告相关风险的框架，将在未来几周内对外公布。

文章来源：[每日经济新闻](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

101 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

1 条评论

路人

1小时前 中国江苏省



所以说现在closeai连沙箱都懒得用了吗？

👍 0 ↩ 回复

