

摘要：

吴恩达深度拆解AI工程师核心能力：从LLM底层原理、数据喂养、智能体搭建，到评估驱动开发、生产环境运维，再到机器学习基础，六块硬骨头环环相扣。其中最关键的一条——能跑通严格评估闭环，才是优秀与普通工程师的真正分水岭。

吴恩达老师刚刚发了一篇文章，专门拆解AI工程师的核心能力。

他研究了大量招聘信息，做了系统的专家访谈和问卷调查，最终把「会做AI应用」这件事拆成了6块。

这6块能力分别是：LLM基础、用数据给模型打地基、搭建智能体系统、以评估驱动开发、生产环境运维，以及机器学习基础。


听起来像是目录，但每一块展开，都有东西。

**Andrew Ng** @AndrewYNg · 17小时

[翻译自 英语](#) [显示原文](#)

构建和部署 AI 应用中最重要技能。

AI Engineering Skills Map: Building and Deploying AI Applications



✕ 文章

AI Engineering Skills Map: Building and Deploying AI Applications

I previously wrote about our AI Engineering Skills Map, with the highest level skills being (i) Building and deploying AI applications, (ii) Software engineering fundamentals, (iii) Using coding...

AI应用和普通软件，差在哪？


先说一个根本性的差异。

传统软件，输入确定，输出确定。你写一个排序函数，跑一万次结果都一样。

AI应用不是这样的。LLM会输出什么，你事先不知道。模型会犯什么错，你也不知道。这种不确定性，让整个开发过程必须反复迭代——写一版，看看效果，再决定下一步怎么改。

所以AI工程师的核心能力，本质上是在不确定中做决策的能力。

AI 工程技能地图：构建与部署 AI 应用



第一块：搞懂LLM的底层

很多人用LLM，就像用一个黑箱，扔进去一个问题，等答案出来，然后不知道为什么它答对了，也不知道为什么它答错了。

吴恩达认为，这不够。

你要理解LLM怎么把文本切成token，怎么逐步生成输出。这样你才能判断：这个任务它能干好吗？在什么情况下它容易出错？

除此之外，还有一堆工程细节需要掌握：什么时候用多模态模型，怎么在有限的上下文窗口里做取舍，缓存怎么算，模型的知识截止到哪里，推理的算力怎么控制，工具调用什么时候用。

再往深走，还有一个问题：什么时候需要微调模型，什么时候考虑自己部署。

这些事，理解了底层才能做出对的判断。

第二块：给模型喂对数据

LLM的输出质量，很大程度取决于它的输入。

早期流行的做法是RAG，用向量搜索把相关内容塞进上下文里。但现在，这套玩法已经远不止于此。

你需要判断：哪些内容应该直接写进prompt，哪些让模型在用的时候自己用工具去查？

数据的组织方式怎么选？向量索引、知识图谱、结构化数据上的语义层，各自适合什么场景？

文档要怎么处理才能让模型读得懂，PDF、HTML、图片，不同格式的处理方式不一样。

还有一件容易被忽视的事：数据的质量要持续维护，不能一次性处理完就不管了。

第三块：搭智能体，有讲究

智能体系统的形态，差异很大。

简单的是固定 workflow：预先设计好一系列LLM调用步骤，一步接一步执行。复杂的是让LLM自己判断下一步，循环决策直到任务完成。

怎么选？吴恩达给了几个判断维度：



哪些步骤可以并行跑，哪些必须串行？什么地方用代码更可靠，什么地方用LLM更灵活？出错了怎么回退？

工具调用方面，模型能用哪些工具、能执行什么命令，都需要设计。记忆怎么管理——特别是会话很长的時候，上下文放不下，怎么办？什么时候需要多个智能体协作而不是一个智能体搞定所有事？

还有一件很重要的事，往往被跳过：原型跑通了，怎么让它变成可以放进生产环境的可靠系统？这需要考虑安全边界、对抗性输入，以及防止数据泄露之类的风险。

第四块：用评估驱动开发，这是真正的分水岭

这一块，吴恩达说：

在他见过的AI工程师里，**能够跑通一套严格的评估闭环，是区分优秀和普通的最关键特质。**

什么意思？

很多人改系统靠感觉，觉得哪里不对就改哪里，改完凭主观判断「好像好了一点」。

厉害的工程师是另一种做法：先要把衡量什么想清楚，再建立一套评估机制，每次改动之后跑评估，根据数据决定下一步改什么。

评估本身也是技术活。你要分析系统的输出和中间过程，结合业务目标确定衡量指标。评估的形式也有很多：代码写死的规则、用LLM来打分、让人来判断。这三种各自适合什么场景，本身就需要判断力。

而且评估也不是一次性的，它要跟着系统迭代一起演进。

第五块：生产环境，另一个世界

把系统做出来是一回事，在生产环境里跑起来是另一回事。

AI应用的运维，和传统软件的运维有几个关键差异。

第一是观测。你需要知道系统在真实用户身上的表现，而不只是测试集上的表现。性能要监控，数据分布的漂移要发现，模型突然变差或者被攻击注入，要能快速响应。

第二是测试体系。AI系统的回归测试，比传统软件复杂——很多结果没有唯一正确答案，需要统计方法来判断是不是变好或者变差了。测试的力度，要和出错的代价匹配。

第三是成本和延迟控制。选哪个模型、要不要蒸馏、工作流能不能简化，这些决策在用户量上来之后，会直接影响系统能不能活下去。

第六块：机器学习基础，绕不开

最后一块，吴恩达说：

他认识的所有在LLM应用上做得好的工程师，都对机器学习和深度学习有一定深度的理解。

为什么？

因为LLM本身就是机器学习的产物，很多判断需要从ML的视角才能做对。而且很多实际应用场景里，还是需要用到传统的机器学习——无论是用别人训练好的模型，还是自己训练。

更重要的是，机器学习里有几个核心概念，对做AI应用极其有用：偏差方差的权衡、错误分析、数据工程。这些概念提供了一套思维框架，帮你在面对不确定输出的系统时，做出更好的判断。

本文来源：[AI寒武纪](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

👍 77 ★ 收藏

分享到:

写评论

请发表您的评论

😊 表情 🖼️ 图片

发表评论

1 条评论



MobileUser5620
1小时前 中国浙江省

每家企业用A1智能体回答同一问题，都是存在大不异同性。

👍 0 ↩️ 回复