

摘要：

城堡证券宏观策略主管Frank Flight指出，未来，仅有少数资本雄厚的企业能够负担顶级模型的部署，而绝大多数应用场景将转向更廉价的替代方案。随着Token价格战全面打响，成本压力正倒逼企业走向精细化部署，加速“前沿AI”与“日常AI使用”的实质性分化。这意味着，行业共识正从过去的能力竞赛，转向成本约束下的理性决策。

Token经济面临严峻挑战，价格战已然打响，前沿AI的部署或将加速向少数资本雄厚的企业集中。

Citadel Securities宏观策略主管Frank Flight在最新报告中明确指出，AI市场正在出现“两极分化”——前沿模型继续突破，但其使用范围将集中于少数头部企业。**只有少数场景值得调用最昂贵的AI，大多数场景将主动降级至更便宜的模型。高昂成本与物理瓶颈正倒逼用户转向廉价方案，也推动部署决策更趋精细化。**

这一判断正在行业层面迅速得到印证。从高盛到阿波罗，从城堡证券到OpenAI自身，多家顶级机构与行业领袖接连发出类似警示：前沿模型的算力成本已触及企业承受极限，曾经的“Token狂欢”正迅速演变为“Token恐慌”。

据《华尔街日报》报道，OpenAI正认真考虑大幅削减Token价格，CEO Sam Altman也公开承认，**成本已成为“一个巨大的问题”**。这一表态标志着AI行业定价逻辑的根本性转折。

对市场而言，上述信号释放了不容忽视的深远影响：AI基础设施的投资逻辑正被重新定价，前沿模型的商业化路径远比预期更为曲折，资产价格也将在雄心与现实、技术与物理极限之间，被迫寻求新的平衡。

市场共识：成本驱动下的集体转向

本周内，多家顶级机构在同一框架下独立得出相近结论，一个新的市场共识正在实时形成。

高盛合伙人Rich Privorotsky指出，**Token支出已触顶，企业客户将主动优化“每项任务成本”**——简单工作路由至本地模型，复杂任务交由云端处理，仅在必要时调用前沿模型。他同时警告，市场“或许已将过多支出分配给以数据为中心的模型”。

阿波罗联席总裁John Zito措辞更为直接：许多公司将前沿模型用于根本不值得消耗如此算力的任务，从每单位知识的成本来看，“价格正在崩塌”。

Frank Flight则在报告中总结道，即便是最强大的技术，也必须经受成本曲线、产能约束与边际回报的检验。“采用与否，越来越不取决于前沿模型在原则上能做什么，而取决于使AI大规模落地所需投入的价格与稀缺性。”

Token账单引爆行业危机

一系列事件已将成本压力从理论推向现实。亚马逊已下线Token排行榜，微软取消了Claude Code订阅，多家企业相继曝出意外高额的Token账单。

据《华尔街日报》报道，OpenAI正考虑“大幅削减”Token价格，以争夺Anthropic的客群。Altman近期表示：“我们将有很多方式帮助用户以更少支出获得更多价值。”

Frank Flight将这一局面定性为“经典的通缩式竞相压价”——恰恰与这个利润本已捉襟见肘的行业所需方向相反。在庞大资产负债表与特殊目的载体（SPV）的压力下，AI行业将同时面临收入下滑与利润率收窄，现金消耗进一步加速。

Silicon Data LLM支出指数的近期下滑印证了这一趋势。Flight指出，该指数的下降反映用户正向更廉价模型迁移——当用户对AI部署全成本（Token价格×用量）的敏感度上升时，前沿技术非必需的场景将加速向高效、低价模型转移。

前沿AI与日常AI的分化

Frank Flight在报告中提出一个关键判断：前沿AI的部署不会消失，但将高度集中于少数具备条件的企业——拥有足够资产负债表吸收算力成本、具备研究深度以有效部署、且能从解决复杂问题中获取规模化回报的机构。

对更广泛的经济体而言，在物理约束缓解之前，更简单的模型或许是更具成本效益的生产力提升路径。Flight将这一趋势概括为“前沿AI与日常AI使用的分化”。

他指出，当前最具可持续性的生产力提升，来自AI作为人类劳动力补充的应用场景：开发者借助编程助手加速开发与调试；客服人员借助Copilot更快解决工单；知识工作者利用模型压缩搜索、起草与翻译等准备工作。这些应用“比自主智能体无处不在的愿景更为聚焦、更具纪律性，且Token效率更高”。

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 60  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论