

摘要：

Kimi K3再次触发“DeepSeek 式”担忧，美股半导体板块应声下挫，但多家华尔街机构认为算力需求并未走弱。这款2.8万亿参数、百万上下文长驻推理开源模型，会拉高KV 缓存、HBM、存储及云基建需求。Kimi K3更像是AI使用量扩散的催化剂，而不是硬件需求见顶信号。

市场把Kimi K3当作“DeepSeek时刻2.0”来恐慌，但这一次，华尔街的判断截然不同。

7月16日深夜，月之暗面在上海发布Kimi K3。这个2.8万亿参数的开源模型，在Artificial Analysis智能指数上得分57，排名全球第三至四位，与Anthropic的Claude Opus 4.8和OpenAI的GPT-5.5持平。更关键的是，在加州大学伯克利分校创建的Frontend Code Arena编程榜单上，K3以1679分登顶，超越Claude Fable 5和GPT-5.6 Sol，成为首个在权威编程榜单上超越全部海外闭源模型的开源模型。

7月17日，美股半导体板块出现明显下跌。市场的条件反射不难理解——2025年初，DeepSeek R1的发布触发了算力股的一轮急跌，逻辑是：**中国模型越来越强，美国AI公司还有必要砸那么多钱在算力上吗？如果中国模型能用更低成本逼近前沿能力，英伟达、HBM、服务器、网络设备的需求是否会被重估？**

然而，据追风交易台消息，来自瑞银、野村、美银美林和花旗等投行的最新研报认为：**Kimi K3不是算力需求的终结者，而是加速器。**

Kimi K3和DeepSeek R1不是同一种冲击。R1更多让市场看到“效率”；K3更突出“规模”。2.8万亿参数、1M token上下文、常开推理、原生多模态、MoE架构，**这些特征不是轻资产的故事。**它们会把推理、内存、网络 and 存储的压力一起抬高。

Fig. 3: Capability vs price scorecard — K3 vs. other frontier models

Benchmark (harness caveats apply)	Kimi K3	Claude Fable 5	Opus 4.8	GPT-5.5	GLM-5.2
AA Intelligence Index (rank of 189)	57 (#3-4)	#1 tier	K3-tier	K3-tier	51
GDPval-AA v2 (Elo, real occupational tasks)	1668	1760	1600	1494	1514
AA-Briefcase (Elo, long-horizon agent)	1547	#1	below K3	below K3	below K3
AutomationBench-AA	~53% (#1)	below K3	below K3	below K3	below K3
DeepSWE (official leaderboard, mini-SWE-agent)	67.3	n/a	n/a	n/a	blog-cited
Cost per AA task	\$0.94	~\$2.75	\$1.80	n/a	\$0.32-0.47
Output speed / verbosity	62 tok/s; ~2x median tokens	faster	faster	n/a	n/a

Source: Company data, Nomura research

Kimi K3有多强？

Kimi K3由月之暗面在2026年7月16日发布，完整模型权重计划于7月27日开放。它是2.8万亿参数开源权重重大模型，被多家机构称为目前最大规模的开源权重LLM。

核心配置包括三点：

第一，1M token上下文窗口。模型可以处理更长文本、更长代码库、更复杂的企业资料和研究任务。

第二，常开推理。不是简单问答，而是面向长链路推理和Agent任务。


第三，原生视觉能力。K3不只处理文本，也面向视频、图像、游戏开发、前端设计、CAD等多模态任务。

架构上，K3使用Kimi Delta Attention、Attention Residuals和Stable LatentMoE。MoE部分为896个专家中每个token激活16个专家。月之暗面给出的口径是，相比Kimi K2，整体 scaling efficiency 提升约2.5倍。

这解释了为什么K3不是“更便宜的K2”。Nomura整理的价格显示，K3输入价格为每百万token 3美元，缓存命中输入为0.30美元，输出为每百万token 15美元；按Artificial Analysis口径，**K3每项任务成本约0.94美元。这个价格低于Claude Fable 5约2.75美元和Claude Opus 4.8约1.80美元**，接近GPT-5.6 Sol的1.04美元，但明显高于GLM-5.2的0.32—0.47美元，也远高于DeepSeek V4 Pro的0.04美元。

所以K3的定位不是最低价，而是用更低价格接近前沿模型的能力。

Fig. 2: Intelligence score ranking – K3 vs other frontier models



Source: Artificial Analysis, Nomura research

四家投行密集定调：这不是需求削弱

对于市场“DeepSeek时刻”冲击的担忧，野村证券亚太科技团队分析师段冰在报告中写道：“我们认为全球大模型市场的竞争与创新不会停止，随着我们越来越接近通用人工智能（AGI），生成式AI在消费者和企业端的应用将持续扩张。前沿AI实验室和超大规模云平台公司都可能在此阶段持续投入，以维持竞争地位——随着规模定律延续，我们将这种竞争解读为对AI基础设施价值链的利好。”

花旗半导体分析师Peter Lee在7月19日的报告中则直接以“又一次杰文斯悖论”为题。杰文斯悖论是什么意思？简单说：煤炭蒸汽机效率提升，反而让煤炭消耗量更大，因为更多人用得起、更多场景用得上。AI模型也一样——当优质模型变得更便宜，开发者和企业就会部署更多应用、处理更多token，最终的算力消耗反而上升。

Peter Lee认为，即便K3被广泛使用，服务器DDR5和eSSD等通用内存需求仍会增加。原因是K3的推理效率与其他前沿模型相当，但KV缓存占用会随上下文增长而扩大，对内存的压力不降

反增。


美银证券半导体分析师Vivek Arya在7月17日的报告中表述更为直接。他认为，**美国前沿AI实验室的回应“不是更少算力，而是更多”**。如果中国开源模型持续逼近，OpenAI、Anthropic和Google必须通过更大规模的训练、更重的推理和更快的迭代来维持差异化。Arya还提到一个容易被忽略的背景：媒体报道称Google的Gemini 3.5 Pro已比计划推迟数月，编程性能未达内部目标，前沿领导地位“正变得越来越难捍卫”。

瑞银分析师Timo Arcuri团队在7月20日的报告中指出，K3与DeepSeek R1的平行之处确实存在，但K3更多关乎规模——它是全球最大的开源模型，拥有2.8万亿参数和100万token上下文窗口。分析师强调，**开源模型通常比闭源前沿模型更吃内存，因为上下文窗口更长，KV缓存需求即便经过量化也在绝对量上持续增长，使开源模型的部署更加依赖HBM和存储。**

BofA GLOBAL RESEARCH

AI Adoption Data

Exhibit 3: Per Ramp, share of US businesses with paid subscriptions to AI models, platforms, and tools at 55% as of June 2026 (vs. U.S. BTOS est. of 21%)
Ramp AI adoption index vs. U.S. census BTOS estimate




Source: Ramp, BofA Global Research

BofA GLOBAL RESEARCH

谁在这场竞争中真正受益？

存储：最直接的受益板块。 瑞银测算显示，存储与内存板块到2028年的累计自由现金流（FCF）预计达到市值的约30%，是所有子板块中占比最高的——美光（MU）一家就高达47%。花旗和野村均维持对三星电子的买入评级，理由是全球内存市场正处于供给极度紧张的状态。花旗分析师Peter Lee指出，Kimi K3的推理侧内存需求不亚于其他前沿模型，KV缓存体量的膨胀将直接推高服务器DDR5和企业级固态硬盘（eSSD）的需求。他尤其指出：Kimi K3的大规模部署需要超过64块GPU的“超节点”集群配置。

Figure 8: Memory/Storage - FCF Through CY28 as % of Market Cap



Source: UBS estimates, FactSet.

算力基础设施：台积电、英伟达首当其冲受益。 无论是训练侧规模定律仍然有效，还是推理侧token需求增长，最终都指向更多的先进制程芯片需求。野村重申对台积电、ASE、联发科等的

买入评级。英伟达曾公开表示，现代MoE（混合专家架构）模型的推理，在GB300 NVL72上的性能功耗比，相比上一代Hopper架构提升高达25倍。K3这样的模型天然就是英伟达最新硬件的受益方。

网络：超节点趋势造就结构性机会。 Kimi K3需要超节点集群，中国本土算力受限于高端芯片出口管制，更需要依赖超节点架构弥补单卡性能差距，这推动了光模块、光芯片等网络层供应商的需求。野村看好中际旭创和苏州旭创。

云平台：受益于生态集聚效应。 托管多种前沿开源模型的云平台议价能力更强，不依赖单一闭源模型供应商。野村看好阿里巴巴（BABA）作为中国AI云生态的核心，以及GDS、万国数据（VNET）等数据中心运营商。

中国AI模型的全球渗透速度有多快？

这或许是整个叙事中最容易被低估的数据点。

根据开放API网关OpenRouter的统计，**中国AI模型的token使用量占全球开发者流量的比例，一年前不足2%，目前已超过45%**。美银美林的数据印证了AI整体渗透的加速：目前约55%的美国企业已订阅AI模型、平台或工具，Anthropic的企业采用率达42%，OpenAI为40%。头部AI消费者（前1%的企业用户）每位员工每月AI支出已达4833美元。

市场正在分化。一方面是以DeepSeek、Kimi K3为代表的中国开源模型，覆盖经济型和中高端性价比市场；另一方面，顶级美国前沿模型正向更复杂的工作负载（如科学计算）聚焦，维持技术和定价溢价。野村的判断是：中美两侧的领先大模型玩家都将受益——前提是各自能持续站在技术曲线的前沿。

OpenRouter Token Data

Exhibit 1: Token usage continues to proliferate
Weekly token usage on OpenRouter by top AI lab





Exhibit 2: On OpenRouter (thus not necessarily indicative of total token usage across enterprise/consumer/etc.), token usage on models from Chinese Labs has surged, surpassing non-Chinese models

Daily token usage of top 50 models on OpenRouter (excluding models outside top 50 for any given day) by China/non-China AI lab affiliation



K3真正改变的是竞争节奏，不是单一公司的故事

K3发布后，市场第一反应还是拿它和DeepSeek R1比较。这种比较有用，但不能停在“是不是又要砸AI硬件”这一层。

DeepSeek让市场重新估算训练效率。K3让市场看到另一件事：开源模型也可以把规模、长上下文、Agent和多模态推到前沿区间。

这会逼迫美国前沿实验室继续投入，也会让中国模型在全球开发者生态中继续扩张。闭源顶级模型保留技术和价格溢价，开源模型覆盖更多价格带和部署场景，云厂商提供模型分发和企业落地，硬件链条承担训练和推理压力。

短期看，交易会因“DeepSeek记忆”出现波动。中期看，只要token使用量继续增长，长上下文和Agent继续扩散，算力、HBM、存储、网络和IDC仍是绕不开的成本项。

这也是多家机构在K3之后给出相似结论的原因：更强的开源模型不是AI基建需求的终点，反而可能是下一轮需求扩散的入口。

不过，美银美林也明确留了一个尾部风险：“如果效率增益的速度超过工作负载的增长，我们可能会看到基础设施建设的某种回落。”换句话说，如果模型越做越便宜，但使用量并未同步大幅扩张，算力需求的增长逻辑就会打折。

~~~~~  
以上精彩内容来自[追风交易台](#)。

更详细的解读，包括实时解读、一线研究等内容，请加入 [【追风交易台·年度会员】](#)

# 追风

RISK CHASE

全球宏观研究 | 交易 | 配置

你 / 不 / 能 / 错 / 过

## 什么是“追风交易台”

追风交易台由顶流全球宏观资讯及研究团队联手打造。

我们的目标是给中国投资者提供专业、独到和适时的全球金融市场研究。

## 在这里，你将看到

### 最专业的解读

来自全球顶尖投行、研究机构、  
一线从业者的最新解读



### 最独到的视角

以全球市场第一线的视角  
感知市场动向



### 最适时的时机

快速、完整、准确  
最终汇集成适时



## 如果你

关心全球宏观经济和资本市场

## 如果你

苦恼于没有合适的信息和研究



关注“追风交易台”  
成为“追风会员”

你将身处全球市场第一线

公众号 · 追风交易台

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

\* 体验资格每人限申领一次

扫码  
免费领取

限免

433

收藏

分享到:

写评论

请发表您的评论

表情

图片

发表评论

8 条评论

- 见闻用户

29分钟前 中国上海

因为贪婪所以华尔街这帮所谓的精英无知到极点，把一个跟人的智慧没有任何关系的网络爬虫软件称为人工智能，让普天下人笑掉大牙

0

回复
- MobileUser7689

VIP会员

3小时前 中国广东省

这个分析太水了，kimi 的出现只会弱化美国的资本开支

1

回复
- 银河铁路999

5小时前 中国北京

还是化解deepseek冲击的老套路。问题是，中国的公司没花那么多钱建那么多数据中心堆那么多卡。很容易判断AI在美国极度过热了。

1

回复
- momo

55分钟前 中国湖北省

回复 银河铁路999：

所以Kimi 反应超级迟钝，现在连迟钝的Kimi都用不上了，直接说算力不够

👍 0    ↩ 回复

 **银河铁路999**   50分钟前   中国北京

回复 momo：

哦，kimi如此先进且受欢迎，以至于算力不够，这可能才是正确的解释。中国企业被卡脖子，你挺高潮的。

👍 0    ↩ 回复

 **SHAWN**   6小时前   中国广东省

华尔街：唱多把泡沫卖给世界 😊

👍 2    ↩ 回复

 **Robin**   6小时前   中国天津

华尔街不是很懂计算，K3只是把训练成本压低了，但是推力成本是上去了。

👍 2    ↩ 回复

 **momo**   49分钟前   中国湖北省

回复 Robin：

Kimi 有披露过训练成本吗？同样参数的大模型，如果你不牺牲性能或者精度，都是顶尖聪明人，你能比别人强在哪？中国模型的低成本很大程度上是牺牲了精度，每次推理只激活少量参数，人家是满负荷运作，你当然便宜，但这样你的性能永远只能接近人家的模型，无法超过人家的模型，世界没啥奇迹

👍 0    ↩ 回复