摘要：

大模型行业的竞争正从模型能力转向商业化变现。智谱、MiniMax等头部厂商押注Coding场景，却仍面临毛利承压、研发投入远超营收的困境，持续依赖融资补充算力。中小AI创业公司则在巨头挤压下转向垂直领域，但B端定制化交付、算力成本高企与融资收缩，令盈利愈发艰难。AI淘金热下，如何实现可持续造血，成为行业共同难题。

大模型这门生意，比拼的重点正从“谁的模型更强”，加速转向“谁能把钱赚回来”。

然而，想要把砸进去的钱收回来并不容易。即便如智谱、MiniMax等，上半年收入虽翻了几倍，却仍分别拖着超20亿元和近3亿美元的亏损。

为了实现“造血”，大模型公司纷纷死磕需求最刚性的Coding（编程）场景。**但无论是智谱、DeepSeek，还是降价冲量的MiniMax，都没能解开“毛利缩水、研发开支数倍于营收”的财务枷锁，最终依然要靠百亿级的新融资金额来解决算力问题。**

独角兽们在烧钱，夹缝中的中小创业公司面临诸多挑战。

商业化端，B端项目定制化程度高，不少企业难以摆脱“纯定制打工人”的处境。在资金端，热钱加速向少数巨头集中——据IT桔子统计，今年第三季度仅43笔超10亿元的融资就卷走了全市场近一半资金，而企业服务领域平均每笔融资已缩水至约3300万元。

这场AI淘金热的寒冬已至，究竟该怎么活下去？

独角兽们在Coding战场厮杀

今年，智谱、月之暗面、MiniMax等公司都在争夺Coding市场。在一个普遍找不到高付费意愿场景的行业里，Coding成了少数几个“客户愿意按效果付钱”的地方。

为什么是Coding？朱啸虎认为，Coding是今年增长最快的场景之一，原因在于“需求刚性、产出容易衡量”。代码能不能跑通、省了多少工时，开发者很快就能看出来，模型公司在定价上也就有了更多余地。

同样是抢Coding，四家公司的定价策略却走向了不同方向。 智谱的提价从今年2月开始。智谱对GLM Coding Plan的价格体系进行结构性调整，整体涨幅30%起，理由是用户规模与调用量快速增长，需要加大算力和模型优化投入。

但提价并没有抑制需求。截至中报发布，智谱Coding Plan的调用量较年初增长超过23倍，API平均售价提高约101%。开放平台及API收入同比增长超27倍，达到8.25亿元，占总收入的比例从一年前的15.2%升至86.5%，取代本地化部署成为公司的主要收入来源。

与智谱的连续提价不同，月之暗面的定价策略是来回调整的。 4月推出Kimi K2.6时，部分API价格上涨约58%；10月发布K3.1 Pro后，新模型API价格较7月的K3降低约三成，并进一步强化编程和智能体能力。

如果说智谱和月之暗面的调价还在几十个百分点的量级，DeepSeek的提价则是倍数级的。 据悉，DeepSeek今年将不同模型的API价格上调至原来的2.3至4.5倍。知情人士透露，梁文锋向投资人表示，公司年化收入已超10亿美元。

前三家调的是价格，MiniMax调的是成本。 MiniMax选择先把成本降下来。闫俊杰在中期业绩电话会上透露，过去两个多月，文本模型的单位算力吞吐提高了3倍。到今年7月，MiniMax平台的Token消耗量已是年初的20倍；上半年，其开放平台及企业服务收入约7390万美元，同比增长703.1%，占总收入的比例从30.3%升至63.4%，首次超过海螺、Talkie等面向消费者的产品。

把这几家公司的账放在一起看，收入结构都变了，但这门生意却没有因此变得更赚钱。

智谱API业务的毛利率今年上半年由负转正，达24.6%，但随着毛利更高的本地化部署占比下降，公司整体毛利率从50%降至26.4%。MiniMax的毛利率从12.1%升至17.9%，上半年毛利仅约2080万美元。

更大的开销在研发。今年上半年，智谱研发开支为同期收入的2.2倍；MiniMax研发开支2.97亿美元，约为收入的2.5倍，主要用于训练相关的云服务支出。

研发与收入之间的缺口，目前仍靠融资填补。7月，智谱完成约314亿港元配售，资金主要投向算力；MiniMax同月通过配股和可转债净筹资约159亿港元。

融资能填上缺口，但能填多久？ 沂景资本董事总经理谢思远认为，大模型本身是资本密集型行业，持续增长的算力投入正在抬高竞争门槛。一些腰部模型公司即使已经获得收入，也未必能够跟上头部厂商的投入节奏，未来能否继续留在竞争中仍存在不确定性。

夹缝里求生存：标品交付难过五成

头部模型公司争夺客户，资金和资源有限的中小创业公司面临更大竞争压力，转向专业细分市场成为更现实的选择。

澜舟科技的部分订单就来自大厂。其产品进入云厂商的采购体系，部分金融项目也由大厂总包，再交给澜舟开发。“他们跟客户签，我们跟他们签。”澜舟科技联席CEO李京梅说。

李京梅认为，**有些大厂“有平台、有算力，但是缺应用”，但随着它们从云、模型逐步进入通用应用市场，中小公司的机会也在收窄。“如果我做的是跟他们一样的，是平行的，没有夹角，那他往上做我们就没了。”**

这家曾研发“孟子”预训练模型的公司，2024年停止了基础模型训练，此后也基本退出了通用平台和通用场景，业务集中在金融等专业领域的智能体上。

李京梅注意到，今年金融机构和央国企开始从小范围试点转向在内部大面积使用AI，一些客户还愿意为咨询服务单独付费。但这些客户的预算通常提前一年定好，不少项目要公开招标、低价中标，算力支出也常常从同一笔钱里出，“算力成本过高的话，那我们其他的付给我们的地方就会少了”。

在某银行总部的法律合规知识问答项目里，澜舟原本用标准产品进场，后来发现产品在专业术语、法条版本和口语化提问上都不够用，只能额外开发；系统上线后，还要试运行、提供一年免费运维。“能超过五成的，用标品去交付，已经是在中国的B端市场不错的。”李京梅说。

当然，靠项目维持经营的，不只澜舟。今年以来，一些拿不到融资的AI应用团队，也转而替企业做定制部署、培训和售后。一位AI领域人士形容它们的处境：应用留在官网上展示想象力，真正到账的钱来自替企业做AI升级。

零壹智库统计显示，今年9月披露金额的金融机构智能体中标项目，平均每单约211万元，智能体越来越多地作为一个模块，被打包进更大的系统建设项目。

澜舟逐年提高对项目毛利率的要求，筛掉难以盈利的商机，并把项目中的工程能力沉淀回标准产品，减少重复开发。2023年完成Pre-A+轮融资后，它没有再公开融资，靠此前的融资和项目回款经营，亏损逐年收窄。李京梅也坦言，“纯定制的To B项目肯定是不可持续的”。

独立模型公司还要靠融资填补研发缺口；中小AI创业公司能否像李京梅说的那样，做到“平台越来越厚，场景化定制越来越薄”，是它们接下来要回答的问题。

本文来源：深网腾讯新闻

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

36 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论