

摘要：

AMD收购AI推理芯片初创公司Taalas之际，一名失业工程师仅凭约7000行代码，独自开发出可将大模型直接编译为芯片电路的工具，并宣称性能有望大幅超越Taalas。尽管项目尚处预硅阶段，这场“个人挑战芯片巨头”的故事，也折射出AI芯片设计正加速向软件化、自动化演进。

谁能想到，2026年硅谷最魔幻的科技爽文，不是巨头之间的烧钱大战，而是一个破产小哥，单枪匹马挑战千亿市值的芯片巨头。

就在今年8月6日，芯片巨头AMD意气风发地宣布，正式收购AI推理芯片领域的当红炸子鸡——Taalas。

这笔交易被视为AMD向英伟达发起挑战的「秘密武器」。

然而，AMD高层们庆祝收购的香槟还没喝完，X上的一条帖子，直接把科技圈的下巴惊掉了。


一位失业工程师，轻描淡写地说——

「过去6个月，我把Taalas的专利拆解研究了一遍。我觉得他们的方案还能做得更好……所以我写了一个大约7000行代码的编译器。」



不仅如此，他还直接放出豪言：自己的方案不仅能比Taalas的技术节省100倍的内存调用，甚至能将推理速度直接翻倍。

他在推文最后心酸地喊话：「你们想看 40,000 tokens/秒 的速度吗？但我现在破产了，还失业了，全网在线等一个便宜的流片渠道。」



一个人，7000行代码，一台电脑，单挑AMD刚收入麾下的顶尖技术团队。

这个魔幻的故事，立刻在圈内引爆了病毒式的传播。


人们惊呼：难道连最硬核、最烧钱的底层芯片制造，也要迎来「车库创业」时代了？

把「AI刻进硅片里」

要看懂失业小哥的操作有多逆天，我们必须先弄明白AMD到底花重金买了个什么神仙公司。

在目前的AI世界里，英伟达的GPU是绝对的霸主。但是，随着大模型越来越庞大，GPU遇到了一堵不可逾越的内存墙。

简单来说，传统的GPU架构（冯·诺依曼架构）中，计算单元和存储单元是分开的。每次计算，GPU都要跑去HBM里把模型的「权重」搬出来，算完了再放回去。



而成立于2023年的加拿大初创公司 Taalas，直接掀翻了这张桌子。



他们的创始人Ljubisa Bajic（前Tenstorrent CEO）提出了一个疯狂的逆向思维：既然搬运数据太慢，那我们为什么不直接把大模型的权重，物理「刻」进芯片的晶体管里？

这就是Taalas的杀手锏——特定模型集成电路。

他们不搞通用的GPU，而是直接围绕着某一个AI模型来定制硅片。将模型的权重和数据流硬连线成电路。

结果极其震撼——

他们的第一代测试芯片HC1（基于台积电6纳米工艺），在运行Meta的Llama 3.1 8B模型时，达到了恐怖的17,000 tokens/秒/用户 的推理速度！

根据Taalas早前的说法，这个速度是英伟达H200的73倍，而功耗却只有其十分之一！虽然代价是「一颗芯片只能跑一个特定的模型」，但由于流片周期短至两个月，成本被极大摊薄。

这就是为什么AMD毫不犹豫地将其买下。

August 6, 2026



AMD Acquires Taalas to Advance Compute Solutions for Rapidly Growing AI Inference Market

News Summary:

- Taalas' technology to further differentiate AMD's AI roadmap by delivering breakthrough inference performance and efficiency
- AMD plans to integrate Taalas' technology to deliver system level solutions together with AMD Instinct™ GPUs

公众号：新智元

看起来，这是一种极其高端、昂贵、只有顶尖硬件团队才能玩得转的「黑科技」。

直到这位失业小哥的出现。


7000行代码的「炼金术」

面对估值过亿的Taalas，他没有被吓倒。相反，在失业的这半年里，他像一个沉迷解谜的黑客，一头扎进了Taalas公开的专利文件中。

看了几个月后，他想到：「Taalas的设计思路，依然有优化的空间！」

他在X上毫不留情地指出，Taalas的技术虽然厉害，但他们依然是从一个只读存储器（ROM）里去读取数据（bitROM）。而在他看来，这种能量消耗是可以「完全跳过的」。

于是，这位老哥闭关爆肝，用大约7000行人类可读的代码，徒手搓出了一个「AI模型硬件编译器」。



这套编译器的逻辑简单粗暴：它能把HuggingFace上的大模型，直接「翻译」成一块硅片电路！

他公布的这个流水线工作流，堪称魔法。

1.输入模型： 直接丢进去一个 HuggingFace 的 checkpoint（模型权重文件）。

2.模型量化： 编译器自动将模型进行极致的量化（他声称自己纯软件驱动的量化，比Taalas硬件团队做得更好）。

3.权重下沉： 将量化后的权重，直接沿着金属层「下沉」转换为 RTL（寄存器传输级，芯片设计的逻辑代码）和 GDS（芯片制造的光刻掩模版图）。

4.物理验证： 自动跑完 DRC（设计规则检查）、Yosys（开源综合工具）、PEX（寄生参数提取）。

5.最终产出： 一张可以直接把 HuggingFace 模型中的矩阵乘法变成电子波形执行的物理电路图！

这个流水线，可以一键输入大模型，一键输出AI芯片图纸。

听起来像天方夜谭，而性能预测更是让人倒吸一口凉气。

他声称，通过这种更彻底的「硬编码」方式，他的设计比Taalas的bitROM减少了100倍的内存获取。

在推特上，他直接艾特了几位大V，发出了灵魂拷问：「想看 40,000 tokens/sec 吗？」

要知道，Taalas跑出17,000 tokens/s已经被AMD视为珍宝，而他的目标，直接把性能翻了一倍还多！

人才招聘现场

其实，这个故事真正让人印象深刻的，失业小哥在帖子中求助——

「顺便问一下，谁有晶圆厂的人脉？或者能弄到7nm的PDK（工艺设计套件）？又或者欧洲PTW班车（一种廉价的多项目晶圆流片服务）的联系方式？……我破产了，而且失业了。」

最高端的技术，最落魄的处境，太令人唏嘘了。

一位网友感慨道：「真没想到，单靠研究专利就能把整套方案做出来，还只有七千行代码……这执行力真强，个人英雄主义的浪漫。」



这篇X，也立刻成了硅谷的「人才招聘现场」。

知名AI研究员 Stanislav Fort 留言：「你能拿这个去融一笔VC的钱吗？如果这是真的，绝对是个灌篮级别的扣篮得分。」 小哥激动回复：「我们正在找钱！」

就连因为操纵药价名噪一时的「医药界华尔街之狼」 Martin Shkreli 都跑来凑热闹：「我雇你，把芯片造出来。」



一群VC合伙人、科技公司高管也纷纷留言：「快看私信，我想我们应该谈谈。」



当然，懂行的工程师也提出了最致命的问题：为什么你第一版就要头铁去挑战 7nm 工艺？

小哥的回答揭示了芯片制造残酷的物理法则：「因为大模型太复杂了，13nm的工艺光刻面积根本装不下。只有TSMC能做7nm及以下。但想做5nm或6nm，你必须是英伟达、苹果或博通这种大鳄，TSMC才会坐下来跟你谈判。」



这就形成了一个巨大的悖论：一个人可以用7000行代码在卧室里颠覆千亿巨头的逻辑设计。

但他却因为掏不起台积电的几百万美元流片费，只能在网上化身赛博乞丐。

这件事也告诉我们：AI芯片的设计，正在从一个「硬件工程」，降维成一个「软件编译」问题。

长期以来，设计一款芯片是一项耗时数年、需要几百名硬件工程师协同、花费数千万美元的浩大工程。但现在的逻辑变了。

如果大模型的最终归宿就是变成「ASIC」，如果输入一个AI模型，经过编译、量化、自动生成电路的流水线能够被彻底打通.....

那么，未来的芯片设计，将不再是一砖一瓦的物理搭建，而仅仅是软件编译器的一个Target。

正如一位大V所写：「这个项目现在还只是预硅片阶段，但释放的信号极其有趣。如果这个流水线（checkpoint → quantization → RTL → GDS）变得自动化，定制AI芯片将越来越不像一个多年的硬件项目，而更像是一次代码编译。

本文来源：[新智元](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
VIP会员·7天畅读卡 | 大师课·入门串讲

扫码
免费领取

* 体验资格每人限申领一次



限免

140 收藏

分享到:

写评论

请发表您的评论



3 条评论



Russia
12小时前 中国安徽省

这不就是个asic芯片吗，这也值千亿市值？

👍 0 ↩ 回复



诺晨的笔记 11小时前 中国广东省

回复 **Russia**:

因为他能真正创造利润，按现在的Ai价格，估计生产完芯片拿来卖几个月就能回本，回本速度大于Ai模型迭代速度

👍 0 ↩ 回复



手机用户
13小时前 中国山东省

AI面前人人平等，才能挑战财团，才能战胜资本，才能替代财力，各领域被颠覆只会越来越快加速到来。

👍 0 ↩ 回复

